The Principles of Diffusion Models

1.2 Prominent Deep Generative Models

渡邉 有志

October 13, 2026

主要な深層生成モデリング

生成モデリングにおける中心的な課題

高次元データの豊かで複雑な構造を捉えられる
表現力の高い確率モデルの学習

計算の扱いやすさ、表現力、学習効率の間で異なるトレードオフ
⇒代表的な戦略を紹介し、計算グラフの比較とともに説明する

1.2 Prominent Deep Generative Models

定義:EBMs(Energy-based Models)

EBMs: エネルギー関数 $E_\phi(x)$ を通して確率分布を定義するモデル

$$p_\phi(x) := \frac{1}{Z(\phi)} \exp(-E_\phi(x))$$

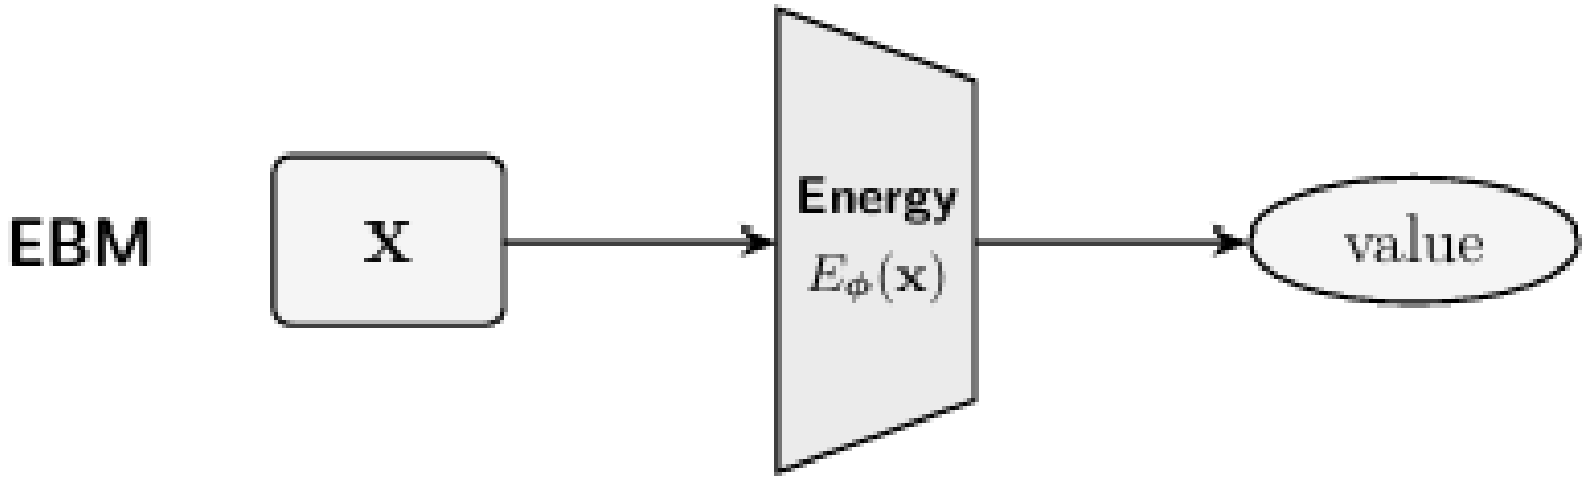
ここで $Z(\phi) = \int \exp(-E_\phi(x))dx$ は分配関数、これを代入すると

$$p_\phi(x) = \frac{\exp(-E_\phi(x))}{\int \exp(-E_\phi(x))dx}$$

- $exp(-E_\phi(x)) > 0$
- 分配関数で割ることで全体の積分が 1 になる
- もし x が離散変数なら $-E_\phi(x)$ に対してソフトマックスを適用したものに近い
  ⇒連続変数の出力は確率密度なので 1 を越えてもいい。
  必要なのは全体の積分が 1 になること

エネルギー関数: 高次元データ x に対して 1 つの実数 $E_\phi(x)$ を割り当てている $(E_\phi(x) : R^D \to R)$
$E_\phi(x)$ は正規化定数が有限の範囲内で柔軟に設計可能
実数全体で $E_\phi(x) = 0 \implies Z = \int_{-\infty}^{\infty} 1dx = \infty$ より正規化できない

EBM を通してエネルギー→確率密度の変換を行っている



EBM の学習ではデータの対数尤度を最大化する
しかし、分配関数が計算困難で対処が必要
⇒次の章で拡散モデルについて解説

AutoRegressive Models

定義:AutoRegressive Models(自己回帰モデル)

AR モデル: 各データ点が前のデータ点に依存して生成されるモデル

これは確率の連鎖率を用いることで、どんな同時分布も一連の条件付確率に分解が可能[1]
変数 $x = (x_1, x_2, \ldots, x_d)$ に対して、
$p_{data}(x) = \prod_{i=1}^{d} p(x_i|x_{<i}), x_{<i} = x_1, \ldots, x_{i-1}$ と表せる
(モデル化の仮定ではなく変数について順不同の厳密な恒等式)

問題は $p_{data}(x_i \mid \boldsymbol{x}_{<i})$ が未知であること
⇒ AR モデルは同じ因数分解の形を持つモデルをパラメータ化
$\log p_\phi(x) = \sum_{i=1}^{D} \log p_\phi(x_i \mid \boldsymbol{x}_{<i})$

[1] chain rule:next slide

AutoReguression Models

NN の出力 (e.x. 語彙生成) ⇒条件付分布の近似

モデルに系列トークンを入力し、次のトークンの確率分布を出力

入力に対し次トークンの候補を数値化し、softmax で確率に変換

$$p_\phi(x_i = k \mid \boldsymbol{x}_{<i}) = \frac{\exp(a_k)}{\sum_{k' \in \mathcal{V}} \exp(a_{k'})}$$

- 確率は非負で候補全体の総和が 1
- a_k は前の要素 $x_{<i}$ とパラメータ ϕ によって変わる

連続値の場合、正規化分布の平均と標準偏差を出力し、
$p_{/phi}(x_i \mid x_{<i}) = \mathcal{N}(\mu_\phi(x_{<i}), \sigma_\phi(x_{<i})^2)$

- 各位置に別々のネットワークが必要とは限らない
- 全ての位置で同じパラメータを使うことも可能
- 入力される前の要素に応じて異なる条件付分布を出力可能

AutoReguression Models

なぜ積をとるだけで全体が正規化されるのか

三つの離散変数の場合

$p_{data}(x_1, x_2, x_3) = p_{data}(x_1 \mid x_2, x_3) p_{data}(x_2 \mid x_3) p_{data}(x_3)$

全ての値について足すと

$\sum_{x1} p_\phi(x_1) \sum_{x2} p_\phi(x_2 \mid x_1) \sum_{x3} p_\phi(x_3 \mid x_1, x_2) = 1$

最後の変数から順に足していくと条件付分布の総和が 1 になり、全体も 1 になる。連続なら和を積分に置き換える

EBM ではデータ空間全体の正規か定数が問題

⇒ AR モデルでは全体正規化が保証される

学習について

尤度に基づく学習が容易になる

データサンプル $x^{(1)}, \ldots, x^{(N)}$ に対応する対数尤度は
$\log p_\phi(x) = \sum_{i=1}^{D} \log p_\phi(x_i \mid x_{<i})$ のように分解される

- 最尤推定によって直接学習可能
  ⇒これは負の対数尤度を最小かすることと同値

- 観測済みの先行変数 $x_{<i}$ が利用できる
  ⇒条件付き予測の並列計算が可能

生成について

生成は逐次的に行われる

生成では正解の列がないためまず一つ目を生成する

$x_1 \sim p_\phi(x_1)$

その結果を使って

$x_2 \sim p_\phi(x_2 \mid x_1)$

これを繰り返していくことで生成が可能

⇒次の分布を決める条件が前の生成結果に依存する

ここでの生成は最も確率が高い候補を選ぶということではなく

分布からランダムにサンプリングする

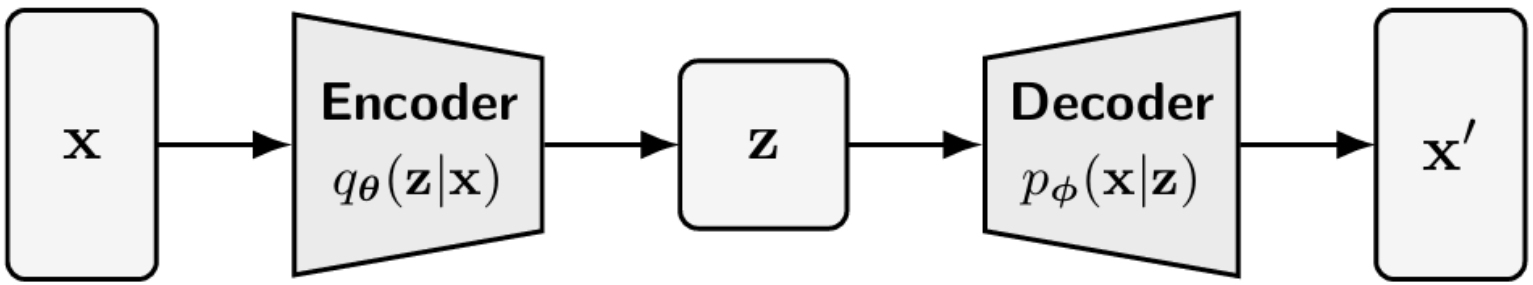
⇒同じ条件で異なるデータを生成可能

VAE:variational Autoencoder

VAE(変分オートエンコーダ)

VAE: データに隠れた構造である潜在変数 z を学習するモデル
(オートエンコーダの拡張)
xとz 間の写像を直接学習する代わりに確率的な見方を採用する
エンコーダとデコーダの両方を学習する

- エンコーダ $q_\theta(z \mid x)$:
  ⇒データが与えられたときの潜在変数の未知の分布を近似
- デコーダ $p_\phi(x \mid z)$:
  ⇒潜在変数からデータを再構成する



AE(AutoEncoder)

AE と VAE の違い

- 学習するもの
  AE: 入力を復元する写像
  VAE: 潜在変数を介してデータを生成する確率モデル

ELBO(Evidence Lower Bound)

ELBO(Evidence Lower Bound)

$$L_{ELBO}(\theta, \phi; x) = \mathbb{E}_{z \sim q_\theta(z|x)}[\log p_\phi(x \mid z)] - D_{KL}(q_\theta(z \mid x) \,||\, p(z))$$

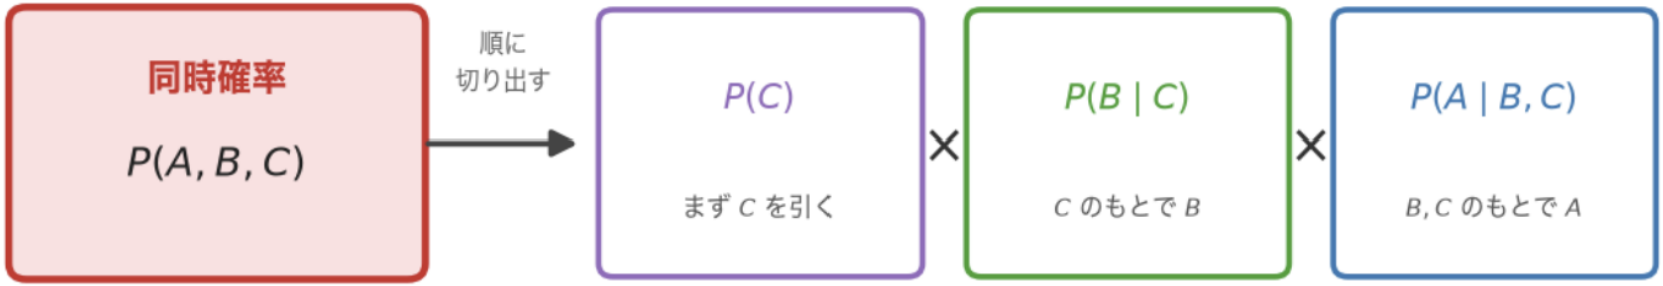
Nomalization Flows

GANs:Generative Advasarial Networks

chain rule

chain rule: 確率の連鎖律 (確率の乗法定理)

複数の確率変数の同時確立を条件付確率の積として表す公式
イメージ：



条件付確率 $P(A \mid B) = \frac{P(A,B)}{P(B)}$
両辺に $P(B)$ をかけると $P(A, B) = P(A \mid B)P(B)$

3 変数の場合

$P(A, B, C) = P(A \mid B, C)P(B \mid C)P(C)$
ここで $P(B, C)$ は 2 変数の同時確立なのでもう一度乗法定理
$P(B, C) = P(B \mid C)P(C)$ より
$P(A, B, C) = P(A \mid B, C)P(B \mid C)P(C)$

chain rule の一般化

chain rule の一般化

n 個の確率変数 $A_1, A_2, ..., A_n$ の同時確率からまず A_1 を切り出すと
$P(A_1, A_2, ..., A_n) = P(A_1 \mid A_2, ..., A_n)P(A_2, A_3, ..., A_n)$
ここで $P(A_2, A_3, ..., A_n)$ は n-1 個の確率変数の同時確率なので
もう一度乗法定理によって
$P(A_1, A_2, ..., A_n) = P(A_1 \mid A_2, ..., A_n)...P(A_{n-1} \mid A_n)P(A_n)$
したがって

$$P(A_1, A_2, ..., A_n) = \prod_{i=1}^{n} P(A_i \mid A_{i+1}, ..., A_n)$$

※最初の項は $P(A_1)$ になる

どの変数にも対称に使え、別の順序でも同じ同時確率が得られる
⇒問題ごとに計算しやすい順序を選べる