The Principles of Diffusion Models

1.3 Taxonomy of Modeling

渡邉 有志

October 15, 2026

1.3 Taxonomy of Modeling

分類の軸

DGM には多様な戦略がある。根本的な違いは、データ分布 $p_\phi(\boldsymbol{x})$ をどうパラメータ化するかにある。

- **Explicit**：密度や質量関数として陽に定める
- **Implicit**：サンプリング手続きだけで陰に定める

この区別は、学習に使う目的関数とは独立である。
最尤推定か、ELBO か、敵対的学習かでは分類しない。

Explicit Models

定義

確率分布 $p_\phi(\boldsymbol{x})$ を、計算可能な、または近似的に計算可能な密度・質量関数として直接パラメータ化する。

$p_\phi(\boldsymbol{x})$ の定め方は二通りある。

- 厳密に書く
  自己回帰モデル（AR）、正規化フロー（NF）
- 計算可能な下界を通して書く
  変分オートエンコーダ（VAE）、拡散モデル（DM）

いずれも $p_\phi(\boldsymbol{x})$ 自体は定義されている。
違いは、その値を厳密に評価できるか、下界で代用するかである。

Implicit Models

定義

分布をサンプリング手続きだけで定める。典型的には、ノイズ $\boldsymbol{z} \sim p_{\text{prior}}$ に対して

$$\boldsymbol{x} = \boldsymbol{G}_\phi(\boldsymbol{z}).$$

このとき $p_\phi(\boldsymbol{x})$ は閉形式で書けない。定義されないこともある。

- 例は GAN。生成器はサンプルを返す
- 尤度 $\log p_\phi(\boldsymbol{x})$ は学習に使わない
- 目的関数は敵対的学習になる

Table 1.1：Explicit と Implicit

	Explicit		Implicit
	Exact Likelihood	Approx. Likelihood	
Likelihood	Tractable	Bound / Approx.	Not Directly Modeled
Objective	MLE	ELBO	Adversarial
Examples	NFs, ARs	VAEs, DMs	GANs

- Exact：密度が計算でき、最尤推定が使える
- Approx.：下界や近似を最大化する
- Implicit：密度を直接は書かず、サンプルの質で学習する

1.2 のモデルの位置

ここまでのモデルは表のどこか

- AR：条件付き確率の積で $\log p_\phi(\boldsymbol{x})$ を正確に書ける $\rightarrow$ Exact
- NF：変数変換の公式で対数密度が計算できる $\rightarrow$ Exact
- VAE：ELBO は周辺尤度の下界 $\rightarrow$ Approx.
- GAN：$\boldsymbol{x} = \boldsymbol{G}_\phi(\boldsymbol{z})$ で密度を返さない $\rightarrow$ Implicit

EBM はエネルギーから p_ϕ を定義するので Explicit に近い。
ただし分配関数 $Z(\phi)$ が計算できず、表の三列には入っていない。
拡散モデルとの接続では、次のスライドで再び現れる。

Connection to Diffusion Models

拡散モデルが引き継ぐもの

古典的な族は、複雑な分布を扱う相補的な戦略である。
拡散モデルはそのいくつかを組み合わせて使う。

- **VAE**：変分的な学習目標。下界を通して学習する
- **EBM**：スコアマッチング。対数密度の勾配を学ぶ。
  エネルギー関数の勾配と結びつく
- **NF**：連続時間の変換。単純な分布をデータの分布へ運ぶ

以降で扱う三つの枠組み

後の章の拡散法に入る前に、次の三つを基礎として見る。

- VAEs　2.1 節
  潜在変数と変分下界
- EBMs　3.1 節
  エネルギーとスコア
- NFs　5.1 節
  可逆変換と連続時間

この三つが、現代の拡散型生成モデルの原理を読むための土台になる。