The Principles of Diffusion Models

1.4 Closing Remarks

渡邉 有志

October 15, 2026

1.4 Closing Remarks

この章の目標

未知で複雑なデータ分布 p_{data} を近似する、計算可能なモデル分布 p_ϕ を学習する。

妥当な確率密度を定義するには、正規化定数（分配関数）

$$Z(\phi) = \int \exp(-E_\phi(\boldsymbol{x}))\, d\boldsymbol{x}$$

が必要になる。高次元では、この積分が計算できない。

計算困難への対処

戦略の違うモデル族

$Z(\phi)$ を直接計算しないために、複数の族が用意されている。

この章で見たものは次の五つである。

- Energy-Based Models（EBMs）
- Autoregressive Models（ARs）
- Variational Autoencoders（VAEs）
- Normalizing Flows（NFs）
- Generative Adversarial Networks（GANs）

大きく分けると、密度を計算可能な形で書く Explicit と、
サンプリング手続きだけで分布を定める Implicit になる。

拡散モデルの三つの起源

このモノグラフの焦点

古典的な枠組みはどれも重要である。
そのうち三つが、拡散モデルの概念上の出発点になる。

- VAEs：変分推論と潜在変数
- EBMs：エネルギーとスコア
- NFs：可逆な変換

以降の章では、この三つから拡散モデルがどう展開するかをたどる。

Part B：変分の視点

Chapter 2

VAE の階層的な潜在変数の構造から、Denoising Diffusion Probabilistic Models（DDPMs）の定式化へ進む。

- 出発点は変分下界（ELBO）
- 潜在変数を一段ではなく、多段にする
- その多段の構造が、ノイズを少しずつ除く拡散モデルになる

スコアに基づく視点

Chapter 3 から Chapter 4

EBM とスコアマッチングから始まり、Noise Conditional Score Networks（NCSN）を経て、より一般の Score SDE に至る。

- 密度そのものではなく、対数密度の勾配（スコア）を学習する
- NCSN は、ノイズの強さごとにスコアを学ぶ
- Score SDE は、その手続きを確率微分方程式として書く

フローに基づく視点

Chapter 5

Normalizing Flows の原理の上に、生成を連続的な変換として定式化する。
その一般化が Flow Matching である。

- NF は、単純な分布を可逆変換でデータの分布へ運ぶ
- 拡散モデルでは、この変換を連続時間で考える
- Flow Matching は、その変換の速度場を直接学習する

この章の位置づけ

三つの起源を押さえると、拡散モデルの多様な定式化を一つの枠組みとして読める。
それらを貫く原理も、そこから見える。

- 変分　VAE $\to$ DDPM（2 章）
- スコア　EBM $\to$ NCSN $\to$ Score SDE（3–4 章）
- フロー　NF $\to$ Flow Matching（5 章）