The Principles of Diffusion Models

2.1 Variational Autoencoder

渡邉 有志

October 26, 2026

In this chapter...

変分法の観点から拡散モデルを見る

VAE は潜在変数でデータを表現し、計算可能な対数尤度の下界（ELBO）を最大化することで学習する。

- VAE：学習するエンコーダとデコーダ

$$\boldsymbol{x} \longrightarrow \boldsymbol{z} \longrightarrow \boldsymbol{x}'$$

- 階層型 VAE：複数の潜在変数層を積み重ねる
- DDPM：順方向のノイズ付加を固定し、逆方向のノイズ除去を学習する

VAE から DDPM へ

VAE

- エンコーダを学習
- デコーダを学習
- 一つの潜在変数層

DDPM

- 順方向過程を固定
- 逆方向過程を学習
- 多数のノイズ付き潜在層

共通する基盤

VAE、階層型 VAE、DDPM はいずれも、変分下界によって定義される尤度の代替目的関数を最適化する。

この章で理解すること

- 厳密な最尤学習が難しいとき、VAE がなぜ ELBO を使うのか
- DDPM が潜在変数による見方を、多数のノイズ付き潜在層へどう拡張するのか
- 条件付けによって、逆方向のノイズ除去を計算可能な目標へ変える仕組み
- 平均、元データ、ノイズの予測が、同じ情報を異なる形で表すこと
- DDPM のノイズ除去損失と ELBO の関係

※ VAE と ELBO に慣れている場合は、2.1 節を確認して 2.2 節へ進んでもよい。

2.1 Variational Autoencoder

Autoencoder（AE）

- Encoder：入力を低次元の潜在表現へ圧縮する決定論的写像
- Decoder：潜在表現から入力を再構成する決定論的写像

$$\boldsymbol{x} \xrightarrow{\text{Encoder}} \boldsymbol{z} \xrightarrow{\text{Decoder}} \boldsymbol{x}'$$

元の入力と再構成された入力の誤差を最小化する。

生成モデルとしての限界

正確に再構成できても、潜在空間に生成に適した構造があるとは限らない。任意の潜在表現をサンプリングすると、意味のない出力になり得る。

VAE：潜在空間に確率的構造を与える

Variational Autoencoder

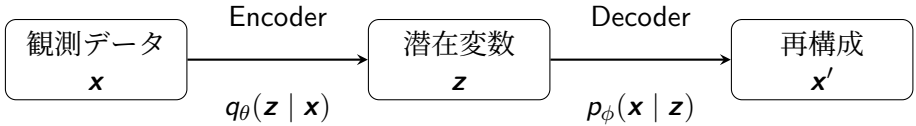
VAE は潜在表現を一つの値ではなく確率分布として扱い、潜在空間に滑らかな構造を与える。

- データの再構成だけでなく、新しいデータの生成を目指す
- 事前分布から潜在変数をサンプリングできるようにする
- 潜在空間の近い点が、似たデータへ対応するように学習する

決定論的 AE との違い

AE は写像を学習する。VAE は条件付き確率分布を学習する。

2.1.1 確率的エンコーダとデコーダ



- エンコーダは $\boldsymbol{x}$ から潜在変数の分布を定め、そこから $\boldsymbol{z}$ をサンプリングする
- デコーダは $\boldsymbol{z}$ からデータの分布を定める

「確率的」の意味

一つの値を直接決めるのではなく、値をサンプリングするための分布を定める。

デコーダ（生成器）の構成

VAE では二種類の変数を区別する。

- 観測変数 $\boldsymbol{x}$：画像など、実際に観測するデータ
- 潜在変数 $\boldsymbol{z}$：形・色・スタイルなど、データの変化を生む隠れた要因

生成モデル

単純な事前分布から潜在変数を生成する。

$$\boldsymbol{z} \sim p_{\text{prior}}(\boldsymbol{z}) := \mathcal{N}(\mathbf{0}, \mathbf{I})$$

デコーダ $p_\phi(\boldsymbol{x} \mid \boldsymbol{z})$ が、潜在変数をデータ空間へ写す。

VAE による新しいサンプルの生成

生成手順

$$\boldsymbol{z} \sim p_{\text{prior}}(\boldsymbol{z}), \qquad \boldsymbol{x} \sim p_{\phi}(\boldsymbol{x} \mid \boldsymbol{z})$$

1. 標準正規分布から $\boldsymbol{z}$ をサンプリング
2. デコーダが定める分布から $\boldsymbol{x}$ をサンプリング

画素を一つずつ直接生成する代わりに、まずコンパクトな潜在表現を生成し、そこから具体的なデータを構成する。

潜在変数を周辺化したモデル分布

VAE が定義する観測データの確率密度は、潜在変数を積分して得られる。

$$p_\phi(\boldsymbol{x}) = \int p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) p(\boldsymbol{z})\, d\boldsymbol{z}$$

意味

$\boldsymbol{z}$ のすべての可能性について、その起こりやすさ $p(\boldsymbol{z})$ で重み付けして足し合わせると、$\boldsymbol{x}$ の確率密度が得られる。

なぜ最尤推定を直接使えないのか

理想的には、周辺尤度 $p_\phi(\boldsymbol{x})$ を最大化してデコーダのパラメータ ϕ を学習したい。

$$\max_\phi \log p_\phi(\boldsymbol{x}) = \max_\phi \log \int p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) p(\boldsymbol{z})\, d\boldsymbol{z}$$

計算上の問題

表現力の高い非線形なデコーダでは、$\boldsymbol{z}$ の全領域にわたる積分が困難である。

厳密な対数尤度の代わりに、計算可能な下界を使う。

真の事後分布も計算困難

観測データ $\boldsymbol{x}$ を生成した潜在変数 $\boldsymbol{z}$ を推論するため、ベイズの定理を使う。

$$p_\phi(\boldsymbol{z} \mid \boldsymbol{x}) = \frac{p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) p(\boldsymbol{z})}{p_\phi(\boldsymbol{x})}$$

問題

分母の $p_\phi(\boldsymbol{x})$ が計算困難なので、真の事後分布 $p_\phi(\boldsymbol{z} \mid \boldsymbol{x})$ も一般には計算できない。

エンコーダ（推論ネットワーク）

計算困難な真の事後分布を、計算可能な近似分布で置き換える。

$$\boxed{q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \approx p_\phi(\boldsymbol{z} \mid \boldsymbol{x})}$$

- q_θ はニューラルネットワークでパラメータ化する
- 各データ $\boldsymbol{x}$ を潜在空間上の分布へ対応付ける
- $\boldsymbol{x}$ から $\boldsymbol{z}$ へ戻る、計算可能な経路を与える

VAE における「変分」

計算困難な事後分布を、扱いやすい分布族の中から近似すること。

2.1.2 ELBO による学習

定理 2.1.1：エビデンス下界

任意のデータ点 $\boldsymbol{x}$ に対して、

$$\log p_\phi(\boldsymbol{x}) \geq \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \boldsymbol{x})$$

$$\mathcal{L}_{\mathrm{ELBO}} = \underbrace{\mathbb{E}_{\boldsymbol{z}\sim q_\theta(\boldsymbol{z}|\boldsymbol{x})}[\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z})]}_{\text{再構成項}} - \underbrace{D_{\mathrm{KL}}(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p(\boldsymbol{z}))}_{\text{正則化項}}$$

ELBO の導出（1）：近似事後を掛ける

$$
\begin{aligned}
\log p_\phi(\boldsymbol{x}) &= \log \int p_\phi(\boldsymbol{x}, \boldsymbol{z})\, d\boldsymbol{z} \\
&= \log \int p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) p_{\text{prior}}(\boldsymbol{z})\, d\boldsymbol{z} \\
&= \log \int q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \frac{p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) p_{\text{prior}}(\boldsymbol{z})}{q_\theta(\boldsymbol{z} \mid \boldsymbol{x})}\, d\boldsymbol{z} \\
&= \log \mathbb{E}_{\boldsymbol{z} \sim q_\theta(\boldsymbol{z} \mid \boldsymbol{x})} \left[\frac{p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) p_{\text{prior}}(\boldsymbol{z})}{q_\theta(\boldsymbol{z} \mid \boldsymbol{x})} \right].
\end{aligned}
$$

3 行目では、積分の中に $q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) / q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) = 1$ を挿入した。

ELBO の導出（2）：イェンセンの不等式

log は凹関数なので、$\log \mathbb{E}[Y] \geq \mathbb{E}[\log Y]$ より、

$$\begin{aligned}\log p_\phi(\boldsymbol{x}) &\geq \mathbb{E}_{\boldsymbol{z}\sim q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\log \frac{p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) p_{\mathrm{prior}}(\boldsymbol{z})}{q_\theta(\boldsymbol{z} \mid \boldsymbol{x})}\right] \\ &= \mathbb{E}_{\boldsymbol{z}\sim q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) + \log p_{\mathrm{prior}}(\boldsymbol{z}) - \log q_\theta(\boldsymbol{z} \mid \boldsymbol{x})\right].\end{aligned}$$

この不等式の右辺が、対数尤度の下界となる。

ELBO の導出（3）：二つの項へ分解

$$
\begin{aligned}
\log p_\phi(\boldsymbol{x}) &\geq \mathbb{E}_{q_\theta}[\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z})] + \mathbb{E}_{q_\theta}[\log p_{\text{prior}}(\boldsymbol{z})] \\
&\quad - \mathbb{E}_{q_\theta}[\log q_\theta(\boldsymbol{z} \mid \boldsymbol{x})] \\
&= \mathbb{E}_{q_\theta}[\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z})] - \mathbb{E}_{q_\theta}\left[\log \frac{q_\theta(\boldsymbol{z} \mid \boldsymbol{x})}{p_{\text{prior}}(\boldsymbol{z})}\right] \\
&= \underbrace{\mathbb{E}_{\boldsymbol{z} \sim q_\theta(\boldsymbol{z} \mid \boldsymbol{x})}[\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z})]}_{\text{再構成項}} \\
&\quad - \underbrace{D_{\mathrm{KL}}(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p_{\text{prior}}(\boldsymbol{z}))}_{\text{正則化項}} \\
&= \mathcal{L}_{\text{ELBO}}(\theta, \phi; \boldsymbol{x}).
\end{aligned}
$$

ELBO の二つの役割

再構成項

$$\mathbb{E}_{q_\theta}[\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z})]$$

潜在表現から元のデータを正確に復元するよう促す。

潜在変数の KL 項

$$D_{\mathrm{KL}}(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p(\boldsymbol{z}))$$

エンコーダの分布を事前分布へ近づけ、潜在空間を滑らかで連続的にする。

二項の釣り合いにより、再構成とサンプル生成の両立を目指す。

再構成項と二乗誤差の関係

「負の再構成項が二乗誤差になる」ためには条件が必要である。

固定分散のガウスデコーダ

$$p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) = \mathcal{N}\big(\boldsymbol{\mu}_\phi(\boldsymbol{z}), \tau^2 \mathbf{I}\big)$$

とすると、

$$-\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) = \frac{\|\boldsymbol{x} - \boldsymbol{\mu}_\phi(\boldsymbol{z})\|_2^2}{2\tau^2} + \text{const.}$$

注意

エンコーダがガウス分布であることだけでは成立しない。

情報理論的な見方

最尤学習は、次の KL を最小化することに相当する。

$$D_{\mathrm{KL}}(p_{\mathrm{data}}(\boldsymbol{x}) \| p_\phi(\boldsymbol{x}))$$

直接扱う代わりに、潜在変数を含む二つの同時分布を比較する。

$$\begin{aligned} &\text{生成側：} \quad p_\phi(\boldsymbol{x}, \boldsymbol{z}) = p(\boldsymbol{z}) p_\phi(\boldsymbol{x} \mid \boldsymbol{z}), \\ &\text{推論側：} \quad q_\theta(\boldsymbol{x}, \boldsymbol{z}) = p_{\mathrm{data}}(\boldsymbol{x}) q_\theta(\boldsymbol{z} \mid \boldsymbol{x}). \end{aligned}$$

同時分布の KL は上界になる

$$D_{\mathrm{KL}}(p_{\mathrm{data}}(\boldsymbol{x}) \| p_\phi(\boldsymbol{x})) \leq D_{\mathrm{KL}}(q_\theta(\boldsymbol{x}, \boldsymbol{z}) \| p_\phi(\boldsymbol{x}, \boldsymbol{z}))$$

直感

$\boldsymbol{x}$ の周辺分布だけを比較した場合には見えない不一致も、潜在変数とデータの同時分布全体を比較すると現れる。

この関係は KL ダイバージェンスの連鎖律から導かれる。

KL 連鎖律の導出（1）：同時分布を展開

$$
\begin{aligned}
&D_{\mathrm{KL}}\left(q_\theta(\boldsymbol{x},\boldsymbol{z}) \| p_\phi(\boldsymbol{x},\boldsymbol{z})\right) \\
&= \iint q_\theta(\boldsymbol{x},\boldsymbol{z}) \log \frac{q_\theta(\boldsymbol{x},\boldsymbol{z})}{p_\phi(\boldsymbol{x},\boldsymbol{z})}\, d\boldsymbol{z}\, d\boldsymbol{x} \\
&= \mathbb{E}_{q_\theta(\boldsymbol{x},\boldsymbol{z})}\left[\log \frac{q_\theta(\boldsymbol{x},\boldsymbol{z})}{p_\phi(\boldsymbol{x},\boldsymbol{z})}\right] \\
&= \mathbb{E}_{q_\theta(\boldsymbol{x},\boldsymbol{z})}\left[\log \frac{q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{z} \mid \boldsymbol{x}) p_\phi(\boldsymbol{x})}\right].
\end{aligned}
$$

ここで、$q_\theta(\boldsymbol{x},\boldsymbol{z}) = p_{\mathrm{data}}(\boldsymbol{x}) q_\theta(\boldsymbol{z} \mid \boldsymbol{x})$ を用いた。

KL 連鎖律の導出（2）：反復期待値へ

$$
\begin{aligned}
&= \iint p_{\mathrm{data}}(\boldsymbol{x}) q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \log \frac{q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{z} \mid \boldsymbol{x}) p_\phi(\boldsymbol{x})} \, d\boldsymbol{z} \, d\boldsymbol{x} \\
&= \int p_{\mathrm{data}}(\boldsymbol{x}) \left[\int q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \log \frac{q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{z} \mid \boldsymbol{x}) p_\phi(\boldsymbol{x})} \, d\boldsymbol{z} \right] d\boldsymbol{x} \\
&= \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})} \left[\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})} \left[\log \frac{q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{z} \mid \boldsymbol{x}) p_\phi(\boldsymbol{x})} \right] \right].
\end{aligned}
$$

KL 連鎖律の導出（3）：対数を分ける

$$
\begin{aligned}
&= \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\log \frac{p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{x})} + \log \frac{q_\theta(\boldsymbol{z} \mid \boldsymbol{x})}{p_\phi(\boldsymbol{z} \mid \boldsymbol{x})}\right]\right] \\
&= \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\log \frac{p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{x})}\right]\right. \\
&\qquad\qquad \left. + \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\log \frac{q_\theta(\boldsymbol{z} \mid \boldsymbol{x})}{p_\phi(\boldsymbol{z} \mid \boldsymbol{x})}\right]\right] \\
&= \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[\int q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \log \frac{p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{x})}\, d\boldsymbol{z} + D_{\mathrm{KL}}\left(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p_\phi(\boldsymbol{z} \mid \boldsymbol{x})\right)\right].
\end{aligned}
$$

KL 連鎖律の導出（4）：二つの誤差へ

$\log[p_{\mathrm{data}}(\boldsymbol{x})/p_\phi(\boldsymbol{x})]$ は $\boldsymbol{z}$ に依存しないので、

$$
\begin{aligned}
&= \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})} \Bigg[\log \frac{p_{\mathrm{data}}(\boldsymbol{x})}{p_\phi(\boldsymbol{x})} \underbrace{\int q_\theta(\boldsymbol{z} \mid \boldsymbol{x})\, d\boldsymbol{z}}_{=1} \\
&\qquad\qquad + D_{\mathrm{KL}}\left(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p_\phi(\boldsymbol{z} \mid \boldsymbol{x})\right) \Bigg] \\
&= D_{\mathrm{KL}}\left(p_{\mathrm{data}}(\boldsymbol{x}) \| p_\phi(\boldsymbol{x})\right) \\
&\quad + \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[D_{\mathrm{KL}}\left(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p_\phi(\boldsymbol{z} \mid \boldsymbol{x})\right)\right].
\end{aligned}
$$

右辺は、モデル化誤差と推論誤差の和である。

モデル化誤差と推論誤差

$$
\begin{aligned}
&D_{\mathrm{KL}}(q_\theta(\boldsymbol{x},\boldsymbol{z})\|p_\phi(\boldsymbol{x},\boldsymbol{z})) \\
&= \underbrace{D_{\mathrm{KL}}(p_{\mathrm{data}}(\boldsymbol{x})\|p_\phi(\boldsymbol{x}))}_{\text{モデル化誤差}} \\
&\quad + \underbrace{\mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[D_{\mathrm{KL}}(q_\theta(\boldsymbol{z}\mid\boldsymbol{x})\|p_\phi(\boldsymbol{z}\mid\boldsymbol{x}))\right]}_{\text{推論誤差}}.
\end{aligned}
$$

推論誤差は非負なので、同時分布の KL が周辺分布の KL の上界になる。

対数尤度と ELBO の差

各データ点 $\boldsymbol{x}$ について、次の恒等式が成り立つ。

$$\boxed{\log p_\phi(\boldsymbol{x}) - \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \boldsymbol{x}) = D_{\mathrm{KL}}(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p_\phi(\boldsymbol{z} \mid \boldsymbol{x}))}$$

- ELBO は必ず対数尤度以下
- 近似事後と真の事後が一致すると、ELBO も対数尤度に一致
- ELBO の緩さは、二つの事後分布の不一致そのもの

ELBO 最大化の正確な意味

生成モデル ϕ を固定する場合

$\log p_\phi(\boldsymbol{x})$ は θ に依存しない。θ について ELBO を最大化することは、推論誤差を最小化することと同値である。

θ と ϕ を同時に学習する場合

通常の VAE では対数尤度自体も変化する。ELBO 最大化はモデル化誤差と推論誤差の和を小さくするが、各誤差が個別に必ず減るという意味ではない。

データ全体で見た ELBO

$$
\begin{aligned}
&D_{\mathrm{KL}}(q_\theta(\boldsymbol{x}, \boldsymbol{z}) \| p_\phi(\boldsymbol{x}, \boldsymbol{z})) \\
&= \underbrace{\mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}[\log p_{\mathrm{data}}(\boldsymbol{x})]}_{\theta,\phi\text{に依存しない定数}} \\
&\quad - \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[\mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \boldsymbol{x})\right].
\end{aligned}
$$

結論

平均 ELBO の最大化は、推論側と生成側の同時分布の KL を最小化することに等しい。

2.1.3 ガウス分布を用いたVAE

エンコーダ

$$q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) := \mathcal{N}\big(\boldsymbol{z}; \boldsymbol{\mu}_\theta(\boldsymbol{x}), \mathrm{diag}(\boldsymbol{\sigma}_\theta^2(\boldsymbol{x}))\big)$$

$$\boldsymbol{\mu}_\theta : \mathbb{R}^D \to \mathbb{R}^d, \qquad \boldsymbol{\sigma}_\theta : \mathbb{R}^D \to \mathbb{R}_+^d.$$

- D は観測データ、d は潜在変数の次元
- ネットワークは潜在分布の平均と標準偏差を出力
- 対角共分散なので、$\boldsymbol{x}$ を条件とした $\boldsymbol{z}$ の各次元は独立

ガウスデコーダ

固定分散のデコーダ

$$p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) := \mathcal{N}\left(\boldsymbol{x}; \boldsymbol{\mu}_\phi(\boldsymbol{z}), \sigma^2 \mathbf{I}\right)$$

$$\boldsymbol{\mu}_\phi : \mathbb{R}^d \to \mathbb{R}^D, \qquad \sigma > 0$$

- デコーダは $\boldsymbol{z}$ からデータ分布の平均 $\boldsymbol{\mu}_\phi(\boldsymbol{z})$ を出力
- 共分散は固定された $\sigma^2 \mathbf{I}$
- $\boldsymbol{z}$ を条件とすると、データの各次元は独立で同じ分散を持つ

再構成項は二乗誤差になる

固定分散のガウスデコーダでは、

$$\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}[\log p_\phi(\boldsymbol{x} \mid \boldsymbol{z})] = -\frac{1}{2\sigma^2}\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\|\boldsymbol{x} - \boldsymbol{\mu}_\phi(\boldsymbol{z})\|_2^2\right] + C$$

ここで C は θ, ϕ に依存しない。

意味

再構成項を最大化することは、デコーダの平均と元データの二乗誤差を最小化することに等しい。

ガウス VAE の学習目的

ELBO の最大化は、次の損失の最小化に帰着する。

$$\min_{\theta,\phi} \left\{ \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})} \left[\frac{\|\boldsymbol{x} - \boldsymbol{\mu}_\phi(\boldsymbol{z})\|_2^2}{2\sigma^2} \right] + D_{\mathrm{KL}}(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| p_{\mathrm{prior}}(\boldsymbol{z})) \right\}$$

- 第 1 項：元データを忠実に再構成
- 第 2 項：潜在分布を事前分布へ近づける正則化
- 実際の学習では訓練データ全体について平均する

ガウス分布間の KL は解析的に計算できる

$p_{\text{prior}}(\boldsymbol{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ とすると、

$$D_{\mathrm{KL}}(q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) \| \mathcal{N}(\mathbf{0}, \mathbf{I})) = \frac{1}{2} \sum_{j=1}^{d} \left[\mu_{\theta,j}(\boldsymbol{x})^2 + \sigma_{\theta,j}(\boldsymbol{x})^2 - 1 - \log \sigma_{\theta,j}(\boldsymbol{x})^2 \right]$$

ガウス VAE の利点

再構成項はサンプリングで推定でき、KL 項は閉形式で計算できるため、学習目的が扱いやすい。

2.1.4 標準的な VAE の欠点

ぼやけた出力

単純なガウスデコーダを用い、二乗再構成誤差に基づいて学習する VAE では、生成画像がぼやけることがある。

- ここで扱うのは、固定分散ガウスデコーダという設定の問題
- すべての VAE や観測モデルに当てはまるわけではない
- 原因を調べるため、エンコーダ q_{enc} を固定する

$$p_{\mathrm{dec}}(\boldsymbol{x} \mid \boldsymbol{z}) = \mathcal{N}\left(\boldsymbol{x}; \boldsymbol{\mu}(\boldsymbol{z}), \sigma^2 \mathbf{I}\right)$$

固定エンコーダでの最適化

エンコーダを固定すると、KL 正則化項は $\boldsymbol{\mu}$ に依存しない。

$$\arg\min_{\boldsymbol{\mu}} \mathbb{E}_{p_{\text{data}}(\boldsymbol{x})q_{\text{enc}}(\boldsymbol{z}|\boldsymbol{x})}\left[\|\boldsymbol{x}-\boldsymbol{\mu}(\boldsymbol{z})\|_2^2\right]$$

これは $\boldsymbol{\mu}(\boldsymbol{z})$ についての標準的な最小二乗問題である。

最適解

$$\boxed{\boldsymbol{\mu}^*(\boldsymbol{z}) = \mathbb{E}_{q_{\text{enc}}(\boldsymbol{x}|\boldsymbol{z})}[\boldsymbol{x}]}$$

エンコーダが定める逆向きの条件付き分布

$$q_{\mathrm{enc}}(\boldsymbol{x} \mid \boldsymbol{z}) = \frac{q_{\mathrm{enc}}(\boldsymbol{z} \mid \boldsymbol{x}) p_{\mathrm{data}}(\boldsymbol{x})}{q_{\mathrm{enc}}(\boldsymbol{z})}$$

$$q_{\mathrm{enc}}(\boldsymbol{z}) := \int q_{\mathrm{enc}}(\boldsymbol{z} \mid \boldsymbol{x}) p_{\mathrm{data}}(\boldsymbol{x})\, d\boldsymbol{x}$$

分布を区別する

$q_{\mathrm{enc}}(\boldsymbol{x} \mid \boldsymbol{z})$ は、デコーダの分布 $p_{\mathrm{dec}}(\boldsymbol{x} \mid \boldsymbol{z})$ とは別物である。

最適なデコーダ平均は重み付き平均

ベイズの定理を使うと、

$$\begin{aligned}\boldsymbol{\mu}^*(\boldsymbol{z}) &= \frac{\mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}[q_{\mathrm{enc}}(\boldsymbol{z} \mid \boldsymbol{x})\boldsymbol{x}]}{q_{\mathrm{enc}}(\boldsymbol{z})} \\ &= \frac{\mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}[q_{\mathrm{enc}}(\boldsymbol{z} \mid \boldsymbol{x})\boldsymbol{x}]}{\mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}[q_{\mathrm{enc}}(\boldsymbol{z} \mid \boldsymbol{x})]}.\end{aligned}$$

ある $\boldsymbol{z}$ に対応しやすい入力ほど大きく重み付けして、複数の入力を平均したものが出力される。

なぜ画像がぼやけるのか

複数の候補を平均する

同じ $\boldsymbol{z}$ に対して、見た目の異なる複数の入力が無視できない条件付き確率を持つと、$\boldsymbol{\mu}^*(\boldsymbol{z})$ はそれらを平均する。

- 輪郭の位置が違う画像を画素ごとに平均する
- 複数の輪郭が薄く重なり、不鮮明になる
- 二乗誤差では、一つを選ぶより条件付き平均が最適になる

厳密な注意

分布の台が重なるだけで必ずぼやけるわけではない。重要なのは、異なる入力が同じ $\boldsymbol{z}$ に対して無視できない条件付き確率を持つことである。

2.1.5 標準的な VAE から階層型 VAE へ

Hierarchical VAE（HVAE）

複数の潜在変数層を導入し、さまざまな抽象度でデータの特徴を捉える。

$$\boldsymbol{x} \xrightarrow{q_\theta(\boldsymbol{z}_1|\boldsymbol{x})} \boldsymbol{z}_1 \xrightarrow{q_\theta(\boldsymbol{z}_2|\boldsymbol{z}_1)} \cdots \longrightarrow \boldsymbol{z}_L$$

$$\boldsymbol{z}_L \xrightarrow{p_\phi(\boldsymbol{z}_{L-1}|\boldsymbol{z}_L)} \cdots \longrightarrow \boldsymbol{z}_1 \xrightarrow{p_\phi(\boldsymbol{x}|\boldsymbol{z}_1)} \boldsymbol{x}$$

増えるのは NN の内部層ではなく、それぞれに分布を持つ潜在変数の層である。

HVAE の生成モデル

上位の潜在変数が、その下の潜在変数の分布を条件付ける。

$$\boxed{p_\phi(\boldsymbol{x}, \boldsymbol{z}_{1:L}) = p_\phi(\boldsymbol{x} \mid \boldsymbol{z}_1) \left[\prod_{i=2}^{L} p_\phi(\boldsymbol{z}_{i-1} \mid \boldsymbol{z}_i) \right] p(\boldsymbol{z}_L)}$$

$$p_{\mathrm{HVAE}}(\boldsymbol{x}) := \int p_\phi(\boldsymbol{x}, \boldsymbol{z}_{1:L})\, d\boldsymbol{z}_{1:L}$$

$\boldsymbol{z}_{1:L}$ は $\boldsymbol{z}_1, \ldots, \boldsymbol{z}_L$ をまとめた表記である。

HVAE の生成手順

1. 最上位の潜在変数を事前分布からサンプリング

$$\boldsymbol{z}_L \sim p(\boldsymbol{z}_L)$$

2. 上位から下位へ潜在変数を順番に生成

$$\boldsymbol{z}_{i-1} \sim p_\phi(\boldsymbol{z}_{i-1} \mid \boldsymbol{z}_i), \quad i = L, \ldots, 2$$

3. 最下位の潜在変数からデータを生成

$$\boldsymbol{x} \sim p_\phi(\boldsymbol{x} \mid \boldsymbol{z}_1)$$

HVAE の変分エンコーダ

生成側の階層に対応する、構造化された近似事後分布を使う。

$$q_\theta(\boldsymbol{z}_{1:L} \mid \boldsymbol{x}) = q_\theta(\boldsymbol{z}_1 \mid \boldsymbol{x}) \prod_{i=2}^{L} q_\theta(\boldsymbol{z}_i \mid \boldsymbol{z}_{i-1})$$

- まず $\boldsymbol{x}$ から $\boldsymbol{z}_1$ を推論
- $\boldsymbol{z}_1$ から $\boldsymbol{z}_2$ へ進む
- 各層は直前の潜在変数だけに依存する

これは下位から上位へ向かうマルコフ分解の一例である。

HVAE の ELBO

イェンセンの不等式により、

$$
\begin{aligned}
\log p_{\mathrm{HVAE}}(\boldsymbol{x}) &= \log \mathbb{E}_{q_\theta(\boldsymbol{z}_{1:L}|\boldsymbol{x})}\left[\frac{p_\phi(\boldsymbol{x}, \boldsymbol{z}_{1:L})}{q_\theta(\boldsymbol{z}_{1:L} \mid \boldsymbol{x})}\right] \\
&\geq \mathbb{E}_{q_\theta(\boldsymbol{z}_{1:L}|\boldsymbol{x})}\left[\log \frac{p_\phi(\boldsymbol{x}, \boldsymbol{z}_{1:L})}{q_\theta(\boldsymbol{z}_{1:L} \mid \boldsymbol{x})}\right] \\
&=: \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \boldsymbol{x}).
\end{aligned}
$$

因子分解した HVAE の ELBO

$$\mathcal{L}_{\mathrm{ELBO}} = \mathbb{E}_{q_\theta(\boldsymbol{z}_{1:L}|\boldsymbol{x})}\left[\log \frac{p(\boldsymbol{z}_L)\left[\prod_{i=2}^{L} p_\phi(\boldsymbol{z}_{i-1} \mid \boldsymbol{z}_i)\right] p_\phi(\boldsymbol{x} \mid \boldsymbol{z}_1)}{q_\theta(\boldsymbol{z}_1 \mid \boldsymbol{x})\left[\prod_{i=2}^{L} q_\theta(\boldsymbol{z}_i \mid \boldsymbol{z}_{i-1})\right]}\right] \tag{2.1.3}$$

- データの再構成を促す項
- 隣接する潜在層どうしの整合を促す項
- 最上位の潜在分布を事前分布へ近づける項

階層構造が与えるもの

観察 2.1.1

層を積み重ねることで、大まかな構造から始め、各段階で細かな情報を加えながらデータを生成できる。

- 各潜在層が隣接する層と直接情報をやり取りする
- 複数の抽象度を使って高次元データを表現できる
- 同じ階層的発想はスコアモデルやフローにも現れる

注意

層を積むだけで各層の役割が自動的に「大まか」「細かい」に分かれるとは限らない。実際の役割は設計と学習結果に依存する。

NN を深くするだけでは不十分（1）

標準的な VAE では、

$$q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) = \mathcal{N}\big(\boldsymbol{z}; \boldsymbol{\mu}_\theta(\boldsymbol{x}), \mathrm{diag}(\boldsymbol{\sigma}^2_\theta(\boldsymbol{x}))\big)\,.$$

- NN を深くすると $\boldsymbol{\mu}_\theta, \boldsymbol{\sigma}_\theta$ の表現力は上がる
- しかし出力が単一ガウスという制約は変わらない
- 真の事後分布が多峰性なら、正確に一致できない
- その結果、対数尤度と ELBO の隔たりが残る

NN を深くするだけでは不十分（2）

事後崩壊

表現力の高いデコーダが潜在変数 $\boldsymbol{z}$ を使わずにデータをモデル化すると、$\boldsymbol{z}$ が入力の情報を持たなくなることがある。

デコーダが

$$p_\phi(\boldsymbol{x} \mid \boldsymbol{z}) = r(\boldsymbol{x})$$

と $\boldsymbol{z}$ を無視できる場合、再構成項は $q_\theta(\boldsymbol{z} \mid \boldsymbol{x})$ を変えても変化しない。

$$q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) = p(\boldsymbol{z})$$

とすれば KL 項をゼロにできる。

事後崩壊と相互情報量

平均 ELBO の KL 正則化項は、次のように分解できる。

$$\begin{aligned}&\mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[D_{\mathrm{KL}}(q_\theta(\boldsymbol{z}\mid\boldsymbol{x})\|p(\boldsymbol{z}))\right]\\&= I_q(\boldsymbol{x};\boldsymbol{z}) + D_{\mathrm{KL}}(q_\theta(\boldsymbol{z})\|p(\boldsymbol{z}))\,,\end{aligned}$$

$$q_\theta(\boldsymbol{z}) = \int p_{\mathrm{data}}(\boldsymbol{x})q_\theta(\boldsymbol{z}\mid\boldsymbol{x})\,d\boldsymbol{x}.$$

事後崩壊では $q_\theta(\boldsymbol{z}\mid\boldsymbol{x}) = p(\boldsymbol{z})$ なので、

$$I_q(\boldsymbol{x};\boldsymbol{z}) = 0.$$

潜在変数は入力と独立になり、生成の制御にも使えなくなる。

事後崩壊についての注意

事後崩壊した解が大域的最大解となる十分な状況

- デコーダが $r(\boldsymbol{x}) = p_{\text{data}}(\boldsymbol{x})$ を厳密に実現できる
- エンコーダが $q_\theta(\boldsymbol{z} \mid \boldsymbol{x}) = p(\boldsymbol{z})$ を実現できる

単に「データ分布に近い $r(\boldsymbol{x})$ を表現できる」というだけでは、事後崩壊した解が必ず大域的最大解になるとは限らない。

階層構造によって何が変わるか

エンコーダ

$$q_\theta(\boldsymbol{z}_i \mid \boldsymbol{z}_{i-1})$$

下位から上位へ情報を伝える。

デコーダ

$$p_\phi(\boldsymbol{z}_{i-1} \mid \boldsymbol{z}_i)$$

上位から下位へ情報を伝える。

ELBO は再構成、隣接層の整合、最上位層の KL 正則化へ分かれる。これは潜在変数を階層的に結び付けた確率モデルだから得られる構造であり、NN の内部層を深くするだけでは得られない。

HVAE の各整合項について

個別の KL とは限らない

階層型 ELBO を展開したときの「隣接層の整合を促す項」は、そのまま個別の KL ダイバージェンスとは限らない。

- エンコーダ側：$q_\theta(\boldsymbol{z}_i \mid \boldsymbol{z}_{i-1})$
- デコーダ側：$p_\phi(\boldsymbol{z}_i \mid \boldsymbol{z}_{i+1})$
- 二つは異なる変数を条件としている
- したがって、展開後の各項が単独で必ず非負とは限らない

HVAE の学習上の課題

- エンコーダとデコーダを同時に最適化するため、学習が不安定になり得る
- 下位層だけで再構成できると、上位の潜在変数へ有効な学習信号が届かない
- 深い層へ届く勾配は間接的で弱くなりやすい
- 条件付き分布の表現力が高すぎると、上位の潜在変数を使う必要性が下がる

HVAE から変分的拡散モデルへ

2.2 節への接続

拡散モデルは HVAE の段階的な構造を引き継ぎながら、主要な弱点を回避する。

- 符号化に相当する順方向過程を固定する
- その経路を逆向きにたどる生成過程だけを学習する
- 多数のノイズ付き潜在層を用いる
- 学習の安定性とモデル化の柔軟性を高める

以降の表記

エンコーダを q、生成器を p とする VAE 固有の慣例から離れ、分布は p で表し、役割は添字・上付き文字で区別する。

2.1 まとめ

- ガウス VAE では、再構成項が二乗誤差、KL 項が解析的な正則化項になる
- 固定分散ガウスデコーダでは、条件付き平均のため出力がぼやけることがある
- HVAE は確率分布を持つ潜在変数層を積み重ねる
- NN を深くするだけでは、近似事後の分布族の制約や事後崩壊は解消しない
- 階層型 ELBO は再構成と潜在層の整合を同時に促す
- DDPM は順方向過程を固定し、逆方向過程だけを学習する