The Principles of Diffusion Models

2.2 Variational Perspective: DDPM

渡邉 有志

October 31, 2026

2.2 変分的観点：DDPM

Denoising Diffusion Probabilistic Model

DDPM は、データをノイズへ変える過程と、ノイズをデータへ戻す過程を組み合わせた生成モデルである。

- VAE・HVAE と同様に、変分的な枠組みに基づく
- 符号化に相当する順方向過程は固定する
- 生成に相当する逆方向過程だけを学習する
- 一度に生成せず、小さなノイズ除去を繰り返す

Sohl-Dickstein et al. (2015), Ho et al. (2020)

DDPM を構成する二つの確率過程

順方向過程

固定されたエンコーダ

$$p(\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1})$$

- データへガウスノイズを加える
- 徐々に情報を失わせる
- パラメータは学習しない

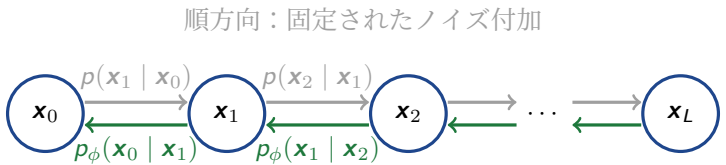
逆方向過程

学習可能なデコーダ

$$p_\phi(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i)$$

- ノイズを段階的に除去する
- 純粋なノイズから生成する
- ニューラルネットワークで学習

図 2.3：DDPM の概略図



- x_0 は実データ、x_L はほぼ純粋なノイズ
- 逆方向では、各ステップの小さな変化だけを学習すればよい

なぜ段階的な生成にするのか

一度に生成

$$z \longrightarrow x$$

ノイズや潜在表現から、複雑なデータ全体を一度に構成する必要がある。

$\Longrightarrow$

段階的に生成

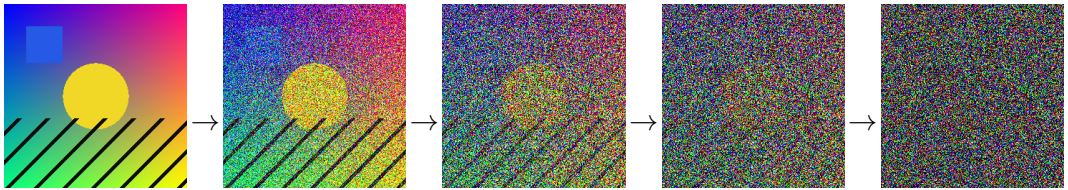
$$x_i \longrightarrow x_{i-1}$$

各ステップでは、少量のノイズによる変化だけを逆転させればよい。

DDPM の工夫

エンコーダを固定し、扱いやすい局所的なノイズ除去へ学習能力を集中させる。

図 2.4：順方向過程によるノイズの増加



ガウスノイズを段階的に加え、データ分布を単純なノイズ分布へ近づける。

固定されたガウス遷移

順方向過程の各ステップを、次の遷移カーネルで定める。

$$\boxed{p(\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1}) := \mathcal{N}\left(\boldsymbol{x}_i;\ \sqrt{1-\beta_i^2}\,\boldsymbol{x}_{i-1}, \beta_i^2 \boldsymbol{I}\right)}$$

$$\alpha_i := \sqrt{1-\beta_i^2}$$

と定義すれば、

$$\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1} \sim \mathcal{N}\left(\alpha_i \boldsymbol{x}_{i-1}, \beta_i^2 \boldsymbol{I}\right).$$

- $\{\beta_i\}_{i=1}^{L}$：あらかじめ定めるノイズスケジュール
- $\beta_i \in (0,1)$：ステップ i で加えるノイズの大きさ
- この順方向遷移には学習パラメータがない

分布の定義と更新式は等価

標準ガウスノイズを用意する。

$$\boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$

すると、遷移カーネルからのサンプリングは

$$\boxed{\boldsymbol{x}_i = \alpha_i \boldsymbol{x}_{i-1} + \beta_i \boldsymbol{\epsilon}_i}$$

と書ける。

$$\begin{aligned}\mathbb{E}[\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1}] &= \alpha_i \boldsymbol{x}_{i-1}, \\ \mathrm{Cov}(\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1}) &= \beta_i^2 \boldsymbol{I}.\end{aligned}$$

直感

前の状態を α_i 倍して少し弱め、独立なノイズを β_i 倍して加える。

係数の関係と分散の保存

定義より、

$$\boxed{\alpha_i^2 + \beta_i^2 = 1}$$

が成り立つ。

標準ガウス分布はこの更新で保存される

$\boldsymbol{x}_{i-1} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I})$、$\boldsymbol{\epsilon}_i \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I})$ が独立なら、

$$\mathrm{Cov}(\boldsymbol{x}_i) = \alpha_i^2 \boldsymbol{I} + \beta_i^2 \boldsymbol{I} = \boldsymbol{I}.$$

記法上の注意

ここではノイズ分散を β_i^2 と書いている。文献によっては分散そのものを β_i と表すため、$\sqrt{1-\beta_i}$ という式が現れる。

摂動カーネル：任意の時点へ直接進む

遷移を繰り返したときの累積信号係数を

$$\bar{\alpha}_i := \prod_{k=1}^{i} \alpha_k = \prod_{k=1}^{i} \sqrt{1-\beta_k^2}$$

と定義する。すると、

$$\boxed{p_i(\boldsymbol{x}_i \mid \boldsymbol{x}_0) = \mathcal{N}\big(\boldsymbol{x}_i;\, \bar{\alpha}_i \boldsymbol{x}_0,\, (1-\bar{\alpha}_i^2)\boldsymbol{I}\big)}$$

を得る。

重要

$\boldsymbol{x}_1, \ldots, \boldsymbol{x}_{i-1}$ を計算せず、$\boldsymbol{x}_0$ から任意の $\boldsymbol{x}_i$ を直接生成できる。

直接サンプリングする式

摂動カーネルは、次の更新式と等価である。

$$\boxed{\boldsymbol{x}_i = \bar{\alpha}_i \boldsymbol{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\, \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})} \tag{2.2.1}$$

逐次計算

$$\boldsymbol{x}_0 \to \boldsymbol{x}_1 \to \cdots \to \boldsymbol{x}_i$$

前の状態が毎回必要。

直接計算

$$\boldsymbol{x}_0 \longrightarrow \boldsymbol{x}_i$$

学習時に効率よくノイズを加えられる。

なぜ複数のノイズを一つにまとめられるのか

例として 2 ステップ展開する。

$$\begin{aligned}\boldsymbol{x}_2 &= \alpha_2 \boldsymbol{x}_1 + \beta_2 \boldsymbol{\epsilon}_2 \\ &= \alpha_2\alpha_1 \boldsymbol{x}_0 + \alpha_2\beta_1 \boldsymbol{\epsilon}_1 + \beta_2 \boldsymbol{\epsilon}_2.\end{aligned}$$

独立なガウス変数の線形結合もガウス分布に従う。ノイズ部分の共分散は、

$$(\alpha_2^2\beta_1^2 + \beta_2^2)\boldsymbol{I} = (1 - \alpha_1^2\alpha_2^2)\boldsymbol{I}.$$

したがって、

$$\boldsymbol{x}_2 \overset{d}{=} \bar{\alpha}_2 \boldsymbol{x}_0 + \sqrt{1 - \bar{\alpha}_2^2}\, \boldsymbol{\epsilon}.$$

$\overset{d}{=}$ は「同じ分布に従う」ことを表す。

順方向過程の終点と事前分布

式（2.2.1）を信号成分とノイズ成分に分ける。

$$\boldsymbol{x}_i = \underbrace{\bar{\alpha}_i \boldsymbol{x}_0}_{\text{元データの成分}} + \underbrace{\sqrt{1-\bar{\alpha}_i^2}\boldsymbol{\epsilon}}_{\text{ノイズ成分}}$$

適切なスケジュールによって $\bar{\alpha}_L \approx 0$ とすれば、

$$\boldsymbol{x}_L \approx \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I}).$$

したがって、生成の出発点として

$$\boxed{p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \boldsymbol{I})}$$

を選べる。

注意

β_i が単調増加するだけでは不十分であり、$\bar{\alpha}_L$ が十分小さくなるスケジュールが必要である。

逆方向ノイズ除去過程

生成時には、純粋なノイズから出発する。

$$\boldsymbol{x}_L \sim p_{\text{prior}}$$

そして、$i = L, \ldots, 1$ について、

$$\boldsymbol{x}_{i-1} \sim p_\phi(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i)$$

と段階的にサンプリングする。

学習の目標

モデルの逆方向遷移 $p_\phi(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i)$ を、真の逆方向遷移 $p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i)$ へ近づける。

$$p_\phi(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i) \approx p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i)$$

図 2.5：逆方向過程の概略図



各ステップで現在の状態だけを使うため、逆方向過程もマルコフ連鎖としてモデル化される。

なぜ真の逆方向遷移は未知なのか

ベイズの定理より、形式的には

$$p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i) = \frac{p(\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1}) p_{i-1}(\boldsymbol{x}_{i-1})}{p_i(\boldsymbol{x}_i)}$$

と書ける。

- $p(\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1})$：固定したので既知
- $p_{i-1}(\boldsymbol{x}_{i-1})$：実データに依存する周辺分布
- $p_i(\boldsymbol{x}_i)$：実データに依存する周辺分布

$$p_i(\boldsymbol{x}_i) = \int p_i(\boldsymbol{x}_i \mid \boldsymbol{x}_0) p_{\text{data}}(\boldsymbol{x}_0)\, d\boldsymbol{x}_0$$

問題

p_{data} の密度は未知なので、これらの周辺分布を閉形式で評価できない。

直接考えた学習目的

未知の真の逆方向遷移をモデルで近似するため、次の期待 KL ダイバージェンスを考える。

$$\boxed{\mathbb{E}_{p_i(\boldsymbol{x}_i)}\left[D_{\mathrm{KL}}(p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i) \,\|\, p_\phi(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i))\right]} \tag{2.2.2}$$

目的

観測された $\boldsymbol{x}_i$ から、一段階前の $\boldsymbol{x}_{i-1}$ の分布を予測する。

そのままでは計算できない

KL の第 1 引数 $p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i)$ 自体が、未知の周辺分布を含む。

条件付けの工夫

学習時には、ノイズ付加の出発点 $\boldsymbol{x}_0$ を知っている。

計算困難

$$p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i)$$

あらゆる元データの可能性を平均した、複雑な混合分布になり得る。

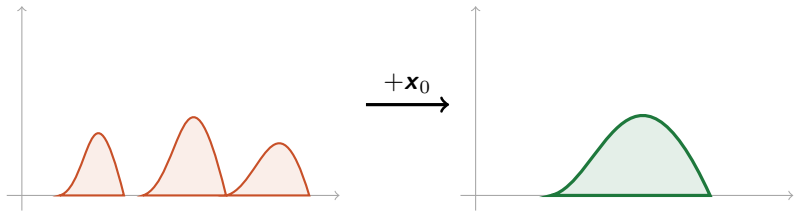
計算可能

$$p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i, \boldsymbol{x}_0)$$

元データを固定すると、平均と分散を解析的に求められるガウス分布になる。

未知の周辺逆遷移 $\Longrightarrow$ 既知のデータで条件付けた逆遷移

図2.6：条件付けによって単純になる



元データを条件へ加えることで、複雑な周辺分布を扱いやすい学習目標へ変換する。

なぜ条件付き分布は計算できるのか

順方向過程では、次の二つが既知のガウス分布である。

$$p(\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1}) \quad \text{と} \quad p_{i-1}(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_0)$$

ベイズの定理から、

$$p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i, \boldsymbol{x}_0) \propto p(\boldsymbol{x}_i \mid \boldsymbol{x}_{i-1}) p_{i-1}(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_0).$$

ガウス密度どうしの積は、正規化すると再びガウス分布になる。

$$p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i, \boldsymbol{x}_0) = \mathcal{N}\big(\boldsymbol{x}_{i-1}; \text{計算可能な平均}, \text{計算可能な共分散}\big)$$

結果

学習用に生成した $(\boldsymbol{x}_0, \boldsymbol{x}_i)$ から、一段階前の分布を解析的な教師として作れる。

条件付き分布と周辺分布の関係

一つの $\boldsymbol{x}_0$ へ条件付けた分布は、本来の周辺逆遷移と同じではない。

$$p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i) = \int p(\boldsymbol{x}_{i-1} \mid \boldsymbol{x}_i, \boldsymbol{x}_0) p(\boldsymbol{x}_0 \mid \boldsymbol{x}_i)\, d\boldsymbol{x}_0$$

- 各 $\boldsymbol{x}_0$ に条件付けた分布：単純なガウス分布
- それらを $p(\boldsymbol{x}_0 \mid \boldsymbol{x}_i)$ で平均：本来求めたい周辺逆遷移
- 多数の訓練例で条件付き目的を平均すると、周辺目的と同じ最適予測を学習できる

2.2 前半のまとめ

1. 順方向過程は、固定ガウス遷移でデータへノイズを加える

$$\boldsymbol{x}_i = \alpha_i \boldsymbol{x}_{i-1} + \beta_i \boldsymbol{\epsilon}_i$$

2. 任意の時点へ直接サンプリングできる

$$\boldsymbol{x}_i = \bar{\alpha}_i \boldsymbol{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\boldsymbol{\epsilon}$$

3. 真の逆方向遷移は、未知の周辺分布を含むため計算困難
4. 学習時に既知の $\boldsymbol{x}_0$ で条件付けると、計算可能なガウス分布になる

中心となる考え方

未知の分布を直接求める問題を、既知の元データで条件付けた回帰問題へ変換する。