The Principles of Diffusion Models

3.1 Energy-Based Models

渡邉 有志

November 11, 2026

第 2 章から第 3 章へ

これまでの見方

第 2 章では、VAE の枠組みを使って、データに少しずつノイズを加える過程を固定その逆のノイズを取り除く過程をどう学習するかを見てきた

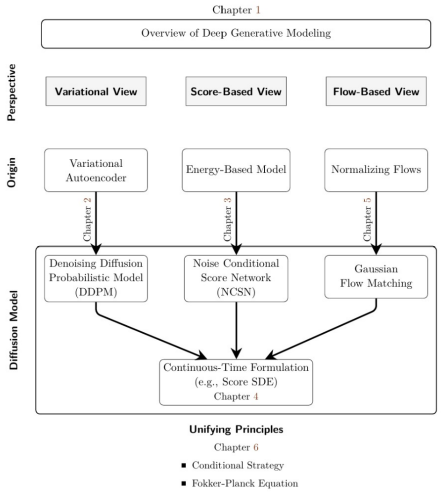
ここからの見方

同じく基礎的な第二の視点として、エネルギーベースモデル（EBM）からスコアへ進む。

- EBM は、データのある領域でエネルギーが低く、ない領域で高くなる関数で分布を表す
- サンプリングには、その勾配であるスコアを使う
- スコアがわかれば、正規化定数なしで生成できる

Ackley et al. (1985), LeCun et al. (2006)

三つの視点と第 3 章の位置



この章は中央の列である。EBM から NCSN へ進み、第 4 章の連続時間へつながる。

3.1 の位置づけ

この節の役割

拡散モデルをスコアの視点から読むための橋渡し

1. **3.1.1: スコアベースモデリングの基礎理解**
   エネルギー関数で分布を表す。最尤学習がなぜ難しいかを見る
2. **3.1.2:DSM(Diffusion Score Matching) からスコアへ**
   スコア関数を定義し、密度そのものではなくスコアを学ぶ理由を見る
3. **3.1.3:NCSN(Noise Conditional Score Network)**
   スコアマッチング
4. **3.1.4** ランジュバン動力学

今回は 3.1.4 までを扱う。

区切り：3.1.1 エネルギー関数によるモデル化

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

3.1.1 エネルギー関数で分布を表す

エネルギーベースモデル (EBM) は、エネルギー関数で分布を表すモデルである。

$$p_\phi(\boldsymbol{x}) := \frac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi}$$

エネルギー関数

$\boldsymbol{x} \in \mathbb{R}^D$ に対し、モデルがどのくらい「ありそう」かを表すスカラー値を返す関数

$$\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)$$

パラメータ ϕ のエネルギー関数 $E_\phi(\boldsymbol{x})$ は、確率が高い配置ほど低い値を割り当てる。

Z_ϕ は分配関数であり、$\int p_\phi(\boldsymbol{x})\, d\boldsymbol{x} = 1$ を保証する。

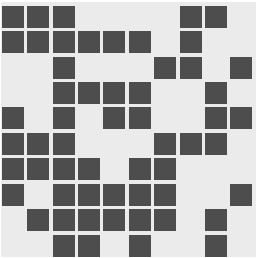
$$Z_\phi := \int_{\mathbb{R}^D} \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\, d\boldsymbol{x}$$

補足：よく現れる画像ほどエネルギーが低い

手書き数字で学習した EBM を考える。



自然な「3」：E_ϕ 低い　$\exp(-E_\phi)$ 高い



ランダム画素：E_ϕ 高い　$\exp(-E_\phi)$ 低い

読み方

よく現れる画像ほどエネルギーを下げ、現れにくい画像ほど上げる。だから $p_\phi(\boldsymbol{x}) \propto \exp(-E_\phi(\boldsymbol{x}))$ では、よく出る画像ほど確率が高くなる。

補足：エネルギーを確率密度へ変換する

エネルギーそのものは確率ではない

$E_\phi : \mathbb{R}^D \to \mathbb{R}$ を、$\exp(-E_\phi(\boldsymbol{x}))$ で正の量に変える。
エネルギーが 1 違うと、$\exp(-E)$ は e 倍になる。

エネルギー	$\exp(-E)$	相対的な密度
-1	$e \approx 2.72$	高い
0	1	中程度
1	$e^{-1} \approx 0.368$	低い

まだ正規化されていない

$\exp(-E_\phi(\boldsymbol{x}))$ の積分は一般に 1 ではない。分配関数 Z_ϕ で割って確率密度にする。

補足：分配関数が積分を 1 にする

$0 < Z_\phi < \infty$ を仮定する。

$$\begin{aligned}\int_{\mathbb{R}^D} p_\phi(\boldsymbol{x})\, d\boldsymbol{x} &= \int_{\mathbb{R}^D} \frac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi}\, d\boldsymbol{x} \\ &= \frac{1}{Z_\phi} \int_{\mathbb{R}^D} \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\, d\boldsymbol{x} \\ &= \frac{Z_\phi}{Z_\phi} = 1.\end{aligned}$$

役割

分配関数は、非正規化密度を積分が 1 の確率密度へ変換する。

図 3.1：学習で密度を上げ下げする

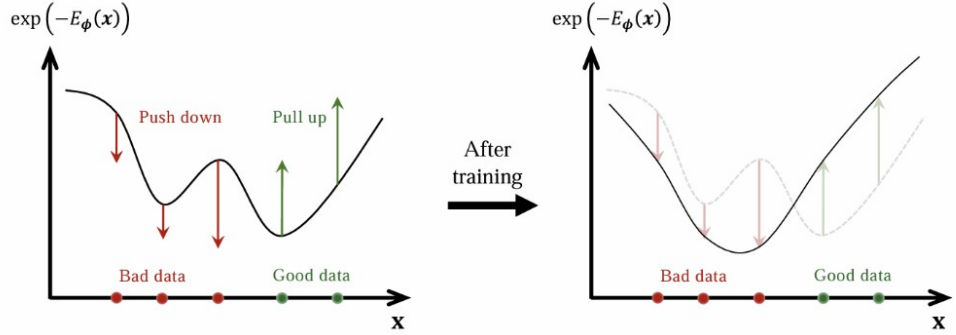


Figure 3.1: Illustration of EBM training. The model lowers density (raises energy) at "bad" data points (red arrows), and raises density (lowers energy) at "good" data points (green arrows).

Source: Created by the authors.

赤は密度を下げる方向、緑は上げる方向である。右の実線が学習後で、破線は学習前の曲線である。

補足：図 3.1 は学習前後の比較

学習前

- 赤の点にも高い密度
- 緑の点には密度が足りない

$\longrightarrow$ 学習

学習後

- 赤の近くの密度を**下げる**
- 緑の近くの密度を**上げる**

図の読み方

- 左図 $\rightarrow$ 右図が「学習前 $\rightarrow$ 学習後」
- 赤の矢印：密度を下げる（エネルギーを上げる）
- 緑の矢印：密度を上げる（エネルギーを下げる）
- 右図の破線は学習前、実線は学習後

重要なのはエネルギーの相対値

定数を加えても分布は変わらない

すべてのエネルギーに同じ定数を足しても、分子と分母が同じ倍率で変わり、確率分布は不変である。

- エネルギーの絶対値ではなく、点どうしの高低が意味をもつ
- ある領域のエネルギーを下げると、その領域の確率は増える
- 積分は 1 のままなので、補集合の確率は相対的に減る

全体的なトレードオフ

確率質量は領域ごとに独立には割り当てられない。空間全体で再分配される。

補足：定数シフトで分布が不変になる

和：エネルギーに定数を足す

$E'_\phi(\boldsymbol{x}) = E_\phi(\boldsymbol{x}) + c$ とする。

$$
\begin{aligned}
p'_\phi(\boldsymbol{x}) &= \frac{\exp\bigl(-(E_\phi(\boldsymbol{x}) + c)\bigr)}{Z'} \\
&= \frac{e^{-c}\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{e^{-c}Z_\phi} \\
&= p_\phi(\boldsymbol{x})
\end{aligned}
$$

積：重みに正定数をかける

$\tilde{p}'(\boldsymbol{x}) = a\,\tilde{p}(\boldsymbol{x})$（$a > 0$）とする。

$$
\begin{aligned}
p'(\boldsymbol{x}) &= \frac{a\,\tilde{p}(\boldsymbol{x})}{\int a\,\tilde{p}(\boldsymbol{u})\,d\boldsymbol{u}} \\
&= \frac{\tilde{p}(\boldsymbol{x})}{Z} = p(\boldsymbol{x})
\end{aligned}
$$

読み方

和はエネルギーの平行移動、積は非正規化密度の定数倍である。
どちらも分子と分母が同じだけ変わり、分布 p は不変である。
意味をもつのは絶対値ではなく、点どうしの相対関係である。

補足：エネルギーを下げた領域へ質量が移る

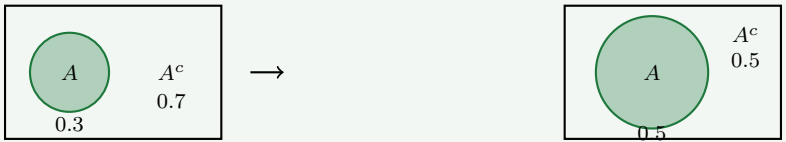
領域 A とその補集合 A^c について、$P_\phi(A) + P_\phi(A^c) = 1$ である。A のエネルギーだけを $\delta > 0$ だけ下げると、A の非正規化密度は e^δ 倍になる。

$$P'_\phi(A) = \frac{e^\delta P_\phi(A)}{e^\delta P_\phi(A) + P_\phi(A^c)}$$

$0 < P_\phi(A) < 1$ なら $P'_\phi(A) > P_\phi(A)$。

例

$P_\phi(A)$ が 0.3 から 0.5 に増えると、$P_\phi(A^c)$ は 0.7 から 0.5 へ減る。



前　　後

最尤学習の目的

原理上、EBM は最尤推定で学習できる。データへの適合と、分布全体の正規化が同時に現れる。

$$\mathcal{L}_{\mathrm{MLE}}(\phi) = \underbrace{-\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(\boldsymbol{x})]}_{\text{実データのエネルギーを下げる}} - \underbrace{\log Z_\phi}_{\text{大域的な正規化}} \tag{3.1.1}$$

二つの項

第 1 項は学習データのエネルギーを下げる。
第 2 項は、空間全体のエネルギーを無制限には下げさせない。
⇒最尤推定で見るのは、実データの重みが、全体の重みに対してどれだけ増えたか

補足：式（3.1.1）の導出

$$\mathcal{L}_{\mathrm{MLE}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}[\log p_\phi(\boldsymbol{x})]$$

に EBM の密度を代入する。

$$\log p_\phi(\boldsymbol{x}) = -E_\phi(\boldsymbol{x}) - \log Z_\phi,$$
$$\mathcal{L}_{\mathrm{MLE}}(\phi) = -\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(\boldsymbol{x})] - \log Z_\phi.$$

第 2 項の意味

ここでの正則化は重み減衰ではない。確率分布の正規化から出る項である。あらゆる場所のエネルギーを下げると Z_ϕ が大きくなり、$-\log Z_\phi$ は小さくなる。

補足：A と B だけで見る最尤の二つの項

候補は A, B の 2 点だけ、実データは A とする。重みは $w(\boldsymbol{x}) = \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)$、確率は $P(A) = \dfrac{w(A)}{w(A) + w(B)}$ である。

	$w(A)$	$w(B)$	$P(A)$
初期	1	1	$1/2$
A だけ下げる	2	1	$2/3$
両方上げる	2	2	$2/4 = 1/2$

A だけ下げる

A の重みは 2 倍だが、全体も $2 \to 3$ へ増える。
第 1 項の改善を第 2 項が一部打ち消しても、合計では $\frac{1}{2} \to \frac{2}{3}$ へ改善する。

両方を同じだけ

両方の重みを 2 にすると、$P(A)$ は $\frac{1}{2}$ のまま。
二つの変化は完全に打ち消し合う。

補足：いつも片方を犠牲にするわけではない

A のエネルギーを下げながら B のエネルギーを上げ、全体の重みも減るなら、二つの項はどちらも大きくなり得る。

読み方

いつも片方を改善するともう片方が悪化するわけではない。
データの適合（第 1 項）と正規化（第 2 項）は、状況によって同時に改善し得る。

見ているもの

最尤推定が見ているのは、実データの重みが全体の重みに対してどれだけ増えたかである。

最尤学習が難しい理由

$$\mathcal{L}_{\mathrm{MLE}}(\phi) = -\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(\boldsymbol{x})] - \log Z_\phi$$

高次元では $\log Z_\phi$ とその ϕ 勾配を、一般には計算できない。

$$\nabla_\phi \log Z_\phi = -\mathbb{E}_{p_\phi(\boldsymbol{x})}[\nabla_\phi E_\phi(\boldsymbol{x})]$$

必要な期待値が二つある

実データについての期待値は学習データから推定できる。モデル分布 p_ϕ についての期待値は、分布全体の積分または高コストなサンプリングを要する。

補足：$\log Z_\phi$ の勾配

微分と積分の交換（優収束定理／ Leibniz rule）のもとで、

$$\begin{aligned}\nabla_\phi \log Z_\phi &= \frac{1}{Z_\phi}\nabla_\phi \int \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\, d\boldsymbol{x} \\ &= \frac{1}{Z_\phi}\int -\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\nabla_\phi E_\phi(\boldsymbol{x})\, d\boldsymbol{x} \\ &= -\mathbb{E}_{p_\phi}[\nabla_\phi E_\phi(\boldsymbol{x})].\end{aligned}$$

最後の変形

$\dfrac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi} = p_\phi(\boldsymbol{x})$ なので、積分をモデル分布 p_ϕ の下での期待値と書ける。

補足：交換が許される条件

ϕ の近傍で $E_\theta(\boldsymbol{x})$ が θ について微分可能と仮定する。

十分条件（優収束）

近傍のすべての θ に対し、θ に依らない可積分な g があり

$$\left\|\nabla_\theta \exp\bigl(-E_\theta(\boldsymbol{x})\bigr)\right\| \le g(\boldsymbol{x}), \qquad \int g(\boldsymbol{x})\, d\boldsymbol{x} < \infty$$

とする。優収束の対象は、ϕ と $\phi + h$ を含む差分商である。

この条件が保証すること

$0 < Z_\phi < \infty$ を仮定する。上の条件のもとでは、差分商も同じ $g(\boldsymbol{x})$ で抑えられるため、優収束定理により微分と積分を交換できる。また、$\mathbb{E}_{p_\phi}[\|\nabla_\phi E_\phi(\boldsymbol{x})\|] < \infty$ も従う。

補足：最尤勾配は二つの期待値の差

$$\nabla_\phi \mathcal{L}_{\mathrm{MLE}}(\phi) = -\mathbb{E}_{p_{\mathrm{data}}}[\nabla_\phi E_\phi(\boldsymbol{x})] + \mathbb{E}_{p_\phi}[\nabla_\phi E_\phi(\boldsymbol{x})]$$

読み方

データ上ではエネルギーを下げる方向へ更新し、モデルが今確率を置いている場所ではエネルギーを上げる方向へ更新する。

回避の方向

コントラスティブ・ダイバージェンスは分配関数の項を近似する。スコアマッチングは、その項の計算自体を避ける。

3.1.1 のまとめ

- EBM は E_ϕ と分配関数 Z_ϕ で密度を定義する
- 意味をもつのはエネルギーの相対値であり、確率質量は空間全体で再分配される
- 最尤勾配にはモデル分布 p_ϕ についての期待値が必要で、高次元では計算が困難である

次

3.1.2 では、分配関数を含まないスコアを導入する。

区切り：3.1.2 スコア関数

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

3.1.2 スコアとは何か

$\mathbb{R}^D$ 上の確率密度 $p(\boldsymbol{x})$ に対し、スコアは対数密度の勾配である。

$$s(\boldsymbol{x}) := \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x})$$

$$s : \mathbb{R}^D \to \mathbb{R}^D$$

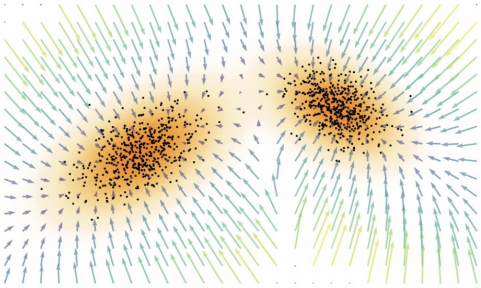


図 3.2：矢印はスコアで、近い山の中心を向く。

直感

スコアは、確率密度がより高い領域へ向かう方向を示すベクトル場である。密度の値そのものではなく、局所的にどちらへ進めば密度が増えるかを与える。

イメージで理解する：データ分布からスコアへ

データ点の分布から、密度の山とスコアの矢印がどう決まるかをイメージで確認できる。

インタラクティブな可視化

データの配置 → 密度の形 → スコアベクトル場、という流れを追いながら、「近い山の中心を向く」意味を掴める。

https://ebm-data-to-score.intactspoon4.chatgpt.site/space.html?dim=3

補足：スコアの成分と相対変化率

$$s(\boldsymbol{x}) = \begin{pmatrix} \partial_{x_1} \log p(\boldsymbol{x}) \\ \vdots \\ \partial_{x_D} \log p(\boldsymbol{x}) \end{pmatrix}$$

入力が D 次元なら、スコアも D 次元である。

$$\nabla_{\boldsymbol{x}} \log p(\boldsymbol{x}) = \frac{\nabla_{\boldsymbol{x}} p(\boldsymbol{x})}{p(\boldsymbol{x})}$$

定義される場所

スコアは密度の絶対的な変化量ではなく、その点の密度に対する相対的な変化率である。$p(\boldsymbol{x}) > 0$ で微分可能な領域で定義される。

補足：標準正規分布では中心を向く

$$p(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

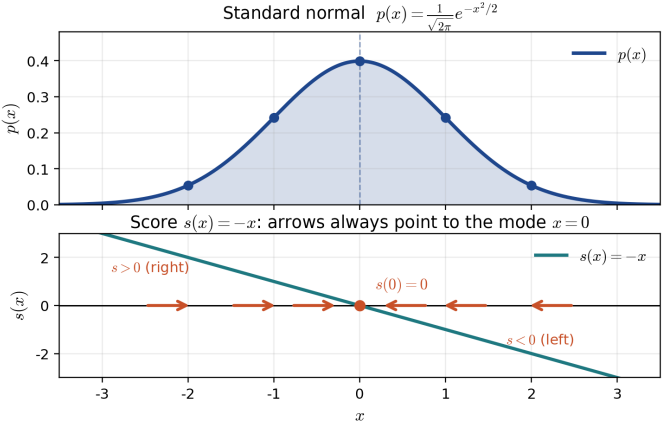
$$\log p(x) = -\frac{1}{2}\log(2\pi) - \frac{x^2}{2}$$

$$s(x) = -x$$

読み方

$x < 0 \Rightarrow s > 0$（右へ）
$x > 0 \Rightarrow s < 0$（左へ）
どちらも密度最大の 0 へ。

多峰なら局所的な増加方向で、大域最大とは限らない。



EBM のスコアから分配関数が消える

$$p_\phi(\boldsymbol{x}) = \frac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi}$$

の対数勾配は

$$s_\phi(\boldsymbol{x}) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x})$$

二つの微分を区別する

$\nabla_\phi \log Z_\phi$ は一般に計算が困難である。$\nabla_{\boldsymbol{x}} \log Z_\phi = 0$ であり、入力で微分すると分配関数は残らない。

エネルギーが下がる方向と、密度が増える方向は一致する。

補足：EBM のスコアの計算

$$
\begin{aligned}
s_\phi(\boldsymbol{x}) &= \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}) \\
&= \nabla_{\boldsymbol{x}} \left[-E_\phi(\boldsymbol{x}) - \log Z_\phi \right] \\
&= -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}).
\end{aligned}
$$

非正規化密度だけでも同じ

$\tilde{p}_\phi(\boldsymbol{x}) = \exp(-E_\phi(\boldsymbol{x}))$ とすると、

$$
\nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log \tilde{p}_\phi(\boldsymbol{x}).
$$

正規化定数を計算しなくても、正規化後の密度のスコアが正確に得られる。

補足：スコアの方向に進むだけでは不十分

ベクトル場の意味

二次元なら、各点で

$$s(\boldsymbol{x}) = \begin{pmatrix} \partial_{x_1} \log p(\boldsymbol{x}) \\ \partial_{x_2} \log p(\boldsymbol{x}) \end{pmatrix}$$

を返す。これは、その点で密度が最も急に増える方向である。

サンプリングとの違い

矢印に沿って進み続けるだけでは、分布全体からのサンプルにはならない。山の頂上へ吸い寄せられる。分布に従うサンプリングには、後のランジュバン動力学のように確率的なノイズも要る。

正規化定数に依存しない

多くの分布は非正規化密度 $\tilde{p}(\boldsymbol{x})$ で定義される。

$$p(\boldsymbol{x}) = \frac{\tilde{p}(\boldsymbol{x})}{Z}, \qquad Z = \int \tilde{p}(\boldsymbol{x})\, d\boldsymbol{x}$$

Z は $\boldsymbol{x}$ に依らないので、

$$\begin{aligned} \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x}) &= \nabla_{\boldsymbol{x}} \log \tilde{p}(\boldsymbol{x}) - \underbrace{\nabla_{\boldsymbol{x}} \log Z}_{=0} \\ &= \nabla_{\boldsymbol{x}} \log \tilde{p}(\boldsymbol{x}) \end{aligned} \tag{3.1.2}$$

利点

スコアを扱うことで、分配関数の計算を避けられる。未知のスコアをどう推定するかは、次のスコアマッチングの問題である。

スコアは分布を定数を除いて決める

スコアは対数密度の勾配なので、基準点 $\boldsymbol{x}_0$ からの積分で対数密度を復元できる。

$$\log p(\boldsymbol{x}) = \log p(\boldsymbol{x}_0) + \int_0^1 s(\boldsymbol{x}_0 + t(\boldsymbol{x} - \boldsymbol{x}_0))^\top (\boldsymbol{x} - \boldsymbol{x}_0)\, dt$$

同等の表現力

スコアが正確にわかれば、適切な条件のもとで確率密度 $p(\boldsymbol{x})$ も一意に決められる。
密度そのものをモデル化する方法と、スコアをモデル化する方法は、理論上同じ分布を表現できる。
学習とサンプリングでは、密度そのものより扱いやすいことが多い。

補足：基準点からの変化量を足す

前の式は、基準点 $\boldsymbol{x}_0$ での $\log p(\boldsymbol{x}_0)$ に、$\boldsymbol{x}_0$ から $\boldsymbol{x}$ までの変化量を足すと $\log p(\boldsymbol{x})$ が求まる、ことを表す。

$$s(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x})$$

経路上で $p > 0$ かつ微分可能とする。

直線経路

$$\boldsymbol{z}(t) = \boldsymbol{x}_0 + t(\boldsymbol{x} - \boldsymbol{x}_0) \qquad (t = 0 \Rightarrow \boldsymbol{x}_0,\ \ t = 1 \Rightarrow \boldsymbol{x})$$

知りたいのは、移動に伴う $\log p(\boldsymbol{z}(t))$ の変化である。

補足：積分の中身は $\log p$ の t 微分

合成関数の微分より

$$\frac{d}{dt}\log p(\boldsymbol{z}(t)) = \underbrace{s(\boldsymbol{z}(t))^\top}_{\text{その位置のスコア}} \underbrace{(\boldsymbol{x} - \boldsymbol{x}_0)}_{d\boldsymbol{z}/dt}$$

つまり、元の式の積分の中身は $\log p$ の t に関する微分である。

転置と内積

「その方向への変化のしやすさ $\times$ その方向への移動量」を座標ごとに計算し、足し合わせている。二次元なら

$$s(\boldsymbol{z})^\top(\boldsymbol{x} - \boldsymbol{x}_0) = s_1(\boldsymbol{z})(x_1 - x_{0,1}) + s_2(\boldsymbol{z})(x_2 - x_{0,2})$$

補足：微分を積分すると変化量が求まる

$t = 0$ から 1 まで積分する。

$$\begin{aligned}\int_0^1 s(\boldsymbol{z}(t))^\top (\boldsymbol{x} - \boldsymbol{x}_0)\, dt &= \int_0^1 \frac{d}{dt} \log p(\boldsymbol{z}(t))\, dt \\ &= \log p(\boldsymbol{x}) - \log p(\boldsymbol{x}_0)\end{aligned}$$

$\log p(\boldsymbol{x}_0)$ を移項すれば、本文の復元式になる。

要点

「微分を積分すると変化量が求まる」を、多変数の $\log p$ に使った式である。
スコアから求まるのはまず差 $\log p(\boldsymbol{x}) - \log p(\boldsymbol{x}_0)$ で、値そのものには基準の値も要る。

補足：積分定数は正規化で決まる

スコアは $\log p$ の微分なので、積分すると

$$\log p(\boldsymbol{x}) = F(\boldsymbol{x}) + C$$

となる。F はスコアを積分した関数、C は $\boldsymbol{x}$ に依らない定数（普通の不定積分の定数と同じ）。両辺の指数を取ると

$$p(\boldsymbol{x}) = e^{F(\boldsymbol{x})+C} = e^{C}\, e^{F(\boldsymbol{x})}$$

まだ決まっていないのは、密度全体に掛かる定数 e^{C} である。

補足：正規化で e^C を決める

正規化条件 $\int p(\boldsymbol{x})\, d\boldsymbol{x} = 1$ に代入する。

$$\int e^C\, e^{F(\boldsymbol{x})}\, d\boldsymbol{x} = 1$$

e^C は $\boldsymbol{x}$ に依らないので外に出せる。

$$e^C \int e^{F(\boldsymbol{x})}\, d\boldsymbol{x} = 1 \qquad \Rightarrow \qquad e^C = \frac{1}{\int e^{F(\boldsymbol{x})}\, d\boldsymbol{x}} = \left(\int e^{F(\boldsymbol{x})}\, d\boldsymbol{x} \right)^{-1}$$

したがって

$$p(\boldsymbol{x}) = \frac{e^{F(\boldsymbol{x})}}{\int e^{F(\boldsymbol{u})}\, d\boldsymbol{u}}$$

読み方

スコアの積分で得た e^F を、全体の積分値で割って積分が 1 になるようにしている。

補足：一意性と同等の表現力

一意性と同等の表現力

連結領域上で正の正規化可能密度があり、スコアが全域で正確なら p は一意に定まる。
密度そのものをモデル化する方法と、スコアをモデル化する方法は、理論上同じ分布を表せる（同等の表現力をもつ）。
ただし任意のベクトル場がスコアになるわけではなく、対数密度の勾配として積分可能である必要がある。

理論と計算

復元できることと、高次元で正規化積分を効率よく計算できることは別である。

3.1.2 のまとめ

- スコア $s(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x})$ は密度が増える方向を与える
- EBM のスコアは $s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ となり、分配関数 Z_ϕ を含まない
- スコアが正確なら、適切な条件のもとで p は一意に決まる（密度モデルと同等の表現力）

次

3.1.3 では、未知のデータ分布のスコアをどう学習するかを扱う。

区切り：3.1.3 スコアマッチング

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

3.1.3 スコアを合わせて EBM を学習する

モデルのスコアはエネルギーだけで書け、Z_ϕ に依らない。

$$\nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x})$$

スコアマッチングは、正規化密度を直接合わせる代わりに、
モデルのスコアをデータ分布のスコアへ近づける。

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \frac{1}{2}\mathbb{E}_{p_{\mathrm{data}}}\left[\|\nabla_{\boldsymbol{x}} \log p_\phi - \nabla_{\boldsymbol{x}} \log p_{\mathrm{data}}\|_2^2\right] \tag{3.1.3}$$

Hyvärinen and Dayan (2005)

データスコアを消した等価な損失

部分積分により、エネルギーとその導関数だけの形に書ける。

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}}\left[-\operatorname{Tr}\left(\nabla_{\boldsymbol{x}}^2 E_\phi(\boldsymbol{x})\right) + \tfrac{1}{2}\left\|\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x})\right\|_2^2\right] + C$$

C は ϕ に依らない。$\nabla_{\boldsymbol{x}}^2 E_\phi$ はヘッセ行列である。

利点と欠点

分配関数も、学習中のモデルからのサンプリングも要らない。代わりに二階微分、正確にはヘッセ行列のトレースが必要で、コストは入力次元 D とともに増える。

補足：合わせたい二つのスコア

モデルとデータ

$$s_\phi(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}), \qquad s_{\text{data}}(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p_{\text{data}}(\boldsymbol{x})$$

学習は $s_\phi(\boldsymbol{x}) \approx s_{\text{data}}(\boldsymbol{x})$ を目指す。

直接は使えない

p_{data} は未知なので、s_{data} も計算できない。損失から未知のスコアを消去する必要がある。

補足：二乗を三つの項に分ける

$$\|s_\phi - s_{\text{data}}\|_2^2 = \|s_\phi\|_2^2 - 2s_\phi^\top s_{\text{data}} + \|s_{\text{data}}\|_2^2$$

したがって

$$\mathcal{L}_{\text{SM}} = \frac{1}{2}\mathbb{E}[\|s_\phi\|_2^2] - \mathbb{E}[s_\phi^\top s_{\text{data}}] + C.$$

定数

$$C = \frac{1}{2}\mathbb{E}_{p_{\text{data}}}[\|s_{\text{data}}\|_2^2]$$

は ϕ に依らないので、最適化には影響しない。

補足：未知のスコアを密度の勾配に書き換える

$$\mathbb{E}[s_\phi^\top s_{\text{data}}] = \int p_{\text{data}}(\boldsymbol{x})\, s_\phi(\boldsymbol{x})^\top \nabla_{\boldsymbol{x}} \log p_{\text{data}}(\boldsymbol{x})\, d\boldsymbol{x}$$

$$\nabla_{\boldsymbol{x}} \log p_{\text{data}} = \frac{\nabla_{\boldsymbol{x}} p_{\text{data}}}{p_{\text{data}}}$$

を代入すると p_{data} が約分され、

$$\int s_\phi(\boldsymbol{x})^\top \nabla_{\boldsymbol{x}} p_{\text{data}}(\boldsymbol{x})\, d\boldsymbol{x}.$$

補足：部分積分で発散になる

境界項が消える正則性を仮定すると、

$$\int s_\phi^\top \nabla_{\boldsymbol{x}} p_{\text{data}}\, d\boldsymbol{x} = -\int p_{\text{data}}\, \nabla_{\boldsymbol{x}} \cdot s_\phi\, d\boldsymbol{x}.$$

発散は各成分の偏微分の和である。

$$\nabla_{\boldsymbol{x}} \cdot s_\phi(\boldsymbol{x}) = \sum_{i=1}^{D} \frac{\partial s_{\phi,i}(\boldsymbol{x})}{\partial x_i}$$

$$\mathbb{E}[s_\phi^\top s_{\text{data}}] = -\mathbb{E}[\nabla_{\boldsymbol{x}} \cdot s_\phi]$$

未知の s_{data} は、モデルのスコアの発散に置き換わる。

補足：エネルギーとヘッセ行列のトレース

発散の形に戻すと

$$\mathcal{L}_{\mathrm{SM}} = \mathbb{E}\left[\nabla_{\boldsymbol{x}} \cdot s_\phi + \frac{1}{2}\|s_\phi\|_2^2\right] + C.$$

$s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ より

$$\nabla_{\boldsymbol{x}} \cdot s_\phi = -\sum_{i=1}^{D} \frac{\partial^2 E_\phi}{\partial x_i^2} = -\operatorname{Tr}(\nabla_{\boldsymbol{x}}^2 E_\phi).$$

これが本文の損失である。必要なのはヘッセ行列の全成分ではなく、対角和だけである。

補足：ヘッセ行列とトレース

ヘッセ行列は、スカラー関数の二階偏微分を並べた行列である。二次元では

$$\nabla_{\boldsymbol{x}}^2 E_\phi = \begin{pmatrix} \partial_{x_1}^2 E_\phi & \partial_{x_1}\partial_{x_2} E_\phi \\ \partial_{x_2}\partial_{x_1} E_\phi & \partial_{x_2}^2 E_\phi \end{pmatrix}.$$

トレースは対角成分の和なので、

$$\mathrm{Tr}(\nabla_{\boldsymbol{x}}^2 E_\phi) = \partial_{x_1}^2 E_\phi + \partial_{x_2}^2 E_\phi.$$

計算上の課題

対角和だけでも、各座標の二階微分を集める必要がある。D が大きいほど厳密な計算は重くなる。本章の後半で、この二階微分を避ける方法を扱う。

補足：最尤推定とスコアマッチング

	最尤推定	スコアマッチング
学習目的	対数尤度を最大化	スコアを一致させる
分配関数	勾配に残る	不要
モデルからのサンプル	勾配の近似で要ることが多い	基本形では不要
主な困難	モデル分布の期待値	二階微分

共通点と違い

どちらもモデルをデータ分布へ近づける。スコアマッチングが比べるのは密度の値ではなく、各点での対数密度の勾配である。

3.1.3 のまとめ

- スコアマッチングは、密度ではなくスコアを一致させて EBM を学習する
- 部分積分により、未知の s_{data} はエネルギーとその二階微分に置き換わる
- 分配関数は不要だが、ヘッセ行列のトレースが必要になる

次

3.1.4 では、学習したスコアからサンプルを得るランジュバン動力学を扱う。

区切り：3.1.4 ランジュバン動力学

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

イメージで理解する：ランジュバン動力学

式に入る前に、空間上での動きのイメージを見ておくとわかりやすい。

インタラクティブな可視化

スコア（エネルギーの勾配）に沿った移動と、ノイズによるゆらぎが合わさる様子を確認できる。

https://ebm-space-motion.intactspoon4.chatgpt.site/

離散時間のランジュバン更新

EBM からのサンプリングは、ランジュバン動力学で行える。

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n - \eta \nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n \tag{3.1.4}$$

$\boldsymbol{x}_0$ は適当な分布、多くはガウス分布から引く。$\eta > 0$: ステップ幅、$\boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$
スコア $\nabla_{\boldsymbol{x}} \log p_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ で書き換えると、

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n + \eta \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n \tag{3.1.5}$$

連続時間では確率微分方程式になる

$\eta \to 0$ とすると、更新は次の SDE に収束する。

$$d\boldsymbol{x}(t) = \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}(t))\, dt + \sqrt{2}\, d\boldsymbol{w}(t) \tag{3.1.6}$$

$\boldsymbol{w}(t)$ は標準ブラウン運動である。式（3.1.4）は、この SDE のオイラー・丸山法による離散化である。

定常分布

E_ϕ が十分滑らかで、サンプルが無限遠へ逃げないとき、$t \to \infty$ で $\boldsymbol{x}(t)$ の分布は p_ϕ へ収束する。追加条件のもとでは、収束は指数的になり得る。

補足：更新則の三つの部分

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n - \eta \nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n$$

エネルギーを下げる項

$-\eta \nabla_{\boldsymbol{x}} E_\phi$ は、エネルギーが増える方向の逆へ進む。エネルギーが低い場所は密度が高いので、この項は密度が高い方向への勾配降下である。

ノイズ項

$\sqrt{2\eta}\, \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, 2\eta \boldsymbol{I})$。勾配だけでは局所的な極小に止まり得る。ノイズは他の領域を探索する余地を作るが、離れた峰のあいだを必ず効率よく越えられるわけではない。

補足：ノイズ係数が $\sqrt{2\eta}$ になる理由

連続時間の式を幅 η で離散化する。

$$\boldsymbol{x}(t+\eta) - \boldsymbol{x}(t) \approx \eta\, s_\phi(\boldsymbol{x}(t)) + \sqrt{2}\left(\boldsymbol{w}(t+\eta) - \boldsymbol{w}(t)\right)$$

ブラウン運動の増分は $\mathcal{N}(\mathbf{0}, \eta \boldsymbol{I})$ なので、

$$\boldsymbol{w}(t+\eta) - \boldsymbol{w}(t) \overset{d}{=} \sqrt{\eta}\, \boldsymbol{\epsilon}_n.$$

したがってノイズ項は $\sqrt{2}\sqrt{\eta}\, \boldsymbol{\epsilon}_n = \sqrt{2\eta}\, \boldsymbol{\epsilon}_n$。

別の係数

$\boldsymbol{x} + \frac{\eta}{2} s_\phi + \sqrt{\eta}\, \boldsymbol{\epsilon}$ もよく使う形である。違いは時間の尺度の取り方であり、同じ動力学の別表記である。

補足：ドリフトと拡散

$$d\boldsymbol{x}(t) = \underbrace{s_\phi(\boldsymbol{x}(t))\,dt}_{\text{ドリフト}} + \underbrace{\sqrt{2}\,d\boldsymbol{w}(t)}_{\text{拡散}}$$

二つの働き

ドリフトはスコアに従い、密度が高い方向へ動かす。拡散はブラウン運動によるランダムな揺れである。

通常の微分との違い

ブラウン運動の経路は、通常の意味ではほとんど確実に微分できない。$d\boldsymbol{w}(t)$ は普通の微小変化ではなく、確率積分で定義される。

図3.3：スコアに沿った確率的な軌跡

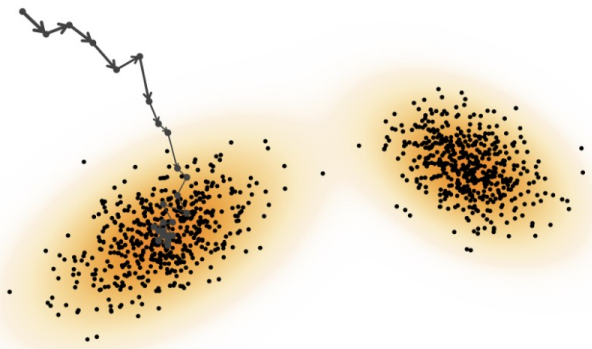


Figure 3.3: Illustration of Langevin sampling. Langevin sampling using the score function $\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x})$ to guide trajectories toward high-density regions via the update in Equation (3.1.5) (indicating by arrows).

Source: Created by the authors.

式（3.1.5）の更新で、軌跡は左の高密度領域へ入る。右の山へは移っていない。

補足：目標分布が定常分布になる

時刻 t の密度を q_t とすると、適切な条件で

$$\partial_t q_t = -\nabla_{\boldsymbol{x}} \cdot \left(q_t \nabla_{\boldsymbol{x}} \log p_\phi \right) + \Delta q_t.$$

$q_t = p_\phi$ を代入すると、$p_\phi \nabla_{\boldsymbol{x}} \log p_\phi = \nabla_{\boldsymbol{x}} p_\phi$ より

$$\partial_t q_t = -\Delta p_\phi + \Delta p_\phi = 0.$$

読み方と限界

p_ϕ は時間的に変化しない定常分布である。初期分布からの収束には、エルゴード性などの追加条件が要る。有限の η では離散化誤差があり、離散連鎖の定常分布は厳密には p_ϕ と一致しない。

なぜランジュバン動力学なのか

エネルギーの勾配だけに従う決定論的な運動は

$$d\boldsymbol{x}(t) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}(t))\, dt$$

であり、局所的な極小へ向かう。そこにノイズを加えると

$$d\boldsymbol{x}(t) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}(t))\, dt + \sqrt{2}\, d\boldsymbol{w}(t)$$

となる。適切な条件のもとで、定常分布は $p_\phi(\boldsymbol{x}) \propto e^{-E_\phi(\boldsymbol{x})}$ である。

EBM での使い道

分配関数を計算せず、エネルギーの勾配だけで p_ϕ からのサンプルを近似できる。

補足：勾配は力、ただし過減衰の運動

力は $F(\boldsymbol{x}) = -\nabla_{\boldsymbol{x}} E(\boldsymbol{x})$ である。$E(x) = \frac{1}{2}x^2$ なら $F(x) = -x$ で、粒子は原点へ向かう。

本文の ODE との違い

$d\boldsymbol{x} = -\nabla_{\boldsymbol{x}} E_\phi \, dt$ は、ニュートンの $m\ddot{\boldsymbol{x}} = F$ そのものではない。慣性を無視した、過減衰系の一次の運動である。

この流れに沿うと

$$\frac{d}{dt} E_\phi(\boldsymbol{x}(t)) = -\|\nabla_{\boldsymbol{x}} E_\phi\|_2^2 \le 0.$$

エネルギーは増えない。別の谷へ行くには、一時的にエネルギーを上げる必要があり、決定論だけでは足りない。

補足：$\sqrt{2}$ は定常性から決まる

一般の SDE $d\boldsymbol{x} = b\,dt + \sigma\,d\boldsymbol{w}$ の密度は

$$\partial_t \rho = -\nabla \cdot (b\rho) + \frac{\sigma^2}{2}\Delta\rho.$$

$b = \nabla_{\boldsymbol{x}} \log p_\phi$、$\rho = p_\phi$ とすると

$$\partial_t \rho = \left(\frac{\sigma^2}{2} - 1\right)\Delta p_\phi.$$

これが一般の分布で 0 になるには $\sigma = \sqrt{2}$。

脚注の意味

$\boldsymbol{x}(0) \sim p_\phi$ なら、任意の $t \geq 0$ で $\boldsymbol{x}(t) \sim p_\phi$ となり得る。これは定常性であり、任意の初期分布からの収束そのものではない。

補足：分配関数なしで更新できる

$$s_\phi(\boldsymbol{x}) = \nabla_{\boldsymbol{x}}\left[-E_\phi(\boldsymbol{x}) - \log Z_\phi\right] = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x})$$

なので更新に必要なのは、エネルギーの入力勾配とガウスノイズだけである。

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n - \eta \nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\,\boldsymbol{\epsilon}_n$$

注意

有限ステップの離散化には誤差がある。ステップ幅と更新回数が、近似の良さに影響する。

ランジュバン動力学と DDPM

ランジュバン動力学

一つの目標分布 p_ϕ に向けて、スコアとノイズで時間発展する。

DDPM

ノイズ量の異なる分布を順にたどり、強いノイズからデータ分布へ移る。

どちらもスコアを使って確率的に生成するが、更新則は同じではない。この違いは、後の NCSN を読むときに重要になる。

ランジュバンサンプリングの課題

混合が遅い

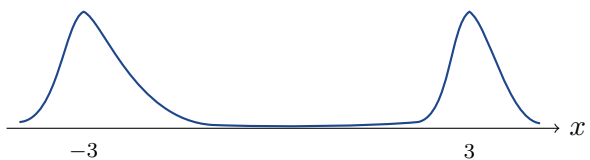
離れたモードが多い分布では、一つの高密度領域から別の領域へ移るのに長い時間がかかる。高次元で、モードのあいだが複雑に分かれていると、この遅れはさらに大きくなり得る。

- 効率はステップ幅、ノイズの大きさ、反復回数に依存する
- 更新は局所的なので、谷のあいだを効率よく渡れない
- 有限時間では、分布の多様性を取りこぼすことがある

補足：モード間は低密度を越えなければならない

モードは、密度が局所的に最大になる位置である。

$$p(x) = \frac{1}{2}\mathcal{N}(x; -3, 0.5^2) + \frac{1}{2}\mathcal{N}(x; 3, 0.5^2)$$



左の峰にいるサンプルは、スコアによって左へ戻されやすい。右へ行くには中央の低密度を越える必要があり、ノイズがそれを実現するまで多数の更新が要ることがある。

補足：混合時間

混合時間は、初期状態から定常分布へ十分近づくまでの時間または更新回数である。

$$t_{\mathrm{mix}}(\varepsilon) = \min\left\{n : \sup_{\boldsymbol{x}_0} \left\| P^n(\boldsymbol{x}_0, \cdot) - \pi \right\|_{\mathrm{TV}} \leq \varepsilon\right\}$$

$P^n(\boldsymbol{x}_0, \cdot)$ は n 回更新後の分布、π は定常分布、$\| \cdot \|_{\mathrm{TV}}$ は全変動距離である。

注意

有限のステップ幅では、π が厳密な p_ϕ と一致しないことがある。混合が遅いと、長く走らせても特定のモード付近に偏る。

補足：ステップ幅は精度と効率を同時に変える

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n + \eta\, s_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\,\boldsymbol{\epsilon}_n$$

小さくする

連続時間の SDE をより正確に近似しやすい。同じ時間を進めるには更新回数が増える。

大きくする

一回の移動は増えるが、離散化誤差と数値的な不安定さが増し得る。ノイズの共分散は $2\eta \boldsymbol{I}$ なので、揺れの大きさも一緒に変わる。

補足：高次元だけで必ず失敗するわけではない

難しくなる典型

高密度領域が離れており、そのあいだのエネルギー障壁が大きいとき、局所的なスコアとガウスノイズだけでは移動が遅い。

例外

十分滑らかな強対数凹分布では、ランジュバン動力学に良い収束保証が付く場合がある。問題になるのは、高次元性に加えて、複数の離れたモードや複雑な形状があるときである。

ノイズで滑らかにしてから戻す

複雑な p_{data} を直接探索するのは難しい。そこで複数のノイズレベルを考える。

$$\tilde{\boldsymbol{x}} = \boldsymbol{x} + \sigma\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$

- σ が大きいと、局所構造が平滑化され、モード間の低密度が埋まりやすくなる
- σ を下げながらサンプルすると、細かい構造を後から再現できる

次につながること

この考え方が、アニーリングされたランジュバン動力学と、Denoising Score Matching、NCSN の動機になる。

3.1.4 のまとめ

- ランジュバン動力学は、スコアによる移動とノイズで p_ϕ からサンプルする
- 連続時間では SDE になり、$\sqrt{2}$ のとき p_ϕ が定常分布になり得る
- 離れたモードでは混合が遅く、ノイズで平滑化した分布を段階的にたどる動機になる

3.1 全体のまとめ

1. **3.1.1 EBM** 分布をエネルギー E_ϕ で表す。最尤は $-\mathbb{E}_{p_{\text{data}}}[E_\phi] - \log Z_\phi$ だが、Z_ϕ が障害になる。
2. **3.1.2 スコア** $s = \nabla_{\boldsymbol{x}} \log p$ は密度が増える方向。EBM では $s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ となり Z_ϕ が消える。
3. **3.1.3 スコアマッチング**未知の s_{data} を直接使わず、エネルギーと二階微分だけで学習できる。
4. **3.1.4 ランジュバン**学習したスコアとノイズで p_ϕ からサンプルする。多峰では混合が遅く、ノイズ平滑化の動機につながる。

3.1 全体のまとめ：一本の流れ

今日の道筋

EBM で分布を書く $\rightarrow$ 最尤の Z_ϕ が難しい $\rightarrow$ スコアで Z_ϕ を避ける $\rightarrow$ スコアマッチングで学習する $\rightarrow$ ランジュバンで生成する

核心

密度そのものではなく、対数密度の勾配（スコア）を扱うことで、正規化定数なしに学習とサンプリングへ進める。

次へ

ノイズ条件付きのスコア学習（DSM / NCSN）と、連続時間の Score SDE へつながる。