# The Principles of Diffusion Models

## 3.1 Energy-Based Models

渡邉 有志

November 12, 2026

# 第 2 章から第 3 章へ

## これまでの見方

第 2 章では、VAE の枠組みを使って、データに少しずつノイズを加える過程を固定その逆のノイズを取り除く過程をどう学習するかを見てきた

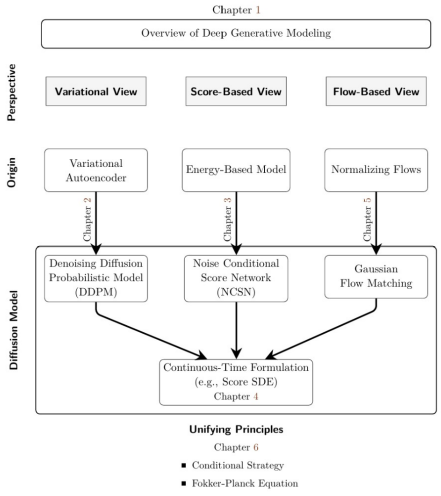
## ここからの見方

同じく基礎的な第二の視点として、エネルギーベースモデル（EBM）からスコアへ進む。

- EBM は、データのある領域でエネルギーが低く、ない領域で高くなる関数で分布を表す
- サンプリングには、その勾配であるスコアを使う
- スコアがわかれば、正規化定数なしで生成できる

Ackley et al. (1985), LeCun et al. (2006)

# 三つの視点と第 3 章の位置




この章は中央の列である。EBM から NCSN へ進み、第 4 章の連続時間へつながる。

# 3.1 の位置づけ

## この節の役割

拡散モデルをスコアの視点から読むための橋渡し

1. **3.1.1: スコアベースモデリングの基礎理解**
   エネルギー関数で分布を表す。最尤学習がなぜ難しいかを見る
2. **3.1.2:DSM(Diffusion Score Matching) からスコアへ**
   スコア関数を定義し、密度そのものではなくスコアを学ぶ理由を見る
3. **3.1.3:NCSN(Noise Conditional Score Network)**
   スコアマッチング
4. **3.1.4** ランジュバン動力学

今回は 3.1.4 までを扱う。

# 区切り：3.1.1 エネルギー関数によるモデル化

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

# 3.1.1 エネルギー関数で分布を表す

エネルギーベースモデル (EBM) は、エネルギー関数で分布を表すモデルである。

$$p_\phi(\boldsymbol{x}) := \frac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi}$$

## エネルギー関数

$\boldsymbol{x} \in \mathbb{R}^D$ に対し、モデルがどのくらい「ありそう」かを表すスカラー値を返す関数

$$\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)$$

パラメータ $\phi$ のエネルギー関数 $E_\phi(\boldsymbol{x})$ は、確率が高い配置ほど低い値を割り当てる。

$Z_\phi$ は分配関数であり、$\int p_\phi(\boldsymbol{x})\, d\boldsymbol{x} = 1$ を保証する。

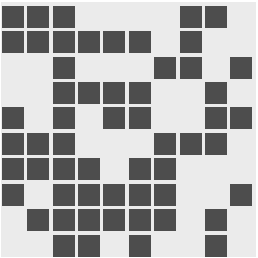
$$Z_\phi := \int_{\mathbb{R}^D} \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\, d\boldsymbol{x}$$

# 補足：よく現れる画像ほどエネルギーが低い

手書き数字で学習した EBM を考える。



自然な「3」：$E_\phi$ 低い　$\exp(-E_\phi)$ 高い



ランダム画素：$E_\phi$ 高い　$\exp(-E_\phi)$ 低い

## 読み方

よく現れる画像ほどエネルギーを下げ、現れにくい画像ほど上げる。だから $p_\phi(\boldsymbol{x}) \propto \exp(-E_\phi(\boldsymbol{x}))$ では、よく出る画像ほど確率が高くなる。

# 補足：エネルギーを確率密度へ変換する

## エネルギーそのものは確率ではない

$E_\phi : \mathbb{R}^D \to \mathbb{R}$ を、$\exp(-E_\phi(\boldsymbol{x}))$ で正の量に変える。
エネルギーが 1 違うと、$\exp(-E)$ は $e$ 倍になる。

| エネルギー | $\exp(-E)$ | 相対的な密度 |
|---|---|---|
| $-1$ | $e \approx 2.72$ | 高い |
| $0$ | $1$ | 中程度 |
| $1$ | $e^{-1} \approx 0.368$ | 低い |

## まだ正規化されていない

$\exp(-E_\phi(\boldsymbol{x}))$ の積分は一般に 1 ではない。分配関数 $Z_\phi$ で割って確率密度にする。

# 補足：分配関数が積分を 1 にする

$0 < Z_\phi < \infty$ を仮定する。

$$\begin{aligned}\int_{\mathbb{R}^D} p_\phi(\boldsymbol{x})\, d\boldsymbol{x} &= \int_{\mathbb{R}^D} \frac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi}\, d\boldsymbol{x} \\ &= \frac{1}{Z_\phi} \int_{\mathbb{R}^D} \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\, d\boldsymbol{x} \\ &= \frac{Z_\phi}{Z_\phi} = 1.\end{aligned}$$

**役割**

分配関数は、非正規化密度を積分が 1 の確率密度へ変換する。

# 図 3.1：学習で密度を上げ下げする

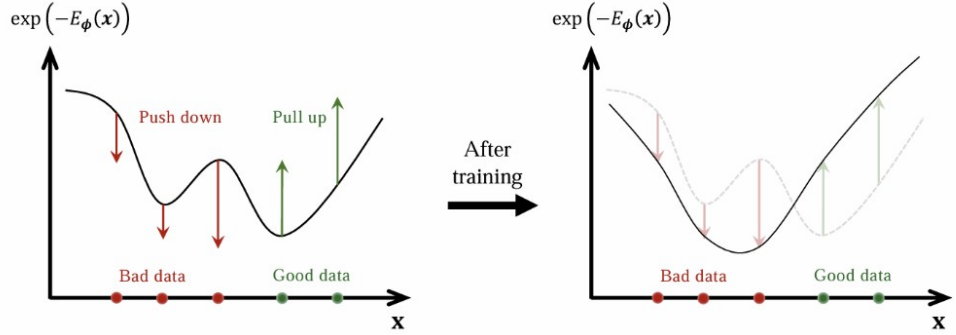



**Figure 3.1: Illustration of EBM training.** The model lowers density (raises energy) at "bad" data points (red arrows), and raises density (lowers energy) at "good" data points (green arrows).

*Source: Created by the authors.*

赤は密度を下げる方向、緑は上げる方向である。右の実線が学習後で、破線は学習前の曲線である。

# 補足：図 3.1 は学習前後の比較

**学習前**

- 赤の点にも高い密度
- 緑の点には密度が足りない

$\longrightarrow$ 学習

**学習後**

- 赤の近くの密度を**下げる**
- 緑の近くの密度を**上げる**

**図の読み方**

- 左図 $\rightarrow$ 右図が「学習前 $\rightarrow$ 学習後」
- 赤の矢印：密度を下げる（エネルギーを上げる）
- 緑の矢印：密度を上げる（エネルギーを下げる）
- 右図の破線は学習前、実線は学習後

# 重要なのはエネルギーの相対値

## 定数を加えても分布は変わらない

すべてのエネルギーに同じ定数を足しても、分子と分母が同じ倍率で変わり、確率分布は不変である。

- エネルギーの絶対値ではなく、点どうしの高低が意味をもつ
- ある領域のエネルギーを下げると、その領域の確率は増える
- 積分は 1 のままなので、補集合の確率は相対的に減る

## 全体的なトレードオフ

確率質量は領域ごとに独立には割り当てられない。空間全体で再分配される。

# 補足：定数シフトで分布が不変になる

## 和：エネルギーに定数を足す

$E'_\phi(\boldsymbol{x}) = E_\phi(\boldsymbol{x}) + c$ とする。

$$
\begin{aligned}
p'_\phi(\boldsymbol{x}) &= \frac{\exp\bigl(-(E_\phi(\boldsymbol{x}) + c)\bigr)}{Z'} \\
&= \frac{e^{-c}\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{e^{-c}Z_\phi} \\
&= p_\phi(\boldsymbol{x})
\end{aligned}
$$

## 積：重みに正定数をかける

$\tilde{p}'(\boldsymbol{x}) = a\,\tilde{p}(\boldsymbol{x})$（$a > 0$）とする。

$$
\begin{aligned}
p'(\boldsymbol{x}) &= \frac{a\,\tilde{p}(\boldsymbol{x})}{\int a\,\tilde{p}(\boldsymbol{u})\,d\boldsymbol{u}} \\
&= \frac{\tilde{p}(\boldsymbol{x})}{Z} = p(\boldsymbol{x})
\end{aligned}
$$

## 読み方

和はエネルギーの平行移動、積は非正規化密度の定数倍である。
どちらも分子と分母が同じだけ変わり、分布 $p$ は不変である。
意味をもつのは絶対値ではなく、点どうしの相対関係である。

# 補足：エネルギーを下げた領域へ質量が移る

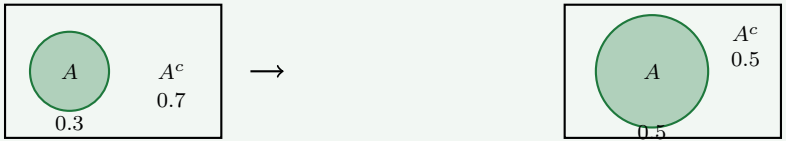
領域 $A$ とその補集合 $A^c$ について、$P_\phi(A) + P_\phi(A^c) = 1$ である。$A$ のエネルギーだけを $\delta > 0$ だけ下げると、$A$ の非正規化密度は $e^\delta$ 倍になる。

$$P'_\phi(A) = \frac{e^\delta P_\phi(A)}{e^\delta P_\phi(A) + P_\phi(A^c)}$$

$0 < P_\phi(A) < 1$ なら $P'_\phi(A) > P_\phi(A)$。

## 例

$P_\phi(A)$ が 0.3 から 0.5 に増えると、$P_\phi(A^c)$ は 0.7 から 0.5 へ減る。



# 最尤学習の目的

原理上、EBM は最尤推定で学習できる。データへの適合と、分布全体の正規化が同時に現れる。

$$\begin{aligned}\mathcal{L}_{\mathrm{MLE}}(\phi) &= \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}\left[\log \frac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi}\right] \\ &= \underbrace{-\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(\boldsymbol{x})]}_{\text{実データのエネルギーを下げる}} - \underbrace{\log Z_\phi}_{\text{大域的な正規化}}\end{aligned} \tag{3.1.1}$$

## 二つの項

第 1 項は学習データのエネルギーを下げる。
第 2 項は、空間全体のエネルギーを無制限には下げさせない。
⇒最尤推定で見るのは、実データの重みが、全体の重みに対してどれだけ増えたか

# 補足：式（3.1.1）の導出

最尤推定の定義は

$$\mathcal{L}_{\mathrm{MLE}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}(\boldsymbol{x})}[\log p_\phi(\boldsymbol{x})]$$

EBM の密度 $p_\phi(\boldsymbol{x}) = \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)/Z_\phi$ を代入すると

$$\mathcal{L}_{\mathrm{MLE}}(\phi) = -\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(\boldsymbol{x})] - \log Z_\phi$$

## 第 2 項の意味

ここでの正則化は重み減衰ではない。確率分布の正規化から出る項である。あらゆる場所のエネルギーを下げると $Z_\phi$ が大きくなり、$-\log Z_\phi$ は小さくなる。

# 補足：A と B だけで見る最尤の二つの項

候補は $A, B$ の 2 点だけ、実データは $A$ とする。重みは $w(\boldsymbol{x}) = \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)$、確率は $P(A) = \dfrac{w(A)}{w(A) + w(B)}$ である。

| | $w(A)$ | $w(B)$ | $P(A)$ |
|---|---|---|---|
| 初期 | 1 | 1 | $1/2$ |
| $A$ だけ下げる | 2 | 1 | $2/3$ |
| 両方上げる | 2 | 2 | $2/4 = 1/2$ |

## $A$ だけ下げる

$A$ の重みは 2 倍だが、全体も $2 \to 3$ へ増える。
第 1 項の改善を第 2 項が一部打ち消しても、合計では $\frac{1}{2} \to \frac{2}{3}$ へ改善する。

## 両方を同じだけ

両方の重みを 2 にすると、$P(A)$ は $\frac{1}{2}$ のまま。
二つの変化は完全に打ち消し合う。

# 補足：いつも片方を犠牲にするわけではない

$A$ のエネルギーを下げながら $B$ のエネルギーを上げ、全体の重みも減るなら、二つの項はどちらも大きくなり得る。

## 読み方

いつも片方を改善するともう片方が悪化するわけではない。
データの適合（第 1 項）と正規化（第 2 項）は、状況によって同時に改善し得る。

## 見ているもの

最尤推定が見ているのは、実データの重みが全体の重みに対してどれだけ増えたかである。

# 最尤学習が難しい理由

$$\mathcal{L}_{\mathrm{MLE}}(\phi) = -\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(\boldsymbol{x})] - \log Z_\phi \tag{3.1.1}$$

高次元では $\log Z_\phi$ とその $\phi$ 勾配を、一般には計算できない。

$$\nabla_\phi \log Z_\phi = -\mathbb{E}_{p_\phi(\boldsymbol{x})}[\nabla_\phi E_\phi(\boldsymbol{x})]$$

## 必要な期待値が二つある

実データについての期待値は学習データから推定できる。モデル分布 $p_\phi$ についての期待値は、分布全体の積分または高コストなサンプリングを要する。

# 補足：最尤勾配は二つの期待値の差

$$\nabla_\phi \mathcal{L}_{\mathrm{MLE}}(\phi) = -\mathbb{E}_{p_{\mathrm{data}}}[\nabla_\phi E_\phi(\boldsymbol{x})] + \mathbb{E}_{p_\phi}[\nabla_\phi E_\phi(\boldsymbol{x})]$$

## 読み方

データ上ではエネルギーを下げる方向へ更新し、モデルが今確率を置いている場所ではエネルギーを上げる方向へ更新する。

## 回避の方向

コントラスティブ・ダイバージェンスは分配関数の項を近似する。スコアマッチングは、その項の計算自体を避ける。

# 補足：$\log Z_\phi$ の勾配

微分と積分の交換（優収束定理／ Leibniz rule）のもとで、

$$\begin{aligned}\nabla_\phi \log Z_\phi &= \frac{1}{Z_\phi}\nabla_\phi \int \exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\, d\boldsymbol{x} \\ &= \frac{1}{Z_\phi}\int -\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)\nabla_\phi E_\phi(\boldsymbol{x})\, d\boldsymbol{x} \\ &= -\mathbb{E}_{p_\phi}[\nabla_\phi E_\phi(\boldsymbol{x})].\end{aligned}$$

**最後の変形**

$\dfrac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi} = p_\phi(\boldsymbol{x})$ なので、積分をモデル分布 $p_\phi$ の下での期待値と書ける。

# 補足：交換が許される条件

$\phi$ の近傍で $E_\theta(\boldsymbol{x})$ が $\theta$ について微分可能と仮定する。

## 十分条件（優収束）

近傍のすべての $\theta$ に対し、$\theta$ に依らない可積分な $g$ があり

$$\left\|\nabla_\theta \exp\bigl(-E_\theta(\boldsymbol{x})\bigr)\right\| \le g(\boldsymbol{x}), \qquad \int g(\boldsymbol{x})\, d\boldsymbol{x} < \infty$$

とする。優収束の対象は、$\phi$ と $\phi + h$ を含む差分商である。

## この条件が保証すること

$0 < Z_\phi < \infty$ を仮定する。上の条件のもとでは、差分商も同じ $g(\boldsymbol{x})$ で抑えられるため、優収束定理により微分と積分を交換できる。また、$\mathbb{E}_{p_\phi}[\|\nabla_\phi E_\phi(\boldsymbol{x})\|] < \infty$ も従う。

# 3.1.1 のまとめ

- EBM は $E_\phi$ と分配関数 $Z_\phi$ で密度を定義する
- 意味をもつのはエネルギーの相対値であり、確率質量は空間全体で再分配される
- 最尤勾配にはモデル分布 $p_\phi$ についての期待値が必要で、高次元では計算が困難である

**次**

3.1.2 では、分配関数を含まないスコアを導入する。

# 区切り：3.1.2 スコア関数

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

# 3.1.2 スコアとは何か

$\mathbb{R}^D$ 上の確率密度 $p(\boldsymbol{x})$ に対し、スコアは対数密度の勾配である。

$$s(\boldsymbol{x}) := \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x})$$

$$s : \mathbb{R}^D \to \mathbb{R}^D$$

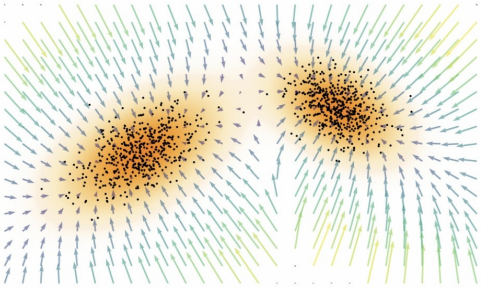


図 3.2：矢印はスコアで、近い山の中心を向く。

**直感**

スコアは、確率密度がより高い領域へ向かう方向を示すベクトル場である。密度の値そのものではなく、局所的にどちらへ進めば密度が増えるかを与える。

# イメージで理解する：データ分布からスコアへ

データ点の分布から、密度の山とスコアの矢印がどう決まるかをイメージで確認できる。

## インタラクティブな可視化

データの配置 → 密度の形 → スコアベクトル場、という流れを追いながら、「近い山の中心を向く」意味を掴める。

https://ebm-data-to-score.intactspoon4.chatgpt.site/space.html?dim=3

# 補足：スコアの成分と相対変化率

$$s(\boldsymbol{x}) = \begin{pmatrix} \partial_{x_1} \log p(\boldsymbol{x}) \\ \vdots \\ \partial_{x_D} \log p(\boldsymbol{x}) \end{pmatrix}$$

入力が $D$ 次元なら、スコアも $D$ 次元である。

$$\nabla_{\boldsymbol{x}} \log p(\boldsymbol{x}) = \frac{\nabla_{\boldsymbol{x}} p(\boldsymbol{x})}{p(\boldsymbol{x})}$$

## 定義される場所

スコアは密度の絶対的な変化量ではなく、その点の密度に対する相対的な変化率である。$p(\boldsymbol{x}) > 0$ で微分可能な領域で定義される。

# 補足：標準正規分布では中心を向く

$$p(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

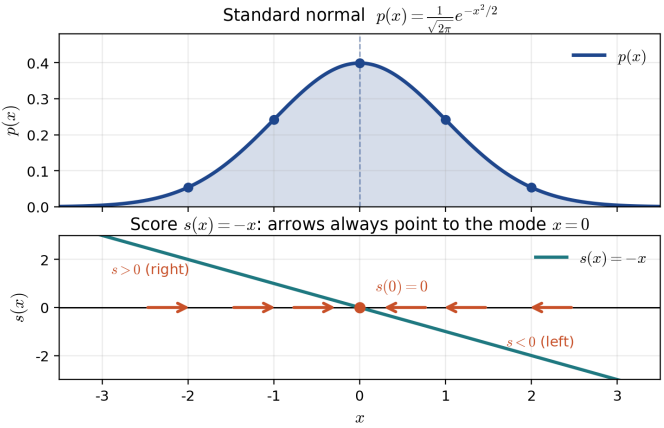
$$\log p(x) = -\frac{1}{2}\log(2\pi) - \frac{x^2}{2}$$

$$s(x) = -x$$

## 読み方

$x < 0 \Rightarrow s > 0$（右へ）
$x > 0 \Rightarrow s < 0$（左へ）
どちらも密度最大の 0 へ。

多峰なら局所的な増加方向で、大域最大とは限らない。



# EBM のスコアから分配関数が消える

$$p_\phi(\boldsymbol{x}) = \frac{\exp\bigl(-E_\phi(\boldsymbol{x})\bigr)}{Z_\phi}$$

の対数勾配は

$$s_\phi(\boldsymbol{x}) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x})$$

## 二つの微分を区別する

$\nabla_\phi \log Z_\phi$ は一般に計算が困難である。$\nabla_{\boldsymbol{x}} \log Z_\phi = 0$ であり、入力で微分すると分配関数は残らない。

エネルギーが下がる方向と、密度が増える方向は一致する。

# 補足：EBM のスコアの計算

$$
\begin{aligned}
s_\phi(\boldsymbol{x}) &= \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}) \\
&= \nabla_{\boldsymbol{x}} \left[ -E_\phi(\boldsymbol{x}) - \log Z_\phi \right] \\
&= -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}).
\end{aligned}
$$

## 非正規化密度だけでも同じ

$\tilde{p}_\phi(\boldsymbol{x}) = \exp(-E_\phi(\boldsymbol{x}))$ とすると、

$$
\nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log \tilde{p}_\phi(\boldsymbol{x}).
$$

正規化定数を計算しなくても、正規化後の密度のスコアが正確に得られる。

# 補足：スコアの方向に進むだけでは不十分

## ベクトル場の意味

二次元なら、各点で

$$s(\boldsymbol{x}) = \begin{pmatrix} \partial_{x_1} \log p(\boldsymbol{x}) \\ \partial_{x_2} \log p(\boldsymbol{x}) \end{pmatrix}$$

を返す。これは、その点で密度が最も急に増える方向である。

## サンプリングとの違い

矢印に沿って進み続けるだけでは、分布全体からのサンプルにはならない。山の頂上へ吸い寄せられる。分布に従うサンプリングには、後のランジュバン動力学のように確率的なノイズも要る。

# 正規化定数に依存しない

多くの分布は非正規化密度 $\tilde{p}(\boldsymbol{x})$ で定義される。

$$p(\boldsymbol{x}) = \frac{\tilde{p}(\boldsymbol{x})}{Z}, \qquad Z = \int \tilde{p}(\boldsymbol{x})\, d\boldsymbol{x}$$

$Z$ は $\boldsymbol{x}$ に依らないので、

$$\begin{aligned} \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x}) &= \nabla_{\boldsymbol{x}} \log \tilde{p}(\boldsymbol{x}) - \underbrace{\nabla_{\boldsymbol{x}} \log Z}_{=0} \\ &= \nabla_{\boldsymbol{x}} \log \tilde{p}(\boldsymbol{x}) \end{aligned} \tag{3.1.2}$$

**利点**

スコアを扱うことで、分配関数の計算を避けられる。未知のスコアをどう推定するかは、次のスコアマッチングの問題である。

# スコアは分布を定数を除いて決める

スコアは対数密度の勾配なので、基準点 $\boldsymbol{x}_0$ からの積分で対数密度を復元できる。

$$\log p(\boldsymbol{x}) = \log p(\boldsymbol{x}_0) + \int_0^1 s(\boldsymbol{x}_0 + t(\boldsymbol{x} - \boldsymbol{x}_0))^\top (\boldsymbol{x} - \boldsymbol{x}_0)\, dt$$

**ここでの意味**

確率密度 $p(\boldsymbol{x})$ を直接求めなくてもよい。各点での対数密度の勾配（スコア）を学べば、元の分布を表せ、その分布からサンプルを生成するのにも使える。

⇒密度の値は要らず、次の更新方向が分かるので、DDPM のノイズ予測や画像生成の各ステップで応用される。

# 補足：基準点からの変化量を足す

前の式は、基準点 $\boldsymbol{x}_0$ での $\log p(\boldsymbol{x}_0)$ に、$\boldsymbol{x}_0$ から $\boldsymbol{x}$ までの変化量を足すと $\log p(\boldsymbol{x})$ が求まる、ことを表す。

$$s(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x})$$

経路上で $p > 0$ かつ微分可能とする。

## 直線経路

$$\boldsymbol{z}(t) = \boldsymbol{x}_0 + t(\boldsymbol{x} - \boldsymbol{x}_0) \qquad (t = 0 \Rightarrow \boldsymbol{x}_0,\ \ t = 1 \Rightarrow \boldsymbol{x})$$

知りたいのは、移動に伴う $\log p(\boldsymbol{z}(t))$ の変化である。

# 補足：積分の中身は $\log p$ の $t$ 微分

合成関数の微分より

$$\frac{d}{dt}\log p(\boldsymbol{z}(t)) = \underbrace{s(\boldsymbol{z}(t))^\top}_{\text{その位置のスコア}} \underbrace{(\boldsymbol{x}-\boldsymbol{x}_0)}_{d\boldsymbol{z}/dt}$$

つまり、元の式の積分の中身は $\log p$ の $t$ に関する微分である。

## 転置と内積

「その方向への変化のしやすさ $\times$ その方向への移動量」を座標ごとに計算し、足し合わせている。二次元なら

$$s(\boldsymbol{z})^\top(\boldsymbol{x}-\boldsymbol{x}_0) = s_1(\boldsymbol{z})(x_1-x_{0,1}) + s_2(\boldsymbol{z})(x_2-x_{0,2})$$

# 補足：微分を積分すると変化量が求まる

$t = 0$ から 1 まで積分する。

$$\begin{aligned}\int_0^1 s(\boldsymbol{z}(t))^\top (\boldsymbol{x} - \boldsymbol{x}_0)\, dt &= \int_0^1 \frac{d}{dt} \log p(\boldsymbol{z}(t))\, dt \\ &= \log p(\boldsymbol{x}) - \log p(\boldsymbol{x}_0)\end{aligned}$$

$\log p(\boldsymbol{x}_0)$ を移項すれば、本文の復元式になる。

**要点**

「微分を積分すると変化量が求まる」を、多変数の $\log p$ に使った式である。
スコアから求まるのはまず差 $\log p(\boldsymbol{x}) - \log p(\boldsymbol{x}_0)$ で、値そのものには基準の値も要る。

# 補足：積分定数は正規化で決まる

スコアは $\log p$ の微分なので、積分すると

$$\log p(\boldsymbol{x}) = F(\boldsymbol{x}) + C$$

となる。$F$ はスコアを積分した関数、$C$ は $\boldsymbol{x}$ に依らない定数（普通の不定積分の定数と同じ）。両辺の指数を取ると

$$p(\boldsymbol{x}) = e^{F(\boldsymbol{x})+C} = e^{C}\, e^{F(\boldsymbol{x})}$$

まだ決まっていないのは、密度全体に掛かる定数 $e^{C}$ である。

# 補足：正規化で $e^C$ を決める

正規化条件 $\int p(\boldsymbol{x})\, d\boldsymbol{x} = 1$ に代入する。

$$\int e^C\, e^{F(\boldsymbol{x})}\, d\boldsymbol{x} = 1$$

$e^C$ は $\boldsymbol{x}$ に依らないので外に出せる。

$$e^C \int e^{F(\boldsymbol{x})}\, d\boldsymbol{x} = 1 \qquad \Rightarrow \qquad e^C = \frac{1}{\int e^{F(\boldsymbol{x})}\, d\boldsymbol{x}} = \left( \int e^{F(\boldsymbol{x})}\, d\boldsymbol{x} \right)^{-1}$$

したがって

$$p(\boldsymbol{x}) = \frac{e^{F(\boldsymbol{x})}}{\int e^{F(\boldsymbol{u})}\, d\boldsymbol{u}}$$

## 読み方

スコアの積分で得た $e^F$ を、全体の積分値で割って積分が 1 になるようにしている。

# 補足：一意性と同等の表現力

## 読み方

$p(\boldsymbol{x})$ を直接求めなくても、各点のスコアがわかれば元の分布を表せる。そのスコアは、あとでランジュバン動力学によりサンプル生成にも使える。

## 条件つきの一意性

連結領域上で正の正規化可能密度があり、スコアが全域で正確なら $p$ は一意に定まる。ただし任意のベクトル場がスコアになるわけではなく、対数密度の勾配として積分可能である必要がある。

# 3.1.2 のまとめ

- スコア $s(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p(\boldsymbol{x})$ は密度が増える方向を与える
- EBM のスコアは $s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ となり、分配関数 $Z_\phi$ を含まない
- $p$ を直接求めなくても、スコアを学べば分布を表せ、サンプリングにも使える

## 次

3.1.3 では、未知のデータ分布のスコアをどう学習するかを扱う。

# 区切り：3.1.3 スコアマッチング

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

# 3.1.3 スコアマッチングで何を消すか

「モデルとデータのスコアを一致させる」学習目標を、実際のデータとエネルギー関数だけで計算できる形に変える。

**中心的な結果**

正規化定数 $Z_\phi$ だけでなく、未知のデータスコア $\nabla_{\boldsymbol{x}} \log p_{\text{data}}$ も学習計算から取り除ける。

Hyvärinen and Dayan (2005)

# モデルのスコアから $Z_\phi$ が消える

EBM では $p_\phi(\boldsymbol{x}) = \exp(-E_\phi(\boldsymbol{x}))/Z_\phi$ なので

$$\log p_\phi(\boldsymbol{x}) = -E_\phi(\boldsymbol{x}) - \log Z_\phi.$$

**入力 $\boldsymbol{x}$** について微分すると

$$\nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}) - \underbrace{\nabla_{\boldsymbol{x}} \log Z_\phi}_{=0} = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}).$$

**注意：微分する変数が違う**

最尤では $\nabla_\phi \log Z_\phi$（パラメータ微分）が残った。
ここでは $\nabla_{\boldsymbol{x}} \log Z_\phi$（入力微分）なので消える。

# スコアを合わせる損失

$$s_\phi(\boldsymbol{x}) := \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}), \qquad s_{\text{data}}(\boldsymbol{x}) := \nabla_{\boldsymbol{x}} \log p_{\text{data}}(\boldsymbol{x})$$

$$\mathcal{L}_{\text{SM}}(\phi) = \frac{1}{2}\mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}}\left[\|s_\phi(\boldsymbol{x}) - s_{\text{data}}(\boldsymbol{x})\|_2^2\right] \tag{3.1.3}$$

## 意味

各位置で、対数密度の各方向への変化をモデルとデータで一致させる。
期待値は $p_{\text{data}}$ なので、データが出やすい位置ほど重みが大きい。
$\frac{1}{2}$ は微分の係数を簡単にするためのもので、最小化の $\phi$ は変わらない。

# 補足：ノルムの二乗と、未知の $s_{\text{data}}$

$$\|s_\phi - s_{\text{data}}\|_2^2 = \sum_{j=1}^{D} \big(s_{\phi,j} - s_{\text{data},j}\big)^2$$

適切な条件のもとではスコア一致 $\Rightarrow$ 正規化密度も一致する。

**問題**

手元にあるのは観測値だけで、真の $p_{\text{data}}$ もそのスコアも通常はわからない。
そこで、損失から未知の $s_{\text{data}}$ を消す式変形が必要になる。

# 補足：一次元で二乗を展開する

仕組みを見やすくするため一次元とし、$p := p_{\text{data}}$、$s := s_\phi$ と書く。

$$\mathcal{L}_{\text{SM}} = \frac{1}{2} \int p(x) \Big( s(x) - \tfrac{d}{dx} \log p(x) \Big)^2 dx$$

展開すると

$$\mathcal{L}_{\text{SM}} = \tfrac{1}{2} \int p\, s^2\, dx - \int p\, s\, \tfrac{d}{dx} \log p\, dx + \tfrac{1}{2} \int p \Big( \tfrac{d}{dx} \log p \Big)^2 dx.$$

最後の項はデータ分布だけで決まり $\phi$ に依らない。これを $C$ とおく。

**注意**

ここでの $C$ は、前に扱った積分定数とは別である。
損失を展開した結果として出た、学習パラメータに依らない項である。

# 補足：真ん中の項で $p$ が約分される

残る問題は

$$-\int p(x)\, s(x)\, \frac{d}{dx} \log p(x)\, dx.$$

$\dfrac{d}{dx} \log p = \dfrac{p'}{p}$ を代入すると $p$ が約分され、

$$-\int s(x)\, p'(x)\, dx$$

になる。

# 補足：部分積分で微分をモデル側へ移す

部分積分 $\int uv' = [uv] - \int u'v$ で $u = s$、$v = p$ とすると

$$-\int s\,p' = -[s\,p]_{-\infty}^{\infty} + \int s'\,p.$$

両端で $s(x)p(x) \to 0$ と仮定すれば境界項が消え、

$$-\int p\,s\,\frac{d}{dx}\log p\,dx = \int p\,s'\,dx.$$

**要点**

データ密度 $p$ に掛かっていた微分を、モデルのスコア $s$ に移した。

# 補足：一次元での等価な損失

元の式に戻すと

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}}\left[\frac{1}{2}s_\phi(x)^2 + s'_\phi(x)\right] + C.$$

未知のデータスコアが期待値の中から消えた。次で、同じ変形を各座標へ広げる。

# 補足：多次元では座標ごとの和になる

多次元では

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \tfrac{1}{2}\mathbb{E}_{p_{\mathrm{data}}}\left[\|s_\phi(\boldsymbol{x}) - s_{\mathrm{data}}(\boldsymbol{x})\|_2^2\right]$$

である。$\|v\|_2^2 = \sum_{j=1}^{D} v_j^2$ なので、展開すると

$$\mathcal{L}_{\mathrm{SM}} = \tfrac{1}{2}\mathbb{E}[\|s_\phi\|_2^2] - \mathbb{E}\left[s_\phi^\top s_{\mathrm{data}}\right] + C.$$

真ん中の項は座標ごとの和である。

$$s_\phi^\top s_{\mathrm{data}} = \sum_{j=1}^{D} s_{\phi,j}(\boldsymbol{x})\, \partial_{x_j} \log p(\boldsymbol{x})$$

## 読み方

一次元で扱った交差項が、各座標 $j$ について一つずつ現れる。

# 補足：各座標で同じ部分積分を行う

第 $j$ 成分だけ取り出すと、一次元と同じく

$$\int p\, s_{\phi,j}\, \partial_{x_j} \log p \, d\boldsymbol{x} = \int s_{\phi,j}\, \partial_{x_j} p \, d\boldsymbol{x}.$$

$x_j$ について部分積分し、境界で $s_{\phi,j} p \to 0$ とすると

$$\int s_{\phi,j}\, \partial_{x_j} p \, d\boldsymbol{x} = -\int p\, \partial_{x_j} s_{\phi,j} \, d\boldsymbol{x}.$$

したがって交差項は

$$-\mathbb{E}\big[s_\phi^\top s_{\mathrm{data}}\big] = \mathbb{E}\Big[\sum_{j=1}^{D} \partial_{x_j} s_{\phi,j}\Big] = \mathbb{E}\big[\mathrm{Tr}(\nabla_{\boldsymbol{x}} s_\phi)\big].$$

**要点**

$\sum_j \partial_{x_j} s_{\phi,j}$ がヤコビ行列の対角和、すなわちトレースである。

# 多次元・EBM での等価な損失

各座標で同じ部分積分を行うと

$$\mathcal{L}_{\mathrm{eSM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}}\left[\mathrm{Tr}(\nabla_{\boldsymbol{x}} s_\phi) + \frac{1}{2}\|s_\phi\|_2^2\right] \tag{3.2.2}$$

$\mathcal{L}_{\mathrm{SM}} = \mathcal{L}_{\mathrm{eSM}} + C$（$C$ は $\phi$ に依らない）。EBM では $s_{\phi,j} = -\partial_{x_j} E_\phi$ なので

$$\mathcal{L}_{\mathrm{eSM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}}\left[-\mathrm{Tr}(\nabla_{\boldsymbol{x}}^2 E_\phi) + \frac{1}{2}\|\nabla_{\boldsymbol{x}} E_\phi\|_2^2\right]$$

$\mathrm{Tr}(\nabla_{\boldsymbol{x}}^2 E_\phi) = \sum_j \partial_{x_j}^2 E_\phi$（ヘッセの対角和）。全成分は不要である。

# 補足：データ平均でどう計算するか

観測 $\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(N)}$ があれば期待値を平均で近似する。

$$\widehat{\mathcal{L}}(\phi) = \frac{1}{N} \sum_{n=1}^{N} \Big[ - \operatorname{Tr}(\nabla_{\boldsymbol{x}}^2 E_\phi(\boldsymbol{x}^{(n)})) + \tfrac{1}{2} \|\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}^{(n)})\|_2^2 \Big].$$

## 読み方

各データをモデルに入れ、その位置でのエネルギーの一階・二階微分を計算して平均する。
$C$ は $\phi$ に依らず $\nabla_\phi C = 0$ なので省略できる。
損失の数値自体は変わるが、最小化の対象としては同じである。

# 補足：$\nabla_{\boldsymbol{x}}$ と $\nabla_\phi$ は別

同じ $\nabla$ でも、何について微分するかが違う。

## $\nabla_{\boldsymbol{x}}$：損失を作る

$\phi$ を固定したまま、入力 $\boldsymbol{x}$ での変化を見る。

$$s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$$

損失の $\mathrm{Tr}(\nabla^2_{\boldsymbol{x}} E_\phi)$ もこちら。

## $\nabla_\phi$：パラメータを更新する

できた損失 $\mathcal{L}_{\mathrm{eSM}}(\phi)$ をパラメータ $\phi$ で微分する。

$$\phi \leftarrow \phi - \alpha \nabla_\phi \mathcal{L}_{\mathrm{eSM}}$$

重みを動かすのはこの微分である。

## 最尤との違い

最尤で残ったのは $\nabla_\phi \log Z_\phi$（パラメータ微分）。
スコアで消えるのは $\nabla_{\boldsymbol{x}} \log Z_\phi$（入力微分）。だから正規化定数と、学習中のモデル分布からのサンプリングを避けられる。

## 残る負担

# 補足：ヘッセ行列とトレース

ヘッセ行列は、スカラー関数の二階偏微分を並べた行列である。二次元では

$$\nabla_{\boldsymbol{x}}^2 E_\phi = \begin{pmatrix} \partial_{x_1}^2 E_\phi & \partial_{x_1}\partial_{x_2} E_\phi \\ \partial_{x_2}\partial_{x_1} E_\phi & \partial_{x_2}^2 E_\phi \end{pmatrix}.$$

トレースは対角成分の和なので、

$$\mathrm{Tr}(\nabla_{\boldsymbol{x}}^2 E_\phi) = \partial_{x_1}^2 E_\phi + \partial_{x_2}^2 E_\phi.$$

## 計算上の課題と予告

対角和だけでも、各座標の二階微分を集める必要がある。$D$ が大きいほど厳密な計算は重くなる（3.1.3）。
のちに、ランダム方向でトレースを推定するスライスド・スコアマッチング（3.3.1）と、ノイズを加えた教師あり損失の DSM（3.3.2）で対処する。

# 補足：最尤推定とスコアマッチング

| | 最尤推定 | スコアマッチング |
|---|---|---|
| 学習目的 | 対数尤度を最大化 | スコアを一致させる |
| 分配関数 | 勾配に残る | 不要 |
| モデルからのサンプル | 勾配の近似で要ることが多い | 基本形では不要 |
| 主な困難 | モデル分布の期待値 | 二階微分 |

## 共通点と違い

どちらもモデルをデータ分布へ近づける。スコアマッチングが比べるのは密度の値ではなく、各点での対数密度の勾配である。

# 3.1.3 のまとめ

- スコアを一致させる損失から、$Z_\phi$ と未知の $s_{\text{data}}$ を消せる
- 一次元では部分積分で $s_{\text{data}}$ が $s'_\phi$ に置き換わる
- EBM ではエネルギーの勾配とヘッセの対角和だけで学習でき、データ平均で近似できる（二階微分のコストは残る）

## 次

3.1.4 では、学習したスコアからサンプルを得るランジュバン動力学を扱う。

# 区切り：3.1.4 ランジュバン動力学

3.1.1 エネルギー関数によるモデル化

3.1.2 スコア関数

3.1.3 スコアマッチング

3.1.4 ランジュバン動力学

# イメージで理解する：ランジュバン動力学

式に入る前に、空間上での動きのイメージを見ておくとわかりやすい。

## インタラクティブな可視化

粒子を動かして、次の見方で追う。

- 勾配：エネルギーの低い場所へ引き戻す
- ノイズ：その周辺を揺れ続けさせる

両方が合わさると、一点に止まらず、低い領域のあたりを動き続ける。

https://ebm-space-motion.intactspoon4.chatgpt.site/

# 離散時間のランジュバン更新

EBM からのサンプリングは、ランジュバン動力学で行える。

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n - \eta \nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n \tag{3.1.4}$$

$\boldsymbol{x}_0$ は適当な分布、多くはガウス分布から引く。$\eta > 0$: ステップ幅、$\boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$
スコア $\nabla_{\boldsymbol{x}} \log p_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ で書き換えると、

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n + \eta \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n \tag{3.1.5}$$

この定式化は拡散モデルにおいて中心的な役割を果たすもの、詳細は後の節で説明

# 連続時間では確率微分方程式になる

$\eta \to 0$ とすると、更新は次の SDE に収束する。

$$d\boldsymbol{x}(t) = \nabla_{\boldsymbol{x}} \log p_\phi(\boldsymbol{x}(t))\, dt + \sqrt{2}\, d\boldsymbol{w}(t) \tag{3.1.6}$$

$\boldsymbol{w}(t)$ は標準ブラウン運動である[1]。式（3.1.4）は、この SDE のオイラー・丸山法による離散化である[2]。

**定常分布**

$E_\phi$ が十分滑らかで、サンプルが無限遠へ逃げないとき、$t \to \infty$ で $\boldsymbol{x}(t)$ の分布は $p_\phi$ へ収束する。追加条件のもとでは、収束は指数的になり得る。

目標の分布 $p_\phi$ に従うサンプルを作れることが重要

[1] ブラウン運動：位置が時間とともに連続的に変わり、変化の向きや大きさがランダムな運動

[2] オイラー・丸山法：ブラウン運動を含む連続時間の方程式を、短い時間刻みごとに計算する近似法

# 補足：更新則の三つの部分

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n - \eta \nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\, \boldsymbol{\epsilon}_n \tag{3.1.4}$$

## エネルギーを下げる項

$-\eta \nabla_{\boldsymbol{x}} E_\phi$ は、エネルギーが増える方向の逆へ進む。エネルギーが低い場所は密度が高いので、この項は密度が高い方向への勾配降下である。

## ノイズ項

$\sqrt{2\eta}\, \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, 2\eta \boldsymbol{I})$。勾配だけでは局所的な極小に止まり得る。ノイズは他の領域を探索する余地を作るが、離れた峰のあいだを必ず効率よく越えられるわけではない。

# 補足：ノイズ係数が $\sqrt{2\eta}$ になる理由

連続時間の式を幅 $\eta$ で離散化する。

$$\boldsymbol{x}(t+\eta) - \boldsymbol{x}(t) \approx \eta\, s_\phi(\boldsymbol{x}(t)) + \sqrt{2}\left(\boldsymbol{w}(t+\eta) - \boldsymbol{w}(t)\right)$$

ブラウン運動の増分は $\mathcal{N}(\mathbf{0}, \eta \boldsymbol{I})$ なので、

$$\boldsymbol{w}(t+\eta) - \boldsymbol{w}(t) \overset{d}{=} \sqrt{\eta}\, \boldsymbol{\epsilon}_n.$$

したがってノイズ項は $\sqrt{2}\sqrt{\eta}\, \boldsymbol{\epsilon}_n = \sqrt{2\eta}\, \boldsymbol{\epsilon}_n$。

## 別の係数

$\boldsymbol{x} + \frac{\eta}{2} s_\phi + \sqrt{\eta}\, \boldsymbol{\epsilon}$ もよく使う形である。違いは時間の尺度の取り方であり、同じ動力学の別表記である。

# 補足：ドリフトと拡散

$$d\boldsymbol{x}(t) = \underbrace{s_\phi(\boldsymbol{x}(t))\,dt}_{\text{ドリフト}} + \underbrace{\sqrt{2}\,d\boldsymbol{w}(t)}_{\text{拡散}} \tag{3.1.6}$$

## 二つの働き

ドリフトはスコアに従い、密度が高い方向へ動かす。拡散はブラウン運動によるランダムな揺れである。

## 通常の微分との違い

ブラウン運動の経路は、どの時刻でも微分できない経路が、確率 1 で選ばれる
$d\boldsymbol{w}(t)$ は普通の微小変化ではなく、確率積分で定義される。

# 図3.3：スコアに沿った確率的な軌跡

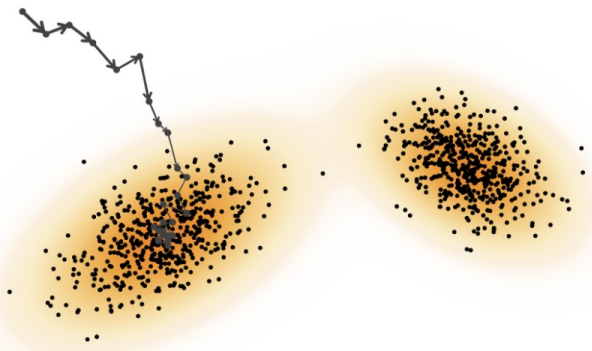


**Figure 3.3: Illustration of Langevin sampling.** Langevin sampling using the score function $\nabla_{\mathbf{x}} \log p_\phi(\mathbf{x})$ to guide trajectories toward high-density regions via the update in Equation (3.1.5) (indicating by arrows).

*Source: Created by the authors.*

式（3.1.5）の更新で、軌跡は左の高密度領域へ入る。右の山へは移っていない。

# 補足：目標分布が定常分布になる

時刻 $t$ の密度を $q_t$ とすると、適切な条件で

$$\partial_t q_t = -\nabla_{\boldsymbol{x}} \cdot \left( q_t \nabla_{\boldsymbol{x}} \log p_\phi \right) + \Delta q_t.$$

$q_t = p_\phi$ を代入すると、$p_\phi \nabla_{\boldsymbol{x}} \log p_\phi = \nabla_{\boldsymbol{x}} p_\phi$ より

$$\partial_t q_t = -\Delta p_\phi + \Delta p_\phi = 0.$$

## 読み方と限界

$p_\phi$ は時間的に変化しない定常分布である。初期分布からの収束には、エルゴード性などの追加条件が要る。有限の $\eta$ では離散化誤差があり、離散連鎖の定常分布は厳密には $p_\phi$ と一致しない。

# なぜランジュバン動力学なのか

エネルギーの勾配だけに従う決定論的な運動は

$$d\boldsymbol{x}(t) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}(t))\, dt$$

であり、局所的な極小へ向かう。そこにノイズを加えると

$$d\boldsymbol{x}(t) = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}(t))\, dt + \sqrt{2}\, d\boldsymbol{w}(t) \tag{3.1.6}$$

となる（$s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ より式（3.1.6）と同値）。適切な条件のもとで、定常分布は $p_\phi(\boldsymbol{x}) \propto e^{-E_\phi(\boldsymbol{x})}$ である。

**EBM での使い道**

分配関数を計算せず、エネルギーの勾配だけで $p_\phi$ からのサンプルを近似できる。

# 補足：勾配は力、ただし過減衰の運動

力は $F(\boldsymbol{x}) = -\nabla_{\boldsymbol{x}} E(\boldsymbol{x})$ である。$E(x) = \frac{1}{2}x^2$ なら $F(x) = -x$ で、粒子は原点へ向かう。

## 本文の ODE との違い

$d\boldsymbol{x} = -\nabla_{\boldsymbol{x}} E_\phi \, dt$ は、ニュートンの $m\ddot{\boldsymbol{x}} = F$ そのものではない。慣性を無視した、過減衰系の一次の運動である。

この流れに沿うと

$$\frac{d}{dt} E_\phi(\boldsymbol{x}(t)) = -\|\nabla_{\boldsymbol{x}} E_\phi\|_2^2 \leq 0.$$

エネルギーは増えない。別の谷へ行くには、一時的にエネルギーを上げる必要があり、決定論だけでは足りない。

# 補足：$\sqrt{2}$ は定常性から決まる

一般の SDE $d\boldsymbol{x} = b\,dt + \sigma\,d\boldsymbol{w}$ の密度は

$$\partial_t \rho = -\nabla \cdot (b\rho) + \frac{\sigma^2}{2}\Delta\rho.$$

$b = \nabla_{\boldsymbol{x}} \log p_\phi$、$\rho = p_\phi$ とすると

$$\partial_t \rho = \left(\frac{\sigma^2}{2} - 1\right)\Delta p_\phi.$$

これが一般の分布で 0 になるには $\sigma = \sqrt{2}$。

## 脚注の意味

$\boldsymbol{x}(0) \sim p_\phi$ なら、任意の $t \geq 0$ で $\boldsymbol{x}(t) \sim p_\phi$ となり得る。これは定常性であり、任意の初期分布からの収束そのものではない。

# 補足：分配関数なしで更新できる

$$s_\phi(\boldsymbol{x}) = \nabla_{\boldsymbol{x}}\left[-E_\phi(\boldsymbol{x}) - \log Z_\phi\right] = -\nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x})$$

なので更新に必要なのは、エネルギーの入力勾配とガウスノイズだけである。

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n - \eta \nabla_{\boldsymbol{x}} E_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\,\boldsymbol{\epsilon}_n \tag{3.1.4}$$

**注意**

有限ステップの離散化には誤差がある。ステップ幅と更新回数が、近似の良さに影響する。

# ランジュバン動力学と DDPM

**ランジュバン動力学**

一つの目標分布 $p_\phi$ に向けて、スコアとノイズで時間発展する。

**DDPM**

ノイズ量の異なる分布を順にたどり、強いノイズからデータ分布へ移る。

どちらもスコアを使って確率的に生成するが、更新則は同じではない。この違いは、後の NCSN を読むときに重要になる。

# ランジュバンサンプリングの課題

## 混合が遅い

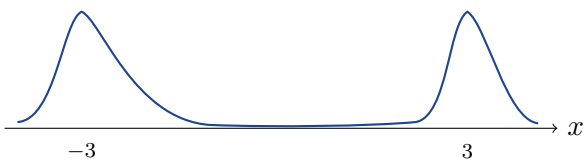
離れたモードが多い分布では、一つの高密度領域から別の領域へ移るのに長い時間がかかる。高次元で、モードのあいだが複雑に分かれていると、この遅れはさらに大きくなり得る。

- 効率はステップ幅、ノイズの大きさ、反復回数に依存する
- 更新は局所的なので、谷のあいだを効率よく渡れない
- 有限時間では、分布の多様性を取りこぼすことがある

# 補足：モード間は低密度を越えなければならない

モードは、密度が局所的に最大になる位置である。

$$p(x) = \frac{1}{2}\mathcal{N}(x; -3, 0.5^2) + \frac{1}{2}\mathcal{N}(x; 3, 0.5^2)$$




左の峰にいるサンプルは、スコアによって左へ戻されやすい。右へ行くには中央の低密度を越える必要があり、ノイズがそれを実現するまで多数の更新が要ることがある。

# 補足：混合時間

混合時間は、初期状態から定常分布へ十分近づくまでの時間または更新回数である。

$$t_{\mathrm{mix}}(\varepsilon) = \min\left\{n : \sup_{\boldsymbol{x}_0} \left\| P^n(\boldsymbol{x}_0, \cdot) - \pi \right\|_{\mathrm{TV}} \leq \varepsilon\right\}$$

$P^n(\boldsymbol{x}_0, \cdot)$ は $n$ 回更新後の分布、$\pi$ は定常分布、$\|\cdot\|_{\mathrm{TV}}$ は全変動距離である。

**注意**

有限のステップ幅では、$\pi$ が厳密な $p_\phi$ と一致しないことがある。混合が遅いと、長く走らせても特定のモード付近に偏る。

# 補足：ステップ幅は精度と効率を同時に変える

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n + \eta\, s_\phi(\boldsymbol{x}_n) + \sqrt{2\eta}\,\boldsymbol{\epsilon}_n \tag{3.1.5}$$

## 小さくする

連続時間の SDE をより正確に近似しやすい。同じ時間を進めるには更新回数が増える。

## 大きくする

一回の移動は増えるが、離散化誤差と数値的な不安定さが増し得る。ノイズの共分散は $2\eta \boldsymbol{I}$ なので、揺れの大きさも一緒に変わる。

# 補足：高次元だけで必ず失敗するわけではない

## 難しくなる典型

高密度領域が離れており、そのあいだのエネルギー障壁が大きいとき、局所的なスコアとガウスノイズだけでは移動が遅い。

## 例外

十分滑らかな強対数凹分布では、ランジュバン動力学に良い収束保証が付く場合がある。問題になるのは、高次元性に加えて、複数の離れたモードや複雑な形状があるときである。

# ノイズで滑らかにしてから戻す

複雑な $p_{\text{data}}$ を直接探索するのは難しい。そこで複数のノイズレベルを考える。

$$\tilde{\boldsymbol{x}} = \boldsymbol{x} + \sigma\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$

- $\sigma$ が大きいと、局所構造が平滑化され、モード間の低密度が埋まりやすくなる
- $\sigma$ を下げながらサンプルすると、細かい構造を後から再現できる

**次につながること**

この考え方が、アニーリングされたランジュバン動力学と、Denoising Score Matching、NCSN の動機になる。

# 3.1.4 のまとめ

- ランジュバン動力学は、スコアによる移動とノイズで $p_\phi$ からサンプルする
- 連続時間では SDE になり、$\sqrt{2}$ のとき $p_\phi$ が定常分布になり得る
- 離れたモードでは混合が遅く、ノイズで平滑化した分布を段階的にたどる動機になる

# 3.1 全体のまとめ

1. **3.1.1 EBM** 分布をエネルギー $E_\phi$ で表す。最尤は $-\mathbb{E}_{p_{\text{data}}}[E_\phi] - \log Z_\phi$ だが、$Z_\phi$ が障害になる。
2. **3.1.2 スコア** $s = \nabla_{\boldsymbol{x}} \log p$ は密度が増える方向。EBM では $s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ となり $Z_\phi$ が消える。
3. **3.1.3 スコアマッチング**未知の $s_{\text{data}}$ を直接使わず、エネルギーと二階微分だけで学習できる。
4. **3.1.4 ランジュバン**学習したスコアとノイズで $p_\phi$ からサンプルする。多峰では混合が遅く、ノイズ平滑化の動機につながる。

# 3.1 全体のまとめ：一本の流れ

## 今日の道筋

EBM で分布を書く $\rightarrow$ 最尤の $Z_\phi$ が難しい $\rightarrow$ スコアで $Z_\phi$ を避ける $\rightarrow$ スコアマッチングで学習する $\rightarrow$ ランジュバンで生成する

## 核心

密度そのものではなく、対数密度の勾配（スコア）を扱うことで、正規化定数なしに学習とサンプリングへ進める。

## 次へ

ノイズ条件付きのスコア学習（DSM / NCSN）と、連続時間の Score SDE へつながる。

# 理解のための参考資料

本編のあとで見ると、各概念のイメージが追いやすい。いずれもインタラクティブな補足資料である。

## 可視化サイト

- 正規化・分配関数：`ebm-normalization-lab`
- 粒子と密度：`ebm-particles-and-density`
- 入力勾配とパラメータ勾配：`ebm-input-vs-parameter`
- スコアからの再構成：`ebm-score-reconstruction`
- スコアマッチング：`ebm-score-matching-lab`
- ステップ幅：`ebm-step-size-lab`
- ノイズによる平滑化：`ebm-noise-smoothing`