# The Principles of Diffusion Models

## 3.2 From Energy-Based to Score-Based Generative Models

渡邉 有志

November 12, 2026

# 3.1 から 3.2 へ

## ここまで（3.1）

EBM はエネルギー $E_\phi$ で分布を表し、スコア $s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ で生成できる。
スコアマッチングは分配関数を避けるが、エネルギー経由だと二階微分が残る。

## ここから（3.2）

ランジュバン動力学に必要なのはスコアだけである。
だからエネルギーを経由せず、ニューラルネットでスコアを直接学習する。

- エネルギーをモデル化する $\rightarrow$ スコアをモデル化する
- この転換が、スコアベース生成モデルの土台になる

# 3.2 の位置づけ

## この節の役割

EBM のスコア視点から、スコアを直接扱う生成モデルへ橋を渡す

1. **3.2.1 スコアマッチングによる学習**
   真のスコアへ当てはめる損失と、真のスコアなしで使える等価形
2. **3.2.2 ランジュバン動力学によるサンプリング**
   学習したスコア $s_{\phi^\star}$ でサンプルを得る
3. **3.2.3 予告：スコアベース生成モデル**
   この章の後半（DSM / NCSN）へのつながり

# 区切り：3.2.1 スコアマッチングによる学習

3.2.1 スコアマッチングによる学習

3.2.2 ランジュバン動力学によるサンプリング

3.2.3 予告：スコアベース生成モデル

# スコアをニューラルネットで直接近似する

データ分布のスコア

$$s(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p_{\text{data}}(\boldsymbol{x})$$

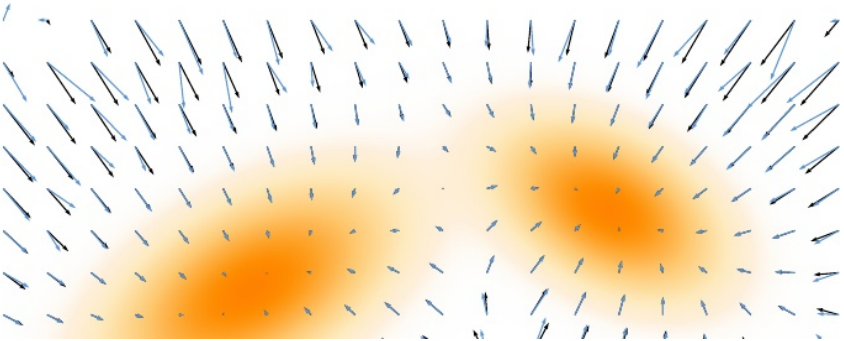
を、ベクトル場としてパラメータ化したネット $s_\phi(\boldsymbol{x})$ で近似する。

$$s_\phi(\boldsymbol{x}) \;\approx\; s(\boldsymbol{x})$$

## 3.1 との違い

3.1 では $s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ と、エネルギー経由でスコアを得た。
ここでは $s_\phi$ そのものを学習対象にする。

# 図3.4：スコアマッチングのイメージ



ニューラルネットのスコア $s_\phi(\boldsymbol{x})$ を、真のスコア $s(\boldsymbol{x})$ に MSE で合わせる。
どちらもベクトル場として表される。

# 補足：図 3.4 の読み方

## オレンジの領域

データの高密度領域（モード）である。スコアはここに向かう向きをもつ。

## 矢印

各点でのスコアベクトルである。
真の場 $s$ とモデルの場 $s_\phi$ を重ねて描き、MSE で一致させるイメージである。

## 学習の目標

どこで密度が増えるかを、エネルギー関数を経由せずにベクトル場として覚える。

# スコアを合わせる損失

真のスコアとモデルのスコアの平均二乗誤差を最小化する。

$$\mathcal{L}_{\mathrm{SM}}(\phi) := \frac{1}{2}\mathbb{E}_{\boldsymbol{x}\sim p_{\mathrm{data}}}\left[\|s_\phi(\boldsymbol{x}) - s(\boldsymbol{x})\|_2^2\right] \tag{3.2.1}$$

## 一見すると使えない

回帰の教師 $s(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p_{\mathrm{data}}(\boldsymbol{x})$ が未知である。
観測できるのはサンプルだけで、真の密度もスコアも通常はわからない。

# 命題 3.2.1：Hyvärinen の扱いやすい形

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \mathcal{L}_{\mathrm{eSM}}(\phi) + C$$

ここで

$$\mathcal{L}_{\mathrm{eSM}}(\phi) := \mathbb{E}_{\boldsymbol{x}\sim p_{\mathrm{data}}}\left[\mathrm{Tr}\left(\nabla_{\boldsymbol{x}} \boldsymbol{s}_{\phi}(\boldsymbol{x})\right) + \frac{1}{2}\left\|s_{\phi}(\boldsymbol{x})\right\|_2^2\right] \tag{3.2.2}$$

であり、$C$ は $\phi$ に依らない定数である。
最小化の解は $s^{\star}(\cdot) = \nabla_{\boldsymbol{x}} \log p(\cdot)$ である。

# 補足：なぜ真のスコアが消えるか

MSE を展開し、部分積分でクロス項の微分をモデル側へ移す（3.1.3 で一次元から多次元まで追った変形）。

## 残るもの

モデルの大きさ $\|s_\phi\|_2^2$ と、ヤコビアンの対角和 $\mathrm{Tr}(\nabla_{\boldsymbol{x}} s_\phi)$ だけである。
データサンプル上の平均で評価できる。

## 注意

トレース項は厳密には入力次元に応じた微分情報が要る。
高次元では計算が重くなり得る（3.3 で別の対処へ進む）。

# 式（3.2.2）の二つの項

$$\mathcal{L}_{\mathrm{eSM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}}\left[\underbrace{\mathrm{Tr}(\nabla_{\boldsymbol{x}} s_\phi)}_{\text{発散項}} + \underbrace{\tfrac{1}{2}\|s_\phi\|_2^2}_{\text{大きさの項}}\right]$$

## 大きさの項

スコアが大きくなりすぎるのを抑える。期待値は $p_{\mathrm{data}}$ 下なので、データの多い場所ほど強く効く。

## 発散項

損失に正の符号で入るので、最小化は局所的な収縮（負の発散）を好む。

二つの項が揃うと、最適解は $s^\star = \nabla_{\boldsymbol{x}} \log p_{\mathrm{data}}$ になる。

# 補足：大きさの項は「データが多い場所」を重視する

期待値は $p_{\text{data}}$ で取るので、高密度領域ほど $\frac{1}{2}\|s_\phi\|_2^2$ の罰則が強く効く。

## 誤解しやすい点

これだけで「高密度のすべての点で $s_\phi = 0$」になるわけではない。
母集団最適では $s^\star(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} \log p_{\text{data}}(\boldsymbol{x})$ であり、ゼロになるのは対数密度の停留点だけである。

# 補足：発散項は局所的な吸い込みを好む

発散 $\mathrm{Tr}(\nabla_{\boldsymbol{x}} s_\phi)$ が負なら、その付近では場が平均的に内側へ向かう。

## 勾配場のとき

$s_\phi = \nabla_{\boldsymbol{x}} u$ なら、$\nabla_{\boldsymbol{x}} s_\phi = \nabla^2_{\boldsymbol{x}} u$（ヘッセ）で、発散は $\mathrm{Tr}(\nabla^2_{\boldsymbol{x}} u)$ である。

停留点 $\boldsymbol{x}_\star$（$s_\phi(\boldsymbol{x}_\star) = 0$）でヘッセが負定値なら、$u$ は局所凹で、対数密度はそこで厳密な局所最大になる。

# 補足：負のトレースだけでは足りない

ヘッセが負定値なら全固有値が負なので、トレースも負である。

## 逆は成り立たない

トレースが負でも、正の固有値が混ざれば鞍点になり得る。
したがって「発散が負 $\Rightarrow$ 必ず局所最大」ではない。

## 読み方

発散項は収縮を促す項であり、単独でモードの形を保証する条件ではない。

# 3.2.1 のまとめ

- スコア $s_\phi$ をニューラルネットで直接近似する
- MSE 損失（3.2.1）の教師は未知だが、等価形（3.2.2）はデータとモデルだけで評価できる
- 大きさの項と発散項が、最適解 $s^\star = \nabla \log p_{\mathrm{data}}$ を与える

**次**

学習した $s_{\phi^\star}$ を、ランジュバン動力学に入れてサンプルする。

# 区切り：3.2.2 ランジュバン動力学によるサンプリング

3.2.1 スコアマッチングによる学習

3.2.2 ランジュバン動力学によるサンプリング

3.2.3 予告：スコアベース生成モデル

# 学習したスコアでランジュバン更新する

式（3.2.2）を最小化して得た $s_{\phi^\star}$ を、ランジュバン動力学のスコアとして使う。

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n + \eta\, s_{\phi^\star}(\boldsymbol{x}_n) + \sqrt{2\eta}\,\boldsymbol{\epsilon}_n, \qquad \boldsymbol{\epsilon}_n \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}) \tag{3.2.3}$$

$\boldsymbol{x}_0$ から始め、$n = 0, 1, 2, \ldots$ と更新する。

## 3.1 との対応

EBM では $s_\phi = -\nabla_{\boldsymbol{x}} E_\phi$ を入れた式（3.1.5）だった。
ここではエネルギーを持たず、$s_{\phi^\star}$ をそのまま入れる。

# 連続時間では SDE になる

式（3.2.3）は、次のランジュバン SDE のオイラー・丸山離散化である。

$$d\boldsymbol{x}(t) = s_{\phi^\star}(\boldsymbol{x}(t))\,dt + \sqrt{2}\,d\boldsymbol{w}(t)$$

$\boldsymbol{w}(t)$ は標準ブラウン運動である。

- ステップ幅 $\eta$ が小さい極限では、離散更新と連続 SDE は一致する
- 実装では離散サンプラを走らせても、SDE を直接シミュレートしてもよい

**要点**

学習の出力はスコア場であり、生成はその場に沿った確率的な流れである。

# 補足：更新の二つの働き

$$\boldsymbol{x}_{n+1} = \boldsymbol{x}_n + \underbrace{\eta\, s_{\phi^\star}(\boldsymbol{x}_n)}_{\text{スコア方向へ進む}} + \underbrace{\sqrt{2\eta}\,\boldsymbol{\epsilon}_n}_{\text{探索のためのノイズ}}$$

**ドリフト**

学習したスコアに従い、密度が高い方向へ動かす。

**拡散**

勾配だけでは局所に止まり得る。ノイズが別の領域を探る余地を作る。

詳細な定常分布や混合の議論は 3.1.4 と同じ骨格である。

# 3.2.2 のまとめ

- 学習後の $s_{\phi^\star}$ を式（3.2.3）に入れればサンプルできる
- 連続時間では $d\boldsymbol{x} = s_{\phi^\star}\, dt + \sqrt{2}\, d\boldsymbol{w}$
- エネルギー関数を保持しなくても、スコア場だけで生成できる

# 区切り：3.2.3 予告：スコアベース生成モデル

3.2.1 スコアマッチングによる学習

3.2.2 ランジュバン動力学によるサンプリング

3.2.3 予告：スコアベース生成モデル

# スコアが拡散モデルの中心になる

スコアは当初、EBM を効率よく学習するための道具だった。いまでは、スコアそのものが生成モデルの中核になっている。

## この章の後半で見ること

スコア関数が、スコアベース拡散モデルの理論と実装をどう支えるか。
確率過程を通じたデータ生成の枠組みへ進む。

- 単一ノイズでのスコア学習（Denoising Score Matching）
- 複数ノイズへの拡張（NCSN）
- DDPM との対応

# 補足：いまの枠組みに残る課題

式（3.2.2）は真のスコアを消すが、$\mathrm{Tr}(\nabla_{\boldsymbol{x}} s_\phi)$ の計算は高次元で重い。

## 次の節への動機

- スライスド・スコアマッチング：ランダム方向でトレースを推定する
- Denoising Score Matching：既知ノイズの条件付きスコアを教師にする

どちらも「生の $p_{\mathrm{data}}$ のスコアを直接扱う」難しさを避ける方向である。

# 3.2 全体のまとめ

1. **転換**生成に必要なのはスコアなので、エネルギーではなく $s_\phi$ を直接学習する。
2. **学習** MSE（3.2.1）は教師が未知だが、等価形（3.2.2）でデータから学習できる。
3. **生成**学習した $s_{\phi^\star}$ をランジュバン動力学（3.2.3）に入れる。
4. **次へ**トレース計算や多様体上の不安定さを避けるため、DSM と多ノイズの NCSN へ進む。

# 3.2 全体のまとめ：一本の流れ

## 今日の道筋

EBM ではスコアで足りる $\rightarrow$ スコアをネットで直接近似する $\rightarrow$ 等価なスコアマッチングで学習する $\rightarrow$ ランジュバンで生成する

## 核心

密度やエネルギーを経由せず、対数密度の勾配（スコア）をベクトル場として学べばよい。

## 次へ

3.3 では、ノイズを入れた条件付きスコア学習（Denoising Score Matching）を扱う。