The Principles of Diffusion Models

3.3 Denoising Score Matching

渡邉 有志

November 12, 2026

3.2 から 3.3 へ

ここまで（3.2）

スコア s_ϕ を直接学習し、ランジュバンで生成できる。
等価形（3.2.2）は真のスコアを消すが、$\mathrm{Tr}(\nabla_{\boldsymbol{x}} s_\phi)$ が残る。

ここから（3.3）

トレース計算を避け、既知ノイズの条件付きスコアを教師にする。
これが Denoising Score Matching（DSM）である。

3.3 の位置づけ

この節の役割

古典的スコアマッチングから、ノイズ付きの実用的学習へ進む

1. **3.3.1 動機**
   トレースの負担と、スライスド SM から DSM への流れ
2. **3.3.2 学習**
   条件付けによる DSM 損失（3.3.2）（3.3.4）
3. **3.3.3 サンプリング**
   学習したスコアでランジュバンする
4. **3.3.4 Tweedie**
   スコア予測がなぜノイズ除去になるか

3.3.5（SURE）と 3.3.6（一般化）は補足

区切り：3.3.1 動機

3.3.1 動機

3.3.2 学習

3.3.3 サンプリング

3.3.4 Tweedie の公式

補足：SURE と一般化

等価形でもトレースが重い

式（3.2.2）

$$\mathcal{L}_{\mathrm{eSM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}}\left[\mathrm{Tr}\big(\nabla_{\boldsymbol{x}} s_\phi(\boldsymbol{x})\big) + \tfrac{1}{2}\|s_\phi(\boldsymbol{x})\|_2^2\right]$$

は真のスコアを使わないが、ヤコビアンの対角和が要る。

高次元での問題

全ヤコビアンを作らなくても、各座標の微分情報を集める必要がある。
入力次元 D が大きいほど、厳密評価は重くなる。

スライスド SM：ランダム方向でトレースを推定

Hutchinson の恒等式 $\mathrm{Tr}(A) = \mathbb{E}_{\boldsymbol{u}}[\boldsymbol{u}^\top A \boldsymbol{u}]$（$\mathbb{E}[\boldsymbol{u}] = \mathbf{0}$、$\mathbb{E}[\boldsymbol{u}\boldsymbol{u}^\top] = \boldsymbol{I}$）より

$$\mathcal{L}_{\mathrm{eSM}}(\phi) = \mathbb{E}_{\boldsymbol{x},\boldsymbol{u}}\left[\boldsymbol{u}^\top(\nabla_{\boldsymbol{x}} s_\phi)\boldsymbol{u} + \frac{1}{2}(\boldsymbol{u}^\top s_\phi)^2\right]$$

- JVP/VJP で方向微分だけ計算すればよく、巨大行列を明示しなくてよい
- K 本のプローブ平均で不偏推定（分散は $O(1/K)$）

補足：スライスド SM の限界

トレースは避けられるが、生の p_{data} 上で場を合わせる点は同じである。

脆さ

- 画像など低次元多様体上では、スコアが定義しにくく不安定になり得る
- 観測点だけで場を縛るため、近傍の制御が弱い
- プローブ分散と、繰り返しの JVP/VJP コストが残る

次の一手

より頑健でスケールしやすいのが、Denoising Score Matching（Vincent, 2011）である。

3.3.1 のまとめ

- Hyvärinen 形は真のスコアを消すが、トレース計算が重い
- スライスド SM はランダム方向でトレースを推定する
- それでも生データ上のスコア合わせは脆いので、DSM へ進む

区切り：3.3.2 学習

3.3.1 動機

3.3.2 学習

3.3.3 サンプリング

3.3.4 Tweedie の公式

補足：SURE と一般化

未知の周辺スコアが障害になる

ノイズ付き周辺 p_σ に対するスコアマッチングは

$$\mathcal{L}_{\mathrm{SM}}(\phi;\sigma) := \frac{1}{2}\mathbb{E}_{\tilde{\boldsymbol{x}}\sim p_\sigma}\left\|s_\phi(\tilde{\boldsymbol{x}},\sigma) - \nabla_{\tilde{\boldsymbol{x}}}\log p_\sigma(\tilde{\boldsymbol{x}})\right\|_2^2 \tag{3.3.1}$$

問題

教師 $\nabla_{\tilde{\boldsymbol{x}}}\log p_\sigma(\tilde{\boldsymbol{x}})$ は一般に未知である。
Vincent (2011) は、きれいな $\boldsymbol{x}$ で条件付けて等価で扱いやすい損失へ移す。

条件付けで DSM 損失にする

既知の条件付き分布 $p_\sigma(\tilde{\boldsymbol{x}}|\boldsymbol{x})$ でノイズを入れ、

$$p_\sigma(\tilde{\boldsymbol{x}}) = \int p_\sigma(\tilde{\boldsymbol{x}}|\boldsymbol{x})\, p_{\text{data}}(\boldsymbol{x})\, d\boldsymbol{x}$$

のスコアを学習する。等価な DSM 損失は

$$\mathcal{L}_{\text{DSM}}(\phi;\sigma) := \frac{1}{2}\mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}},\, \tilde{\boldsymbol{x}}\sim p_\sigma(\cdot|\boldsymbol{x})}\left\| s_\phi(\tilde{\boldsymbol{x}},\sigma) - \nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}}|\boldsymbol{x})\right\|_2^2 \tag{3.3.2}$$

定理 3.3.1：$\mathcal{L}_{\mathrm{SM}}$ と $\mathcal{L}_{\mathrm{DSM}}$ は同じ最小化

任意の固定 $\sigma > 0$ について

$$\mathcal{L}_{\mathrm{SM}}(\phi;\sigma) = \mathcal{L}_{\mathrm{DSM}}(\phi;\sigma) + C \tag{3.3.3}$$

（C は ϕ に依らない）。両者の最小化子は

$$s^{\star}(\tilde{\boldsymbol{x}},\sigma) = \nabla_{\tilde{\boldsymbol{x}}} \log p_{\sigma}(\tilde{\boldsymbol{x}})$$

（ほとんどすべての $\tilde{\boldsymbol{x}}$）である。

読み方

条件付きスコアを教師にすれば、未知の周辺スコアを直接使わずに同じ最適解へ到達できる。

補足：条件付けの技法（Insight 3.3.1）

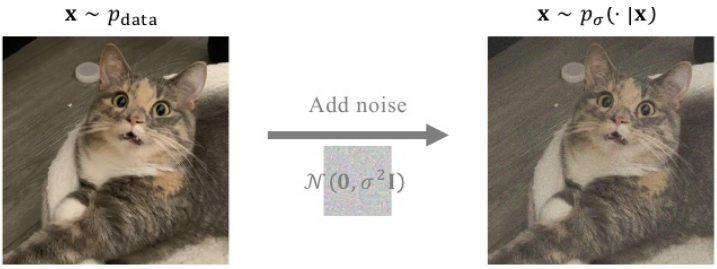
共通の原理

データ点 $\boldsymbol{x}$ で条件付けると、扱いにくい損失がモンテカルロ可能な形になる。
DDPM の変分視点（定理 2.2.1）でも同じ発想が出る。

あとで

Flow Matching など、フロー視点でも類似の条件付けが現れる（5.2）。

図 3.5：条件付けで教師が閉じた形になる



左の真のスコアは未知。右の条件付きスコアはガウスなら閉じた形で書ける。

補足：図 3.5 の読み方

左（×）

$\nabla_{\boldsymbol{x}} \log p_{\text{data}}$ は通常わからない。
そのままでは回帰の教師にできない。

右（✓）

$\tilde{\boldsymbol{x}} = \boldsymbol{x} + \sigma\boldsymbol{\epsilon}$ なら $\nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}}|\boldsymbol{x})$ は明示できる。

ポイント

ノイズの入れ方を自分で決めるから、条件付きスコアが計算可能になる。

ガウスノイズなら教師が明示できる

$\tilde{\boldsymbol{x}} = \boldsymbol{x} + \sigma\boldsymbol{\epsilon}$、$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$ とすると

$$\nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}}|\boldsymbol{x}) = \frac{\boldsymbol{x} - \tilde{\boldsymbol{x}}}{\sigma^2} = -\frac{\boldsymbol{\epsilon}}{\sigma}$$

よって

$$\begin{aligned} \mathcal{L}_{\mathrm{DSM}}(\phi; \sigma) &= \frac{1}{2}\mathbb{E}_{\boldsymbol{x},\tilde{\boldsymbol{x}}}\left\| s_\phi(\tilde{\boldsymbol{x}}, \sigma) - \frac{\boldsymbol{x} - \tilde{\boldsymbol{x}}}{\sigma^2} \right\|_2^2 \\ &= \frac{1}{2}\mathbb{E}_{\boldsymbol{x},\boldsymbol{\epsilon}}\left\| s_\phi(\boldsymbol{x} + \sigma\boldsymbol{\epsilon}, \sigma) + \frac{\boldsymbol{\epsilon}}{\sigma} \right\|_2^2 \end{aligned} \tag{3.3.4}$$

DSM が学ぶのは平滑化した分布のスコア

固定 $\sigma > 0$ では、$p_\sigma = p_{\text{data}} * \mathcal{N}(\mathbf{0}, \sigma^2 \boldsymbol{I})$ のスコアを学ぶ。

σ が小さい

局所構造が残り、ノイズ付き点をデータ側へ戻す向きが得られる。

σ が大きい

細部が消え、モードが合流し、粗い大域構造のスコアになる。

3.4 では複数ノイズを組み合わせ、粗探索と細部復元を分担させる。

3.3.2 のまとめ

- 周辺スコアは未知だが、条件付きスコアなら教師にできる
- $\mathcal{L}_{\mathrm{SM}}$ と $\mathcal{L}_{\mathrm{DSM}}$ は定数差で同じ最小化（3.3.3）
- ガウスなら教師は $(\boldsymbol{x} - \tilde{\boldsymbol{x}})/\sigma^2$（3.3.4）

区切り：3.3.3 サンプリング

3.3.1 動機

3.3.2 学習

3.3.3 サンプリング

3.3.4 Tweedie の公式

補足：SURE と一般化

学習したスコアでランジュバンする

ノイズレベル σ で学習した $s_{\phi^\star}(\tilde{\boldsymbol{x}}, \sigma)$ を入れ、

$$\tilde{\boldsymbol{x}}_{n+1} = \tilde{\boldsymbol{x}}_n + \eta\, s_{\phi^\star}(\tilde{\boldsymbol{x}}_n, \sigma) + \sqrt{2\eta}\,\boldsymbol{\epsilon}_n, \qquad \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I}) \tag{3.3.5}$$

$$s_{\phi^\star}(\tilde{\boldsymbol{x}}_n, \sigma) \;\approx\; \nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}}_n)$$

σ が十分小さく、十分反復すれば、$\tilde{\boldsymbol{x}}_n$ は p_{data} からのサンプルに近づく。

ノイズを入れる二つの利点

生のスコアマッチング（3.2.1）と比べ、p_σ を作るガウス摂動には次の利点がある。

勾配が定義しやすい

データが低次元多様体上でも、ノイズで $\mathbb{R}^D$ 全体に広がる。
だから $\nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma$ が至る所で定義される。

被覆が良くなる

モード間の薄い領域が平滑化され、学習信号が安定しやすい。
ランジュバンも低密度を渡りやすくなる。

3.3.3 のまとめ

- 学習後は式（3.3.5）のランジュバンでサンプルする
- ノイズはスコアの定義域とモード間の被覆を改善する
- 単一 σ だけでは粗さ／細部の両立はまだ難しい（3.4 へ）

区切り：3.3.4 Tweedie の公式

3.3.1 動機

3.3.2 学習

3.3.3 サンプリング

3.3.4 Tweedie の公式

補足：SURE と一般化

なぜ DSM が「ノイズ除去」なのか

Tweedie の公式は、ノイズ付き観測だけからきれいな信号の事後平均をスコアで書ける、という主張である。

直感

ノイズ付き $\tilde{\boldsymbol{x}}$ を、周辺スコアの向きにちょうど σ^2 だけ動かすと、きれいな $\boldsymbol{x}$ の条件付き平均（デノイザ）が得られる。

補題 3.3.2：Tweedie の公式

$\boldsymbol{x} \sim p_{\text{data}}$、$\tilde{\boldsymbol{x}}|\boldsymbol{x} \sim \mathcal{N}(\cdot;\, \alpha\boldsymbol{x},\, \sigma^2\boldsymbol{I})$（$\alpha \neq 0$）とすると

$$\alpha\, \mathbb{E}[\boldsymbol{x}|\tilde{\boldsymbol{x}}] = \tilde{\boldsymbol{x}} + \sigma^2\, \nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}}) \tag{3.3.6}$$

特に $\alpha = 1$ なら

$$\mathbb{E}[\boldsymbol{x}|\tilde{\boldsymbol{x}}] = \tilde{\boldsymbol{x}} + \sigma^2\, \nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}})$$

スコア予測はデノイザを決める

DSM で $s_\phi(\tilde{\boldsymbol{x}}, \sigma) \approx \nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}})$ なら

$$\widehat{\boldsymbol{x}} = \frac{1}{\alpha}\Big(\tilde{\boldsymbol{x}} + \sigma^2\, s_\phi(\tilde{\boldsymbol{x}}, \sigma)\Big)$$

がデノイザ（事後平均の近似）である。

核心

スコアを学ぶことと、ノイズ除去を学ぶことは、ガウス摂動のもとでは同じ情報の裏表である。

補足：高次の Tweedie（任意）

古典的 Tweedie は事後平均を 1 階のスコアで書く。
高次では事後共分散などが $\log p_\sigma$ の高階微分で書ける。

$$\mathrm{Cov}[\boldsymbol{x}|\tilde{\boldsymbol{x}}] = \sigma^2 \boldsymbol{I} + \sigma^4 \nabla^2_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}})$$

読み方

平均だけでなく不確かさも、ノイズ付き周辺の幾何から読める。
高次スコアを直接学ぶ研究もあるが、本節の本筋は 1 階である。

3.3.4 のまとめ

- Tweedie により、デノイザはスコアの一次式で書ける
- DSM の最適スコアは、そのまま最適デノイザを与える
- だから DSM は「スコア学習」であると同時に「ノイズ除去学習」である

区切り：補足（SURE / 一般化スコアマッチング）

3.3.1 動機

3.3.2 学習

3.3.3 サンプリング

3.3.4 Tweedie の公式

補足：SURE と一般化

補足：SURE はきれいな信号なしで MSE を見積もる

$\tilde{\boldsymbol{x}} = \boldsymbol{x} + \sigma\boldsymbol{\epsilon}$ に対するデノイザ D について

$$\mathrm{SURE}(D;\tilde{\boldsymbol{x}}) = \|D(\tilde{\boldsymbol{x}}) - \tilde{\boldsymbol{x}}\|_2^2 + 2\sigma^2\,\nabla_{\tilde{\boldsymbol{x}}}\cdot D(\tilde{\boldsymbol{x}}) - D\sigma^2 \tag{3.3.7}$$

（末項の D は入力次元。デノイザと同じ記号なので注意。）

意味

右辺はノイズ付き $\tilde{\boldsymbol{x}}$ だけで計算できる。
期待値をとると、未知のきれいな $\boldsymbol{x}$ に対する真の MSE と一致する。

補足：SURE 最適＝ Tweedie のデノイザ

期待 SURE を最小化すると、Bayes デノイザ

$$D^\star(\tilde{\boldsymbol{x}}) = \mathbb{E}[\boldsymbol{x}|\tilde{\boldsymbol{x}}] = \tilde{\boldsymbol{x}} + \sigma^2 \nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}}) \tag{3.3.8}$$

に到達する。$D(\tilde{\boldsymbol{x}}) = \tilde{\boldsymbol{x}} + \sigma^2 s_\phi(\tilde{\boldsymbol{x}}, \sigma)$ と置くと、SURE 最小化は（定数を除き）ノイズレベル σ での Hyvärinen 形と一致する。

補足：一般化スコアマッチングの見方

古典・DSM・高次はいずれも、ある線形作用素 L について Lp/p を場 s_ϕ で当てる、と統一できる。

$$\mathcal{L}_{\mathrm{GSM}}(\phi) = \mathbb{E}_p\left[\tfrac{1}{2}\|s_\phi\|_2^2 - L^\dagger s_\phi\right] + \mathrm{const}$$

例

$L = \nabla$ なら古典的スコアマッチング。
ガウス DSM に対応する L では、$Lp_\sigma/p_\sigma = \mathbb{E}[\boldsymbol{x}|\tilde{\boldsymbol{x}}]$（Tweedie）。

3.3 全体のまとめ

1. **動機**トレース付き SM は高次元で重い。DSM は条件付き教師で避ける。
2. **学習** $\mathcal{L}_{\mathrm{DSM}}$（3.3.2）（3.3.4）で平滑化分布のスコアを学ぶ。
3. **生成**学習スコアをランジュバン（3.3.5）に入れる。
4. **意味** Tweedie により、スコア学習＝デノイザ学習である。

3.3 全体のまとめ：一本の流れ

今日の道筋

トレースが重い → ノイズを入れて条件付ける → 閉じた教師で DSM → Tweedie でノイズ除去と接続

核心

未知の周辺スコアの代わりに、自分で入れたノイズの条件付きスコアを教師にする。

次へ

3.4 では複数ノイズの NCSN へ拡張し、粗探索と細部復元を段階的に行う。