The Principles of Diffusion Models

3.4 Multi-Noise Levels of Denoising Score Matching (NCSN)

渡邉 有志

November 12, 2026

3.3 から 3.4 へ

ここまで（3.3）

単一ノイズの DSM で、条件付きスコアを教師にして周辺分布のスコアを学習できる。
Tweedie の公式により、スコア予測とノイズ除去が結びつく。

ここから（3.4）

ノイズが 1 段階だけだと、粗さ・細かさ・モード横断を同時には満たせない。
複数ノイズでスコアを条件付き学習し、アニーリングしたランジュバンで生成する（NCSN）。

3.4 の位置づけ

この節の役割

単一ノイズの DSM を、複数ノイズの NCSN へ拡張する

1. **3.4.1 動機**
   単一ノイズの限界と、複数ノイズ＋アニーリングの発想
2. **3.4.2 学習**
   ノイズ条件付きスコアネットと損失（3.4.1）、DDPM との対応
3. **3.4.3 サンプリング**
   Annealed Langevin Dynamics と、遅い理由

Song and Ermon (2019)

区切り：3.4.1 動機

3.4.1 動機

3.4.2 学習

3.4.3 サンプリング

単一ノイズでは足りない

固定分散のガウスノイズを１つだけ入れると、分布はある程度滑らかになる。
しかし、ノイズレベルを１つに固定すると次の限界が出る。

低ノイズ

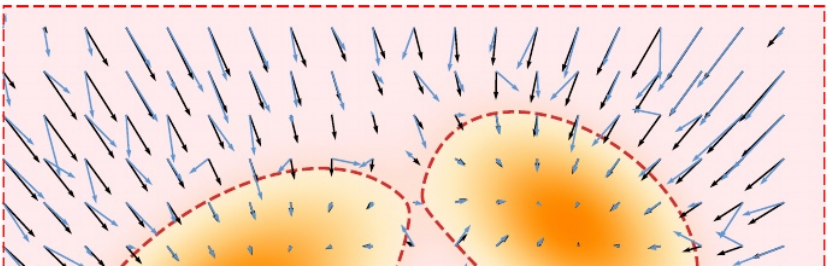
細部は残るが、低密度領域で勾配が弱く、多峰分布のモード間を渡りにくい。

高ノイズ

探索はしやすいが、粗い構造しか捉えられず、ぼけたサンプルになりやすい。

高次元では、初期化が悪いとプラトーや鞍点付近で探索が止まり、一つのモードに閉じ込もり得る。

図 3.6：低密度ではスコア推定が不安定



赤の領域はサンプルが少なく、スコア推定が不正確になりやすい。
高密度側では推定が比較的安定する。

補足：図 3.6 の読み方

オレンジの島

データの高密度領域である。
ここでのスコアは、サンプルが多いため比較的信じやすい。

赤い低密度領域

観測が薄いので、スコアマッチングの誤差が大きくなりやすい。
ランジュバンがモード間を渡るときに通る場所でもある。

単一ノイズの難しさ

細部を残す低ノイズでは、この低密度の壁が残りやすい。
壁を消す高ノイズでは、細部が潰れる。

複数ノイズとアニーリングで両方を取る

Song and Ermon (2019) は、複数レベルのガウスノイズを入れ、ノイズ条件付きスコアネット（NCSN）をまとめて学習する。

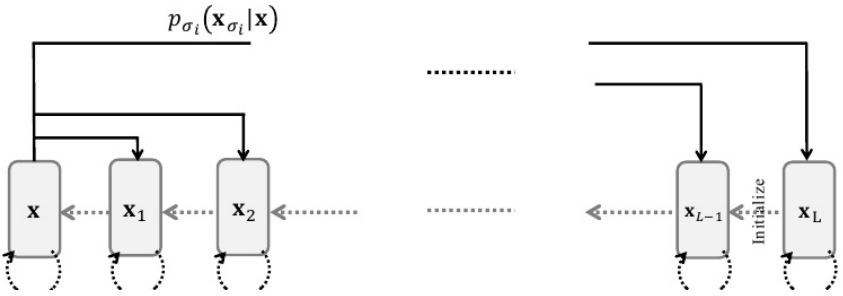
生成時

ノイズをアニーリングするランジュバン動力学を使う。

- 高ノイズ：粗い探索でモード間を渡りやすくする
- 低ノイズ：細部を復元する

- 学習：$s_\phi(\boldsymbol{x}, \sigma)$ を多くの σ で同時に当てる
- 生成：大きい σ から小さい σ へ段階的に移る

図 3.7：NCSN の流れ



前方は複数ノイズ $p_\sigma(\boldsymbol{x}_\sigma|\boldsymbol{x})$ でデータを崩す。
生成（破線）は各ノイズでランジュバンし、次のより低いノイズの初期値にする。

補足：図 3.7 の読み方

上向きの実線

きれいな $\boldsymbol{x}$ から、各ノイズレベル σ_i の $\boldsymbol{x}_i$ を作る前向き過程。

破線の右 $\rightarrow$ 左

$\boldsymbol{x}_L$ から $\boldsymbol{x}$ へ戻る生成。
各段の下のループが、そのノイズでのランジュバン更新。

Initialize

あるノイズ段の最終状態を、ひとつ小さいノイズ段の初期値にする。
これがアニーリングの本体である。

3.4.1 のまとめ

- 単一ノイズでは、細部保存とモード横断を両立しにくい
- 低密度ではスコア推定が不安定になりやすい（図 3.6）
- NCSN は複数ノイズで学習し、高 → 低へアニーリングして生成する

次

複数ノイズでの学習目的関数を書く。

区切り：3.4.2 学習

3.4.1 動機

3.4.2 学習

3.4.3 サンプリング

複数のノイズレベルを用意する

ノイズ列 $\{\sigma_i\}_{i=1}^{L}$ を

$$0 < \sigma_1 < \sigma_2 < \cdots < \sigma_L$$

となるように選ぶ。

- σ_1：細部がほぼ残る程度に小さい
- σ_L：分布が十分滑らかになる程度に大きい

各ノイズでは、きれいなデータ $\boldsymbol{x} \sim p_{\text{data}}$ に

$$\boldsymbol{x}_\sigma = \boldsymbol{x} + \sigma \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I})$$

を加える。

摂動核と周辺分布

摂動核

$$p_\sigma(\boldsymbol{x}_\sigma|\boldsymbol{x}) := \mathcal{N}(\boldsymbol{x}_\sigma;\, \boldsymbol{x},\, \sigma^2 \boldsymbol{I})$$

周辺分布

$$p_\sigma(\boldsymbol{x}_\sigma) = \int p_\sigma(\boldsymbol{x}_\sigma|\boldsymbol{x})\, p_{\mathrm{data}}(\boldsymbol{x})\, d\boldsymbol{x}$$

各 σ での、ガウス平滑化されたデータ分布である。

NCSN の学習目的

ノイズ条件付きスコアネット $s_\phi(\boldsymbol{x}, \sigma)$ で、すべての $\sigma \in \{\sigma_i\}_{i=1}^L$ について
$\nabla_{\boldsymbol{x}} \log p_\sigma(\boldsymbol{x})$ を推定する。

$$\mathcal{L}_{\mathrm{NCSN}}(\phi) := \sum_{i=1}^{L} \lambda(\sigma_i)\, \mathcal{L}_{\mathrm{DSM}}(\phi; \sigma_i) \tag{3.4.1}$$

ここで $\lambda(\sigma_i) > 0$ は各スケールの重みである。

$$\mathcal{L}_{\mathrm{DSM}}(\phi; \sigma) = \frac{1}{2} \mathbb{E}_{\boldsymbol{x} \sim p_{\mathrm{data}},\, \tilde{\boldsymbol{x}} \sim p_\sigma(\cdot|\boldsymbol{x})} \left\| s_\phi(\tilde{\boldsymbol{x}}, \sigma) - \frac{\boldsymbol{x} - \tilde{\boldsymbol{x}}}{\sigma^2} \right\|_2^2$$

補足：単一 DSM の和になっている

各 σ_i での $\mathcal{L}_{\mathrm{DSM}}$ は 3.3 の DSM そのものである。
教師は条件付きスコア $\nabla_{\tilde{\boldsymbol{x}}} \log p_\sigma(\tilde{\boldsymbol{x}}|\boldsymbol{x}) = (\boldsymbol{x} - \tilde{\boldsymbol{x}})/\sigma^2$。

最適解

定理 3.3.1 より、各ノイズで

$$s^\star(\cdot, \sigma) = \nabla_{\boldsymbol{x}} \log p_\sigma(\cdot)$$

が得られる。NCSN はそれを全 σ_i で同時に求める。

DDPM 損失との関係

$\boldsymbol{x}_\sigma = \boldsymbol{x} + \sigma\boldsymbol{\epsilon}$ とし、Tweedie より

$$\nabla_{\boldsymbol{x}_\sigma} \log p_\sigma(\boldsymbol{x}_\sigma) = -\frac{1}{\sigma}\,\mathbb{E}[\boldsymbol{\epsilon}|\boldsymbol{x}_\sigma]$$

したがって

$$s^\star(\boldsymbol{x}_\sigma, \sigma) = -\frac{1}{\sigma}\,\boldsymbol{\epsilon}^\star(\boldsymbol{x}_\sigma, \sigma), \qquad \boldsymbol{\epsilon}^\star(\boldsymbol{x}_\sigma, \sigma) = -\sigma\, s^\star(\boldsymbol{x}_\sigma, \sigma)$$

読み方

DDPM の最適ノイズ予測と、NCSN の最適スコアは、既知のスケール $1/\sigma$ を除いて同じ情報をもつ。

補足：DDPM のステップ表記との対応

DDPM では

$$\sigma_i := \sqrt{1 - \bar{\alpha}_i^2}, \qquad \boldsymbol{x}_i = \bar{\alpha}_i \boldsymbol{x}_0 + \sigma_i \boldsymbol{\epsilon}$$

と書ける。このとき

$$s^\star(\boldsymbol{x}_i, i) = -\frac{1}{\sigma_i}\, \mathbb{E}[\boldsymbol{\epsilon} | \boldsymbol{x}_i]$$

要点

ステップ i でのノイズ予測は、ノイズレベル i でのスコア予測と等価である（係数 $1/\sigma_i$ を除く）。
系統的な比較は第 6 章に回す。

3.4.2 のまとめ

- 複数ノイズ $0 < \sigma_1 < \cdots < \sigma_L$ で DSM を足し合わせる（3.4.1）
- ネットは $s_\phi(\boldsymbol{x}, \sigma)$ としてノイズを条件に取る
- 最適スコアと DDPM の最適ノイズ予測は $1/\sigma$ で互いに移る

次

学習した複数スコアを、アニーリング・ランジュバンで使う。

区切り：3.4.3 サンプリング

3.4.1 動機

3.4.2 学習

3.4.3 サンプリング

Annealed Langevin Dynamics

学習済みスコア $s_{\phi^\star}(\cdot, \sigma_1), \ldots, s_{\phi^\star}(\cdot, \sigma_L)$ を使い、大きいノイズ σ_L から小さいノイズ $\sigma_1 \approx 0$ へ進む。

1. $\boldsymbol{x} \sim p_{\text{init}}$（最大ノイズ向けの雑な初期分布）
2. $\ell = L, L-1, \ldots, 1$ について：
   - 前段の出力を初期値 $\tilde{\boldsymbol{x}}_0 \leftarrow \boldsymbol{x}$ にする
   - σ_ℓ でランジュバンを N_ℓ 回回す
   - 最終状態を次段へ渡す

最終的に最小ノイズ σ_1 での洗練を経た $\boldsymbol{x}$ を出力する。

各ノイズでの更新則

ノイズレベル σ_ℓ では

$$\tilde{\boldsymbol{x}}_{n+1} = \tilde{\boldsymbol{x}}_n + \eta_\ell \, s_{\phi^\star}(\tilde{\boldsymbol{x}}_n, \sigma_\ell) + \sqrt{2\eta_\ell}\, \boldsymbol{\epsilon}_n, \qquad \boldsymbol{\epsilon}_n \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$

ステップ幅の典型例は

$$\eta_\ell = \delta \, \frac{\sigma_\ell^2}{\sigma_1^2}, \qquad \delta > 0$$

要点

ノイズが大きいほどステップを大きく取り、ノイズが小さくなるほど細かく動かす。

補足：アルゴリズムの骨格

1. $\boldsymbol{x} \sim p_{\text{init}}$
2. **for** $\ell = L, L-1, \ldots, 1$ **do**
   - 2.1 $\tilde{\boldsymbol{x}}_0 \leftarrow \boldsymbol{x}$
   - 2.2 **for** $n = 0, \ldots, N_\ell - 1$ **do**
     - 2.2.1 $\boldsymbol{\epsilon}_n \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I})$
     - 2.2.2 $\tilde{\boldsymbol{x}}_{n+1} \leftarrow \tilde{\boldsymbol{x}}_n + \eta_\ell s_{\phi^\star}(\tilde{\boldsymbol{x}}_n, \sigma_\ell) + \sqrt{2\eta_\ell}\,\boldsymbol{\epsilon}_n$
   - 2.3 $\boldsymbol{x} \leftarrow \tilde{\boldsymbol{x}}_{N_\ell}$
3. 出力 $\boldsymbol{x}$

読み方

外側のループがノイズのアニーリング、内側のループがそのノイズでの MCMC である。

NCSN のサンプリングは遅い

各ノイズ σ_i で、スコア評価＋微小ノイズの更新を K 回繰り返す。
全体でおおよそ $L \times K$ 回の順次ネット評価が要る。

(i) 局所精度

学習したスコアは小さな摂動向きに信頼できる。
ステップを小さくし、段ごとに多数回回す必要がある。

(ii) 混合の遅さ

高次元・多峰では局所的な MCMC 移動が非効率で、典型領域へ届くまで反復が増える。

更新は直前状態に依存し並列化しにくいので、計算コストは $\mathcal{O}(LK)$ になる。

3.4.3 のまとめ

- 生成は高ノイズから低ノイズへ、段ごとにランジュバンする
- 前段の出力が次段の初期値になる（アニーリング）
- 段数 × 段内反復のため、サンプリングは計算的に重い

3.4 全体のまとめ

1. **動機**単一ノイズでは粗さ・細部・モード横断を同時に満たせない。
2. **学習** $s_\phi(\boldsymbol{x}, \sigma)$ を複数 σ の DSM 和（3.4.1）で学ぶ。
   DDPM のノイズ予測とは $1/\sigma$ で等価。
3. **生成** Annealed Langevin で $\sigma_L \to \sigma_1$ と洗練する。
4. **課題** $\mathcal{O}(LK)$ の順次評価によりサンプリングが遅い。

3.4 全体のまとめ：一本の流れ

今日の道筋

単一ノイズの限界 $\rightarrow$ 複数ノイズでスコアを条件付き学習 $\rightarrow$ 高 $\rightarrow$ 低へアニーリング生成 $\rightarrow$ ただし MCMC が重い

核心

NCSN は「どのくらい崩れた分布のスコアか」を σ で条件付け、粗い探索から細部復元へ段階的に戻す。

次へ

3.5 では NCSN と DDPM を表で比較し、共通点と違いを整理する。