The Principles of Diffusion Models

4.1 Score SDE: Its Principles

渡邉 有志

November 13, 2026

第 3 章から第 4 章へ

ここまで（第 3 章）

NCSN は複数ノイズの離散はしごでスコアを学び、
Annealed Langevin で高 $\sigma \to$ 低 σ と生成する。
DDPM も離散ステップの前向き／逆向き過程である。

ここから（4.1）

ノイズレベルを連続時間 $t \in [0, T]$ に広げ、
前向き過程を SDE、生成を逆時間 SDE ／ PF-ODE として定式化する。
鍵は時間依存スコア $\nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x})$ である。

4.1 の位置づけ

この節の役割

離散のはしごを連続化し、前向き・逆向き・確定的流を一本の枠にまとめる

1. **動機**
   NCSN ／ DDPM の離散更新 $\rightarrow$ 共通形 $\rightarrow$ 前向き SDE
2. **前向き SDE**
   データ $\rightarrow$ ノイズ（式 4.1.3）。周辺 p_t を定義する
3. **逆時間 SDE**
   スコア補正でノイズ $\rightarrow$ データ（式 4.1.6）
4. **PF-ODE と周辺の一致**
   同じ $\{p_t\}$ を確率的／確定的に辿る（論文 4.2 の要点）

区切り：動機（離散 → 連続）

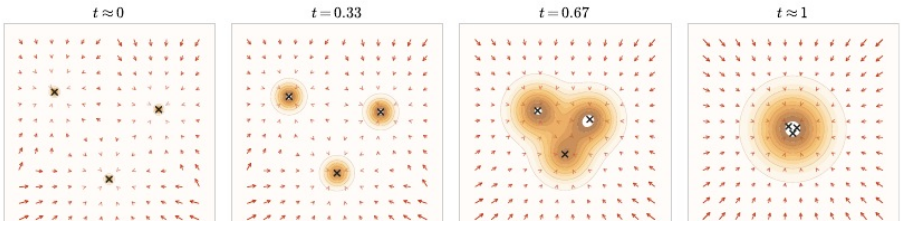
動機：離散から連続へ

前向き SDE

逆時間 SDE

PF-ODE と周辺の一致

図 4.1：時間依存のスコア場



ノイズが増えると p_t は多峰 $\to$ 単峰へ。
スコア $\nabla_{\boldsymbol{x}} \log p_t$ は局所的な引き寄せから、大域的な中心向きへ変わる。

補足：図 4.1 の読み方

$t \approx 0$

モード近傍に鋭い場。
近くの峰へ強く引き戻す。

$t \approx 1$

平滑な単峰。
全体の重心へ穏やかに向く。

Score SDE の学習対象

この時間依存スコアの族を学ぶことが、
生成＝微分方程式を解く、という問題設定になる。

NCSN と DDPM の離散ノイズ注入

NCSN：増加列 $\{\sigma_i\}$ で

$$\boldsymbol{x}_{\sigma_i} = \boldsymbol{x}_0 + \sigma_i \boldsymbol{\epsilon}_i, \qquad \boldsymbol{\epsilon}_i \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$

DDPM：分散スケジュール $\{\beta_i\}$ で

$$\boldsymbol{x}_i = \sqrt{1-\beta_i}\, \boldsymbol{x}_{i-1} + \sqrt{\beta_i}\, \boldsymbol{\epsilon}_i$$

見方

どちらも「少しずつノイズを足す」離散更新である。
連続極限では同じ構造の SDE に乗る。

共通の 1 ステップ形

離散時刻での更新はおおむね

$$\boldsymbol{x}_{t+\Delta t} \approx \boldsymbol{x}_t + \boldsymbol{f}(\boldsymbol{x}_t, t)\,\Delta t + g(t)\sqrt{\Delta t}\,\boldsymbol{\epsilon}_t \tag{4.1.1}$$

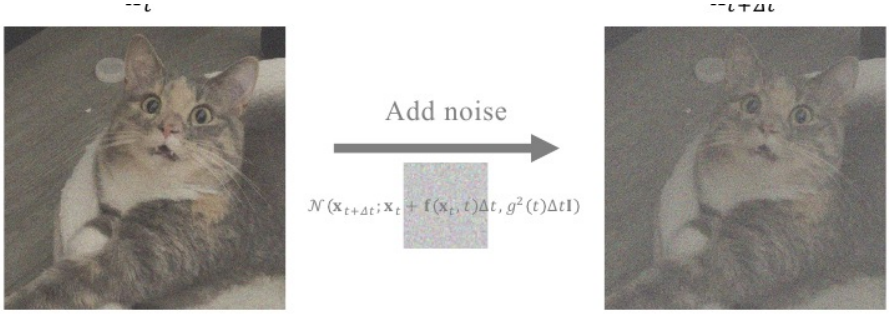
NCSN

$\boldsymbol{f} = \boldsymbol{0}$,
$g(t) = \sqrt{\dfrac{d\sigma^2(t)}{dt}}$

DDPM

$\boldsymbol{f} = -\dfrac{1}{2}\beta(t)\boldsymbol{x}$,
$g(t) = \sqrt{\beta(t)}$

図 4.2：離散のノイズ追加ステップ



遷移は $\mathcal{N}\big(\boldsymbol{x}_{t+\Delta t};\, \boldsymbol{x}_t + \boldsymbol{f}\Delta t,\, g^2(t)\Delta t\, \boldsymbol{I}\big)$（式 4.1.2）。

$\Delta t \to 0$ で前向き SDE へ

$$d\boldsymbol{x}(t) = \boldsymbol{f}(\boldsymbol{x}(t), t)\, dt + g(t)\, d\boldsymbol{w}(t)$$

対応の読み方：

- $\boldsymbol{x}(t + \Delta t) - \boldsymbol{x}(t) \approx d\boldsymbol{x}(t)$
- $\Delta t \approx dt$
- $\sqrt{\Delta t}\, \boldsymbol{\epsilon}_t \approx d\boldsymbol{w}(t)$ $(d\boldsymbol{w}(t) \sim \mathcal{N}(\boldsymbol{0}, dt\, \boldsymbol{I}))$

要点

ドリフト $\boldsymbol{f}$ と拡散 g を決めれば前向き過程は確定する。
逆過程に残る未知は、各時刻のスコアだけである。

動機のまとめ

- 複数ノイズのはしごは、連続時間のスコア場へ一般化できる
- NCSN ／ DDPM の 1 ステップは共通形（4.1.1）に乗る
- $\Delta t \to 0$ で前向き SDE になり、生成は逆過程の数値積分になる

次

前向き SDE が誘導する摂動核と周辺 p_t を書く。

区切り：前向き SDE

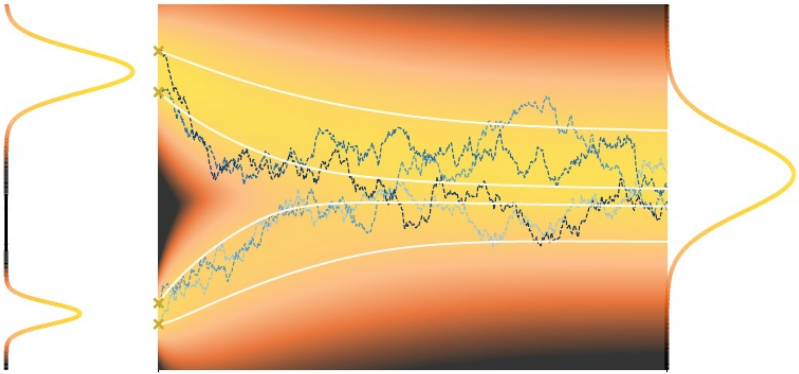
動機：離散から連続へ

前向き SDE

逆時間 SDE

PF-ODE と周辺の一致

図4.3：データからノイズへ



青：確率的な前向き SDE 軌跡。白：同じ周辺を辿る PF-ODE。
背景は周辺密度 p_t の時間発展。

前向き SDE の定義

$[0, T]$ 上の確率過程

$$d\boldsymbol{x}(t) = \boldsymbol{f}(\boldsymbol{x}(t), t)\, dt + g(t)\, d\boldsymbol{w}(t), \qquad \boldsymbol{x}(0) \sim p_{\text{data}} \tag{4.1.3}$$

- $\boldsymbol{f}(\cdot, t)$：ドリフト
- $g(t)$：スカラー拡散係数
- $\boldsymbol{w}(t)$：標準 Wiener 過程

NCSN ／ DDPM はこの連続枠に埋め込まれる。

摂動核と周辺密度

摂動核

$p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)$：きれいな $\boldsymbol{x}_0$ が時刻 t でどう崩れるか。
アフィン・ドリフト $\boldsymbol{f}(\boldsymbol{x}, t) = f(t)\boldsymbol{x}$ ならガウスで閉じる（シミュレーション不要）。

周辺

$$p_t(\boldsymbol{x}_t) := \int p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\, p_{\text{data}}(\boldsymbol{x}_0)\, d\boldsymbol{x}_0 \tag{4.1.5}$$

$p_0 = p_{\text{data}}$。T を十分大きく取ると $p_T \approx p_{\text{prior}}$（典型的にはガウス）。

補足：アフィン・ドリフトなら平均・分散が閉じる

$\boldsymbol{f}(\boldsymbol{x}, t) = f(t)\boldsymbol{x}$（$f(t) \le 0$ が多い）なら

$$p_t(\boldsymbol{x}_t|\boldsymbol{x}_0) = \mathcal{N}\big(\boldsymbol{x}_t;\, m(t),\, P(t)\boldsymbol{I}\big)$$

$$m(t) = \exp\Big(\int_0^t f(u)\,du\Big)\boldsymbol{x}_0, \quad P(t) = \int_0^t \exp\Big(2\int_s^t f(u)\,du\Big) g^2(s)\,ds$$

意味

$\boldsymbol{x}_t|\boldsymbol{x}_0$ を SDE 積分なしで直接サンプルできる。
NCSN・DDPM はこの設定に属する。具体形は 4.4 へ。

前向き SDE のまとめ

- 式（4.1.3）がデータ $\to$ ノイズの連続過程を定義する
- 周辺 $\{p_t\}$ が学習・生成の共通の舞台になる
- $p_T \approx p_{\text{prior}}$ なら、生成の初期分布が扱いやすい

次

この周辺列を逆向きに辿る逆時間 SDE を書く。

区切り：逆時間 SDE

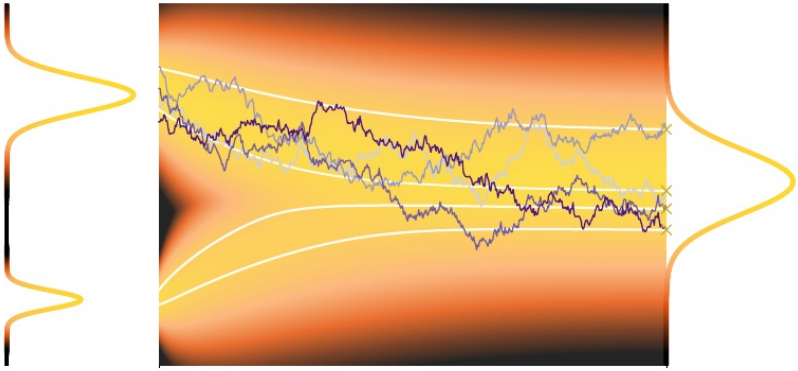
動機：離散から連続へ

前向き SDE

逆時間 SDE

PF-ODE と周辺の一致

図4.4：ノイズからデータへ



$t = T$ の事前から逆時間 SDE で戻すと、$t = 0$ で目標の多峰分布に集まる。

Anderson の逆時間 SDE

個別のブラウン軌跡は単純には逆回せないが、
周辺分布の族は逆時間 SDE で再現できる（Anderson, 1982）：

$$d\bar{\boldsymbol{x}}(t) = \left[\boldsymbol{f}(\bar{\boldsymbol{x}}(t), t) - g^2(t)\nabla_{\boldsymbol{x}} \log p_t(\bar{\boldsymbol{x}}(t))\right] dt + g(t)\, d\bar{\boldsymbol{w}}(t) \tag{4.1.6}$$

$\bar{\boldsymbol{x}}(T) \sim p_{\text{prior}} \approx p_T$。
時計 t はデータ $= 0$、ノイズ $= T$。逆向き積分では $dt < 0$。

スコア補正が必要な理由

拡散 $g \neq 0$ があると、ドリフトをそのまま時間反転しただけでは足りない。
補正項 $-g^2(t)\nabla_{\boldsymbol{x}} \log p_t$ が、前向きと同じ周辺発展を保証する。

ランジュバンとの接続（$f \equiv 0$）

逆時計 $s = T - t$ で書き直すと、温度が時間変化するランジュバン形になる。
スコアは各時刻の「きれいな信号」側へ引き戻す（Tweedie）。

アニーリング

早い段階（$t \approx T$）では g が大きく探索しやすい。
$t \to 0$ で確率的項が弱まり、高密度領域へ集中する。

未知は時間依存スコアだけ

前向きの $\boldsymbol{f}, g$ を決めたあと、逆過程に残る未知は

$$s(\boldsymbol{x}, t) := \nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x})$$

だけである。ネット $s_\phi(\boldsymbol{x}, t)$ で近似すれば（4.3 で学習）、
式（4.1.6）を $t = T \to 0$ と解けば生成になる。

保証

前向きと逆向きの周辺は一致する。
よって $t = 0$ のサンプルは p_{data} に近い。

逆時間SDEのまとめ

- 生成＝事前から式（4.1.6）を逆向きに数値積分すること
- スコア補正 $-g^2\nabla \log p_t$ が周辺の整合を担う
- 学習対象は $s_\phi(\boldsymbol{x}, t) \approx \nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x})$

次

確率を入れない確定的な流れ（PF-ODE）もある。

区切り：PF-ODE と周辺の一致

動機：離散から連続へ

前向き SDE

逆時間 SDE

PF-ODE と周辺の一致

Question：SDE でサンプルする必要があるか？

逆時間 SDE は確率的で多様性を出しやすいが、
同じ周辺 $\{p_t\}$ を辿る確定的な ODE も存在する。

Probability Flow ODE（PF-ODE）

$$\frac{d\tilde{\boldsymbol{x}}(t)}{dt} = \boldsymbol{f}(\tilde{\boldsymbol{x}}(t), t) - \tfrac{1}{2} g^2(t) \nabla_{\boldsymbol{x}} \log p_t(\tilde{\boldsymbol{x}}(t)) \tag{4.1.7}$$

学習スコアを代入し、$t = T \to 0$ と解けば生成できる。
係数 $\frac{1}{2}$ は「拡散項を消しただけ」ではない（Fokker–Planck から来る）。

PF-ODE の利点

双方向

同じ式を $0 \to T$ にも $T \to 0$ にも使える。
（SDE は一般に前向き向きが基本）

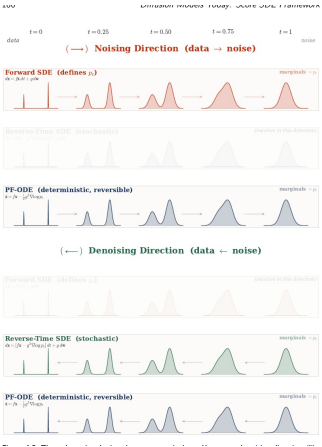
数値解法

ODE 用の既存ソルバがそのまま使える。
高速化の議論は第 9 章へ。

注意

周辺は同じでも、サンプル軌跡の法則は SDE と ODE で異なる。

図4.5：同じ周辺、違うダイナミクス



補足：図 4.5 の読み方

上段（ノイズ化）

前向き SDE が $\{p_t\}$ を定義する。
PF-ODE を前向きに解いても同じ周辺列を辿る。

下段（デノイズ）

逆時間 SDE と PF-ODE を $T \to 0$ で解くと、
再び同じ $\{p_t\}$ を逆向きに再現する。

ポイント

スナップショットの密度が揃うことと、
軌跡が同じであることとは別である。

定理 4.2.1：Fokker–Planck による周辺の一致

前向き SDE の周辺 p_t は

$$\partial_t p_t(\boldsymbol{x}) = -\nabla_{\boldsymbol{x}} \cdot \left[\boldsymbol{v}(\boldsymbol{x}, t)\, p_t(\boldsymbol{x})\right] \tag{4.2.1}$$

$$\boldsymbol{v}(\boldsymbol{x}, t) := \boldsymbol{f}(\boldsymbol{x}, t) - \tfrac{1}{2} g^2(t) \nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x})$$

を満たす。同じ $\{p_t\}$ は次のどちらでも実現できる。

1. PF-ODE：$\dfrac{d\tilde{\boldsymbol{x}}}{dt} = \boldsymbol{v}$（双方向）
2. 逆時間 SDE：式（4.1.6）を $T \to 0$

Observation：周辺が揃えば生成過程は一つでなくてよい

核心

大事なのは Fokker–Planck を満たして $\{p_t\}$ を再現すること。
確率的か確定的か、どの条件付きを使うかは設計の自由度である。

- 確率的核 $p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)$（シミュレーション不要な場合も）
- 確定的流 $\delta\big(\boldsymbol{x}_t - \Psi_{0\to t}(\boldsymbol{x}_0)\big)$（ODE を解く）
- その混合なども、同じ周辺 p_t を与え得る

この非一意性は、のちの Flow Matching などでも再登場する。

補足：ガウス例のスケッチ（論文 4.2.2）

p_{data} がガウスなら各 p_t もガウスで、スコアが閉じる。

逆時間 SDE

微小ステップの Bayes 逆遷移を $\Delta t \to 0$ で展開すると、
一般形（4.1.6）と同じドリフト＋拡散が得られる。

PF-ODE

平均・分散の ODE を前向き SDE と一致させるアフィン速度を選ぶと、
式（4.1.7）が出る。周辺ガウスは両者で同一。

一般論（Anderson ／ Fokker–Planck）を、計算だけで検算できる例である。

PF-ODE ／周辺一致のまとめ

- PF-ODE（4.1.7）は同じ $\{p_t\}$ を確定的に運ぶ
- Fokker–Planck（4.2.1）が「周辺が揃う」原理である
- 軌跡の法則は違ってよく、生成器の設計に自由度がある

4.1 全体のまとめ

1. **連続化**離散はしご $\to$ 前向き SDE（4.1.3）
2. **生成（確率的）**逆時間 SDE（4.1.6）。未知はスコアのみ
3. **生成（確定的）**PF-ODE（4.1.7）。双方向・ODE ソルバ向き
4. **周辺**どちらも同じ $\{p_t\}$（Fokker–Planck ／定理 4.2.1）

4.1 全体のまとめ：一本の流れ

今日の道筋

離散ノイズ $\rightarrow$ 前向き SDE $\rightarrow$ スコア付き逆過程 $\rightarrow$ PF-ODE と周辺の一致

核心

時間依存スコア $\nabla_{\boldsymbol{x}} \log p_t$ を学べば、
生成は逆時間 SDE または PF-ODE を解く問題になる。

次へ

4.2 では、このスコアを DSM で学び、
逆 SDE ／ PF-ODE でサンプル（および尤度）する方法を見る。