The Principles of Diffusion Models

4.2 Score SDE: Its Training and Sampling

渡邉 有志

November 13, 2026

4.1 から 4.2 へ

ここまで（4.1）

前向き SDE が周辺 $\{p_t\}$ を定義し、
逆時間 SDE ／ PF-ODE はスコア $\nabla_{\boldsymbol{x}} \log p_t$ で生成する。
周辺は揃うが、軌跡の法則は違ってよい。

ここから（4.2 ＝論文 4.3）

時間条件付きネット $s_\phi(\boldsymbol{x}, t)$ を DSM で学習する。
学習スコアを逆 SDE ／ PF-ODE に入れてサンプルし、
PF-ODE では尤度評価もできる。

4.2 の位置づけ

この節の役割

原理（SDE ／ ODE）を、学習とサンプリングの手続きに落とす

1. **学習**
   時間依存 DSM（式 4.3.1）と最適解（命題 4.3.1）
2. **サンプリング**
   経験逆時間 SDE（4.3.3）（4.3.4）と経験 PF-ODE（4.3.5）（4.3.6）
3. **尤度**
   前向き PF-ODE ＋変数変換（式 4.3.7）

フォルダ字幕は「4.2 Training and Sampling」。内容は論文 §4.3。

区切り：学習（DSM）

学習（DSM）

サンプリング

反転と尤度

時間条件付きスコアネット

第 3 章と同じ思想で、オラクル $\nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x})$ を

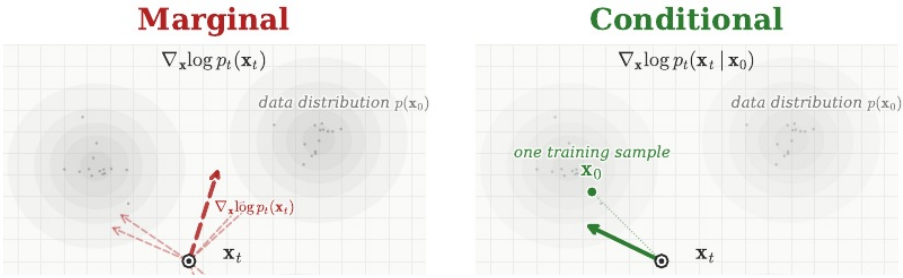
$$s_\phi = s_\phi(\boldsymbol{x}, t) \qquad (t \in [0, T])$$

で近似する。素朴なスコアマッチングは

$$\mathcal{L}_{\mathrm{SM}}(\phi; \omega) := \frac{1}{2} \mathbb{E}_{t \sim p_{\mathrm{time}}} \mathbb{E}_{\boldsymbol{x}_t \sim p_t} \left[\omega(t) \left\| s_\phi(\boldsymbol{x}_t, t) - \nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x}_t) \right\|_2^2 \right]$$

だが、教師 $\nabla \log p_t$ は一般に未知である。

図4.6：DSMのトリック



左：周辺スコアは全データの寄与の和で扱いづらい。
右：訓練時は $\boldsymbol{x}_0$ が分かるので、条件付きスコアが閉じた教師になる。

補足：図 4.6 の読み方

左（周辺）

固定 $\boldsymbol{x}_t$ への寄与を、
あり得るきれいな $\boldsymbol{x}_0$ 全体で足す必要がある。

右（条件付き）

そのサンプルを作った $\boldsymbol{x}_0$ だけを使う。
ガウス摂動なら教師は明示できる。

平均の意味

条件付きスコアを多くの $(\boldsymbol{x}_0, \boldsymbol{x}_t)$ で回帰すると、
平均的には周辺スコアに一致する。

連続時間の DSM 損失

$$\mathcal{L}_{\mathrm{DSM}}(\phi;\omega) := \frac{1}{2}\mathbb{E}_t\mathbb{E}_{\boldsymbol{x}_0}\mathbb{E}_{p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)}\left[\omega(t)\left\|s_\phi(\boldsymbol{x}_t,t)-\nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\right\|_2^2\right] \tag{4.3.1}$$

読み方

離散 NCSN の和（3.4.1）の連続版。
和 $\sum_i$ が時間期待 $\mathbb{E}_t$ に置き換わる。

命題 4.3.1：DSM の最小化子

最小化子 $s^\star$ は、ほとんどすべての $\boldsymbol{x}_t \sim p_t$ と t について

$$s^\star(\boldsymbol{x}_t, t) = \mathbb{E}_{\boldsymbol{x}_0 \sim p(\boldsymbol{x}_0|\boldsymbol{x}_t)}\left[\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\right] = \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t) \tag{4.3.2}$$

意味

条件付きスコアへの回帰でも、欲しい周辺スコアが一意に得られる。
（定理 3.3.1 の連続時間版）

学習のまとめ

- ネットは $s_\phi(\boldsymbol{x}, t)$：時刻を条件にする
- 実用は DSM（4.3.1）。教師は $\nabla \log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)$
- 最適解は周辺スコアそのもの（4.3.2）

次

学習スコアを逆時間 SDE ／ PF-ODE に代入してサンプルする。

区切り：サンプリング

学習（DSM）

サンプリング

反転と尤度

経験逆時間 SDE

$s_{\phi^\star}(\boldsymbol{x}, t) \approx \nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x})$ を式（4.1.6）へ代入：

$$d\boldsymbol{x}^{\mathrm{SDE}}(t) = \left[\boldsymbol{f}(\boldsymbol{x}^{\mathrm{SDE}}(t), t) - g^2(t)\, s_{\phi^\star}(\boldsymbol{x}^{\mathrm{SDE}}(t), t)\right] dt + g(t)\, d\bar{\boldsymbol{w}}(t) \tag{4.3.3}$$

$\boldsymbol{x}_T \sim p_{\mathrm{prior}}$ から $t = T \to 0$ と数値積分する。

Euler–Maruyama 更新

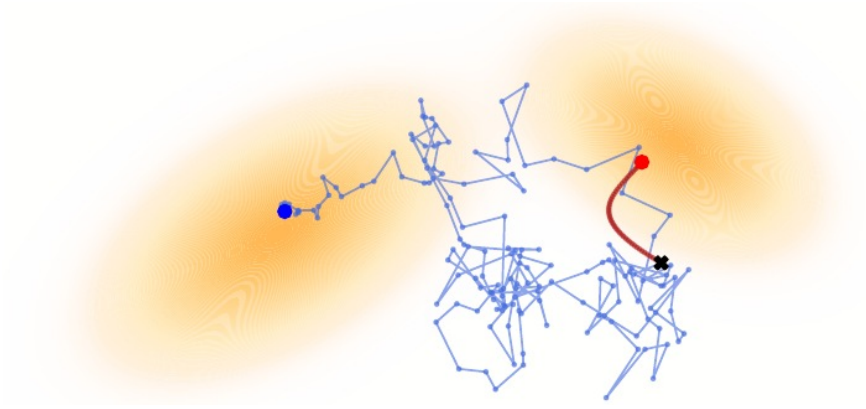
ステップ幅 $\Delta t > 0$、$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$ として

$$\boldsymbol{x}_{t-\Delta t} \leftarrow \boldsymbol{x}_t - \left[\boldsymbol{f}(\boldsymbol{x}_t, t) - g^2(t)\, s_{\phi^\star}(\boldsymbol{x}_t, t)\right]\Delta t + g(t)\sqrt{\Delta t}\,\boldsymbol{\epsilon} \tag{4.3.4}$$

結果

最終状態の分布 $p_{\phi^\star}^{\mathrm{SDE}}(\cdot; 0) \approx p_{\mathrm{data}}$。
VP 構成では、DDPM サンプリングの連続極限と一致する（4.4）。

図 4.7：逆 SDE と PF-ODE の軌跡



青：逆時間 SDE（確率的）。赤：PF-ODE（確定的）。
どちらも $t \to 0$ で p_{data} の支持へ向かう。

補足：図 4.7 の設定

前向き

$d\boldsymbol{x} = \sqrt{2t}\, d\boldsymbol{w}$（$\boldsymbol{f} \equiv \boldsymbol{0}$）。
2 峰混合 p_0 が $p_T \approx \mathcal{N}(\boldsymbol{0}, T^2\boldsymbol{I})$ へ広がる。

生成

暗い $\times$ が $\boldsymbol{x}_T \sim p_{\text{prior}}$。
青は式（4.3.4）、赤は式（4.3.6）の数値解。

読み方

周辺は同じでも、1 本の道のりは確率的と確定的で見た目が違う。

経験 PF-ODE によるサンプリング

式（4.1.7）のスコアを $s_{\phi^\star}$ に置換：

$$\frac{d\boldsymbol{x}^{\mathrm{ODE}}(t)}{dt} = \boldsymbol{f}(\boldsymbol{x}^{\mathrm{ODE}}(t), t) - \tfrac{1}{2} g^2(t)\, s_{\phi^\star}(\boldsymbol{x}^{\mathrm{ODE}}(t), t) \tag{4.3.5}$$

Euler 法では

$$\boldsymbol{x}_{t-\Delta t} \leftarrow \boldsymbol{x}_t - \Big[\boldsymbol{f}(\boldsymbol{x}_t, t) - \tfrac{1}{2} g^2(t)\, s_{\phi^\star}(\boldsymbol{x}_t, t)\Big]\Delta t \tag{4.3.6}$$

Insight：生成＝ODE／SDE を解くこと

Insight 4.3.1

拡散モデルからのサンプリングは、
本質的に確率流 ODE または逆時間 SDE を解くことと等価である。

- だから反復が多く、生成が遅い（第 3 章の問いへの答え）
- 一方で、ODE 加速の文献をそのまま借りやすい（第 9 章）
- 典型的には数千回の関数評価が使われる例が多い

サンプリングのまとめ

- 逆 SDE：式（4.3.3）を Euler–Maruyama（4.3.4）で $T \to 0$
- PF-ODE：式（4.3.5）を Euler（4.3.6）などで $T \to 0$
- 生成コストの本体は、微分方程式の反復求解である

次

同じ PF-ODE で、符号化と尤度評価もできる。

区切り：反転と尤度

学習（DSM）

サンプリング

反転と尤度

PF-ODE の反転（符号化）

SDE と違い、同じ式（4.3.5）を $0 \to T$ にも解ける。

前向きに解く

データ $\boldsymbol{x}_0$ を、各 t の潜在表現へ運ぶ（エンコーダ）。
画像翻訳・編集など、制御可能な生成の土台になる。

逆向きに解く

事前からデータへ戻す（通常の生成）。

尤度：変数変換に沿った密度の変化

学習済み速度場

$$\boldsymbol{v}_{\phi^\star}(\boldsymbol{x}, t) := \boldsymbol{f}(\boldsymbol{x}, t) - \tfrac{1}{2} g^2(t)\, s_{\phi^\star}(\boldsymbol{x}, t)$$

に沿う軌跡では

$$\frac{d}{dt} \log p^{\mathrm{ODE}}_{\phi^\star}(\boldsymbol{x}(t); t) = -\nabla_{\boldsymbol{x}} \cdot \boldsymbol{v}_{\phi^\star}(\boldsymbol{x}(t), t)$$

状態と対数密度の増分を同時に積分できる。

式（4.3.7）：同時積分

$$\frac{d}{dt}\begin{bmatrix}\boldsymbol{x}(t)\\ \delta(t)\end{bmatrix} = \begin{bmatrix}\boldsymbol{v}_{\phi^\star}(\boldsymbol{x}(t),t)\\ -\nabla_{\boldsymbol{x}}\cdot\boldsymbol{v}_{\phi^\star}(\boldsymbol{x}(t),t)\end{bmatrix}, \quad \begin{bmatrix}\boldsymbol{x}(0)\\ \delta(0)\end{bmatrix} = \begin{bmatrix}\boldsymbol{x}_0\\ 0\end{bmatrix} \tag{4.3.7}$$

$t = T$ で $p_{\mathrm{prior}}(\boldsymbol{x}(T))$ が既知なので

$$\log p^{\mathrm{ODE}}_{\phi^\star}(\boldsymbol{x}_0;0) = \log p_{\mathrm{prior}}(\boldsymbol{x}(T)) - \delta(T)$$

補足：積分形での尤度

同等に

$$\log p_{\phi^\star}^{\mathrm{ODE}}(\boldsymbol{x}_0; 0) = \log p_{\mathrm{prior}}(\boldsymbol{x}(T)) + \int_0^T \nabla_{\boldsymbol{x}} \cdot \boldsymbol{v}_{\phi^\star}(\boldsymbol{x}(t), t)\, dt$$

要点

生成・反転に使う同じ PF-ODE が、
連続の変数変換公式として尤度も与える。

反転・尤度のまとめ

- PF-ODE は $0 \leftrightarrow T$ の双方向流である
- 前向き流は潜在符号化、逆向き流は生成
- 発散の積分で $\log p(\boldsymbol{x}_0)$ を評価できる（4.3.7）

4.2 全体のまとめ

1. **学習**連続 DSM（4.3.1）で $s_\phi(\boldsymbol{x}, t)$ を学ぶ。最適は周辺スコア。
2. **生成**逆 SDE（4.3.3 – 4.3.4）または PF-ODE（4.3.5 – 4.3.6）を解く。
3. **尤度**同じ PF-ODE の発散積分（4.3.7）で $\log p$ が取れる。
4. **含意**生成の遅さは、DE ソルバの反復コストそのものである。

4.2 全体のまとめ：一本の流れ

今日の道筋

時間依存スコアを DSM で学ぶ → 逆 SDE ／ PF-ODE でサンプル → PF-ODE で符号化・尤度

核心

原理は「スコアを入れた微分方程式」。
実装は「条件付き教師で回帰し、数値積分する」こと。

次へ

4.3 では VE ／ VP など、前向き SDE の具体的な選び方（インスタンス）を見る。