The Principles of Diffusion Models

4.4 (Optional) Forward Kernels

渡邉 有志

November 13, 2026

補足：4.3 から 4.4 へ（任意）

ここまで

VE / VP の $\boldsymbol{f}, g$ から摂動核 $p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ を導いた。

ここから（スライド 4.4 ＝論文 4.5）

逆に、**累積摂動核を先に置く**見方を取る。
Score SDE と変分 DDPM をつなぎ、学習の直感をはっきりさせる。

初読ではスキップ可。学習目的に出てくる $p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ の「なぜ便利か」を埋める節。

補足：4.4 の位置づけ

この節の役割（任意）

局所ノイズ注入ではなく、累積核 α_t, σ_t から前向き過程を見る

1. 図 4.8：局所 SDE と累積核は同じアフィン過程の二面
2. Score SDE へ：α_t, σ_t から $f(t), g(t)$ を復元（補題 4.5.1）
3. 変分/DDPM へ：逆条件付きと拡散損失を核から書く
4. なぜ学習に効くか：信号とノイズの量が時刻で明示される

区切り：補足 累積摂動核

累積摂動核

Score SDE との接続

変分 / DDPM との接続

学習への効き方

補足：局所注入ではなく累積核

DDPM は $p(\boldsymbol{x}_t \mid \boldsymbol{x}_{t-\Delta t})$、Score SDE は連続 SDE で
「局所的なノイズの足し方」から入ることが多い。

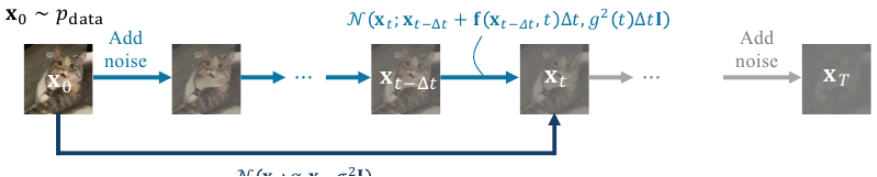
学習で本当に使うもの

累積摂動核 $p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ である。
DDPM 損失や連続時間 DSM（2.2.8）（4.3.1）にそのまま現れる。

そこで、局所注入から導くのではなく、
累積核を直接指定する見方をとる。

補足：図 4.8：同じ過程の二面

perturbation kernel directly. For the linear-Gaussian processes considered below, an admissible accumulated kernel determines the corresponding linear SDE, and vice versa. This viewpoint makes the amount of signal and noise at each time explicit, connects directly to practical training objectives, and will also provide a useful bridge to the probability-path viewpoint of Flow Matching in Chapter 5.



上：微小ステップのノイズ注入。下：$\boldsymbol{x}_0$ から $\boldsymbol{x}_t$ へ一気に書く累積核。

補足：一般のアフィン前向き過程

$$p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0) := \mathcal{N}\big(\boldsymbol{x}_t;\, \alpha_t \boldsymbol{x}_0,\, \sigma_t^2 \boldsymbol{I}\big) \tag{4.5.1}$$

等価なサンプリング：

$$\boldsymbol{x}_t = \alpha_t \boldsymbol{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I})$$

標準設定：$\alpha_0 = 1$、$\sigma_0 = 0$（時刻 0 はデータそのもの）。

補足：よくある確率パス

- **VE（NCSN）**：$\alpha_t \equiv 1$、σ_t は時間とともに増加
- **VP（DDPM）**：$\alpha_t^2 + \sigma_t^2 = 1$
- **線形補間**：$\alpha_t = 1 - t$、$\sigma_t = t$（$t \in [0, 1]$）
  Flow Matching / Rectified Flow でよく使うパス

読み方

α_t が残る信号、σ_t が載せたノイズ。
時刻ごとの SNR がパラメータに直接見える。

区切り：補足 Score SDE との接続

累積摂動核

Score SDE との接続

変分 / DDPM との接続

学習への効き方

補足：核から SDE 係数を復元

許容されるアフィン日程なら、対応する前向き SDE は線形：

$$d\boldsymbol{x}(t) = f(t)\boldsymbol{x}(t)\,dt + g(t)\,d\boldsymbol{w}(t)$$

α_t, σ_t から f, g を解析的に復元できる。
ただし任意の (α_t, σ_t) が拡散になるわけではない：
暗示される $g^2(t)$ が非負である必要がある（SNR α_t^2/σ_t^2 は時間とともに増やせない）。

補足：補題 4.5.1（要点）

$\lambda_t := \log(\alpha_t/\sigma_t)$ とおく。
核 $\boldsymbol{x}_t = \alpha_t \boldsymbol{x}_0 + \sigma_t \boldsymbol{\epsilon}$ に対応する線形 SDE がある必要十分条件は

$$f(t) = \frac{d}{dt}\log \alpha_t, \qquad g^2(t) = \frac{d\sigma_t^2}{dt} - 2\Big(\frac{d}{dt}\log \alpha_t\Big)\sigma_t^2 \tag{4.5.2}$$

が $g^2(t) \geq 0$（同値：λ_t が非増加）を満たすこと。

補足：観察 4.5.1

同値性

妥当なアフィン拡散では、次の二つは同じ対象を指す。

- 累積核を α_t, σ_t で指定する
- 線形 SDE を $f(t), g(t)$ で指定する

文献では両者が入れ替わりに使われる。
学習の話では核側、連続時間の解析では SDE 側が便利なことが多い。

区切り：補足 変分・DDPM との接続

累積摂動核

Score SDE との接続

変分 / DDPM との接続

学習への効き方

補足：Bayes で逆条件付き

DDPM の中核は Bayes：

$$p(\boldsymbol{x}_{t-\Delta t} \mid \boldsymbol{x}_t, \boldsymbol{x}) = p(\boldsymbol{x}_t \mid \boldsymbol{x}_{t-\Delta t}) \frac{p_{t-\Delta t}(\boldsymbol{x}_{t-\Delta t} \mid \boldsymbol{x})}{p_t(\boldsymbol{x}_t \mid \boldsymbol{x})} \tag{4.5.3}$$

連続時間でも、$0 \leq t < s \leq T$ に対し同じ発想で
$p(\boldsymbol{x}_t \mid \boldsymbol{x}_s, \boldsymbol{x})$ が書ける（補題 4.5.2）。

補足：補題 4.5.2（逆条件付き）

$p(\boldsymbol{x}_t \mid \boldsymbol{x}_s, \boldsymbol{x})$ はガウスで、平均は

$$\mu = \frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2}\boldsymbol{x}_s + \frac{\alpha_t \sigma_{s|t}^2}{\sigma_s^2}\boldsymbol{x}$$

分散は $\sigma^2(s,t) = \sigma_{s|t}^2\,(\sigma_t^2/\sigma_s^2)$。
ここで $\alpha_{s|t} = \alpha_s/\alpha_t$、$\sigma_{s|t}^2 = \sigma_s^2 - \alpha_{s|t}^2\sigma_t^2$。

要点

累積核があれば、逆過程の教師分布が閉じる
（$\alpha_t^2 + \sigma_t^2 = 1$ を仮定しなくてもよい）。

補足：学習：$\boldsymbol{x}$ 予測と拡散損失

きれいな $\boldsymbol{x}$ を $\boldsymbol{x}_\phi(\boldsymbol{x}_s, s)$ で置き換えると

$$p_\phi(\boldsymbol{x}_t \mid \boldsymbol{x}_s) = \mathcal{N}\big(\boldsymbol{x}_t;\, \mu_\phi(\boldsymbol{x}_s, s, t),\, \sigma^2(s,t)\boldsymbol{I}\big) \tag{4.5.6}$$

KL は重み付き回帰に落ちる：

$$D_{\mathrm{KL}} = \frac{1}{2}\big(\mathrm{SNR}(t) - \mathrm{SNR}(s)\big)\,\big\|\boldsymbol{x}_0 - \boldsymbol{x}_\phi(\boldsymbol{x}_s, s)\big\|_2^2 \tag{4.5.7}$$

ここで $\mathrm{SNR}(s) = \alpha_s^2/\sigma_s^2$。
$\boldsymbol{\epsilon}$ 予測も $\boldsymbol{x}_s = \alpha_s \boldsymbol{x}_\phi + \sigma_s \boldsymbol{\epsilon}_\phi$ で等価。

補足：サンプリング

学習した核（4.5.6）で、DDPM と同様に戻す：

$$\boldsymbol{x}_t = \frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2}\boldsymbol{x}_s + \frac{\alpha_t \sigma_{s|t}^2}{\sigma_s^2}\boldsymbol{x}_\phi(\boldsymbol{x}_s, s) + \sigma_{s|t}\frac{\sigma_t}{\sigma_s}\boldsymbol{\epsilon}_s \tag{4.5.8}$$

読み方

平均は「現在の $\boldsymbol{x}_s$」と「予測したきれいな信号」の線形結合。
残りは既知分散のガウスノイズ。

区切り：補足 学習への効き方

累積摂動核

Score SDE との接続

変分 / DDPM との接続

学習への効き方

補足：なぜ累積核の見方が便利か

1. **信号とノイズが明示**
   α_t, σ_t を見れば、その時刻で何が残っているかが分かる
2. **損失が直接書ける**
   DSM や ELBO の教師は $p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ から来る
3. **SDE と変分が同じ対象**
   f, g と α, σ は同値（観察 4.5.1）なので視点を切り替えやすい
4. **第 5 章への橋**
   Flow Matching の確率パスも同じアフィン核の言葉で書ける

補足：4.4 全体のまとめ

- 学習の本体は累積核 $p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0) = \mathcal{N}(\alpha_t \boldsymbol{x}_0, \sigma_t^2 \boldsymbol{I})$
- VE/VP/線形パスは (α_t, σ_t) の選び方の違い
- 妥当なら線形 SDE の f, g と一対一（補題 4.5.1）
- Bayes で逆条件付き・拡散損失・サンプリングが核から出る

核心

「局所にどうノイズを足すか」と「時刻 t で信号がどれだけ残るか」は
アフィン拡散では同じ情報の二面である。

本編への戻り

任意節の位置

スライド 4.4 は、4.3 の VE/VP を学習の言葉（α_t, σ_t）で見直す補足である。

次へ

以降は Score SDE 枠の続き（逆過程の根拠・周辺化など）へ進む。