The Principles of Diffusion Models

6.1 Conditional Tricks: The Secret Sauce of Diffusion Models

渡邉 有志

November 13, 2026

第 5 章から第 6 章へ

ここまで（第 2–5 章）

変分（DDPM）、スコア（DSM / Score SDE）、
フロー（FM / CFM）を、それぞれ別の動機から見てきた。

ここから（第 6 章）

見た目の違いの奥に、共通原理があることを示す。
鍵は「周辺の扱いづらい目標」を「条件付きの扱いやすい教師」で学ぶこと。

この章の学習目標（導入）

- 変分／スコア／フローに共通する**条件付け原理**を認識する
- 4 つの予測型（clean / noise / score / velocity）を理解する
- 訓練設計を分解する：スケジュール・予測対象・p_{time}・重み $\omega(t)$
- 「同値」の意味を区別する（オラクル／目的関数／周辺経路／実務アルゴリズム）

今日（6.1）の焦点

条件付けトリック：扱いにくい周辺目標を、条件付き目標で回復する。

6.1 の位置づけ

この節の役割

三視点の訓練目標が、同じ「条件付け」で tractable になることを示す

1. **扱いにくい周辺目標**
   J_{KL}、J_{SM}、J_{FM}
2. **条件付けトリック**
   J_{CKL}、J_{DSM}、J_{CFM}（定数差で同値）
3. **共通パターン（式 6.1.1）**
   周辺オラクル＝ $p(\cdot|\boldsymbol{x}_t)$ 上の条件付きオラクルの平均
4. **有限データでの具体化（任意）**
   事後重み w_i と記憶化の注意

区切り：三視点の扱いにくい目標

三視点の扱いにくい目標

条件付けトリック

共通パターン：事後平均

有限データでの具体化

まとめ

三つの起源、三つの訓練目標

これまで別々に見えていた三視点は、固定 t で次の目標に至る：

- **変分**：逆遷移 $p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t)$ を p_ϕ で近似
- **スコア**：周辺スコア $\nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x}_t)$ を s_ϕ で近似
- **フロー**：周辺速度 $\boldsymbol{v}_t(\boldsymbol{x}_t)$ を $\boldsymbol{v}_\phi$ で近似

一見すると絶望的

いずれも「オラクル量」を直接必要とし、一般には計算不能。

変分：J_{KL}

パラメータ化密度 $p_\phi(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t)$ で
オラクル逆遷移 $p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t)$ を近似する：

$$J_{\mathrm{KL}}(\phi) := \mathbb{E}_{p_t(\boldsymbol{x}_t)}\Big[D_{\mathrm{KL}}\big(p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t)\,\big\|\,p_\phi(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t)\big)\Big]$$

困難

真の逆遷移 $p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t)$ は一般に未知。

スコア：J_{SM}

スコアモデル $s_\phi(\boldsymbol{x}_t, t)$ で周辺スコアを当てる：

$$J_{\mathrm{SM}}(\phi) := \mathbb{E}_{p_t(\boldsymbol{x}_t)} \left\| s_\phi(\boldsymbol{x}_t, t) - \nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x}_t) \right\|_2^2$$

困難

周辺密度 p_t のスコアは閉じた形では書けない。

フロー：J_{FM}

速度モデル $\boldsymbol{v}_\phi(\boldsymbol{x}_t, t)$ でオラクル速度（例：式 5.2.9）を当てる：

$$J_{\mathrm{FM}}(\phi) := \mathbb{E}_{p_t(\boldsymbol{x}_t)} \left\| \boldsymbol{v}_\phi(\boldsymbol{x}_t, t) - \boldsymbol{v}_t(\boldsymbol{x}_t) \right\|_2^2$$

困難

周辺速度 $\boldsymbol{v}_t(\boldsymbol{x}_t)$ も、一般には未知の期待値。

共通の行き詰まり

変分	スコア	フロー
$p(\boldsymbol{x}_{t-\Delta t}\|\boldsymbol{x}_t)$	$\nabla \log p_t$	$\boldsymbol{v}_t(\boldsymbol{x}_t)$

一言で

「周辺の教師」が欲しいのに、周辺の教師が手に入らない。

次

データ $\boldsymbol{x}_0$ で条件付けると、教師が tractable になる。

区切り：条件付けトリック

三視点の扱いにくい目標

条件付けトリック

共通パターン：事後平均

有限データでの具体化

まとめ

解決策：$\boldsymbol{x}_0$ で条件付ける

各手法が独立にたどり着いた elegant な解は同じ：

条件付けテクニック

未知の周辺量ではなく、既知のガウス条件付き $p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)$ の下で
条件付き目標を回帰する。

- 条件付き目標は閉じた形（または安い式）で書ける
- 周辺目標との差は、ϕ に依存しない定数 C
- したがって勾配（最小化子）は一致する

変分：CKL（式 2.2.3 の形）

$$J_{\mathrm{KL}}(\phi) = \mathbb{E}_{\boldsymbol{x}_0}\mathbb{E}_{p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)}\Big[D_{\mathrm{KL}}\big(p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t,\boldsymbol{x}_0)\,\big\|\,p_\phi(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t)\big)\Big] + C$$

右辺の ϕ 依存部を $J_{\mathrm{CKL}}(\phi)$ と呼ぶ。

- 条件付き逆遷移 $p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t,\boldsymbol{x}_0)$ はガウスで閉じる（補題 2.2.2）
- $J_{\mathrm{KL}} = J_{\mathrm{CKL}} + C$（$C$ は ϕ に独立）

スコア：DSM（式 3.3.3 の形）

$$J_{\mathrm{SM}}(\phi) = \mathbb{E}_{\boldsymbol{x}_0}\mathbb{E}_{p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)}\left\|s_\phi(\boldsymbol{x}_t, t) - \nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\right\|_2^2 + C$$

右辺の ϕ 依存部を $J_{\mathrm{DSM}}(\phi)$ と呼ぶ。

- 条件付きスコアは $\nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0) = -\sigma_t^{-2}(\boldsymbol{x}_t - \alpha_t\boldsymbol{x}_0)$
- 第 3 章の Denoising Score Matching そのもの

フロー：CFM（式 5.2.10 の形）

$$J_{\mathrm{FM}}(\phi) = \mathbb{E}_{\boldsymbol{x}_0}\mathbb{E}_{p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)}\left\|\boldsymbol{v}_\phi(\boldsymbol{x}_t, t) - \boldsymbol{v}_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\right\|_2^2 + C$$

右辺の ϕ 依存部を $J_{\mathrm{CFM}}(\phi)$ と呼ぶ。

- 条件付き速度 $\boldsymbol{v}_t(\boldsymbol{x}_t|\boldsymbol{x}_0)$ はスケジュールから閉じた形
- 第 5 章の Conditional Flow Matching と同じ原理

勾配同値：周辺 $\leftrightarrow$ 条件付き

視点	周辺	条件付き
変分	J_{KL}	J_{CKL}
スコア	J_{SM}	J_{DSM}
フロー	J_{FM}	J_{CFM}

要点

条件付き版は周辺版と定数だけ違う。
同じモデル族の中では最小化子が一致する。

実務的意味

訓練では条件付き教師だけを使えばよい。
周辺オラクルを直接計算する必要はない。

区切り：共通パターン（事後平均）

三視点の扱いにくい目標

条件付けトリック

共通パターン：事後平均

有限データでの具体化

まとめ

理想の最小化子が回復するもの

モデルが十分表現力をもてば、三視点は同じ概念パターンに収束する：

$$\underbrace{\text{周辺オラクル}}_{\text{一般に intractable}} = \mathbb{E}_{\boldsymbol{x}_0 \sim p(\cdot|\boldsymbol{x}_t)} \Big[\underbrace{\text{条件付きオラクル}}_{\boldsymbol{x}_0\text{が与えれば tractable}} \Big]$$

- $\boldsymbol{x}_0$ で条件付ける $\Rightarrow$ 閉じた教師
- $\boldsymbol{x}_t$ と整合する $\boldsymbol{x}_0$ について平均 $\Rightarrow$ 欲しい周辺オラクル

式 (6.1.1)：三つのオラクル恒等式

$$
\begin{aligned}
p^\star(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t) &= \mathbb{E}_{\boldsymbol{x}_0\sim p(\cdot|\boldsymbol{x}_t)}\big[p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t,\boldsymbol{x}_0)\big] = p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t),\\
s^\star(\boldsymbol{x}_t,t) &= \mathbb{E}_{\boldsymbol{x}_0\sim p(\cdot|\boldsymbol{x}_t)}\big[\nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\big] = \nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}_t),\\
\boldsymbol{v}^\star(\boldsymbol{x}_t,t) &= \mathbb{E}_{\boldsymbol{x}_0\sim p(\cdot|\boldsymbol{x}_t)}\big[\boldsymbol{v}_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\big] = \boldsymbol{v}_t(\boldsymbol{x}_t).
\end{aligned}
\tag{6.1.1}
$$

なぜ平均になるか

変分

条件付き逆遷移を $\boldsymbol{x}_0$ で周辺化すると
真の逆遷移。
KL の最小化子はその周辺。

スコア／速度

二乗誤差回帰の母集団最小化子は
条件付き期待値。

注意

これらは unrestricted な母集団オラクルの話。
有限容量のニューラルネットが完全再現するとは限らない。

直観：$p(\boldsymbol{x}_0|\boldsymbol{x}_t)$ 上の平均

観測 $\boldsymbol{x}_t$ を見たとき、あり得るきれいなデータ $\boldsymbol{x}_0$ の事後

$$p(\boldsymbol{x}_0|\boldsymbol{x}_t) = \frac{p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\, p_{\text{data}}(\boldsymbol{x}_0)}{\int p_t(\boldsymbol{x}_t|\tilde{\boldsymbol{x}}_0)\, p_{\text{data}}(\tilde{\boldsymbol{x}}_0)\, d\tilde{\boldsymbol{x}}_0}$$

の上で、条件付き教師を平均している。

一言

拡散モデルの学習目標は、
「ノイズ観測から見た、きれいなデータの事後平均」である。

区切り：補足 有限データでの具体化

三視点の扱いにくい目標

条件付けトリック

共通パターン：事後平均

有限データでの具体化

まとめ

補足：経験測度と事後重み

データを経験測度 $\hat{p}_0 = \frac{1}{N}\sum_{i=1}^{N} \delta_{\boldsymbol{x}_0^{(i)}}$ で置くと、事後は訓練点だけに乗る：

$$p(\boldsymbol{x}_0 = \boldsymbol{x}_0^{(i)} | \boldsymbol{x}_t) = \frac{p_t(\boldsymbol{x}_t | \boldsymbol{x}_0^{(i)})}{\sum_{j=1}^{N} p_t(\boldsymbol{x}_t | \boldsymbol{x}_0^{(j)})} =: w_i(\boldsymbol{x}_t, t), \qquad \sum_{i=1}^{N} w_i = 1.$$

任意の量 $h(\boldsymbol{x}_0)$ の事後期待は

$$\mathbb{E}_{\boldsymbol{x}_0 \sim p(\cdot|\boldsymbol{x}_t)}[h(\boldsymbol{x}_0)] = \sum_{i=1}^{N} w_i(\boldsymbol{x}_t, t)\, h(\boldsymbol{x}_0^{(i)}).$$

補足：変分オラクル（有限データ）

$$p^\star(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t) = \sum_{i=1}^{N} w_i(\boldsymbol{x}_t, t)\, p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t, \boldsymbol{x}_0^{(i)})$$

- 各 $p(\boldsymbol{x}_{t-\Delta t}|\boldsymbol{x}_t, \boldsymbol{x}_0^{(i)})$ はガウスブリッジで閉じる
- 真の逆遷移は、明示的ガウスの事後重み付き混合

補足：スコアオラクル（有限データ）

条件付きスコア $\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0^{(i)}) = -\sigma_t^{-2}(\boldsymbol{x}_t - \alpha_t \boldsymbol{x}_0^{(i)})$ より

$$s^\star(\boldsymbol{x}_t, t) = -\frac{1}{\sigma_t^2}\left(\boldsymbol{x}_t - \alpha_t \sum_{i=1}^{N} w_i(\boldsymbol{x}_t, t)\, \boldsymbol{x}_0^{(i)}\right).$$

読み方

周辺スコアは、ノイズ点から「事後平均されたきれいなデータ」へ向かう。

補足：速度オラクル（有限データ）

条件付き速度

$$\boldsymbol{v}_t(\boldsymbol{x}_t|\boldsymbol{x}_0^{(i)}) = \alpha_t'\boldsymbol{x}_0^{(i)} + \frac{\sigma_t'}{\sigma_t}\big(\boldsymbol{x}_t - \alpha_t\boldsymbol{x}_0^{(i)}\big)$$

を重み付き平均すると

$$\boldsymbol{v}^\star(\boldsymbol{x}_t, t) = \sum_{i=1}^{N} w_i(\boldsymbol{x}_t, t)\, \boldsymbol{v}_t(\boldsymbol{x}_t|\boldsymbol{x}_0^{(i)}).$$

三視点とも、閉じた条件付き量の事後重み付き平均に帰着する。

補足：記憶化（memorization）への注意

- 上式は人口分布 p_{data} ではなく、経験測度 $\hat{p}_0$ のオラクル
- 経験オラクルを全ノイズレベルで完全学習し、逆過程も誤差なしなら
  生成分布は $\hat{p}_0$（＝訓練点のみ）になる
- 理想化された意味では「完全フィット＝記憶化」

しかし実務では

有限容量・有限最適化・数値サンプリング誤差がある。
有限データ計算は記憶化が厳密解になり得ることを示すが、
実モデルが必ず記憶するとは言わない。

区切り：6.1 のまとめ

三視点の扱いにくい目標

条件付けトリック

共通パターン：事後平均

有限データでの具体化

まとめ

条件付けは偶然ではない

共通の条件付き書き換えは偶然ではない：

1. 訓練を tractable にする
2. 三視点が同じ原理の異なる面だと示す
3. 変分拡散・スコア SDE・Flow Matching を一本の物語に繋ぐ

標語

Three perspectives, one insight.

6.1 全体のまとめ

1. **行き詰まり** J_{KL} ／ J_{SM} ／ J_{FM} は周辺オラクルを要し intractable
2. **条件付け** $\boldsymbol{x}_0$ 条件で J_{CKL} ／ J_{DSM} ／ J_{CFM} へ。定数差で同値
3. **式 (6.1.1)** 周辺オラクル＝ $p(\boldsymbol{x}_0|\boldsymbol{x}_t)$ 上の条件付きオラクル平均
4. **有限データ**事後重み w_i の明示和；記憶化は理想解の注意書き

6.1 全体のまとめ：一本の流れ

今日の道筋

扱いにくい周辺目標 $\rightarrow$ $\boldsymbol{x}_0$ 条件付け $\rightarrow$ 定数差の同値 $\rightarrow$ 事後平均としてのオラクル

核心

欲しいのは周辺の教師。
閉じた条件付き教師を回帰すれば、平均的に周辺が得られる。

次へ（6.2）

予測型を 4 つに広げ、訓練損失の設計要素を分解する。