The Principles of Diffusion Models

6.2 A Roadmap for Elucidating Training Losses in Diffusion Models

渡邉 有志

November 13, 2026

6.1 から 6.2 へ

ここまで（6.1）

変分／スコア／フローの周辺目標は、$\boldsymbol{x}_0$ 条件付けで tractable になる。
条件付き版は定数差で同値（J_{CKL} ／ J_{DSM} ／ J_{CFM}）。

ここから（6.2）

予測型を 4 つに広げ、訓練損失の設計を分解する。
「何が再パラメータ化で、何が最適化に効くか」を整理する。

6.2 の位置づけ

この節の役割

拡散の訓練損失を、見通しのよい設計空間として書く

1. **6.2.1 四つのパラメータ化**
   clean x ／ noise $\boldsymbol{\epsilon}$ ／ score s ／ velocity $\boldsymbol{v}$
2. **6.2.2 目的関数の分解**
   スケジュール・予測対象・p_{time}・重み $\omega(t)$
3. **再パラメータ化 vs 最適化**
   代数的同値と、実務で効く違いを区別する

区切り：6.2.1 四つのパラメータ化

6.2.1 四つのパラメータ化

6.2.2 訓練目的の分解

(A) ノイズスケジュール

(B) 予測型と回帰ターゲット

(C)(D) 時間分布と重み

再パラメータ化と最適化

まとめ

前向き核の共通設定

本節では、特に断らない限り

$$p_t(\boldsymbol{x}_t|\boldsymbol{x}_0) = \mathcal{N}(\boldsymbol{x}_t; \alpha_t \boldsymbol{x}_0, \sigma_t^2 \boldsymbol{I}), \qquad \boldsymbol{x}_0 \sim p_{\text{data}}$$

（式 4.5.1）を用いる。

- 正の時間重み $\omega : [0, T] \to \mathbb{R}_{>0}$ を置く
- 4 つの標準パラメータ化：$\boldsymbol{\epsilon}_\phi$、$x_\phi$、$s_\phi$、$\boldsymbol{v}_\phi$
- 対応する最小化子：$\boldsymbol{\epsilon}^\star$、$x^\star$、$s^\star$、$\boldsymbol{v}^\star$

変分視点：何を予測するか

DDPM 系の KL（2.2.4 節、4.5.2 節）は、次のどちらかに落ちる：

- $\boldsymbol{x}_t$ を作ったノイズの期待値（$\boldsymbol{\epsilon}$-prediction）
- $\boldsymbol{x}_t$ の元になったきれいな信号の期待値（x-prediction）

見方

どちらも「ノイズ観測 $\boldsymbol{x}_t$ から見た条件付き期待」である。
式 (6.1.1) の事後平均と同じ思想。

ϵ-prediction（ノイズ予測）

$$\boldsymbol{\epsilon}_\phi(\boldsymbol{x}_t, t) \approx \mathbb{E}[\boldsymbol{\epsilon}|\boldsymbol{x}_t] = \boldsymbol{\epsilon}^\star(\boldsymbol{x}_t, t) \tag{6.2.1}$$

訓練目的：

$$L_{\text{noise}}(\phi) := \mathbb{E}_t\, \omega(t)\, \mathbb{E}_{\boldsymbol{x}_0, \boldsymbol{\epsilon}} \left\| \boldsymbol{\epsilon}_\phi(\boldsymbol{x}_t, t) - \boldsymbol{\epsilon} \right\|_2^2$$

意味

$\boldsymbol{\epsilon}^\star$ は、与えられた $\boldsymbol{x}_t$ を得るために注入されたノイズの平均。

x-prediction（クリーン予測）

$$x_\phi(\boldsymbol{x}_t, t) \approx \mathbb{E}[\boldsymbol{x}_0|\boldsymbol{x}_t] = x^\star(\boldsymbol{x}_t, t) \tag{6.2.2}$$

訓練目的：

$$L_{\text{clean}}(\phi) := \mathbb{E}_t\, \omega(t)\, \mathbb{E}_{\boldsymbol{x}_0, \boldsymbol{\epsilon}} \left\| x_\phi(\boldsymbol{x}_t, t) - \boldsymbol{x}_0 \right\|_2^2$$

意味

$x^\star$ は、ノイズ観測 $\boldsymbol{x}_t$ から見た、あり得るきれいなデータの平均。

スコア視点：s-prediction

スコアは、$\boldsymbol{x}_t$ を生み得たきれいなサンプル群へ戻る平均方向を指す：

$$s_\phi(\boldsymbol{x}_t, t) \approx \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t) = \mathbb{E}\big[\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0)\big|\boldsymbol{x}_t\big] = s^\star(\boldsymbol{x}_t, t) \tag{6.2.3}$$

$$L_{\text{score}}(\phi) := \mathbb{E}_t\, \omega(t)\, \mathbb{E}_{\boldsymbol{x}_0, \boldsymbol{\epsilon}} \big\| s_\phi(\boldsymbol{x}_t, t) - \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0) \big\|_2^2$$

条件付きスコアは $\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{x}_0) = -\sigma_t^{-1}\boldsymbol{\epsilon}_\circ$

フロー視点：v-prediction

$$\boldsymbol{v}_\phi(\boldsymbol{x}_t, t) \approx \mathbb{E}\left[\frac{d\boldsymbol{x}_t}{dt}\,\middle|\,\boldsymbol{x}_t\right] = \boldsymbol{v}^\star(\boldsymbol{x}_t, t) \tag{6.2.4}$$

$$L_{\text{velocity}}(\phi) := \mathbb{E}_t\,\omega(t)\,\mathbb{E}_{\boldsymbol{x}_0,\boldsymbol{\epsilon}}\left\|\boldsymbol{v}_\phi(\boldsymbol{x}_t, t) - \boldsymbol{v}_t(\boldsymbol{x}_t|\boldsymbol{x}_0, \boldsymbol{\epsilon})\right\|_2^2$$

条件付き速度は $\boldsymbol{v}_t(\boldsymbol{x}_t|\boldsymbol{x}_0, \boldsymbol{\epsilon}) = \alpha_t'\boldsymbol{x}_0 + \sigma_t'\boldsymbol{\epsilon}$。

意味

$\boldsymbol{v}^\star$ は、観測点 $\boldsymbol{x}_t$ を通る平均速度ベクトル。

四点の共通点（6.1.1 の延長）

4 つの予測型は、いずれも

「観測$\boldsymbol{x}_t$で条件付けた期待値」

を近似している：

- 平均ノイズ $\mathbb{E}[\boldsymbol{\epsilon}|\boldsymbol{x}_t]$
- 平均クリーン $\mathbb{E}[\boldsymbol{x}_0|\boldsymbol{x}_t]$
- 平均条件付きスコア
- 平均条件付き速度

次

これらを一つのテンプレート損失にまとめ、設計要素を分解する。

区切り：6.2.2 訓練目的の分解

6.2.1 四つのパラメータ化

6.2.2 訓練目的の分解

(A) ノイズスケジュール

(B) 予測型と回帰ターゲット

(C)(D) 時間分布と重み

再パラメータ化と最適化

まとめ

共通テンプレート（式 6.2.5）

4 予測型の目的は、次の形にまとまる：

$$L(\phi) := \mathbb{E}_{\boldsymbol{x}_0,\boldsymbol{\epsilon}}\mathbb{E}_{p_{\text{time}}(t)}\Big[\omega(t)\,\big\|\mathrm{NN}_\phi(\boldsymbol{x}_t,t) - (A_t\boldsymbol{x}_0 + B_t\boldsymbol{\epsilon})\big\|_2^2\Big] \tag{6.2.5}$$

- 時間分布 p_{time}
- 時間重み $\omega(t)$
- MSE 部分：ネット出力 vs 回帰ターゲット $A_t\boldsymbol{x}_0 + B_t\boldsymbol{\epsilon}$

四つの設計選択

訓練効率と学習パイプラインを左右する鍵（Karras et al., 2022; Lu and Song, 2024）：

(A) 前向きのノイズスケジュール (α_t, σ_t)

(B) 予測型 NN_ϕ と回帰ターゲット $(A_t \boldsymbol{x}_0 + B_t \boldsymbol{\epsilon})$

(C) 時間重み $\omega(\cdot) : [0, T] \to \mathbb{R}_{\geq 0}$

(D) 時間分布 p_{time}

ロードマップ

以降、(A)–(D) を順に見る。
6.3 の同値結果への下地になる。

区切り：(A) ノイズスケジュール

6.2.1 四つのパラメータ化

6.2.2 訓練目的の分解

(A) ノイズスケジュール

(B) 予測型と回帰ターゲット

(C)(D) 時間分布と重み

再パラメータ化と最適化

まとめ

(A) α_t と σ_t

応用に応じてスケジュールを選べる（例：表 5.2）。

重要な予告（6.3 へ）

アフィン流 $\boldsymbol{x}_t = \alpha_t \boldsymbol{x}_0 + \sigma_t \boldsymbol{\epsilon}$ は数学的に同値。
時間の再パラメータ化と空間スケール変換で、
標準線形 $(\alpha_t = 1 - t, \sigma_t = t)$ や三角 $(\alpha_t = \cos t, \sigma_t = \sin t)$ へ写せる（式 6.3.3、6.3.5）。

注意

「同値」でも、学習時のスケールや勾配の様子は変わり得る。
代数的同値＝実務で全く同じ、ではない。

区切り：(B) 予測型と回帰ターゲット

6.2.1 四つのパラメータ化

6.2.2 訓練目的の分解

(A) ノイズスケジュール

(B) 予測型と回帰ターゲット

(C)(D) 時間分布と重み

再パラメータ化と最適化

まとめ

表6.1：パラメータ化の関係

Table 6.1: Summary of the Relationships Between Different Parameterizations. All four parameterizations are mathematically equivalent and can be converted into one another through straightforward algebraic transformations.

Regression Target =	$A_t\mathbf{x}_0 + B_t\boldsymbol{\epsilon}$	
	A_t	B_t
Clean	1	0
Noise	0	1
Conditional Score	0	$-\frac{1}{\sigma_t}$
Conditional Velocity	α'_t	σ'_t

表 6.1 の読み方

回帰ターゲットは常に

$$A_t \boldsymbol{x}_0 + B_t \boldsymbol{\epsilon}$$

予測型	A_t	B_t
Clean	1	0
Noise	0	1
Conditional Score	0	$-\sigma_t^{-1}$
Conditional Velocity	α_t'	σ_t'

含意

4 パラメータ化は代数的に相互変換できる（後の式 6.3.1）。

マッチした予測と損失

式 (6.2.5) の標準は、ネット出力と損失の予測型を一致させる：

- x-prediction $\leftrightarrow$ ターゲット $\boldsymbol{x}_0$
- v-prediction $\leftrightarrow$ ターゲット $\alpha'_t \boldsymbol{x}_0 + \sigma'_t \boldsymbol{\epsilon}$

オラクル情報

4 予測型は同じオラクル情報を符号化し、相互変換できる（式 6.3.1）。

予測と損失をずらす場合

ネットが直接出す量と、損失で測る量は分離できる。
まず式 (6.3.1) で変換し、変換先のターゲットと比較する。

例：標準線形 $\boldsymbol{x}_t = (1-t)\boldsymbol{x}_0 + t\boldsymbol{\epsilon}$

ネットが x_ϕ を出すとき、速度へ変換すると

$$\boldsymbol{v}_\phi = \frac{\boldsymbol{x}_t - x_\phi}{t}, \qquad \boldsymbol{v}_t = \frac{\boldsymbol{x}_t - \boldsymbol{x}_0}{t}$$

よって

$$\|\boldsymbol{v}_\phi - \boldsymbol{v}_t\|_2^2 = t^{-2}\|x_\phi - \boldsymbol{x}_0\|_2^2.$$

ずらし損失＝追加の時間重み

ネット出力を clean に固定したまま velocity 損失を使うのは、
clean 損失に時間依存重み t^{-2} を掛けたものと厳密同値。

- 一般アフィン＋他予測型の関係は後の式 (6.3.6)
- 式 (6.2.5) は、断りがなければ「マッチした」場合を指す

ネットが直接予測する量の追加効果

オラクルは代数変換できても、有限ネットは別関数を表現する。
出力スケールとパラメータ勾配が変わる ⇒ 最適化に効く。

区切り：(C)(D) 時間分布と重み

6.2.1 四つのパラメータ化

6.2.2 訓練目的の分解

(A) ノイズスケジュール

(B) 予測型と回帰ターゲット

(C)(D) 時間分布と重み

再パラメータ化と最適化

まとめ

固定時刻の回帰損失

便宜上、固定 t の回帰損失を

$$L_t(\phi) := \mathbb{E}_{\boldsymbol{x}_0,\boldsymbol{\epsilon}} \left\| \mathrm{NN}_\phi(\boldsymbol{x}_t, t) - (A_t \boldsymbol{x}_0 + B_t \boldsymbol{\epsilon}) \right\|_2^2, \quad \boldsymbol{x}_t = \alpha_t \boldsymbol{x}_0 + \sigma_t \boldsymbol{\epsilon}$$

と書くと、式 (6.2.5) は

$$L(\phi) = \mathbb{E}_{t \sim p_{\mathrm{time}}} \left[\omega(t)\, L_t(\phi) \right].$$

(D) p_{time}：目的を変えるか推定を変えるか

補正なしで時刻を偏ってサンプルすると、その時刻の重みも増える。
期待損失のレベルでは、積 $p_{\mathrm{time}}(t)\omega(t)$ だけが効く。一方、目的を固定したまま提案 q_{time} から引き、

$$L(\phi) = \mathbb{E}_{t\sim q_{\mathrm{time}}}\left[\frac{p_{\mathrm{time}}(t)}{q_{\mathrm{time}}(t)}\,\omega(t)\,L_t(\phi)\right]$$

と補正すれば（importance sampling）、目的は不変で推定分散だけが変わる。

区別の標語

p_{time}を目的で変える $\Longrightarrow$ 異なる重み、異なる目的

q_{time} + IS 補正 $\Longrightarrow$ 同じ目的、異なる推定器

- 時間サンプリングと損失重みは概念的に分けておく
- 一様サンプリングでは密度が定数倍なので区別が見えにくい
- 非一様では「目的の定義か、ただの提案分布か」を明示する

実務での現れ方

- **ScoreFlow**：固定の尤度重み目的に対し IS で分散低減
- **VDM**：ノイズレベル座標で目的を固定すると、
  スケジュールが IS 分布のように振る舞う
- **EDM**：ノイズレベル上の非一様訓練分布と、
  別の損失重みを両方指定。実効重みは両者の積

(C) 時間重み $\omega(t)$

固定 p_{time} の下で、$\omega(t)$ が各時刻の相対寄与を決める。
実効重みは $p_{\text{time}}(t)\omega(t)$。

- 基線：一様時間＋ $\omega(t) \equiv 1$（簡易 $\boldsymbol{\epsilon}$-pred、FM/RF）
- 尤度重み：スコア目的で $\omega(t) = g^2(t)$ は、
  適当な正則性の下で負対数尤度の上界（Song et al., 2021）
- SNR 依存重み：ノイズレベル間の強調を再配分

補足：log-SNR と単調重み

腐敗度の座標として log-SNR

$$\Lambda_t := \log \frac{\alpha_t^2}{\sigma_t^2}$$

を用いる（半 log-SNR $\lambda_t = \frac{1}{2}\Lambda_t$ は第 9 章）。
Λ_t はノイズが増えるほど減少する。

Kingma and Gao (2023)

共通予測パラメータ化の下で、有効重み $w(\Lambda)$ が Λ について
非増加なら、重み付き拡散目的は（ϕ 独立項を除き）
ガウス摂動データ上の平均負 ELBO として書ける。

補足：ELBO-with-augmentation の直観

- 単調重みは「ただ一部のノイズを強調する」以上の意味をもつ
- 異なる腐敗強度での変分訓練を平均している、と読める
- 詳細は脚注の $\frac{d}{dt}L(t;\boldsymbol{x}_0)$ と部分積分の議論（論文本文）

ゼミでの扱い

ここでは解釈の存在を押さえる。
導出の細部は必要に応じて原論文へ。

区切り：再パラメータ化と最適化

6.2.1 四つのパラメータ化

6.2.2 訓練目的の分解

(A) ノイズスケジュール

(B) 予測型と回帰ターゲット

(C)(D) 時間分布と重み

再パラメータ化と最適化

まとめ

何が「同じ」で、何が「違う」か

主に再パラメータ化	最適化に効き得る
アフィン日程の時間／空間変換	ネットが直接予測する量の選択
オラクル予測の代数変換	損失の予測型（実効時間重み）
IS 補正付きの提案 q_{time}	p_{time} や $\omega(t)$ の変更

教訓

数学的同値でも、有限ネット＋ SGD では挙動が変わり得る。

結論（6.2 のメッセージ）

見た目の違う設計の多くは、
「ノイズレベル上の実効重みをどう形作るか」として理解できる。

- 実効重みは最適化地形に影響する
- 単調重みなど特殊例では変分解釈も持つ
- 6.3 では、予測・損失・アフィン流の同値をもっと精密に述べる

区切り：6.2 のまとめ

6.2.1 四つのパラメータ化

6.2.2 訓練目的の分解

(A) ノイズスケジュール

(B) 予測型と回帰ターゲット

(C)(D) 時間分布と重み

再パラメータ化と最適化

まとめ

6.2 全体のまとめ

1. **四予測** x ／ $\boldsymbol{\epsilon}$ ／ s ／ $\boldsymbol{v}$ はいずれも $\boldsymbol{x}_t$ 条件付き期待
2. **テンプレート**式 (6.2.5)：p_{time}、$\omega(t)$、ターゲット $A_t\boldsymbol{x}_0 + B_t\boldsymbol{\epsilon}$
3. **表 6.1** (A_t, B_t) が予測型を決める；相互変換可能
4. **設計の分解**スケジュール／予測／重み／時間分布を分けて考える
5. **同値の注意**再パラメータ化と、最適化に効く変更を混同しない

6.2 全体のまとめ：一本の流れ

今日の道筋

条件付け原理 $\rightarrow$ 4 予測型 $\rightarrow$ テンプレート損失 $\rightarrow$ (A)–(D) の設計空間

核心

拡散の訓練は「どの量を、どのノイズレベルで、どれだけ強調して回帰するか」。
同値変換と実効重みの変化を分けて読む。

次へ（6.3）

予測・目的・アフィン前向き過程の同値を精密化する。