The Principles of Diffusion Models

8.1 Prologue of Guidance and Controllable Generation

渡邉 有志

November 13, 2026

第 7 章から第 8 章へ

ここまで（第 7 章・任意）

分布間翻訳と OT ／ SB のレンズで、
「どう運ぶか」の最適性を整理した。

ここから（第 8 章）

生成軌道を**ユーザ意図で操る**枠組みへ。
逆時間スコア／ PF-ODE に誘導方向 G_t を足すのが基本形。

この章の位置づけ

中心の問い

無条件の生成軌道を、条件・嗜好に合わせて
どのように**誘導（guidance）**できるか？

- 粗から細への生成過程は、途中介入の余地を与える
- ベイズ分解が「無条件方向＋誘導方向」の加法構造を示す
- CG ／ CFG ／学習不要誘導／嗜好整合が同じテンプレートに乗る

8.1 の位置づけと学習目標

この節の役割

制御可能生成の動機を置き、
誘導の共通テンプレートと各手法の予告を行う序章

1. ベイズ分解と誘導方向 G_t、誘導付き PF-ODE（8.1.2–8.1.3）
2. CG ／ CFG ／学習不要／嗜好整合の役割分担
3. 固定時刻の傾き密度と、誘導サンプラ周辺の違いに注意

区切り：動機：制御可能生成

動機：制御可能生成

原理：ベイズ分解と誘導

誘導方向の具体化

共通テンプレート

嗜好整合への橋

まとめ

粗から細への生成と介入

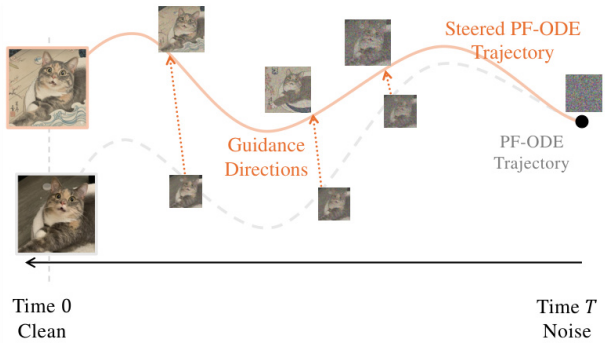
拡散の生成は粗 → 細に進む：

- 各ステップでわずかにノイズを除き、構造と細部が現れる
- 時間依存の速度場（スコア）に**誘導項**を足せば、
  ユーザ意図に沿って軌道を曲げられる

直感

「最終サンプルだけ」ではなく、
軌道そのものを条件・属性へ寄せる。

図 8.1：誘導付き拡散サンプリング



右（$t = T$，ノイズ）から左（$t = 0$，クリーン）へ逆時間 PF-ODE。
誘導方向（重み w_t）が無条件軌道を属性（例：日本画風）へ曲げる。

補足：図 8.1 の読み方

灰色：PF-ODE

無条件の逆時間軌道。
学習済みスコア場に従う。

橙：誘導付き

各時刻の誘導方向が
軌道を望ましい属性へ寄せる。

要点

誘導は「別モデルで一発生成」ではなく、
逆時間力学への時間依存な補正である。

区切り：原理：ベイズ分解と誘導

動機：制御可能生成

原理：ベイズ分解と誘導

誘導方向の具体化

共通テンプレート

嗜好整合への橋

まとめ

条件付きスコアの加法分解

各ノイズレベル t で、ベイズ則より

$$\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{c}) = \underbrace{\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t)}_{\text{無条件方向}} + \underbrace{\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)}_{\text{誘導方向}} \tag{8.1.1}$$

含意

真の条件付き逆時間力学は、
無条件スコアに $\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)$ を足せば得られる。

誘導付き PF-ODE

正確な条件付きスコアのもとで

$$\begin{aligned}\frac{\mathrm{d}\boldsymbol{x}(t)}{\mathrm{d}t} &= f(t)\boldsymbol{x}(t) - \frac{1}{2}g^2(t)\,\nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}(t)|\boldsymbol{c}) \\ &= f(t)\boldsymbol{x}(t) - \frac{1}{2}g^2(t)\Big[\nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}(t)) + \nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{c}|\boldsymbol{x}(t))\Big].\end{aligned} \tag{8.1.2}$$

- 正確なスコアと正確な積分なら、$p_T(\cdot|\boldsymbol{c})$ から $p_0(\cdot|\boldsymbol{c})$ へ
- 標準構成では $p_T(\boldsymbol{x}_T|\boldsymbol{c})$ は条件にほぼ依存しない事前で近似
- $\boldsymbol{x}/\boldsymbol{\epsilon}/$スコア$/\boldsymbol{v}$ 予測は式 6.3.1 の線形変換で結べる

区切り：誘導方向の具体化

動機：制御可能生成

原理：ベイズ分解と誘導

誘導方向の具体化

共通テンプレート

嗜好整合への橋

まとめ

三つの入り口（予告）

1. **Classifier Guidance（CG，8.2）**
   ノイズ時刻の分類器 $\nabla_{\boldsymbol{x}_t} \log p_\psi(\boldsymbol{c}|\boldsymbol{x}_t, t)$ を直接足す
2. **Classifier-Free Guidance（CFG，8.3）**
   条件付き・無条件スコアの差として誘導方向を暗に推定
3. **学習不要（代理）誘導（8.4）**
   タスク損失からの代理ポテンシャルで G_t を構成

CG：分類器勾配を足す

時刻条件付き分類器 $p_\psi(\boldsymbol{c}|\boldsymbol{x}_t, t)$ を
ノイズ付きラベルデータで学習する（Dhariwal & Nichol, 2021）。

$$\nabla_{\boldsymbol{x}_t} \log p_\psi(\boldsymbol{c}|\boldsymbol{x}_t, t) \;\approx\; \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)$$

サンプリング時

この勾配を無条件スコアに加算する。
拡散本体の再学習は不要（分類器は別途）。

CFG：差として誘導を読む

単一モデル $s_\phi(\boldsymbol{x}_t, t, \boldsymbol{c}) \approx \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{c})$ を学習し、
条件を特殊なヌルトークンに置き換えて無条件も同時学習する
(Ho & Salimans, 2021)。

読み替え

誘導方向 $\nabla \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)$ は、
条件付きスコアと無条件スコアの差として現れる（8.3 で展開）。

学習不要：なぜ代理が必要か

標準の前向きノイズでは $\boldsymbol{x}_t \sim p_t(\cdot|\boldsymbol{x}_0)$ で、
前向き核は $\boldsymbol{c}$ に追加依存しない（$\boldsymbol{c} \perp \boldsymbol{x}_t \mid \boldsymbol{x}_0$）。

$$p_t(\boldsymbol{c}|\boldsymbol{x}_t) = \int p(\boldsymbol{c}|\boldsymbol{x}_0)\, p(\boldsymbol{x}_0|\boldsymbol{x}_t)\, \mathrm{d}\boldsymbol{x}_0$$

困難

この事後平均は一般に計算不能。
$\Rightarrow$ タスク固有の代理誘導方向を構成する動機。

損失ベースの代理ポテンシャル

オフザシェルフ損失 $\ell(\boldsymbol{x}_t, \boldsymbol{c}; t)$（小さいほど条件に合う）から

$$h_t(\boldsymbol{x}_t; \boldsymbol{c}) := \exp\big(-\tau\, \ell(\boldsymbol{x}_t, \boldsymbol{c}; t)\big), \qquad \tau > 0$$

$$G_t(\boldsymbol{x}_t, \boldsymbol{c}) := \nabla_{\boldsymbol{x}_t} \log h_t(\boldsymbol{x}_t; \boldsymbol{c}) = -\tau\, \nabla_{\boldsymbol{x}_t} \ell(\boldsymbol{x}_t, \boldsymbol{c}; t)$$

- CG は $h_t = p_t(\boldsymbol{c}|\boldsymbol{x}_t)$（実践では p_ψ）に対応
- 同値な損失：$\ell = -\log p_\psi(\boldsymbol{c}|\boldsymbol{x}_t, t)$，$\tau = 1$

区切り：共通テンプレート

動機：制御可能生成

原理：ベイズ分解と誘導

誘導方向の具体化

共通テンプレート

嗜好整合への橋

まとめ

誘導付きスコア場

正のポテンシャル h_t と強度 $w_t \geq 0$ に対し

$$s^{\mathrm{guide}}(\boldsymbol{x}_t, t, \boldsymbol{c}; w_t) := \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t) + w_t \, G_t(\boldsymbol{x}_t, \boldsymbol{c}) \tag{8.1.3}$$

- 損失ベース：$G_t = -\tau \nabla_{\boldsymbol{x}_t} \ell$
- 正確な CG：$G_t = \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)$
- CFG：同じ母集団誘導を条件／無条件スコア差で表現

傾き密度と固定時刻解釈

各固定 t で、正規化可能なら式 (8.1.3) は

$$\tilde{p}_t^{\mathrm{tilt}}(\boldsymbol{x}_t|\boldsymbol{c}) \;\propto\; p_t(\boldsymbol{x}_t)\, h_t(\boldsymbol{x}_t;\boldsymbol{c})^{w_t}$$

のスコア（ベース＝拡散支持、ポテンシャル＝条件へ再重み）。

注意

$\{\tilde{p}_t^{\mathrm{tilt}}\}$ は固定時刻の解釈にすぎない。
誘導サンプラの周辺と一致するとは限らず、整合は 8.4.2。

区切り：嗜好整合への橋

動機：制御可能生成

原理：ベイズ分解と誘導

誘導方向の具体化

共通テンプレート

嗜好整合への橋

まとめ

嗜好整合：条件充足だけでは足りない

強い制御でも、条件は満たすが好みから外れることがある。

$$\tilde{p}_0^{\mathrm{tilt}}(\boldsymbol{x}_0|\boldsymbol{c}) \;\propto\; p_0(\boldsymbol{x}_0|\boldsymbol{c})\,\exp\!\big(\lambda_{\mathrm{pref}}\, r(\boldsymbol{x}_0,\boldsymbol{c})\big)$$

- r：嗜好評点、$\lambda_{\mathrm{pref}} > 0$（KL 正則化では $1/\beta$）
- 典型は RLHF だが不安定になりやすい（報酬モデル＋ RL）
- 8.5：Diffusion-DPO はペア選択から傾きを直接学習

区切り：8.1 のまとめ

動機：制御可能生成

原理：ベイズ分解と誘導

誘導方向の具体化

共通テンプレート

嗜好整合への橋

まとめ

8.1 全体のまとめ

1. **動機**粗 $\rightarrow$ 細の軌道に誘導項を足して意図を反映
2. **原理**ベイズ分解（8.1.1）と誘導付き PF-ODE（8.1.2）
3. **統一形** $s^{\mathrm{guide}} = \nabla \log p_t + w_t G_t$（8.1.3）
4. **地図** CG ／ CFG ／学習不要／嗜好整合（DPO）
5. **注意**傾き密度は固定時刻解釈；周辺一致は別問題

8.1 全体のまとめ：一本の流れ

今日の道筋

制御の動機 $\rightarrow$ ベイズ分解 $\rightarrow$ 誘導テンプレート $\rightarrow$ 各手法の予告

核心

誘導とは、逆時間スコア場への加法的補正である。
G_t の作り方が CG ／ CFG ／代理損失を分ける。

次へ（8.2）

Classifier Guidance：分類器勾配とスケール ω。