The Principles of Diffusion Models

8.2 Classifier Guidance

渡邉 有志

November 13, 2026

8.1 から 8.2 へ

ここまで（8.1）

誘導の共通形 $s^{\text{guide}} = \nabla \log p_t + w_t G_t$ と、CG ／ CFG ／代理誘導の地図を置いた。

ここから（8.2）

最初の具体化：**Classifier Guidance**。
ベイズ分解 $\rightarrow$ スケール ω $\rightarrow$ 学習分類器 $\rightarrow$ 推論と限界。

8.2 の位置づけ

この節の役割

無条件拡散＋時刻条件付き分類器で、
条件付き生成をサンプリング時に実現する

1. **8.2.1 基礎**
   ベイズ分解とオラクル誘導場（スケール ω）
2. **8.2.2 推論**
   学習分類器勾配を無条件スコアへ加算
3. **8.2.3 利点と限界**
   柔軟さ vs ノイズ時刻分類器の負担

目標設定

条件変数 $\boldsymbol{c} \sim p(\boldsymbol{c})$（クラス、キャプション等）に対し、
$p_0(\boldsymbol{x}|\boldsymbol{c})$ からサンプルしたい。

- 拡散の条件付き生成では、周辺が $p_t(\cdot|\boldsymbol{c})$ となる
  逆時間力学を走らせる
- そのドリフトは条件付きスコア $\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{c})$ に依存する

標準ルート

この条件付きスコアを推定する。

区切り：8.2.1 基礎

8.2.1 基礎：ベイズと誘導場

8.2.2 推論

8.2.3 利点と限界

まとめ

ベイズ分解（母集団）

$$\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{c}) = \nabla_{\boldsymbol{x}_t} \log \left(\frac{p_t(\boldsymbol{x}_t)\, p_t(\boldsymbol{c}|\boldsymbol{x}_t)}{p(\boldsymbol{c})} \right)$$

$p(\boldsymbol{c})$ は $\boldsymbol{x}_t$ に依らないので落として

$$\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{c}) = \underbrace{\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t)}_{\text{無条件スコア}} + \underbrace{\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)}_{\text{分類器勾配}} \tag{8.2.1}$$

補足：なぜこの分解が有用か

- 無条件スコアは既存の無条件拡散から使える
- 誘導は「$\boldsymbol{c}$ をノイズ入力 $\boldsymbol{x}_t$ から読む」勾配に分離される
- 棄却／重要度サンプリングでも原理上は可能だが、
  高次元・稀な条件では現実的でないことが多い

CG の発想

分類器側だけを別途学習し、サンプリング時に足す
(Dhariwal & Nichol, 2021)。

オラクル：傾き密度と誘導場

誘導スケール $\omega \geq 0$ に対し、各固定 t で

$$\tilde{p}_t^{\mathrm{CG},\omega}(\boldsymbol{x}_t|\boldsymbol{c}) \;\propto\; p_t(\boldsymbol{x}_t)\, p_t(\boldsymbol{c}|\boldsymbol{x}_t)^{\omega} \tag{8.2.2}$$

そのスコアは

$$s^{\mathrm{CG}}(\boldsymbol{x}_t, t, \boldsymbol{c}; \omega) := \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t) + \omega\, \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{c}|\boldsymbol{x}_t) \tag{8.2.3}$$

- $\omega = 1$：ベイズより $\tilde{p}_t^{\mathrm{CG},1} = p_t(\cdot|\boldsymbol{c})$（正確な条件付きスコア）
- 一般の ω：固定時刻の温度付き解釈（周辺経路との一致は 8.4.2）

スケール ω の役割

スカラー $\omega \geq 0$ が分類器信号の強さを変調する：

- $\omega = 1$：真の条件付きスコア $\nabla \log p_t(\boldsymbol{x}_t|\boldsymbol{c})$ を回復
- $\omega > 1$：分類器信号を増幅。条件忠実度↑、多様性↓が多い
- $0 \leq \omega < 1$：分類器を弱める。多様性↑、条件付け↓が多い

運用

ω はサンプリング時のノブ。
拡散モデル本体の重みは触らない。

実践近似：拡散は凍結

CG は（拡散モデルに対しては）**学習不要**な誘導法：

$$s_{\phi^\star}(\boldsymbol{x}_t, t) \;\approx\; \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t)$$

- 事前学習済み無条件拡散をそのまま使う
- 修正はサンプリング時のみ
- 追加で必要なのは、ノイズ入力から $\boldsymbol{c}$ を読む
  時刻依存分類器 $p_\psi(\boldsymbol{c}|\boldsymbol{x}_t, t)$

分類器の学習目標

交差エントロピーをノイズレベル全体で最小化：

$$\mathbb{E}_{t\sim\mathcal{U}[0,T],\,(\boldsymbol{x},\boldsymbol{c})\sim p_{\text{data}},\,\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I})}\left[-\log p_\psi(\boldsymbol{c}|\boldsymbol{x}_t,t)\right] \tag{8.2.4}$$

ここで $\boldsymbol{x}_t = \alpha_t\boldsymbol{x} + \sigma_t\boldsymbol{\epsilon}$。

要件

分類器は全ノイズレベルで動作し、
t（または同等のノイズ表現）を入力に含める。

補足：何を近似しているか

学習後の入力勾配が、真の尤度勾配の代理になる：

$$\nabla_{\boldsymbol{x}_t} \log p_{\psi^\star}(\boldsymbol{c}|\boldsymbol{x}_t, t) \;\approx\; \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)$$

8.1 との対応

$G_t \approx \nabla \log p_{\psi^\star}$
$h_t \approx p_{\psi^\star}$
$w_t \leftrightarrow \omega$

損失として

$\ell = -\log p_{\psi^\star}$
$\tau = 1$

区切り：8.2.2 推論

8.2.1 基礎：ベイズと誘導場

8.2.2 推論

8.2.3 利点と限界

まとめ

学習済み誘導場

推論時は、オラクル場 (8.2.3) を次で近似する：

$$s^{\mathrm{CG}}_{\mathrm{model}}(\boldsymbol{x}_t, t, \boldsymbol{c}; \omega) := \underbrace{s_{\phi^\star}(\boldsymbol{x}_t, t)}_{\text{無条件方向}} + \omega \underbrace{\nabla_{\boldsymbol{x}_t} \log p_{\psi^\star}(\boldsymbol{c}|\boldsymbol{x}_t, t)}_{\text{誘導方向}}$$

$$s^{\mathrm{CG}}_{\mathrm{model}} \approx s^{\mathrm{CG}}(\boldsymbol{x}_t, t, \boldsymbol{c}; \omega)$$

逆時間力学への差し替え

逆時間 SDE または PF-ODE 中の無条件スコア推定を
$s^{\mathrm{CG}}_{\mathrm{model}}(\boldsymbol{x}_t, t, \boldsymbol{c}; \omega)$ で置き換える。

- 生成軌道が条件 $\boldsymbol{c}$ に整合する方向へ曲がる
- ω を変えるだけで、同じ二モデルから
  忠実度と多様性のトレードオフを調整できる

手順の骨格

ノイズ $\boldsymbol{x}_T$ から出発 $\rightarrow$ 各 t で誘導場を評価 $\rightarrow$ 逆時間更新。

補足：実装上のイメージ

1. 無条件スコアネット $s_{\phi^\star}(\boldsymbol{x}_t, t)$ を評価
2. 分類器 $\log p_{\psi^\star}(\boldsymbol{c}|\boldsymbol{x}_t, t)$ を $\boldsymbol{x}_t$ で微分
3. ω 倍して加算し、SDE ／ ODE のドリフトへ投入

計算コスト

各ステップで拡散ネットに加え、
分類器の前向き＋入力勾配が必要。

8.1 テンプレートとの対応表

8.1 の記号	CG での実体
$\nabla \log p_t(\boldsymbol{x}_t)$	$s_{\phi^\star}(\boldsymbol{x}_t, t)$
$G_t(\boldsymbol{x}_t, \boldsymbol{c})$	$\nabla_{\boldsymbol{x}_t} \log p_{\psi^\star}(\boldsymbol{c}\|\boldsymbol{x}_t, t)$
w_t	定数スケール ω（または時刻依存に拡張可）
h_t	$p_t(\boldsymbol{c}\|\boldsymbol{x}_t) \,/\, p_{\psi^\star}$

一文

CG は「分類器対数尤度の勾配」を G_t に選んだ誘導である。

区切り：8.2.3 利点と限界

8.2.1 基礎：ベイズと誘導場

8.2.2 推論

8.2.3 利点と限界

まとめ

利点

- **単純**：条件付け強度を ω で明示的に制御
- **柔軟**：任意の事前学習済み無条件拡散に後付け可能
- **分離**：拡散本体を再学習せず、分類器追加だけで条件付け
- **解釈**：ベイズ分解に直結し、母集団では $\omega = 1$ が厳密

限界（1）：学習コスト

Training Cost

分類器を**すべてのノイズレベル**で動くよう訓練する必要があり、
計算コストが大きい。

- $t \sim \mathcal{U}[0, T]$ で $\boldsymbol{x}_t$ を広くカバーする必要がある
- クリーン画像用の分類器をそのまま流用できない

限界（2）：頑健性

Robustness

特に大きい t では $\boldsymbol{x}_t$ が強く壊れており、
分類器の一般化が難しい。

- 粗段階での誤った誘導は、後段の細部にも残る
- 誘導スケール $\omega > 1$ は誤信号も増幅し得る

限界（3）：分離学習のずれ

Separate Training

分類器は拡散と独立に学習されるため、
学習済みデータ分布と完全には整合しないことがある。

次節への動機

分類器を捨て、条件付き・無条件スコアを
同一拡散モデル内で学ぶのが CFG（8.3）。

補足：いつ CG を選ぶか

向きやすい状況

強い無条件モデルが既にある
条件は分類器で測りやすい
ω で強度を触りたい

慎重になる状況

強ノイズでの分類が不安定
分類器学習の予算が乏しい
拡散分布との整合が重要

区切り：8.2 のまとめ

8.2.1 基礎：ベイズと誘導場

8.2.2 推論

8.2.3 利点と限界

まとめ

8.2 全体のまとめ

1. **分解** $\nabla \log p_t(\boldsymbol{x}_t|\boldsymbol{c}) = \nabla \log p_t + \nabla \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)$
2. **オラクル** $s^{\mathrm{CG}} = \nabla \log p_t + \omega \nabla \log p_t(\boldsymbol{c}|\boldsymbol{x}_t)$
3. **実践**無条件拡散＋ノイズ時刻分類器；損失は (8.2.4)
4. **推論** $s^{\mathrm{CG}}_{\mathrm{model}}$ を逆時間力学へ差し替え
5. **限界**全 t 分類器のコスト・頑健性・分離学習のずれ

8.2 全体のまとめ：一本の流れ

今日の道筋

ベイズ分解 $\rightarrow$ ω 付き誘導場 $\rightarrow$ 分類器学習 $\rightarrow$ サンプリング差し替え $\rightarrow$ 利点／限界

核心

CG は「分類器勾配を ω 倍して足す」誘導である。
拡散は凍結でき、代わりにノイズ時刻分類器が要る。

次へ（8.3）

Classifier-Free Guidance：分類器なしで同じ母集団場へ。