The Principles of Diffusion Models

8.3 Classifier-Free Guidance

渡邉 有志

November 13, 2026

8.3 Classifier-Free Guidance

この節の役割（論文 8.3）

別途の分類器なしで、条件付き／無条件スコアの
線形結合によって誘導方向を実現する（CFG）。

- **8.3.1** 基礎：Bayes 恒等式とオラクル CFG 場、ω の役割
- **8.3.2** 訓練（null 条件の dropout）とサンプリング
- 図 8.2：条件付き・無条件スコアの線形結合の直感

8.2 から 8.3 へ

ここまで（8.2 CG）

無条件スコア + 分類器勾配 $\omega \nabla_{\boldsymbol{x}_t} \log p_t(c|\boldsymbol{x}_t)$。
拡散モデルは固定し、ノイズ入力用の分類器を別訓練する。

ここから（8.3 CFG）

分類器をやめ、**1 つの条件付き拡散モデル**で
条件付きスコアと無条件スコアを同時に学ぶ。

ねらい

オラクルでは CG と同じ誘導場を、学習・実装の負担を減らして得る。

8.3 の道筋

1. **Bayes**：$\nabla \log p_t(c|\boldsymbol{x}_t)$ を条件付き・無条件スコアの差へ
2. **オラクル CFG**：ω 付き線形結合（式 (8.3.2)）
3. **図 8.2**：補間（$0 \le \omega \le 1$）と外挿（$\omega > 1$）
4. **訓練**：条件を確率的に $\varnothing$ に落とす（Algorithm 4）
5. **サンプリング**：学習済み結合場で逆時間 SDE / PF-ODE を駆動

区切り：8.3.1 Foundation of CFG

8.3.1 Foundation

8.3.2 Training and Sampling

CFG の出発点

動機

Classifier Guidance は別分類器が必要で、
全ノイズレベルでの頑健な学習コストが大きい（§8.2.3）。

CFG (Ho and Salimans, 2021) は、
条件付きスコアと無条件スコアだけで同じ誘導方向を表す。

- 目標は依然として条件付き生成（$p_0(\boldsymbol{x}|c)$ 方向へ）
- ただし $\nabla_{\boldsymbol{x}_t} \log p_t(c|\boldsymbol{x}_t)$ を分類器で近似しない

Bayes 恒等式（8.3.1）

Bayes 則より

$$\nabla_{\boldsymbol{x}_t} \log p_t(c|\boldsymbol{x}_t) = \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|c) - \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t). \tag{8.3.1}$$

読み方

「分類器勾配」＝「条件付きスコア」−「無条件スコア」。
右辺はどちらも拡散モデル側の量である。

オラクル CFG 場（8.3.2）

式 (8.2.3) に (8.3.1) を代入すると

$$
\begin{aligned}
s^{\mathrm{CFG}}(\boldsymbol{x}_t, t, c; \omega) &:= \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t) + \omega\big(\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|c) - \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t)\big) \\
&= \omega\, \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|c) + (1-\omega)\, \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t). \qquad (8.3.2)
\end{aligned}
$$

- 第 1 項：条件付きスコア
- 第 2 項：無条件スコア

CG との代数的一致

オラクル水準

正確なスコアがあれば、式 (8.3.2) は式 (8.2.3) と
同じ誘導場である（書き換えに過ぎない）。

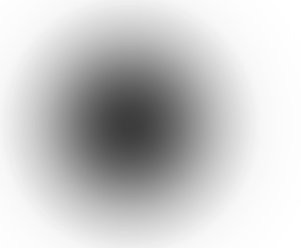
- $\omega = 1$：純粋な条件付きスコア $\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|c)$
- 一般の ω：固定時刻の tilted 密度解釈は可能だが、
  誘導力学が生成する周辺とは区別する（§8.4.2）

実務の差

CG は分類器近似、CFG は条件付き／無条件スコア近似。
近似の置き方が違うので、学習・頑健性の性質も変わる。

図 8.2：CFG の線形結合





Source: Created by the authors.（論文 Figure 8.2）

図 8.2 の読み方

現在点 $\boldsymbol{x}_t$ から、2 本の灰色矢印の和が青の誘導方向になる。

- $(1-\omega)\nabla \log p_t(\boldsymbol{x}_t)$：無条件方向（データ全体）
- $\omega \nabla \log p_t(\boldsymbol{x}_t|c)$：条件付き方向（target mode 寄り）
- $0 \le \omega \le 1$：2 方向の**補間**
- $\omega > 1$：条件付き方向への**外挿**（条件をより強く）

直感

ω を大きくすると、条件モードへ押し出す力が強まる一方、
多様性は下がりやすい。

誘導強度 ω の役割

$\omega \geq 0$ を取る。

- $\omega = 0$：完全に無条件。条件 c を無視
- $\omega = 1$：追加誘導なしの条件付きスコア
- $\omega > 1$：条件付きスコアを強調し、
  条件への整合は強まるが多様性は典型的に低下

運用上の要点

ω は**サンプリング時**のハイパーパラメータ。
訓練損失には入れない（次節）。

固定時刻の解釈（予告）

CG と同様、固定 t では

$$\tilde{p}_t^{\mathrm{CG},\omega}(\boldsymbol{x}_t|c) \propto p_t(\boldsymbol{x}_t)\, p_t(c|\boldsymbol{x}_t)^{\omega}$$

のスコアが (8.2.3)/(8.3.2) である。

注意（§8.4.2 へ）

この tilted 密度は「その時刻の場の解釈」であり、
誘導付き力学を $T \to 0$ で積分した結果の周辺分布とは
一般には一致しない。

区切り：8.3.2 Training and Sampling

8.3.1 Foundation

8.3.2 Training and Sampling

1 モデルで条件付き＋無条件

CFG は条件付き予測と無条件予測の**両方**を要する。

方針

2 モデルに分けず、単一モデル $s_\phi(\boldsymbol{x}_t, t, c)$ を使う。
訓練中に条件入力をランダムに null トークン $\varnothing$ へ置換する。

- $\varnothing$ 入力：無条件予測 $s_\phi(\boldsymbol{x}_t, t, \varnothing)$ を学習
- 本来の c：条件付き予測 $s_\phi(\boldsymbol{x}_t, t, c)$ を学習

条件ドロップアウト

ユーザ指定の確率 p_{uncond} で

$$c \leftarrow \varnothing$$

とする（condition dropout）。

- 大きい p_{uncond}：無条件側の学習機会が増える
- 小さすぎると無条件推定が弱く、CFG の結合が不安定になりうる
- ω 自体は訓練に現れない（推論時のみ）

ポイント

「条件を時々忘れる」ことで、同じネットが両モードを担う。

Algorithm 3：無条件 DM（対比）

標準的な無条件スコア学習の骨格：

1. $\boldsymbol{x} \sim p_{\mathrm{data}}(\boldsymbol{x})$，$t \sim U[0,T]$，$\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$
2. $\boldsymbol{x}_t = \alpha_t \boldsymbol{x} + \sigma_t \boldsymbol{\epsilon}$
3. 勾配ステップ：$\nabla_\phi \| s_\phi(\boldsymbol{x}_t, t) - s \|_2^2$
4. 収束まで繰り返す

対比の狙い

Algorithm 4 は、データが $(\boldsymbol{x}, c)$ ペアになり、
入力に条件（または $\varnothing$）が付く点だけが本質的に違う。

Algorithm 4：CFG 用の条件付き訓練

入力：p_{uncond}（無条件ドロップアウト確率）

1. $(\boldsymbol{x}, c) \sim p_{\text{data}}(\boldsymbol{x}, c)$
2. 確率 p_{uncond} で $c \leftarrow \varnothing$
3. $t \sim U[0, T]$，$\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$
4. $\boldsymbol{x}_t = \alpha_t \boldsymbol{x} + \sigma_t \boldsymbol{\epsilon}$
5. 勾配ステップ：$\nabla_\phi \| s_\phi(\boldsymbol{x}_t, t, c) - s \|_2^2$
6. 収束まで繰り返す

注意

ここでの c は「本物の条件」か「$\varnothing$」かのいずれか。
誘導スケール ω はまだ出てこない。

学習済み CFG 場（8.3.3）

訓練後のモデルを $s_{\phi^\times}(\boldsymbol{x}_t, t, c)$ と書くと

$$
\begin{aligned}
s^{\mathrm{CFG}}_{\mathrm{model}}(\boldsymbol{x}_t, t, c; \omega) &:= \omega\, s_{\phi^\times}(\boldsymbol{x}_t, t, c) + (1-\omega)\, s_{\phi^\times}(\boldsymbol{x}_t, t, \varnothing) \\
&\approx s^{\mathrm{CFG}}(\boldsymbol{x}_t, t, c; \omega).
\end{aligned} \tag{8.3.3}
$$

- 条件付き推定：ω の係数
- 無条件推定：$(1-\omega)$ の係数（$\varnothing$ 入力）

サンプリング手順

逆時間 SDE または PF-ODE で、
無条件スコア推定を $s_{\text{model}}^{\text{CFG}}$ に置き換える。

1. 各ステップで条件付き評価 $s_{\phi^\times}(\boldsymbol{x}_t, t, c)$ を計算
2. 同じ $\boldsymbol{x}_t$ で無条件評価 $s_{\phi^\times}(\boldsymbol{x}_t, t, \varnothing)$ を計算
3. ω で線形結合し、その場で 1 ステップ更新

コスト感

1 ステップあたりネット評価が実質 2 回（条件あり／なし）。
分類器を別途走らせる CG より実装は単純なことが多い。

制御可能性：強さと多様性

訓練後に ω だけを動かして、
条件への整合と**多様性**のトレードオフを調整できる。

ω 小

無条件寄り。
多様だが条件が弱い。

ω 大

条件を強調。
整合は強いが単調になりやすい。

別分類器も、別の無条件拡散モデルも不要。

CG と CFG の比較（再掲）

	CG（8.2）	**CFG（8.3）**
拡散モデル	無条件を流用	条件付き（$+\varnothing$）を学習
追加モデル	時間依存分類器	不要（同一ネット）
誘導の中身	$\omega\nabla \log p_\psi(c\|\boldsymbol{x}_t, t)$	条件／無条件スコアの差
ω の位置	推論時	推論時
典型コスト	分類器＋拡散	拡散 2 評価／ステップ

オラクルでは同じ場、実装では「何を近似するか」が違う。

補足：実装メモ（スコア以外のパラメータ化）

本文はスコア予測で書いているが、
$\boldsymbol{\epsilon}$ 予測や $\boldsymbol{x}$ 予測でも同様の結合が広く使われる。

- 実務の CFG はしばしば $\tilde{\boldsymbol{\epsilon}} = \boldsymbol{\epsilon}_\phi(\boldsymbol{x}_t, t, \varnothing) + \omega\big(\boldsymbol{\epsilon}_\phi(\boldsymbol{x}_t, t, c) - \boldsymbol{\epsilon}_\phi(\boldsymbol{x}_t, t, \varnothing)\big)$
- これは (8.3.2) と同じ「無条件 $+\ \omega\times$ 差」の形
- パラメータ化の換算は第 6 章の同値関係に従う

8.3 のまとめ

- Bayes で分類器勾配 = 条件付き − 無条件スコア
- オラクル CFG 場は CG 場の書き換え（式 (8.3.2)）
- ω：補間／外挿で条件の強さを制御
- 訓練：null 条件ドロップアウトで 1 モデル二役
- 推論：2 評価の線形結合で逆過程を駆動

残る問い

では、訓練せずに外部損失だけで誘導すると何が起きるか？
→ 次節 8.4（Training-Free Guidance）

次節へ：8.4 Training-Free Guidance

1. 凍結した事前学習モデルを、推論時だけ外部条件で曲げる
2. data-space / noise-space の 2 系統の補正
3. 誘導が本当に作る分布（tilted / 近似事後）
4. 逆問題への適用例（ILVR、DPS など）

8.4 は論文上 Optional。ゼミでは本筋を青、深い整合条件は緑で。