The Principles of Diffusion Models

8.4 (Optional) Training-Free Guidance

渡邉 有志

November 13, 2026

補足：8.4 の位置づけ（Optional）

この節の役割（論文 8.4）

事前学習済み拡散モデルを**再学習せず**、
外部の条件・損失・観測でサンプリング力学だけを曲げる。

- 8.4.1：data-space / noise-space の概念枠
- 8.4.2：誘導が作る分布（tilted と実際の周辺）
- 8.4.3：逆問題への例（ILVR、DPS、関連する InDI）

任意節。ゼミでは青で本筋、Fokker–Planck 整合や InDI 詳細は緑。

なぜ Training-Free か

動機

CFG/CG は条件付き学習や分類器学習を要する。
タスクが変わるたび再訓練するのは重い。

- 既製の無条件（または条件付き）拡散を**凍結**
- 推論時に損失・観測 y・外部表現（例：CLIP）で補正
- Bayes 分解（式 (8.1.1)/(8.1.3)）がスコア空間での動機付け

実務のイメージ

「きれいな画像の事前分布」は拡散が担い、
「観測に合う／プロンプトに近い」はサンプリング中の補正が担う。

8.4 の道筋

1. **設定**：事前学習スコア、x-予測、タスク損失 ℓ
2. **8.4.1** DDIM 更新を data / noise でどう曲げるか
3. **8.4.2** 固定時刻の tilted 密度 $\neq$ 積分後の周辺（一般）
4. **8.4.3** 逆問題：ILVR（投影）と DPS（尤度スコア近似）
5. **補足** InDI と PF-ODE のつながり

設定と記号

- 条件変数 c（プロンプト、観測、参照など）
- 凍結モデル $s_{\phi^\times}(\boldsymbol{x}_t, t) \approx \nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t)$（スコア形）
- タスク損失 $\ell(\cdot, c) : \mathbb{R}^D \to \mathbb{R}$（小さいほど条件に合う）

例：参照への知覚距離、CLIP 特徴の負類似度など。

前向き核

$p_t(\cdot|\boldsymbol{x}_0) = \mathcal{N}(\cdot; \alpha_t \boldsymbol{x}_0, \sigma_t^2 I)$。

DDIM 更新を具体例に

後の式 (9.2.2) の DDIM 更新を借用すると

$$\boldsymbol{x}_{t\to t-1} = \alpha_{t-1}\ \underbrace{\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)}_{\text{data space}}\ -\sigma_{t-1}\sigma_t\ \underbrace{\hat{s}(\boldsymbol{x}_t)}_{\text{noise space}}\ . \tag{8.4.1}$$

- $\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t) := \boldsymbol{x}_{\phi^\times}(\boldsymbol{x}_t, t)$：クリーン予測
- $\hat{s}(\boldsymbol{x}_t) := s_{\phi^\times}(\boldsymbol{x}_t, t)$：スコア予測

読み方

1 ステップは「きれいに戻す項」と「ノイズ／スコア項」の組。
Training-free は、どちらか（または両方）を補正する。

2つの補正場所（概観）

A. Data space

$\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)$ を
$+\eta_t^{\mathrm{data}} G_t^{\mathrm{data}}$ で動かす。
（クリーン推定の修正）

B. Noise space

$\hat{s}(\boldsymbol{x}_t)$ に
$+\eta_t^{\mathrm{latent}} G_t$ を足す。
（スコア項の修正）

どちらも DDIM 更新 (8.4.1) の部品を曲げる操作。
強さは $\eta_t^{\mathrm{data}}, \eta_t^{\mathrm{latent}} \geq 0$ で制御する。

区切り：8.4.1 Conceptual Framework

Setup

8.4.1 Conceptual Framework

8.4.2 What Distribution

8.4.3 Inverse Problems

Related: InDI

誘導方向の定義

data-space 方向：

$$G_t^{\mathrm{data}}(\boldsymbol{x}_t, c) := -\nabla_{\boldsymbol{x}_0} \ell(\boldsymbol{x}_0, c)\big|_{\boldsymbol{x}_0 = \hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)}.$$

noise-space では Prologue の誘導方向を再利用：

$$G_t(\boldsymbol{x}_t, c) := \nabla_{\boldsymbol{x}_t} \log h_t(\boldsymbol{x}_t; c)$$

（正値ポテンシャル h_t は後で損失から構成）。

統一更新（8.4.2）

DDIM 形に両補正を書くと

$$\boldsymbol{x}_{t\to t-1} = \alpha_{t-1}\Big(\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t) + \eta_t^{\mathrm{data}} G_t^{\mathrm{data}}(\boldsymbol{x}_t, c)\Big) - \sigma_{t-1}\sigma_t\Big(\hat{s}(\boldsymbol{x}_t) + \eta_t^{\mathrm{latent}} G_t(\boldsymbol{x}_t, c)\Big). \tag{8.4.2}$$

- $\eta_t^{\mathrm{data}} \geq 0$：data-space の強さ
- $\eta_t^{\mathrm{latent}} \geq 0$：noise-space の強さ

A. Guidance in Data Space

クリーン推定を局所的に損失減少させる：

$$\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t) \longmapsto \hat{\boldsymbol{x}}_0(\boldsymbol{x}_t) + \eta_t^{\text{data}} G_t^{\text{data}}(\boldsymbol{x}_t, c).$$

- 条件に合う方向へ $\hat{\boldsymbol{x}}_0$ を動かしてから更新に使う
- 必要なら同じ補正を複数回繰り返せる
- 代表例：MGPD (He et al., 2023)、UGD (Bansal et al., 2023)

直感

「まずきれいな画像の推定を直してから、次のノイズ段へ進む」。

B. Guidance in Noise Space

スコア側へ直接誘導を足す。損失をクリーン推定上で評価し

$$h_t(\boldsymbol{x}_t; c) := \exp\big(-\tau\, \ell(\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t), c)\big), \qquad \tau > 0$$

とすると

$$G_t(\boldsymbol{x}_t, c) = -\tau \nabla_{\boldsymbol{x}_t} \ell\big(\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t), c\big).$$

スコア項は $\hat{s}(\boldsymbol{x}_t) + \eta_t^{\text{latent}} G_t(\boldsymbol{x}_t, c)$。

ポテンシャル観との対応

人口レベル構成（式 (8.1.3)）と比べると：

- $\eta_t^{\text{latent}} \leftrightarrow$ 一般の誘導強度 w_t
- $\hat{s}(\boldsymbol{x}_t) \leftrightarrow$ 正確な無条件スコアの学習近似

いつ真の Bayes 方向になるか

$h_t \propto p_t(c|\boldsymbol{x}_t)$（$\boldsymbol{x}_t$ に依らない因子を除く）なら、
G_t は $\nabla_{\boldsymbol{x}_t} \log p_t(c|\boldsymbol{x}_t)$ を回復する。
一般のタスク損失では**代理（surrogate）**誘導になる。

補足：G_t の計算コスト

G_t は x-予測を通した微分を要する：

$$G_t(\boldsymbol{x}_t, c) = -\tau \big[\nabla_{\boldsymbol{x}_t} \hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)\big]^\top \nabla_{\boldsymbol{x}_0} \ell(\boldsymbol{x}_0, c)\big|_{\boldsymbol{x}_0 = \hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)}.$$

- ネットの Jacobian–vector が必要で計算が重い場合がある
- 代表例：Yu et al. (2023)、Chung et al. (2022)、Bansal et al. (2023)

本稿の線引き

ここまでは「1 ステップをどう曲げるか」。
「曲げた力学が最終的にどの分布を出すか」は次節。

区切り：8.4.2 What Distribution?

Setup

8.4.1 Conceptual Framework

8.4.2 What Distribution

8.4.3 Inverse Problems

Related: InDI

固定時刻の tilted 密度

学習スコアを正確なスコアに置き換えると、
正値ポテンシャル h_t と強度 $w_t \geq 0$ は理想誘導場

$$\nabla_{\boldsymbol{x}} \log p_t(\boldsymbol{x}) + w_t \nabla_{\boldsymbol{x}} \log h_t(\boldsymbol{x}; c)$$

を定める。これは（正規化可能なら）次のスコアである：

$$\tilde{p}_t^{\mathrm{tilt}}(\boldsymbol{x}|c) = \frac{1}{Z_t(c)}\, p_t(\boldsymbol{x})\, h_t(\boldsymbol{x}; c)^{w_t}. \tag{8.4.3}$$

損失ベースでは $h_t = \exp(-\tau \ell(\hat{\boldsymbol{x}}_0, c))$、$\eta_t^{\mathrm{latent}} \leftrightarrow w_t$。

重要な区別

固定時刻の解釈 $\neq$ 生成分布

誘導付き PF-ODE を $T \to 0$ で解いても、
一般には $\tilde{p}_0^{\mathrm{tilt}}(\cdot|c)$ からのサンプルには**ならない**。

理由は**時刻横断の整合性**：
各 t の密度を独立に好きに選べない。

- $\{\tilde{p}_t^{\mathrm{tilt}}\}_t$ が同じ前向き拡散の周辺パスなら、
  対応する Fokker–Planck を満たす必要がある
- 汎用の損失・スケジュールでは、この条件は保証されない

補足：Fokker–Planck 整合

$\{\tilde{p}_t^{\mathrm{tilt}}\}$ が周辺パスなら

$$\partial_t \tilde{p}_t^{\mathrm{tilt}} + \nabla_{\boldsymbol{x}} \cdot \left(f(t)\boldsymbol{x}\, \tilde{p}_t^{\mathrm{tilt}} \right) - \tfrac{1}{2} g^2(t) \Delta_{\boldsymbol{x}} \tilde{p}_t^{\mathrm{tilt}} = 0.$$

このとき PF-ODE

$$\frac{d\boldsymbol{x}}{dt} = f(t)\boldsymbol{x} - \tfrac{1}{2} g^2(t) \nabla_{\boldsymbol{x}} \log \tilde{p}_t^{\mathrm{tilt}}(\boldsymbol{x}|c)$$

は、終端 $\tilde{p}_T^{\mathrm{tilt}}$ から出発すればその周辺を保つ。

補足：整合条件の中身

(8.4.3) を FP に代入し、p_t 自身が同じ FP を満たすことを使うと、
余剰項（括弧内）が残る：

$$\partial_t \log(h_t^{w_t}) + f(t)\boldsymbol{x} \cdot \nabla \log(h_t^{w_t}) - g^2(t)\nabla \log p_t \cdot \nabla \log(h_t^{w_t}) - \cdots .$$

結論

括弧が消えるときだけ tilted 族は正当な周辺パス。
汎用タスク損失では消えるとは限らない。
不一致は離散化誤差ではなく、**誘導力学そのもの**に由来しうる
(Lai et al., 2023a の FP 整合の一例)。

わかりやすい特別ケース

- $w_t \equiv 0$：tilt なし。元の無条件パス p_t に戻る
- 正確な分類器誘導で $h_t = p_t(c|\boldsymbol{x})$、$w_t \equiv 1$：
  Bayes より $\tilde{p}_t^{\mathrm{tilt}}(\boldsymbol{x}|c) = p_t(\boldsymbol{x}|c)$。
  tilted 族は条件付き周辺パスそのもの

なぜ $\omega = 1$ が特別か

オラクル分類器尤度では、固定時刻解釈と条件付き周辺が一致する。
これが「誘導重み 1」の特別な位置づけ。

一般の ω では？

例えば $p_t(\boldsymbol{x})\, p_t(c|\boldsymbol{x})^{\omega}$ は、正規化できれば
固定時刻の tilted 密度としては常に意味を持つ。

- しかし誘導サンプラーの周辺を記述する保証は一般にない
- 特殊な選び方では整合条件を満たしうる
- したがって $\omega \neq 1$ だけで直ちに不整合、とは限らない

実務への含意

「場の式を tilted 密度のスコアだと思い込む」ことと、
「最終サンプルがその密度から来たと思う」ことを分けて扱う。

補足：Feynman–Kac Correctors

あらかじめ指定した tilted 列により忠実に従いたい場合、
時刻横断のずれを明示的に補正する手法がある
（Feynman–Kac Correctors; skreta2025feynman）。

- 単なる surrogate 勾配の加算を超える補正層
- 「作りたい周辺列」と「実際の誘導力学」のギャップを意識した設計

詳細は論文参照。ゼミ本筋では「ずれがあり得る」ことだけ押さえる。

区切り：8.4.3 Inverse Problems

Setup

8.4.1 Conceptual Framework

8.4.2 What Distribution

8.4.3 Inverse Problems

Related: InDI

逆問題の背景

既知の前向き作用素 A（非線形でも可）と観測

$$\boldsymbol{y} = A(\boldsymbol{x}_0) + \sigma_y \boldsymbol{z}, \qquad \boldsymbol{z} \sim \mathcal{N}(0, I). \tag{8.4.4}$$

目標は事後 $p_0(\boldsymbol{x}_0|\boldsymbol{y})$ の特徴付け（事前分布＋計測モデル）。

- 古典：データ忠実度 + 手設計事前分布（変分／ Bayes）
- 教師あり復元：計測 $\to$ クリーンの直接写像を学習
- **第 3 の道**：事前学習拡散を事前分布として再利用し、
  計測情報は推論時だけ入れる

拡散事前分布 + 計測誘導

Bayes より

$$\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t|\boldsymbol{y}) = \underbrace{\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{x}_t)}_{\text{data score}} + \underbrace{\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{y}|\boldsymbol{x}_t)}_{\text{measurement guidance}} . \tag{8.4.5}$$

- data score：事前学習拡散が供給
- 計測項：一般に閉形式なし → 推論時に近似／強制

2 つの戦略

(i) 中間サンプルを計測整合へ修正・投影する
(ii) $\nabla \log p_t(\boldsymbol{y}|\boldsymbol{x}_t)$ を近似して (8.4.5) に加算する

ILVR：サンプル空間の整合

ILVR (Choi et al., 2021) は戦略 (i) の単純例。
ϕ_N を線形ローパスとする。

1. 無条件提案 $\boldsymbol{x}'_{t-1} \sim p_\theta(\boldsymbol{x}'_{t-1}|\boldsymbol{x}_t)$
2. 参照画像を同レベルへノイズ：$\boldsymbol{y}_{t-1} \sim p_{t-1}(\boldsymbol{y}_{t-1}|\boldsymbol{y})$
3. 低周波を参照から、補空間を提案から：

$$\boldsymbol{x}_{t-1} = \phi_N(\boldsymbol{y}_{t-1}) + (I - \phi_N)\boldsymbol{x}'_{t-1}$$

位置づけ

尤度スコアの明示近似ではなく、
サンプル空間の一貫性補正である。

DPS：尤度のプラグイン近似

DPS (Chung et al., 2022)：既知の（非線形可）A と $\sigma_y > 0$ に対し

$$\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{y}|\boldsymbol{x}_t) \approx \nabla_{\boldsymbol{x}_t} \log p\big(\boldsymbol{y} \,\big|\, X_0 = \hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)\big). \tag{8.4.6}$$

$\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t) \approx \mathbb{E}[\boldsymbol{x}_0|\boldsymbol{x}_t]$（Tweedie；式 (3.3.6)）。

近似の中身

事後 $p(\boldsymbol{x}_0|\boldsymbol{x}_t)$ での尤度平均を、
事後平均の一点評価で置き換える（ピークが鋭いとき妥当）。

DPS の導出スケッチ

y は x_0 経由にだけ依るので

$$p_t(\boldsymbol{y}|\boldsymbol{x}_t) = \int p_t(\boldsymbol{y}|\boldsymbol{x}_0)\, p(\boldsymbol{x}_0|\boldsymbol{x}_t)\, d\boldsymbol{x}_0 \approx p_t\big(\boldsymbol{y}|X_0 = \hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)\big).$$

ガウス計測なら

$$p_t\big(\boldsymbol{y}|X_0 = \hat{\boldsymbol{x}}_0\big) = \mathcal{N}\big(\boldsymbol{y}; A(\hat{\boldsymbol{x}}_0), \sigma_y^2 I\big).$$

勾配は

$$\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{y}|\boldsymbol{x}_t) \approx \frac{1}{\sigma_y^2}\Big[J_A(\hat{\boldsymbol{x}}_0) \cdot \nabla_{\boldsymbol{x}_t}\hat{\boldsymbol{x}}_0\Big]^\top \big(\boldsymbol{y} - A(\hat{\boldsymbol{x}}_0)\big).$$

線形逆問題での簡略形

A が線形なら

$$\nabla_{\boldsymbol{x}_t} \log p_t(\boldsymbol{y}|\boldsymbol{x}_t) \approx \frac{1}{\sigma_y^2} \left[A \cdot \nabla_{\boldsymbol{x}_t} \hat{\boldsymbol{x}}_0(\boldsymbol{x}_t) \right]^\top \left(\boldsymbol{y} - A(\hat{\boldsymbol{x}}_0(\boldsymbol{x}_t)) \right).$$

- 計測残差 $\boldsymbol{y} - A(\hat{\boldsymbol{x}}_0)$ を、Jacobian 経由で $\boldsymbol{x}_t$ へ戻す
- 8.4.1 の noise-space 補正（損失 $= \|y - A(\hat{x}_0)\|^2$ 型）と相性が良い
- 様々な $\nabla \log p_t(y|\boldsymbol{x}_t)$ 近似が提案されている
  （概観：Daras et al., 2024）

ILVR と DPS の対比

	ILVR	**DPS**
戦略	サンプル修正・投影	尤度スコア近似＋加算
典型操作	低周波を参照で置換	$\hat{\boldsymbol{x}}_0$ 経由の $\nabla \log p(y\|\cdot)$
数式の姿	整合制約	式 (8.4.5) の第 2 項
仮定	ローパス整合が有用	計測モデル A, σ_y が既知

どちらも「拡散事前分布は固定、計測は推論時」という training-free の型。

補足：教師あり反復復元の視点

上の方法は Bayes 分解 (8.4.5) で事前分布スコア＋計測を合成する。
別路線として、**壊れた入力を多段で直す**教師あり復元がある。

InDI (delbracio2023inversion)

ペア (y, x_0) から直接、洗練手続きを学習。
一般に腐敗過程が解析的／ガウスである必要はない。

補間経路

$$\boldsymbol{x}_t = (1-t)\boldsymbol{x}_0 + t\boldsymbol{y}, \qquad t \in [0,1]$$

は「クリーン $\leftrightarrow$ 観測」を結ぶ便利な軌跡（一般のガウス拡散とは限らない）。

補足：InDI の学習目標

時間条件付き予測器 $F_\phi(\boldsymbol{x}_t, t)$ を

$$\min_{\phi} \mathbb{E}\big\| F_\phi\big((1-t)\boldsymbol{x}_0 + t\boldsymbol{y},\, t\big) - \boldsymbol{x}_0 \big\|_2^2$$

で学習する。二乗損失の Bayes 最適は $F^*(\boldsymbol{x}_t, t) = \mathbb{E}[\boldsymbol{x}_0 | \boldsymbol{x}_t]$。

- 精神は拡散の「中間状態 $\to$ よりクリーン」回帰に近い
- 違いは、端点ペア (y, x_0) が教師あり復元データから来ること

補足：推論と residual-flow ODE

$\hat{\boldsymbol{x}}_1 = \boldsymbol{y}$ から反復：

$$\hat{\boldsymbol{x}}_{t-\Delta t} = \frac{\Delta t}{t} F_\phi(\hat{\boldsymbol{x}}_t, t) + \left(1 - \frac{\Delta t}{t}\right) \hat{\boldsymbol{x}}_t.$$

連続極限は

$$\frac{d\boldsymbol{x}_t}{dt} = \frac{\boldsymbol{x}_t - F_\phi(\boldsymbol{x}_t, t)}{t}.$$

メッセージ

一発予測ではなく、段階的洗練で最終再構成を得る。

補足：ガウス特殊化 $\Rightarrow$ PF-ODE

腐敗が $y = \boldsymbol{x}_0 + \sigma\boldsymbol{\epsilon}$ のとき、補間は

$$\boldsymbol{x}_t = \boldsymbol{x}_0 + t\sigma\boldsymbol{\epsilon} \quad (\alpha_t = 1,\ \sigma_t = t\sigma)$$

となり、標準的拡散形に一致する。Tweedie より

$$\frac{d\boldsymbol{x}_t}{dt} = \frac{\boldsymbol{x}_t - \mathbb{E}[\boldsymbol{x}_0|\boldsymbol{x}_t]}{t} = -\dot{\sigma}_t\sigma_t\nabla_{\boldsymbol{x}_t}\log p_t(\boldsymbol{x}_t),$$

すなわちこの経路の **PF-ODE** そのもの。

補足：解釈のまとめ（InDI）

ガウス denoising 特殊化の下では、InDI は

- ガウス腐敗データ上の教師あり denoiser 学習
- その連続極限として PF-ODE

という拡散モデルの別解釈を示唆する。

8.4.3 本体との関係

Bayes ＋事前学習スコアの路線（DPS 等）とは出発点が違うが、
「多段の小さな更新で壊れた入力を直す」という高水準戦略は共有。

8.4 のまとめ

- Training-free：凍結拡散 + 推論時の外部損失／観測
- 補正は data-space（$\hat{\boldsymbol{x}}_0$）と noise-space（スコア）の 2 系統
- 固定時刻 tilted 解釈と、積分後の周辺は一般に別物
- 逆問題：ILVR（投影）と DPS（尤度プラグイン）が代表
- （補足）InDI は教師あり反復復元と PF-ODE の橋

次節へ：8.5 Alignment（DPO）

条件に合っても、人の好みから外れる生成がありうる。

1. 好みで条件付き分布を tilt する（alignment）
2. RLHF の複雑さを避け、Diffusion-DPO へ
3. 「制御」から「選好への整合」へ焦点が移る

8.4 は任意節。本筋の誘導三態（CG / CFG / training-free）はここまで。