The Principles of Diffusion Models

8.5 From Reinforcement Learning to Direct Preference Optimization for Model Alignment

渡邉 有志

November 13, 2026

8.5 From RL to DPO for Model Alignment

この節の主題（論文 8.5）

人間の好みに合わせて生成モデルを揃える（alignment）。
主流の RLHF は強力だが多段で不安定。
DPO は同じ目標を、明示的報酬モデルと RL なしで狙う。

- 言語モデル向け DPO（Rafailov et al., 2023）
- 拡散への拡張：**Diffusion-DPO**（Wallace et al., 2024）
- ゼミでは直観と鍵式を中心に追う（細部の導出は補足）

8.5 の道筋

1. **8.5.1 動機**
   RLHF の落とし穴と「直接好みで最適化できないか」
2. **8.5.2 RLHF（Bradley–Terry 視点）**
   報酬モデルと KL 正則化付き方策最適化
3. **8.5.3 DPO 枠組み**
   RLHF 目的の閉形式解 $\rightarrow$ 暗黙報酬 $\rightarrow$ ロジスティック損失
4. **8.5.4 Diffusion-DPO**
   軌跡／逆過程への持ち上げと実用的代理損失

前回までとの接続

- **8.1–8.3**：条件付きスコアの分解と CG / CFG
- **8.4**：学習なし誘導（タスク損失から誘導方向）
- **ここ（8.5）**：条件を満たしても好みから外れる問題へ
  control（条件適合）と *alignment*（人間好み）を区別

好みによる傾き（プロローグのイメージ）

$$\tilde{p}_0(\boldsymbol{x}_0 \mid c) \propto p_0(\boldsymbol{x}_0 \mid c)\, \exp\!\big(\lambda_{\mathrm{pref}}\, r(\boldsymbol{x}_0, c)\big)$$

大きい r ほど好ましいクリーン出力。KL 正則化では $\lambda_{\mathrm{pref}} = 1/\beta$。

区切り：8.5.1 RLHF の落とし穴を避ける

8.5.1 Motivation

8.5.2 RLHF: Bradley–Terry View

8.5.3 DPO Framework

8.5.4 Diffusion-DPO

Alignment の目標

ベース（例：SFT 済み）モデルを、
人間が好む出力へ舵取りすること。

RLHF の三段パイプライン

1. **SFT**：プロンプト – 応答ペアで教師あり微調整
2. **報酬モデリング（RM）**：好みペア $(c, \boldsymbol{x}^w, \boldsymbol{x}^l)$ から
   スカラー $r(c, \boldsymbol{x})$ を学習（勝者が敗者より高得点）
3. **RL 微調整**：PPO 等で期待報酬を最大化しつつ、
   参照（SFT）分布への KL ペナルティで離れすぎを防ぐ

RLHF が抱える実務上の欠点

- **不安定・高コスト**：on-policy。各更新で現行方策から
  新しいサンプルを生成し直す必要がある
- **多モデル運用**：SFT・報酬・（しばしば）価値モデルを
  同時に学習・ホストする
- **代理目的**：最適化しているのは人間好みそのものではなく
  学習した報酬の代理。報酬の欠陥を突く（reward hacking）余地

Question 8.5.1

明示的報酬モデリングと不安定な RL 段階をやめ、
好みデータ上でモデルを**直接**最適化できるか？

DPO の一言答え

Direct Preference Optimization

多段 RLHF を、**単一の教師あり風ステップ**に置き換える。
別報酬モデルも PPO も使わず、
固定参照モデルに近づきつつ、好みペアへロジスティック損失で適合。

- 鍵：KL 正則化付き RLHF 目的を書き換えると、
  方策と参照の**対数尤度比**が暗黙の報酬になる
- 同じ「参照への正則化」を保ちつつ、
  高価なロールアウトと明示的 RM を避けられる

この節の残りでやること

1. **8.5.2**：RLHF パイプラインと大規模報酬モデルへの依存を短く復習
2. **8.5.3**：言語モデル向け DPO — RM と RL を迂回する仕組み
3. **8.5.4**：拡散への拡張（Diffusion-DPO）—
   生成モデリング設定での実用的・安定な alignment

脚注の「方策」：プロンプト／履歴（状態）を応答／行動の分布へ写す写像。

区切り：8.5.2 RLHF（Bradley–Terry 視点）

8.5.1 Motivation

8.5.2 RLHF: Bradley–Terry View

8.5.3 DPO Framework

8.5.4 Diffusion-DPO

報酬モデル：好みの「審判」を学ぶ

同じプロンプト c に対する候補応答へ、スカラー好み得点を付ける $r_{\boldsymbol{\psi}}$。

- データ $\mathcal{D}$：組 $(\tilde{\boldsymbol{x}}, \boldsymbol{x})$ とラベル y
  （$\tilde{\boldsymbol{x}}$ が $\boldsymbol{x}$ より好まれるか）
- $y \in \{0, 1\}$（二値）または複数評価者の集約 $y \in [0, 1]$（ソフト）

ロジスティック損失（一般形）

$$\mathcal{L}_{\mathrm{RM}}(\boldsymbol{\psi}) = -\mathbb{E}\Big[\, y \log \sigma\big(\Delta r\big) + (1 - y) \log\big(1 - \sigma(\Delta r)\big) \Big]$$

ただし $\Delta r := r_{\boldsymbol{\psi}}(c, \tilde{\boldsymbol{x}}) - r_{\boldsymbol{\psi}}(c, \boldsymbol{x})$，$\sigma(u) = 1/(1 + e^{-u})$。

勝者・敗者の順序付け表記

実務では好みペアを $(\boldsymbol{x}^w, \boldsymbol{x}^l, c)$ の順序付きで保存することが多い。

- この慣例では常に $y = 1$（勝者が先）
- $\tilde{\boldsymbol{x}} = \boldsymbol{x}^w$，$\boldsymbol{x} = \boldsymbol{x}^l$ と置けば一般形は次に退化：

順序付き RM 損失（式 8.5.2）

$$\mathcal{L}_{\mathrm{RM}}(\boldsymbol{\psi}) = -\mathbb{E}_{(c,\boldsymbol{x}^w,\boldsymbol{x}^l)\sim\mathcal{D}} \log \sigma\big(r_{\boldsymbol{\psi}}(c, \boldsymbol{x}^w) - r_{\boldsymbol{\psi}}(c, \boldsymbol{x}^l)\big)$$

データの出どころ

人手キュレーション、異なるチェックポイント、
事前学習済み条件付き拡散の生成、など。

Bradley–Terry：スコア差 → 勝率

$$p_{r_{\psi}}(\tilde{\boldsymbol{x}} \succ \boldsymbol{x} \mid c) := \sigma\big(r_{\psi}(c, \tilde{\boldsymbol{x}}) - r_{\psi}(c, \boldsymbol{x})\big)$$

- **差だけが効く**：$r_{\psi}(c, \cdot)$ は定数シフト不変
- 損失は「予測勝率」を人間ラベルに合わせ、
  勝者のスコアを敗者より高く押し上げる

直感（勾配）

$\Delta r \leftarrow \Delta r - \eta\big(\sigma(\Delta r) - y\big)$。
$y = 1$ なら Δr が増える（勝者↑・敗者↓）。

補足：RM 損失 = ベルヌーイ KL

1 サンプルのロジスティック損失は、観測ラベルと予測勝率の交差エントロピー：

$$-\big[y\log p+(1-y)\log(1-p)\big]=D_{\mathrm{KL}}\big(\mathrm{Bern}(y)\,\|\,\mathrm{Bern}(p)\big)+H\big(\mathrm{Bern}(y)\big).$$

データ平均（式 8.5.3）

$$\mathcal{L}_{\mathrm{RM}}=\mathbb{E}_{\mathcal{D}}D_{\mathrm{KL}}\big(\mathrm{Bern}(y)\,\|\,\mathrm{Bern}(p_r)\big)+\underbrace{\mathbb{E}_{\mathcal{D}}H(\mathrm{Bern}(y))}_{\psi\text{に非依存}}$$

最小化 = 人間の経験的勝率に予測勝率を合わせること（ソフトラベルでは定数オフセット差）。

固定報酬のもとでの KL 正則化方策最適化

フィット済み報酬 $r := r_{\psi^\star}$ と、参照 $\pi_{\mathrm{ref}}(\boldsymbol{x} \mid c) := p_{\phi^\star}(\boldsymbol{x} \mid c)$（事前学習条件付き拡散）を固定。

RLHF 目的（式 8.5.4）

$$\max_{\boldsymbol{\theta}} \mathbb{E}_c \Big[\mathbb{E}_{\boldsymbol{x} \sim \pi_{\boldsymbol{\theta}}(\cdot \mid c)} r(c, \boldsymbol{x}) - \beta \, D_{\mathrm{KL}}\big(\pi_{\boldsymbol{\theta}}(\cdot \mid c) \,\|\, \pi_{\mathrm{ref}}(\cdot \mid c)\big) \Big]$$

- 審判が高得点を付けるサンプルを増やす
- ただし参照（事前学習）から離れすぎない

RLHF の二段まとめ

1. 式 8.5.2（＝二値 KL の期待）を最小化して報酬 $r^\star$ をフィット
2. 式 8.5.4 を解いて方策 $\pi^\star$ を最適化

補足

RM は**参照モデルが生成したペア**を必須としない。
ただし、使う領域に近いモデルから集めると分布シフトが減り、
報酬の信頼性が上がりやすい。

次へ

この KL 正則化目的には閉形式解があり、
それを逆に読むと「明示的 r なし」の DPO に到達する。

区切り：8.5.3 DPO 枠組み

8.5.1 Motivation

8.5.2 RLHF: Bradley–Terry View

8.5.3 DPO Framework

8.5.4 Diffusion-DPO

RLHF から DPO への橋：閉形式解

各プロンプト c について、式 8.5.4 の最適方策はエネルギー型（式 8.5.5）：

$$\pi^\star(\boldsymbol{x} \mid c) = \frac{1}{Z(c)}\, \pi_{\mathrm{ref}}(\boldsymbol{x} \mid c)\, \exp\!\big(r(c, \boldsymbol{x})/\beta\big).$$

小さい β

$\exp(r/\beta)$ が尖る
$\rightarrow$ 高報酬に集中
参照から遠く、多様性↓
不安定・hack のリスク↑

大きい β

$\exp(r/\beta)$ が平坦
$\rightarrow$ 参照に近い
更新は保守的、多様性は参照寄り
報酬の伸びは限定的

暗黙報酬：式 8.5.5 の反転

任意の方策 π（サポートが π_{ref} に含まれる）に対し

$$r_\pi(c, \boldsymbol{x}) = \beta \log \frac{\pi(\boldsymbol{x} \mid c)}{\pi_{\mathrm{ref}}(\boldsymbol{x} \mid c)} + \beta \log Z(c) \qquad \text{（式 8.5.6）}$$

と置けば、その π は「報酬 r_π に対する」式 8.5.4 の最適解になる。

- r_π は方策が誘起する**暗黙報酬**
- 定数 $\beta \log Z(c)$ はプロンプト依存だが、
  ペア比較（BT）では**打ち消される**

ペアでは正規化定数が消える

$$r_\pi(c, \boldsymbol{x}^w) - r_\pi(c, \boldsymbol{x}^l) = \beta \log \frac{\pi(\boldsymbol{x}^w \mid c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}^w \mid c)} - \beta \log \frac{\pi(\boldsymbol{x}^l \mid c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}^l \mid c)}$$

要点

好み学習に必要なのは絶対スコアではなく、
「参照に対する対数尤度の改善」の勝者 – 敗者差だけ。
これが DPO 損失へ直結する。

DPO の学習損失

暗黙報酬を BT（式 8.5.2）へ代入すると、$Z(c)$ が消え、

DPO 損失

$$\mathcal{L}_{\mathrm{DPO}}(\boldsymbol{\theta}; \pi_{\mathrm{ref}}) = -\mathbb{E} \log \sigma \left(\beta \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{x}^w \mid c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}^w \mid c)} - \beta \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{x}^l \mid c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}^l \mid c)} \right)$$

- 勝者の（温度付き）優位を、参照からの対数比改善の差として押し上げる
- **単一の分類風微調整**で RLHF の目標に到達
- 明示的報酬モデルも、不安定な RL ロールアウトも不要

DPO の読み方（一文）

$$-\log\sigma\Big(\beta\cdot\underbrace{\big[\text{log-ratio of }\pi_{\boldsymbol{\theta}}/\pi_{\text{ref}}\big]_{\boldsymbol{x}^w}-\big[\text{log-ratio}\big]_{\boldsymbol{x}^l}}_{\text{winner–loser margin}}\Big)$$

標語

「好みペア上のロジスティック回帰」として、
方策の参照相対対数尤度を直接動かす。

補足：RLHF と DPO の対応表

	RLHF	DPO
報酬	明示的 r_ψ を学習	方策の対数比が暗黙報酬
最適化	PPO 等の RL（on-policy）	単一の教師あり風損失
正則化	β KL を明示	同じ β が温度として残る
データ	好みペア（＋ロールアウト）	好みペアのみ
狙い	式 8.5.4 の解	同じ解クラスを直接フィット

注意

DPO は「RL が不要」であって「好みデータが不要」ではない。
参照モデルの選択と β は、依然として重要な設計レバー。

区切り：8.5.4 Diffusion-DPO

8.5.1 Motivation

8.5.2 RLHF: Bradley–Terry View

8.5.3 DPO Framework

8.5.4 Diffusion-DPO

拡散では素朴な DPO がつらい

表記は 8.5.3 を引き継ぐ：$\pi_{\boldsymbol{\theta}}$ / π_{ref} は学習・参照の拡散方策
（経路・遷移分布を含む）。前向きノイズ $p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ は固定。

なぜそのままではダメか

- サンプル尤度 $\pi_{\boldsymbol{\theta}}(\boldsymbol{x} \mid c)$ の評価には、
  ODE の瞬間的変数変換（ドリフトの発散）等が必要で重い
- サンプリング軌跡全体を通した微分は、
  勾配の消失・爆発のリスク

$\Rightarrow$ Diffusion-DPO は**経路レベル**で議論する
（離散時間 DDPM を例に；連続時間も同様）。

経路と端点報酬

軌跡 $\boldsymbol{x}_{0:T} := (\boldsymbol{x}_T, \ldots, \boldsymbol{x}_0)$。
逆時間マルコフ鎖の条件付き $\pi(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, c)$。
$\boldsymbol{x}_T$ は最高ノイズ、$\boldsymbol{x}_0$ はクリーン出力。

- 人間の好みは最終出力上の $r(c, \boldsymbol{x}_0)$ で定義される
- $\boldsymbol{x}_0$ はどの軌跡にも含まれるので、
  「報酬の定義」自体を経路空間で変える必要はない
- 有用なのは、**逆過程全体**を正則化すること

KL の連鎖則

経路分布の KL $\geq$ 端点周辺の KL。
$\Rightarrow$ 潜在の denoising 軌跡の逸脱も制御する動機。

経路版の KL 正則化目的

$$\max_{\boldsymbol{\theta}} \mathbb{E}_c \Big[\mathbb{E}_{\boldsymbol{x}_{0:T} \sim \pi_{\boldsymbol{\theta}}(\cdot|c)} r(c, \boldsymbol{x}_0) - \beta \, D_{\mathrm{KL}}\big(\pi_{\boldsymbol{\theta}}(\cdot \mid c) \,\|\, \pi_{\mathrm{ref}}(\cdot \mid c)\big) \Big]$$

- 報酬項は端点のまま
- KL は経路分布どうし（潜在軌跡のずれも含む）
- $\pi_{\boldsymbol{\theta}}(\cdot \mid c)$，$\pi_{\mathrm{ref}}(\cdot \mid c)$ は対応する**経路分布**

経路の最適解と暗黙経路報酬

正規化定数が有限なら、各 c で（式 8.5.7）

$$\pi^\star(\boldsymbol{x}_{0:T} \mid c) = \frac{1}{Z(c)}\, \pi_{\mathrm{ref}}(\boldsymbol{x}_{0:T} \mid c)\, \exp\!\big(r(c, \boldsymbol{x}_0)/\beta\big).$$

反転して任意の π に暗黙経路報酬を定義：

$$R_\pi(c, \boldsymbol{x}_{0:T}) := \beta \log \frac{\pi(\boldsymbol{x}_{0:T} \mid c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}_{0:T} \mid c)} + \beta \log Z(c).$$

- 経路最適では $R_{\pi^\star}(c, \boldsymbol{x}_{0:T}) = r(c, \boldsymbol{x}_0)$
- 一般の π では潜在軌跡にも依存しうる
- 好みデータはクリーン端点だけを比較 $\Rightarrow$
  端点ごとに軌跡平均を取る

端点ペアから Diff-DPO マージンへ

ラベル付き端点対 $(\boldsymbol{x}_0^w, \boldsymbol{x}_0^l)$ に対し、暗黙経路報酬の条件付き平均を比較：

$$\mathcal{L}_{\text{Diff-DPO}} = -\mathbb{E} \log \sigma\big(\Delta R(c; \boldsymbol{\theta})\big)$$

$$\Delta R := \mathbb{E}_{\boldsymbol{x}_{1:T}^w \sim \pi_{\boldsymbol{\theta}}(\cdot|\boldsymbol{x}_0^w, c)}\big[R_{\pi_{\boldsymbol{\theta}}}\big] - \mathbb{E}_{\boldsymbol{x}_{1:T}^l \sim \pi_{\boldsymbol{\theta}}(\cdot|\boldsymbol{x}_0^l, c)}\big[R_{\pi_{\boldsymbol{\theta}}}\big]$$

条件付き経路の意味

固定端点 $\boldsymbol{x}_0$ のもと、その $\boldsymbol{x}_0$ を生みうる逆時間軌跡の
モデル誘導事後（拡散ブリッジ的）で平均する。

式 8.5.8 が実務でつらい三理由

1. **端点条件付き経路事後が intractable**
   サンプラは $\boldsymbol{x}_T \to \cdots \to \boldsymbol{x}_0$（無制約）。
   端点固定は一般に閉形式がなく、サンプリングも高価
2. **入れ子で $\boldsymbol{\theta}$ 結合の期待**
   経路分布も被積分関数 R も $\boldsymbol{\theta}$ 依存
   $\Rightarrow$ REINFORCE / pathwise 結合、高分散勾配
3. **長い鎖と重い逆伝播**
   経路対数密度は $O(T)$ ステップ（$T \sim 10^2$–10^3）。
   winner/loser・policy/ref の両方で計算し、予算を超えやすい

Jensen で上界：経路尤度比へ

$-\log\sigma(\cdot)$ は凸。内側期待を外へ出すと上界：

$$\mathcal{L}_{\text{Diff-DPO}} \le -\mathbb{E}\log\sigma\Big(R_{\pi_{\boldsymbol{\theta}}}(c, \boldsymbol{x}^{w}_{0:T}) - R_{\pi_{\boldsymbol{\theta}}}(c, \boldsymbol{x}^{l}_{0:T})\Big)$$

暗黙報酬の恒等式と定数打ち消しのあと（式 8.5.9）：

$$\le -\mathbb{E}\log\sigma\left(\beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{x}^{w}_{0:T}\mid c)}{\pi_{\text{ref}}(\boldsymbol{x}^{w}_{0:T}\mid c)} - \beta\log\frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{x}^{l}_{0:T}\mid c)}{\pi_{\text{ref}}(\boldsymbol{x}^{l}_{0:T}\mid c)}\right).$$

まだ

経路全体の尤度比が残る ⇒ マルコフ分解で一歩ずつへ。

マルコフ分解：経路比 → ステップ和

$$\pi_{\boldsymbol{\theta}}(\boldsymbol{x}_{0:T} \mid c) = \pi_{\boldsymbol{\theta}}(\boldsymbol{x}_T \mid c) \prod_{t=1}^{T} \pi_{\boldsymbol{\theta}}(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, c)$$

参照も同様。時刻 T の事前が共通なら先頭比は 1 で、

$$\log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{x}_{0:T} \mid c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}_{0:T} \mid c)} = \sum_{t=1}^{T} \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, c)}.$$

したがって上界は

$$-\mathbb{E} \log \sigma\Big(\beta \sum_{t=1}^{T} \Delta_t\Big)$$

の形（各 Δ_t は winner/loser の 1 ステップ対数比差）。

時刻の一様サンプルとさらなる Jensen

$\beta \sum_s \Delta_s = \mathbb{E}_{t\sim \mathrm{Unif}\{1,\dots,T\}}[\beta T\, \Delta_t]$。
再び $-\log\sigma$ の凸性より

$$\mathcal{L}_{\text{Diff-DPO}} \le -\mathbb{E}\log\sigma\big(\beta T\, \Delta_t\big).$$

- 期待は $(c, \boldsymbol{x}_0^w, \boldsymbol{x}_0^l)$、$t$、および端点条件付き遷移対の上
- **1 遷移**だけに依存するが、
  端点条件付き遷移のサンプリングは依然 intractable

前向きノイズによる実用近似

Diffusion-DPO では、モデル誘導の条件付き経路を
固定の前向きノイズ過程で近似する。

1. クリーン端点 $\boldsymbol{x}_0$ から $\boldsymbol{x}_t \sim p_t(\boldsymbol{x}_t \mid \boldsymbol{x}_0)$ をサンプル
2. $(\boldsymbol{x}_0, \boldsymbol{x}_t)$ 条件下の前向き事後 $p(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, \boldsymbol{x}_0)$ は tractable
3. その事後で逆遷移の対数比を平均

$$\mathbb{E}_{p(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t,\boldsymbol{x}_0)} \log \frac{\pi_{\boldsymbol{\theta}}(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, c)}{\pi_{\mathrm{ref}}(\boldsymbol{x}_{t-1} \mid \boldsymbol{x}_t, c)} = -D_{\mathrm{KL}}(p\|\pi_{\boldsymbol{\theta}}) + D_{\mathrm{KL}}(p\|\pi_{\mathrm{ref}}).$$

ガウス逆核 → DSM 風 MSE 差

逆分散が共通のガウス核では、KL は重み付き denoising 回帰誤差へ退化。
ϵ-予測では（式 8.5.10）

$$\mathbb{E}\log\frac{\pi_{\boldsymbol{\theta}}}{\pi_{\mathrm{ref}}} = -\lambda_t\Big(\|\hat{\boldsymbol{\epsilon}}_{\boldsymbol{\theta}}(\boldsymbol{x}_t,t,c)-\boldsymbol{\epsilon}\|^2 - \|\hat{\boldsymbol{\epsilon}}_{\mathrm{ref}}(\boldsymbol{x}_t,t,c)-\boldsymbol{\epsilon}\|^2\Big),$$

ただし $\boldsymbol{x}_t = \alpha_t\boldsymbol{x}_0 + \sigma_t\boldsymbol{\epsilon},\ \ \boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},I),\ \ \lambda_t>0$。

略記

$$\Delta\mathrm{MSE}(\boldsymbol{x}_t;\boldsymbol{\epsilon}) := \|\hat{\boldsymbol{\epsilon}}_{\boldsymbol{\theta}}-\boldsymbol{\epsilon}\|^2 - \|\hat{\boldsymbol{\epsilon}}_{\mathrm{ref}}-\boldsymbol{\epsilon}\|^2$$

実用的な 1 ステップ Diffusion-DPO 代理損失

$$\widetilde{\mathcal{L}}_{\text{Diff-DPO}} = -\mathbb{E}\log\sigma\Big(\beta T\lambda_t\big(\Delta\text{MSE}(\boldsymbol{x}_t^l;\boldsymbol{\epsilon}^l) - \Delta\text{MSE}(\boldsymbol{x}_t^w;\boldsymbol{\epsilon}^w)\big)\Big)$$

期待は $(c,\boldsymbol{x}_0^w,\boldsymbol{x}_0^l)\sim\mathcal{D}$, $t\sim\text{Unif}$, $\boldsymbol{\epsilon}^w,\boldsymbol{\epsilon}^l\sim\mathcal{N}(\mathbf{0},I)$。
$\boldsymbol{x}_t^{w/l} = \alpha_t\boldsymbol{x}_0^{w/l} + \sigma_t\boldsymbol{\epsilon}^{w/l}$。

- 共有ノイズ $\boldsymbol{\epsilon}^w = \boldsymbol{\epsilon}^l$ は分散低減の変種（形は DPO 風のまま）
- 参照は $\log\sigma$ 内のマージンに残り、例ごとの重み付けを形作る
  （参照自体への直接勾配はない）

直感：何を押し上げているか

$\widetilde{\mathcal{L}}$ を最小化すると、参照正規化の
勝者 – 敗者マージンが増える。

等価な読み

凍結参照に対し、
勝者側の denoising 誤差をより減らし、
敗者側より相対的に良く当てるよう促す。

ゼミ向け要約

拡散では「サンプル尤度の DPO」を避け、
経路 $\rightarrow$ ステップ $\rightarrow$ 前向き近似 $\rightarrow$ ϵ-MSE 差、
と tractable な代理へ落とす。

補足：Diffusion-DPO の設計フロー（地図）

1. 端点報酬＋経路 KL 正則化（RLHF の経路版）
2. 閉形式 $\Rightarrow$ 暗黙経路報酬 R_π
3. 端点条件付き平均で BT マージン（式 8.5.8）— しかし intractable
4. Jensen：経路尤度比の上界（式 8.5.9）
5. マルコフ分解＋時刻一様化：1 ステップ対数比
6. 前向き事後で近似：KL $=$ 重み付き MSE 差
7. 実用損失：$\log\sigma$ 内の ΔMSE 勝者 – 敗者差

8.5 のまとめ

- RLHF は強いが、RM + on-policy RL で重く不安定になりうる
- DPO：KL 正則化 RLHF の閉形式を反転し、
  対数比を暗黙報酬として好みペアへ直接フィット
- 拡散では尤度評価が重い ⇒ 経路版へ持ち上げ、
  Jensen・マルコフ・前向き近似で DSM 風の代理損失へ
- 結果：明示的報酬モデルなしの、安定な alignment 微調整

次節

第 8 章全体の道具立てをまとめ、第 9 章（高速ソルバ）へ橋渡しする。