The Principles of Diffusion Models

1.4 Closing Remarks：学習とサンプリングの見取り図

川端 紀楽

October 22, 2026

1.4 目次

- 拡散モデルの全体像（2つの部品）
- ノイズ付きデータを作る
- 実験：ノイズ付きデータを作ってみる
- 学習：きれいな信号を予測する
- 何を学習しているのか
- 補足：なぜ$\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$になるのか
- サンプリング：新しいノイズから始める
- 次の章とのつながり

拡散モデルの全体像

基本的な構成は2つの部分

1. きれいなデータを，任意のノイズレベルのノイズ付き観測へと変える
   既知の劣化ルールを定める
2. ノイズ付き観測から元のきれいな信号を推定するよう
   ニューラルネットワークを学習させる

- 多くのノイズレベルで学習できれば，生成にも使える
- 新しいノイズから，高ノイズ→低ノイズへとネットワークを繰り返し適用
  ⇒ データ分布の構造を徐々に獲得した新しいサンプル

メッセージ

多くのノイズレベルでノイズ付きデータを作り，きれいな信号を予測できるよう学習し，その予測を高ノイズから低ノイズへと繰り返し適用して生成する

ノイズ付きデータを作る

劣化ルール

きれいなデータ $\mathbf{x}_0 \sim \mathrm{p}_{\mathrm{data}}$（画像など）に，独立なガウスノイズを混ぜてノイズレベルtで劣化させる

$$\mathbf{x}_\mathrm{t} = \alpha_\mathrm{t}\mathbf{x}_0 + \sigma_\mathrm{t}\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

- α_t, σ_t：あらかじめ固定した2つの「つまみ」
  （信号とノイズがそれぞれどれだけ混ざるかを決める）

最も単純な例：$\alpha_\mathrm{t} = 1,\ \sigma_\mathrm{t} = \mathrm{t}$

$$\mathbf{x}_\mathrm{t} = \mathbf{x}_0 + \mathrm{t}\boldsymbol{\epsilon}$$

tは文字どおり「ノイズのダイヤル」
$\mathrm{t} \to 0$ならほぼきれいなサンプル，tを上げるとノイズ項$\mathrm{t}\boldsymbol{\epsilon}$が支配的になる

分布のスナップショット p_t

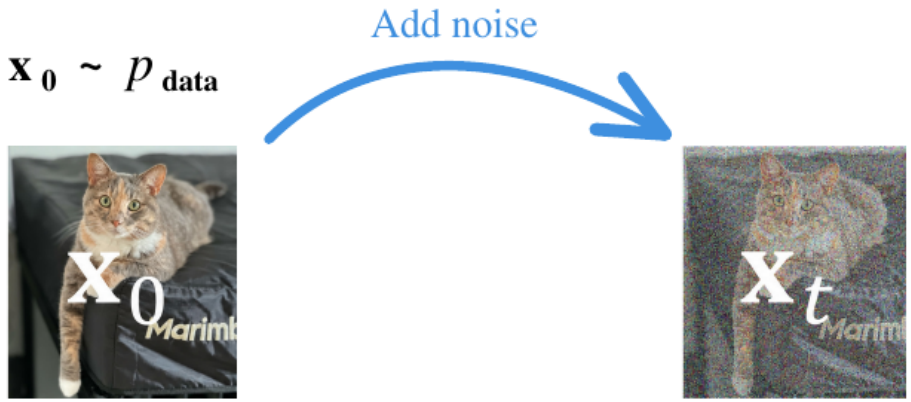


図1.3：順方向拡散（出典：Lai et al., The Principles of Diffusion Models）

- 各ノイズレベルtは，ノイズ付きサンプルの分布p_tを定める
- p_t＝同じtでノイズ付きサンプルを大量に作ったときの分布（スナップショット）

スケジュール(α_t, σ_t)の選び方

$$p_0 = p_{\text{data}} \longrightarrow p_t \longrightarrow p_T \approx p_{\text{prior}}$$

p_{prior}：サンプリングしやすい単純な分布（典型的にはガウス）
$\{p_t\}_{t\in[0,T]}$：ノイズを増やすと分布がどう変わるか

補足：一気に足す vs 少しずつ足す

累積的な劣化

$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$ は，ノイズレベルtでの**累積的な劣化**を直接与える式

- DDPMやScore SDEでは，小さなステップでノイズを逐次加えていっても，
  同じ周辺分布p_tが得られる（2.2節，第4章）
- 後で出てくる離散的なDDPMの記法では

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\, \epsilon$$

実験：ノイズ付きデータを実際に作ってみる

やったこと

人工的な画像$\mathbf{x}_0$（グラデーション＋四角＋円＋斜線）に，劣化ルール

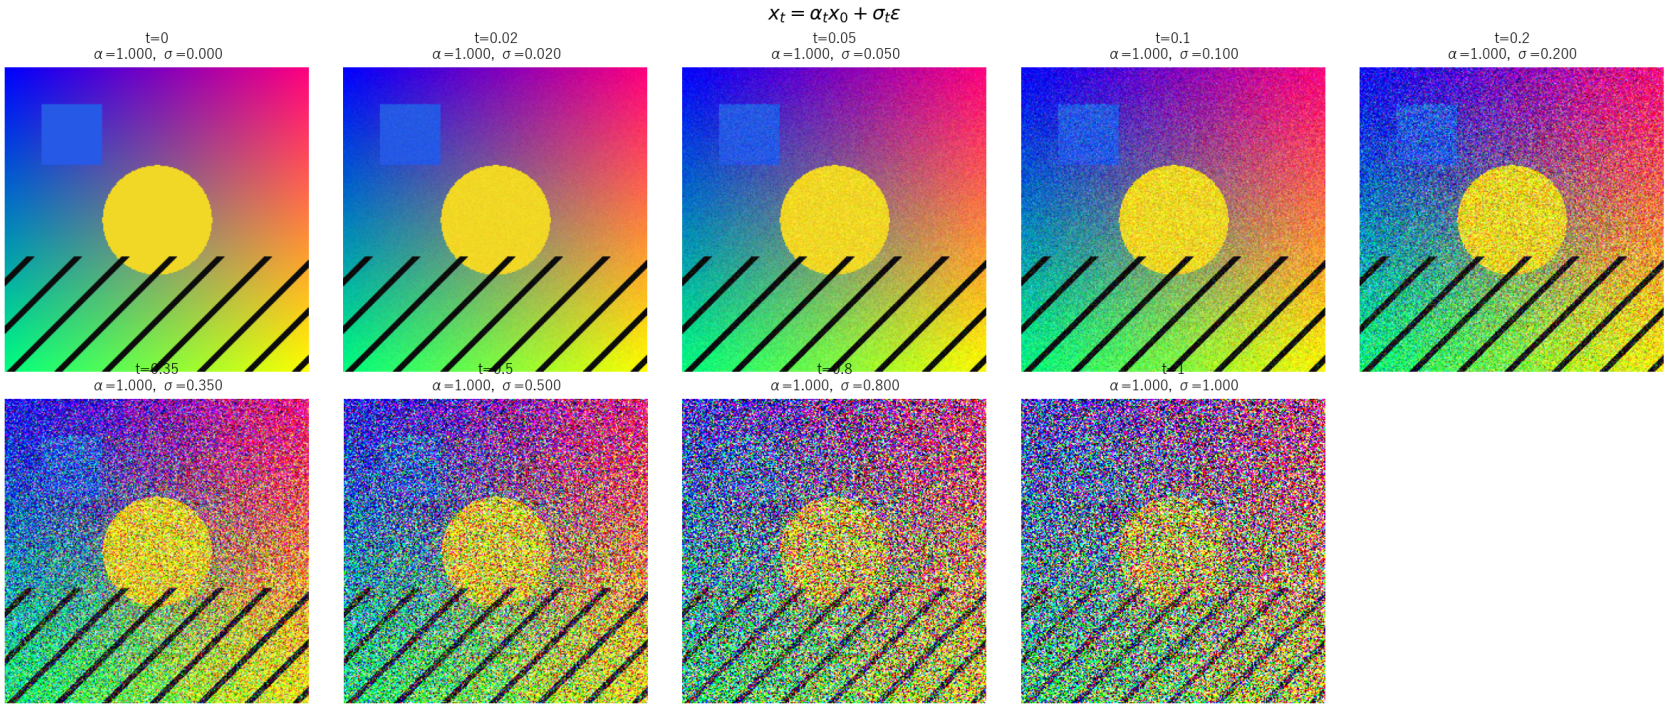
$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

を当てはめ，(α_t, σ_t)の決め方を変えて見え方を比べた

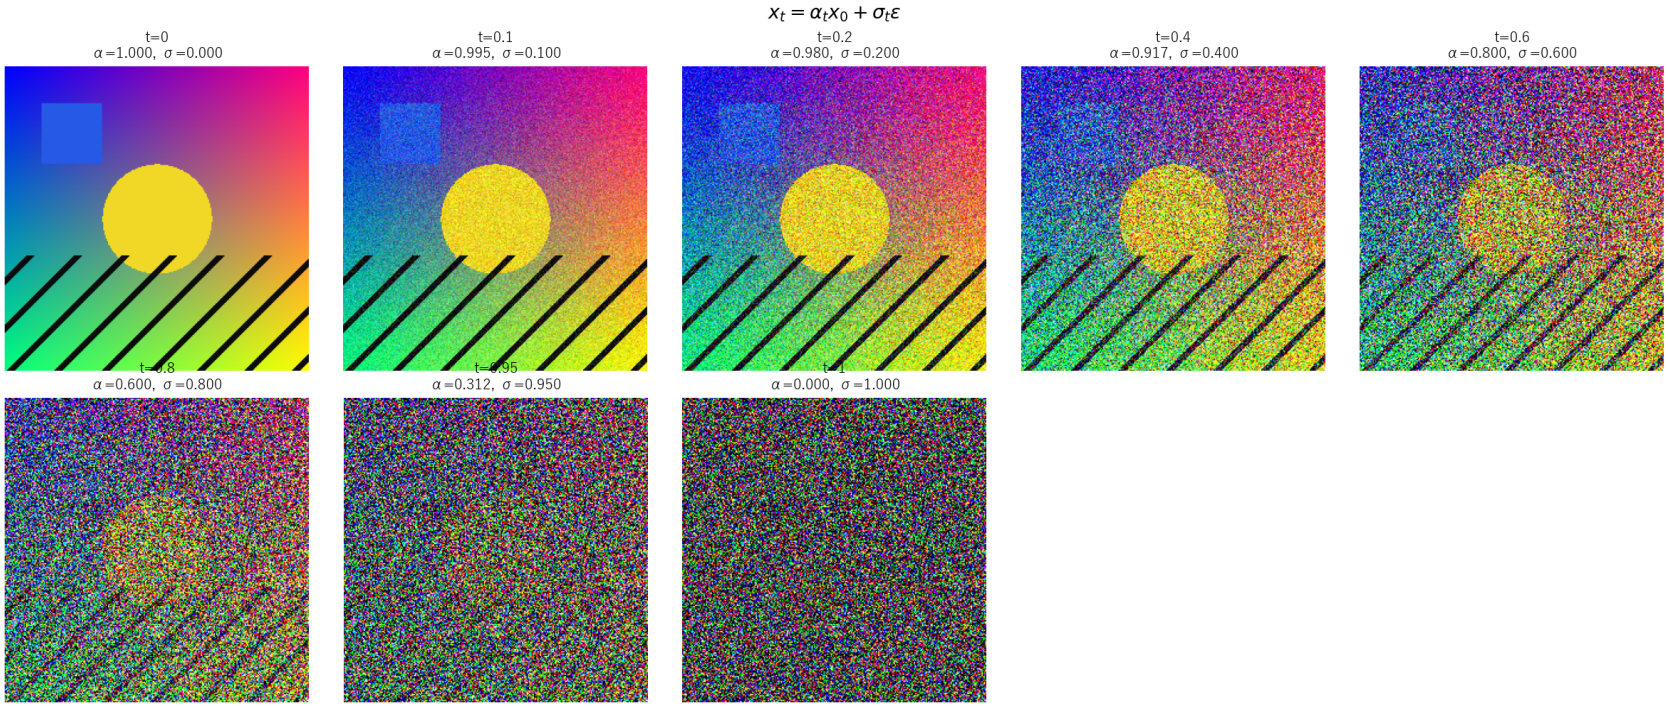
1. 本の最も単純な例：$\alpha_t = 1,\ \sigma_t = t$
2. 信号を弱めながらノイズを強める：$\alpha_t = \sqrt{1 - t^2},\ \sigma_t = t$
3. ノイズを固定してαだけ変える：$\sigma = 0.3$，$\boldsymbol{\epsilon}$も固定

- 見どころ：構造（四角・円・斜線）がどのノイズレベルで見えなくなるか

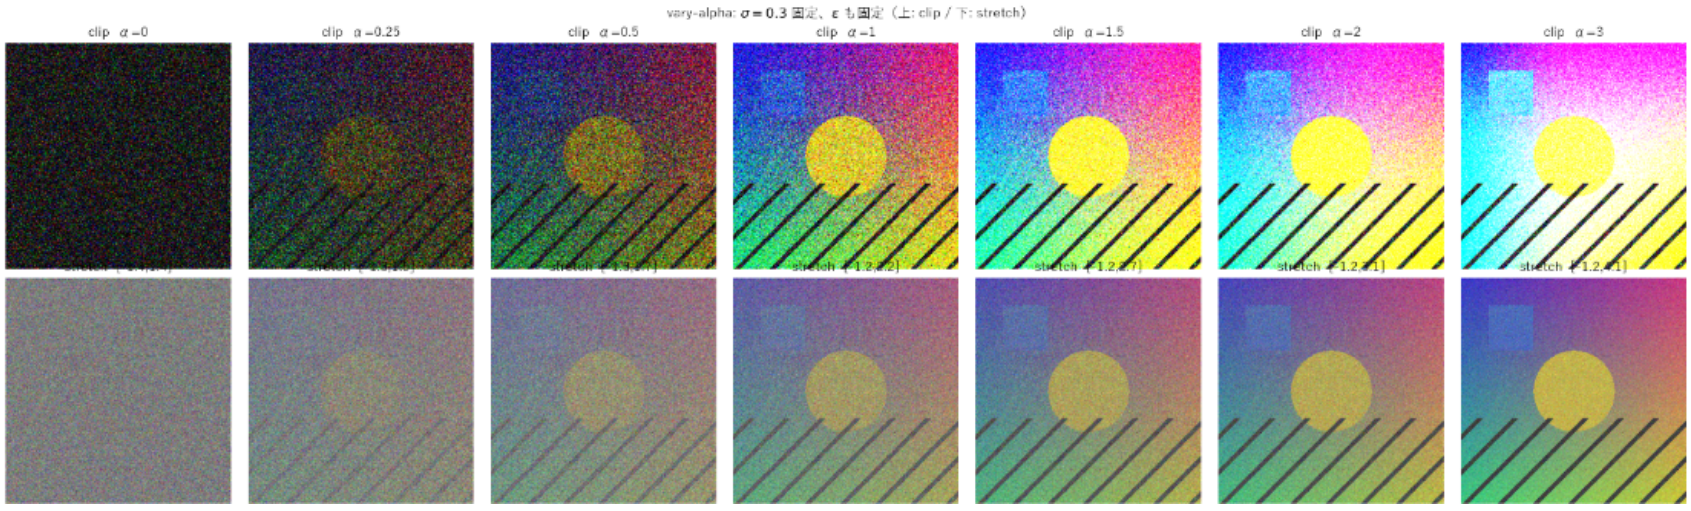
実験1：$\alpha_t = 1,\ \sigma_t = t$（ノイズを足すだけ）



実験2：$\alpha_t = \sqrt{1 - t^2}$, $\sigma_t = t$（信号も弱める）



実験3：$\sigma = 0.3$を固定してαだけ変える



上：$[0, 1]$で切り捨てて表示（clip）　下：最小〜最大を引き伸ばして表示（stretch）

学習：きれいな信号を予測する

鍵となるトリック

データを劣化させているのは自分たちなので，**正解は常に分かっている**

1. きれいなデータ$\mathbf{x}_0$をとり，ノイズレベルtを選び，ノイズϵを引く
2. $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$ を作る（元の$\mathbf{x}_0$は既知）
3. ネットワークには$(\mathbf{x}_t, t)$だけを見せ，$\mathbf{x}_0$を当てさせる

$$\mathbf{x}_0^{\text{pred}} := \mathbf{x}_\phi(\mathbf{x}_t, t)$$

4. 二乗誤差で評価して改善する

$$\left\| \mathbf{x}_0^{\text{pred}} - \mathbf{x}_0 \right\|_2^2$$

メッセージ

正解が分かっているノイズ付き観測を作り，正解をネットワークから隠して，それを予測させる

何を学習しているのか

- データ・ノイズ・ノイズレベルを変えて何度も繰り返す
  $\Rightarrow$ 1つのネットワークが「ほぼ無傷」から「ほぼ純粋なノイズ」まで
  全範囲で予測できるようになる

二乗誤差の最適解

$$\mathbf{x}_0^*(\mathbf{x}_t, t) = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t, t]$$

（ノイズレベルが文脈から明らかなときは$\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$と略す）

- 1つの$\mathbf{x}_t$に対して，元の$\mathbf{x}_0$は一意に決まらない
  （似た$\mathbf{x}_t$を生む$\mathbf{x}_0$が複数ありうる）
- この曖昧さはノイズが大きいほど強くなる
- ネットワークは「もっともらしい$\mathbf{x}_0$たちの**平均**」を学ぶ

補足：なぜ$\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$になるのか（1）

1次元の例：サイコロの目Xを1つの数cで予想する

予想のずれを二乗誤差$(X-c)^2$で測り，その期待値を最小にするcを求める

$$\frac{d}{dc}\mathbb{E}[(X-c)^2] = -2\,\mathbb{E}[X-c] = -2\,(\mathbb{E}[X]-c) = 0$$

$$\Rightarrow \quad c = \mathbb{E}[X] = \frac{1+2+\cdots+6}{6} = 3.5$$

3.5の目は出ないが，二乗誤差のもとでは**平均**が最良の1点予想

拡散モデルに当てはめる

ネットワークが見るのは$(\mathbf{x}_t, t)$だけ．元の$\mathbf{x}_0$は$p(\mathbf{x}_0 \mid \mathbf{x}_t)$に従ってばらつく
$\Rightarrow$ 各$\mathbf{x}_t$ごとに1つの答え$\mathbf{c}$を出す問題を解いている

$$\min_{\mathbf{c}} \mathbb{E}\left[\|\mathbf{x}_0 - \mathbf{c}\|^2 \,\middle|\, \mathbf{x}_t\right]$$

サイコロと同じ形（分布が条件付きになっただけ）

補足：なぜ$\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$になるのか（2）

証明

$\mathbf{m} := \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$とおき，$\mathbf{x}_0 - \mathbf{c} = (\mathbf{x}_0 - \mathbf{m}) + (\mathbf{m} - \mathbf{c})$と分けて展開

$$\mathbb{E}\left[\|\mathbf{x}_0 - \mathbf{c}\|^2 \mid \mathbf{x}_t\right] = \underbrace{\mathbb{E}\left[\|\mathbf{x}_0 - \mathbf{m}\|^2 \mid \mathbf{x}_t\right]}_{\mathbf{c}\text{に無関係}} + 2\underbrace{\mathbb{E}[\mathbf{x}_0 - \mathbf{m} \mid \mathbf{x}_t]^\top}_{=\mathbf{0}}(\mathbf{m} - \mathbf{c}) + \|\mathbf{m} - \mathbf{c}\|^2$$

交差項は0なので，最小になるのは$\mathbf{c} = \mathbf{m}$のときだけ

$$\Rightarrow \quad \mathbf{x}_0^*(\mathbf{x}_t, t) = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t, t]$$

サンプリング：新しいノイズから始める

- 学習後，パラメータを固定して$\phi^{\times}$とする
- 生成は逆向き：データからではなく，ノイズだけから始める

$$\tilde{\mathbf{x}}_T \sim p_{\text{prior}}$$

- 生成中の状態はチルダ付き$\tilde{\mathbf{x}}_t$で書き，学習時の$\mathbf{x}_t$と区別する

「録画の巻き戻し」ではない

$\tilde{\mathbf{x}}_T$は，隠れた本物のサンプルを劣化させて作ったものではない
$\Rightarrow$ 取り戻すべき「本当の$\mathbf{x}_0$」は存在しない

- 各ノイズレベルで「今きれいな信号はどう見えるか」をネットワークに尋ね，
その答えを使ってデータの方へ1歩戻る

サンプリングの1ステップ

予測した信号とノイズ

$$\mathbf{x}_0^{\text{pred}} := \mathbf{x}_{\phi\times}(\tilde{\mathbf{x}}_t, t), \qquad \boldsymbol{\epsilon}_t^{\text{pred}} := \frac{\tilde{\mathbf{x}}_t - \alpha_t \mathbf{x}_0^{\text{pred}}}{\sigma_t} \quad (t > 0)$$

2つは独立な推測ではなく，現在の状態をちょうど組み立て直す：
$\tilde{\mathbf{x}}_t = \alpha_t \mathbf{x}_0^{\text{pred}} + \sigma_t \boldsymbol{\epsilon}_t^{\text{pred}}$

混ぜ直す：係数だけ少し低いノイズレベル$t - \Delta t$のものに替える

$$\tilde{\mathbf{x}}_{t-\Delta t} = \alpha_{t-\Delta t} \mathbf{x}_0^{\text{pred}} + \sigma_{t-\Delta t} \boldsymbol{\epsilon}_t^{\text{pred}}$$

同値な書き方（現在の状態への小さな更新）：

$$\tilde{\mathbf{x}}_{t-\Delta t} = \tilde{\mathbf{x}}_t + (\alpha_{t-\Delta t} - \alpha_t)\mathbf{x}_0^{\text{pred}} + (\sigma_{t-\Delta t} - \sigma_t)\boldsymbol{\epsilon}_t^{\text{pred}} \qquad (1.4.1)$$

サンプリングのループ

- 新しい状態$\tilde{\mathbf{x}}_{t-\Delta t}$を再びネットワークに入れる
- 更新された（たいていは前と違う）予測を得て，さらに1段ノイズを下げる
- これを$t = T$から$t = 0$まで繰り返すのがサンプリング

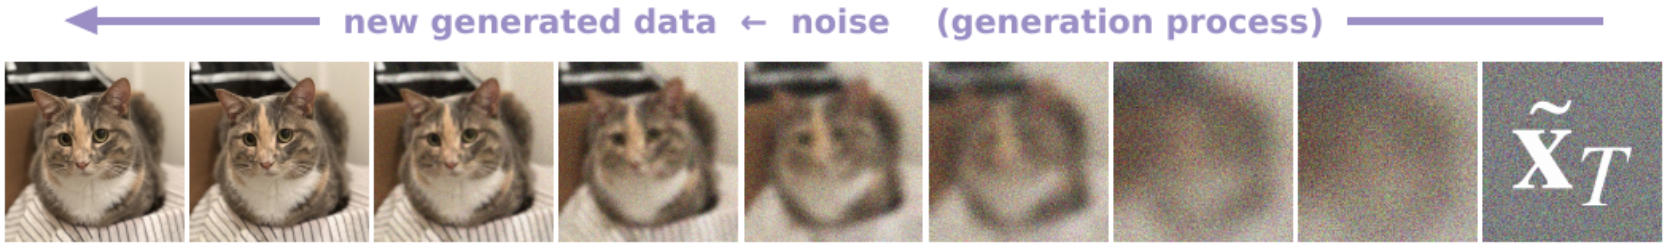


図1.4：拡散モデルによる生成（出典：Lai et al., The Principles of Diffusion Models）

メッセージ

新しいノイズから始め，きれいな信号を予測し，少し低いノイズレベルへ進み，また予測する

なぜ最初の予測で止めないのか

疑問

最初の$\mathbf{x}_0^{\text{pred}}$をそのまま出力すればよいのでは？

- 高ノイズでは，状態にきれいな構造の情報がほとんど残っていない
- そのため予測は「多くのもっともらしいサンプルの大まかな平均」にすぎない
  （$\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$ なのでぼやける）
- 少しノイズを下げると，曖昧さの少ない状態から予測できる
  $\Rightarrow$ 次の予測がよりシャープになる
- これを何度も繰り返すことで，細部まで描かれたサンプルが徐々に現れる

※この決定論的な更新は，9.2節でDDIMサンプリングとオイラー法的な解釈につながる． 確率的なDDPMのサンプラーは2.2節で扱う．

次の章とのつながり

本全体で共通するパターン

- 学習：きれいなデータからノイズ付き観測を作り，有用な情報の予測を学ぶ
- 生成：新しいノイズから始め，ノイズレベルを下げながら予測を使ってサンプルを作る

- 第2章：DDPMと潜在変数モデル（固定ノイズ過程＝エンコーダ，学習した逆遷移＝デコーダ）
- 第3章：スコアによるデノイズ（ノイズ付きサンプルを更新する方向）
- 第4章：連続時間へ．逆時間の確率的ダイナミクスによる生成
- 第5章：単純な事前分布からデータ分布への連続的な輸送としての生成
- 第6章：これらの見方のつながり

1.4 まとめ

- 劣化ルール：$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$， $p_0 = p_{\text{data}} \to p_T \approx p_{\text{prior}}$
- 学習：$(\mathbf{x}_t, t)$から$\mathbf{x}_0$を予測（最適解は$\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$）
- 生成：$\tilde{\mathbf{x}}_T \sim p_{\text{prior}}$から，予測と混ぜ直し(1.4.1)を繰り返す

まとめ

拡散モデルは多くのノイズレベルのノイズ付きデータから学び，その予測を繰り返し使って新しいノイズを新しいサンプルに変える