# The Principles of Diffusion Models

## 2 Variational Perspective: From VAEs to DDPM

青山 京

October 30, 2026

# 第 2 章のテーマ

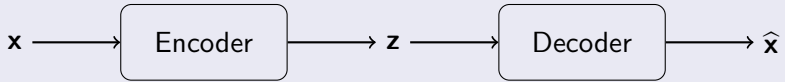
この章では、変分的な視点から拡散モデルを理解する。

- Variational Autoencoder (VAE)
- Hierarchical VAE (階層型 VAE)
- Denoising Diffusion Probabilistic Models (DDPM)
- 変分下界（ELBO）による共通の視点

# VAE の基本的な考え方

## VAE の基本構造

VAE では、潜在変数 $\mathbf{z}$ を用いてデータ $\mathbf{x}$ の分布をモデル化する。

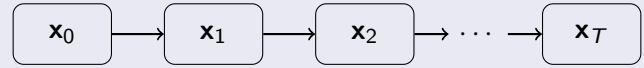



- Encoder: 入力データ $\mathbf{x}$ から潜在変数 $\mathbf{z}$ の分布を推定する。
- Decoder: 潜在変数 $\mathbf{z}$ を基に、元のデータに対応するデータを生成する。
- 対数尤度の厳密な最大化が難しいため、ELBO を最大化する。

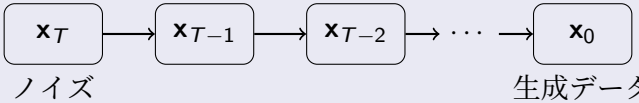
# VAE から DDPM へ

## DDPM の基本構造

**順方向：ノイズ付加過程**




**逆方向：ノイズ除去過程**



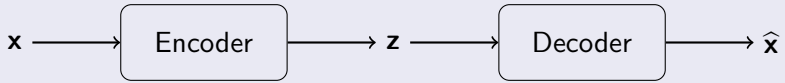

- 順方向過程では、データに段階的にノイズを加える (過程は固定)。
- 逆方向過程では、学習したモデルによってノイズから段階的に除去する。

# この章で理解すること

- VAE が ELBO を最適化する理由
- DDPM における順方向・逆方向の過程
- 条件付けによって学習目標を扱いやすくなる仕組み
- 平均値予測・クリーンデータ予測・ノイズ予測の関係
- DDPM のノイズ除去損失と ELBO の関係

## AE の基本構造

Autoencoder(AE) は、2 つのネットワーク (Encoder と Decoder) から構成される。




- Encoder: 入力を低次元の潜在コードに圧縮する決定論的写像
- Decoder: その潜在コードから入力を再構成する決定論的写像

## AE の課題：潜在空間の構造が保証されない

- 潜在空間に明確な構造が形成されるとは限らない。
- そのため、潜在空間からランダムにサンプリングしても、意味のあるデータが生成されるとは限らない。

# VAE の基本的な考え方

VAE は、潜在空間に確率的な構造を導入することで、AE が抱える課題の解決を目指す。

## 通常の AE

- 潜在表現 $\mathbf{z}$ を求める ($\mathbf{x} \to \mathbf{z}$ の写像)
- エンコーダが潜在表現を出力
- 潜在空間に明確な構造が形成されるとは限らない

## VAE

- 潜在変数 $\mathbf{z}$ の確率分布を推定
- 分布から $\mathbf{z}$ をサンプリング
- 生成に適した潜在空間の学習を目指す

## ポイント

VAE では、潜在変数を確率分布を通して扱い、単なる再構成の仕組みではなく生成に適した潜在空間の学習を目指す。

# VAE の確率モデルと基本構造

## VAE の確率モデル

$$\mathbf{x} \longrightarrow \boxed{q_\theta(\mathbf{z} \mid \mathbf{x})} \longrightarrow \mathbf{z} \longrightarrow \boxed{p_\phi(\mathbf{x} \mid \mathbf{z})} \longrightarrow \mathbf{x}'$$

- $\mathbf{x}$：観測データ
- $q_\theta(\mathbf{z} \mid \mathbf{x})$：潜在変数の分布を推定するエンコーダ
- $\mathbf{z}$：潜在変数
- $p_\phi(\mathbf{x} \mid \mathbf{z})$：潜在変数からデータを生成するデコーダの条件付き分布
- $\mathbf{x}'$：生成・再構成されたデータ

# 潜在変数を用いる意義とデータ生成

## 潜在変数を用いる意義

- 潜在変数によるコンパクトな表現を介して、データの生成を行う。
- デコーダを単純な分布に保つことで、有用な潜在特徴の抽出を重視する。

## 新しいサンプルの生成

$$\mathbf{z} \sim p_{\text{prior}}(\mathbf{z}) \quad \longrightarrow \quad \mathbf{x} \sim p_\phi(\mathbf{x} \mid \mathbf{z})$$

- 事前分布 $p_{\text{prior}}(\mathbf{z})$ から潜在変数 $\mathbf{z}$ をサンプリングする。
- 事前分布には通常、標準ガウス分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ を用いる。
- デコーダの条件付き分布 $p_\phi(\mathbf{x} \mid \mathbf{z})$ から新しいデータ $\mathbf{x}$ をサンプリングする。

# 周辺尤度と最尤推定

## 周辺尤度

観測データ $\mathbf{x}$ の周辺尤度は、潜在変数 $\mathbf{z}$ の可能性をすべて考慮したときの、データ $\mathbf{x}$ の確率を表す。

$$p_\phi(\mathbf{x}) = \int p_\phi(\mathbf{x} \mid \mathbf{z})\, p_{\text{prior}}(\mathbf{z})\, d\mathbf{z}$$

- $p_\phi(\mathbf{x} \mid \mathbf{z})$：デコーダの条件付き分布
- $p_{\text{prior}}(\mathbf{z})$：潜在変数の事前分布

# 周辺尤度の計算上の問題

## 理想的な学習目標

観測データの尤度を最大化するようにモデルを学習する。すなわち、対数周辺尤度を最大化する。

$$\max_{\phi} \log p_\phi(\mathbf{x}) = \max_{\phi} \log \left[ \int p_\phi(\mathbf{x} \mid \mathbf{z})\, p_{\text{prior}}(\mathbf{z})\, d\mathbf{z} \right]$$

周辺尤度の計算には、潜在変数 $z$ に関する積分が必要となる。
しかし、表現力の高い非線形デコーダを用いる場合、この積分を厳密に計算することは一般に困難である。

## 変分的アプローチの導入

周辺尤度を直接最大化することが難しいため、計算可能な下界を最大化する方法を考える。この下界を **ELBO**（Evidence Lower Bound）と呼ぶ。

# 真の事後分布と近似事後分布

## 事後分布

事後分布 $p_\phi(\mathbf{z} \mid \mathbf{x})$ は、観測データ $\mathbf{x}$ が与えられたときの潜在変数 $\mathbf{z}$ の分布である。これはベイズの定理より以下の式で与えられる。

$$p_\phi(\mathbf{z} \mid \mathbf{x}) = \frac{p_\phi(\mathbf{x} \mid \mathbf{z}) p_{\text{prior}}(\mathbf{z})}{p_\phi(\mathbf{x})}$$

## 事後分布の計算上の問題

分母の周辺尤度 $p_\phi(\mathbf{x})$ の計算が困難なため、事後分布を厳密に求めることも一般に困難である。

# 変分推論とエンコーダ

## 近似事後分布の導入

真の事後分布 $p_\phi(\mathbf{z} \mid \mathbf{x})$ を直接求める代わりに、近似事後分布 $q_\theta(\mathbf{z} \mid \mathbf{x})$ を導入する。つまり、

$$q_\theta(\mathbf{z} \mid \mathbf{x}) \approx p_\phi(\mathbf{z} \mid \mathbf{x})$$

## エンコーダの役割

- $q_\theta$ はニューラルネットワークによってパラメータ化
- 観測された各データ点 $\mathbf{x}$ を潜在コード上の確率分布に対応
- 実行・学習可能な経路が構築される

# Evidence Lower Bound (ELBO)

周辺尤度 $p_\phi(\mathbf{x})$ の直接的な計算は難しいため、その対数尤度の下界を最大化することを考える。

**ELBO の定義**

$$\mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})} \left[\log p_\phi(\mathbf{x} \mid \mathbf{z})\right] - D_{\mathrm{KL}} \left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_{\mathrm{prior}}(\mathbf{z})\right)$$

このとき、ELBO は計算可能で対数周辺尤度の下界を与える。

$$\boxed{\log p_\phi(\mathbf{x}) \geq \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x})}$$

# ELBO の 2 つの項

ELBO は、次の 2 つの項から構成される。

## 1. 再構成項（Reconstruction Term）

$$\mathbb{E}_{\mathbf{z}\sim q_\theta(\mathbf{z}|\mathbf{x})}\left[\log p_\phi(\mathbf{x} \mid \mathbf{z})\right]$$

潜在変数 $\mathbf{z}$ から、元のデータ $\mathbf{x}$ をどれだけ適切に再構成できるかを評価する。

## 2. 潜在変数の正則化項（Latent Regularization）

$$D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_{\mathrm{prior}}(\mathbf{z})\right)$$

近似事後分布 $q_\theta(\mathbf{z} \mid \mathbf{x})$ を事前分布 $p_{\mathrm{prior}}(\mathbf{z})$ に近づけ、潜在空間を滑らかで連続的な構造を持つようにする。

$\Rightarrow$ 2 つの項のバランスをとりながら再構成と意味のあるサンプル生成を目指して学習する。

# ELBO の導出 (1)

周辺尤度の対数から出発する。

$$\begin{aligned}\log p_\phi(\mathbf{x}) &= \log \int p_\phi(\mathbf{x}, \mathbf{z})\, d\mathbf{z} \\ &= \log \int q_\theta(\mathbf{z} \mid \mathbf{x}) \frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z} \mid \mathbf{x})}\, d\mathbf{z} \\ &= \log \mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})} \left[ \frac{p_\phi(\mathbf{x}, \mathbf{z})}{q_\theta(\mathbf{z} \mid \mathbf{x})} \right].\end{aligned}$$

- 同時分布 $p_\phi(\mathbf{x}, \mathbf{z})$ を利用する。
- 近似事後分布 $q_\theta(\mathbf{z} \mid \mathbf{x})$ を掛けて割ることで、期待値の形に変形する。

# ELBO の導出 (2)

対数関数 $\log x$ は凹関数であるため、Jensen の不等式より

$$\log \mathbb{E}[X] \geq \mathbb{E}[\log X]$$

が成立する。

これをスライド 3 の式に適用すると、

$$\begin{aligned}\log p_\phi(\mathbf{x}) &= \log \mathbb{E}_{\mathbf{z}\sim q_\theta(\mathbf{z}|\mathbf{x})}\left[\frac{p_\phi(\mathbf{x},\mathbf{z})}{q_\theta(\mathbf{z}\mid\mathbf{x})}\right] \\ &\geq \mathbb{E}_{\mathbf{z}\sim q_\theta(\mathbf{z}|\mathbf{x})}\left[\log \frac{p_\phi(\mathbf{x},\mathbf{z})}{q_\theta(\mathbf{z}\mid\mathbf{x})}\right].\end{aligned}$$

$\Rightarrow$ 対数周辺尤度の下界が得られた。

# ELBO の導出 (3)

同時分布を条件付き分布と事前分布に分解する。

$$p_\phi(\mathbf{x}, \mathbf{z}) = p_\phi(\mathbf{x} \mid \mathbf{z}) p_{\text{prior}}(\mathbf{z})$$

これを代入すると、

$$\begin{aligned}
\log p_\phi(\mathbf{x}) &\geq \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} \left[ \log \frac{p_\phi(\mathbf{x} \mid \mathbf{z}) p_{\text{prior}}(\mathbf{z})}{q_\theta(\mathbf{z} \mid \mathbf{x})} \right] \\
&= \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} \left[ \log p_\phi(\mathbf{x} \mid \mathbf{z}) + \log p_{\text{prior}}(\mathbf{z}) - \log q_\theta(\mathbf{z} \mid \mathbf{x}) \right] \\
&= \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} \left[ \log p_\phi(\mathbf{x} \mid \mathbf{z}) \right] \\
&\quad - \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} \left[ \log \frac{q_\theta(\mathbf{z} \mid \mathbf{x})}{p_{\text{prior}}(\mathbf{z})} \right].
\end{aligned}$$

# ELBO の導出 (4)

KL ダイバージェンスの定義より、

$$D_{\mathrm{KL}}(q\|p) = \mathbb{E}_q\left[\log \frac{q}{p}\right]$$

したがって、

$$\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log \frac{q_\theta(\mathbf{z}\mid\mathbf{x})}{p_{\mathrm{prior}}(\mathbf{z})}\right] = D_{\mathrm{KL}}\left(q_\theta(\mathbf{z}\mid\mathbf{x})\|p_{\mathrm{prior}}(\mathbf{z})\right).$$

よって、

$$\begin{aligned}\log p_\phi(\mathbf{x}) &\geq \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log p_\phi(\mathbf{x}\mid\mathbf{z})\right] \\ &\quad - D_{\mathrm{KL}}\left(q_\theta(\mathbf{z}\mid\mathbf{x})\|p_{\mathrm{prior}}(\mathbf{z})\right) \\ &= \mathcal{L}_{\mathrm{ELBO}}(\theta,\phi;\mathbf{x}).\end{aligned}$$

$$\boxed{\log p_\phi(\mathbf{x}) \geq \mathcal{L}_{\mathrm{ELBO}}(\theta,\phi;\mathbf{x})}$$

# 情報理論的な解釈：最尤推定との関係

最尤推定は、データの対数尤度を最大化することに相当する。これは、データ分布と生成モデルの分布の間の KL ダイバージェンスを最小化することと等価である。

**最小化したい KL ダイバージェンス**

$$D_{\mathrm{KL}}\left(p_{\mathrm{data}}(\mathbf{x}) \| p_{\phi}(\mathbf{x})\right)$$

しかし、潜在変数を含む生成モデルでは、周辺分布 $p_{\phi}(\mathbf{x})$ の計算が難しい。

$\Rightarrow$ 潜在変数を含む同時分布に着目する。

# 同時分布の KL ダイバージェンスによる上界

次の 2 つの同時分布を定義する。

$$p_\phi(\mathbf{x}, \mathbf{z}) = p_{\text{prior}}(\mathbf{z}) p_\phi(\mathbf{x} \mid \mathbf{z}),$$
$$q_\theta(\mathbf{x}, \mathbf{z}) = p_{\text{data}}(\mathbf{x}) q_\theta(\mathbf{z} \mid \mathbf{x}).$$

これらの KL ダイバージェンスは、次のように分解できる。

$$\begin{aligned} & D_{\mathrm{KL}}\left(q_\theta(\mathbf{x}, \mathbf{z}) \| p_\phi(\mathbf{x}, \mathbf{z})\right) \\ & = D_{\mathrm{KL}}\left(p_{\text{data}}(\mathbf{x}) \| p_\phi(\mathbf{x})\right) \\ & \quad + \mathbb{E}_{p_{\text{data}}(\mathbf{x})}\left[D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\right)\right]. \end{aligned}$$

KL ダイバージェンスは非負であるため、

$$\boxed{D_{\mathrm{KL}}(p_{\text{data}} \| p_\phi) \leq D_{\mathrm{KL}}(q_\theta(\mathbf{x}, \mathbf{z}) \| p_\phi(\mathbf{x}, \mathbf{z}))}$$

# 同時分布の KL ダイバージェンスによる上界の証明（1）

KL ダイバージェンスの定義より、

$$
\begin{aligned}
&D_{\mathrm{KL}}\left(q_\theta(\mathbf{x},\mathbf{z}) \| p_\phi(\mathbf{x},\mathbf{z})\right) \\
&= \mathbb{E}_{q_\theta(\mathbf{x},\mathbf{z})}\left[\log \frac{q_\theta(\mathbf{x},\mathbf{z})}{p_\phi(\mathbf{x},\mathbf{z})}\right].
\end{aligned}
$$

同時分布の定義

$$
\begin{aligned}
q_\theta(\mathbf{x},\mathbf{z}) &= p_{\mathrm{data}}(\mathbf{x}) q_\theta(\mathbf{z} \mid \mathbf{x}), \\
p_\phi(\mathbf{x},\mathbf{z}) &= p_\phi(\mathbf{x}) p_\phi(\mathbf{z} \mid \mathbf{x})
\end{aligned}
$$

を代入すると、

$$
\begin{aligned}
&D_{\mathrm{KL}}\left(q_\theta(\mathbf{x},\mathbf{z}) \| p_\phi(\mathbf{x},\mathbf{z})\right) \\
&= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log \frac{p_{\mathrm{data}}(\mathbf{x}) q_\theta(\mathbf{z} \mid \mathbf{x})}{p_\phi(\mathbf{x}) p_\phi(\mathbf{z} \mid \mathbf{x})}\right]\right].
\end{aligned}
$$

# 同時分布の KL ダイバージェンスによる上界の証明（2）

対数を分けると、

$$
\begin{aligned}
&D_{\mathrm{KL}}\left(q_\theta(\mathbf{x},\mathbf{z})\|p_\phi(\mathbf{x},\mathbf{z})\right) \\
&= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log\frac{p_{\mathrm{data}}(\mathbf{x})}{p_\phi(\mathbf{x})}+\log\frac{q_\theta(\mathbf{z}\mid\mathbf{x})}{p_\phi(\mathbf{z}\mid\mathbf{x})}\right]\right] \\
&= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[\log\frac{p_{\mathrm{data}}(\mathbf{x})}{p_\phi(\mathbf{x})}+\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log\frac{q_\theta(\mathbf{z}\mid\mathbf{x})}{p_\phi(\mathbf{z}\mid\mathbf{x})}\right]\right] \\
&= D_{\mathrm{KL}}\left(p_{\mathrm{data}}(\mathbf{x})\|p_\phi(\mathbf{x})\right)+\mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[D_{\mathrm{KL}}\left(q_\theta(\mathbf{z}\mid\mathbf{x})\|p_\phi(\mathbf{z}\mid\mathbf{x})\right)\right]
\end{aligned}
$$

KL ダイバージェンスの非負性より、

$$
\boxed{D_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi)\le D_{\mathrm{KL}}\left(q_\theta(\mathbf{x},\mathbf{z})\|p_\phi(\mathbf{x},\mathbf{z})\right)}
$$

# 真のモデル化誤差と推論誤差

## 1. 真のモデル化誤差（Modeling Error）

$$D_{\mathrm{KL}}\left(p_{\mathrm{data}}(\mathbf{x}) \| p_{\phi}(\mathbf{x})\right)$$

データの真の分布と生成モデルの分布のずれを表す。

## 2. 推論誤差（Inference Error）

$$\mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[D_{\mathrm{KL}}\left(q_{\theta}(\mathbf{z} \mid \mathbf{x}) \| p_{\phi}(\mathbf{z} \mid \mathbf{x})\right)\right]$$

近似事後分布と真の事後分布のずれを表す。

**生成モデルの表現能力と、事後分布の近似精度を区別する。**

# 対数尤度と ELBO の差

対数尤度と ELBO の差は、近似事後分布と真の事後分布の KL ダイバージェンスに一致する。

## 重要な関係式

$$\log p_\phi(\mathbf{x}) - \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}) = D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\right)$$

右辺は推論誤差を表すため、

- ELBO は対数尤度の下界となる。
- 近似事後分布が真の事後分布に一致すると、両者の差は 0 となる。

# 対数尤度と ELBO の差の証明 (1)

KL ダイバージェンスの定義より、

$$
\begin{aligned}
&D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\right) \\
&= \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log \frac{q_\theta(\mathbf{z} \mid \mathbf{x})}{p_\phi(\mathbf{z} \mid \mathbf{x})}\right].
\end{aligned}
$$

ベイズの定理より、

$$
p_\phi(\mathbf{z} \mid \mathbf{x}) = \frac{p_\phi(\mathbf{x} \mid \mathbf{z}) p_{\mathrm{prior}}(\mathbf{z})}{p_\phi(\mathbf{x})}
$$

なので、

$$
\begin{aligned}
D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\right) &= \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log \frac{q_\theta(\mathbf{z} \mid \mathbf{x}) p_\phi(\mathbf{x})}{p_\phi(\mathbf{x} \mid \mathbf{z}) p_{\mathrm{prior}}(\mathbf{z})}\right] \\
&= \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log p_\phi(\mathbf{x})\right] - \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log p_\phi(\mathbf{x} \mid \mathbf{z})\right] + \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log \frac{q_\theta(\mathbf{z} \mid \mathbf{x})}{p_{\mathrm{prior}}(\mathbf{z})}\right]
\end{aligned}
$$

# 対数尤度と ELBO の差の証明 (2)

第 1 項は $\mathbf{z}$ に依存しないことと、第 3 項は KL ダイバージェンスの定義式になっていることを踏まえると、

$$\begin{aligned} D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_\phi(\mathbf{z} \mid \mathbf{x})\right) &= \log p_\phi(\mathbf{x}) - \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log p_\phi(\mathbf{x} \mid \mathbf{z})\right] + D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p_{prior}(\mathbf{z})\right) \\ &= \log p_\phi(\mathbf{x}) - \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}). \end{aligned}$$

よって、対数尤度を固定したとき、ELBO を最大化することは推論誤差を直接的に減少させることに対応する。

# 2.1.3 Standard Gaussian VAE：Encoder

エンコーダは、入力データ $\mathbf{x}$ から潜在変数 $\mathbf{z}$ の条件付き分布 $q_\theta(\mathbf{z} \mid \mathbf{x})$ を定める。

**エンコーダの定式化**

$$q_\theta(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}\left(\mathbf{z}; \boldsymbol{\mu}_\theta(\mathbf{x}), \mathrm{diag}\left(\boldsymbol{\sigma}_\theta^2(\mathbf{x})\right)\right)$$

- $\mathbf{x} \in \mathbb{R}^D$：入力データ（データ次元 $D$）
- $\mathbf{z} \in \mathbb{R}^d$：潜在変数（潜在次元 $d$）
- $\boldsymbol{\mu}_\theta(\mathbf{x}) \in \mathbb{R}^d$：各潜在次元の平均を表すベクトル
- $\boldsymbol{\sigma}_\theta(\mathbf{x}) \in \mathbb{R}_+^d$：各潜在次元の標準偏差を表すベクトル

共分散行列を対角行列とすることで、潜在次元間の共分散をモデル化せず、各次元の分散を独立に扱う。

# 2.1.3 Standard Gaussian VAE：Decoder

デコーダは、潜在変数 $\mathbf{z}$ からデータ $\mathbf{x}$ の条件付き分布 $p_\phi(\mathbf{x} \mid \mathbf{z})$ を定める。

## デコーダの定式化

$$p_\phi(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}\left(\mathbf{x}; \boldsymbol{\mu}_\phi(\mathbf{z}), \sigma^2 I\right)$$

- $\boldsymbol{\mu}_\phi(\mathbf{z}) \in \mathbb{R}^D$：デコーダが出力するデータ空間での平均ベクトル
- $\sigma^2 I \in \mathbb{R}^{D \times D}$：各次元の分散が $\sigma^2$ である共分散行列
- $\sigma > 0$：学習中に変化させない固定定数

## 分散を固定する理由

- 尤度の計算を簡単にできる。
- 対数尤度を、二乗再構成誤差に比例する形で表せる。

# 再構成項と二乗誤差

デコーダの分散を固定すると、ELBO に含まれる再構成項は二乗再構成誤差を用いて表せる。

## 再構成項の変形

$$\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log p_\phi(\mathbf{x} \mid \mathbf{z})\right] = -\frac{1}{2\sigma^2}\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\left\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\right\|^2\right] + C$$

$C$ は学習パラメータに依存しない定数

- $\mathbf{x}$ と $\boldsymbol{\mu}_\phi(\mathbf{z})$ の差が再構成誤差に対応する。
- 再構成項の最大化は、期待二乗再構成誤差の最小化に対応する。
- ただし、ELBO 全体では KL ダイバージェンスの項も考慮する。

# 再構成項の導出 (1)：準備

## 計算したい式

$$\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log p_\phi(\mathbf{x} \mid \mathbf{z})\right]$$

デコーダは、次のガウス分布で定式化される。

$$p_\phi(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}\left(\mathbf{x}; \boldsymbol{\mu}_\phi(\mathbf{z}), \sigma^2 I\right)$$

## $D$ 次元ガウス分布の確率密度関数

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{D/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})\right)$$

$\boldsymbol{\mu} \in \mathbb{R}^D$：平均ベクトル、$\Sigma \in \mathbb{R}^{D\times D}$：共分散行列

# 再構成項の導出 (2)：確率密度関数への代入

デコーダの分布に対して、ガウス分布の確率密度関数を適用する。

## 行列式と逆行列の計算

$I$ は $D \times D$ の単位行列であるため、

$$|\sigma^2 I| = (\sigma^2)^D, \qquad (\sigma^2 I)^{-1} = \frac{1}{\sigma^2} I$$

が成り立つ。

これらを代入すると、

$$p_\phi(\mathbf{x} \mid \mathbf{z}) = \frac{1}{(2\pi\sigma^2)^{D/2}} \cdot \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2\right)$$

# 再構成項の導出 (3)：対数尤度の整理

前スライドの式の対数を取ると、

$$\log p_\phi(\mathbf{x} \mid \mathbf{z}) = -\frac{D}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2$$

ここで、第 1 項は学習パラメータに依存しない定数である。

**再構成項**

両辺について $q_\theta(\mathbf{z} \mid \mathbf{x})$ に関する期待値を取ると、

$$\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}[\log p_\phi(\mathbf{x} \mid \mathbf{z})] = -\frac{1}{2\sigma^2}\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2\right] + C$$

したがって、再構成項の最大化は、期待二乗再構成誤差の最小化に対応する。

# 2.1.3 Standard Gaussian VAE：学習目的

## ELBO の定義

$$\begin{aligned}\mathrm{ELBO}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}[\log p_\phi(\mathbf{x} \mid \mathbf{z})] \\ - D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \,\|\, p_{\mathrm{prior}}(\mathbf{z})\right)\end{aligned}$$

再構成項の変形より、

$$\begin{aligned}\mathrm{ELBO}(\theta, \phi; \mathbf{x}) = & -\frac{1}{2\sigma^2}\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2\right] \\ & - D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \,\|\, p_{\mathrm{prior}}(\mathbf{z})\right) + C\end{aligned}$$

ELBO の最大化は、定数 $C$ を除き、負号を反転させた次の目的関数の最小化と等価である。

$$\begin{aligned}\mathcal{L}(\theta, \phi; \mathbf{x}) = \frac{1}{2\sigma^2}\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2\right] \\ + D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \,\|\, p_{\mathrm{prior}}(\mathbf{z})\right)\end{aligned}$$

# 2.1.3 Standard Gaussian VAE：KL ダイバージェンス

エンコーダの分布と事前分布がガウス分布の場合、KL ダイバージェンスは解析的に計算できる。

## KL ダイバージェンスの閉形式

エンコーダの分布を

$$q_\theta(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}\left(\boldsymbol{\mu}, \mathrm{diag}(\boldsymbol{\sigma}^2)\right)$$

事前分布を $p_{\mathrm{prior}}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I)$ とすると、

$$D_{\mathrm{KL}}(q_\theta \| p_{\mathrm{prior}}) = \frac{1}{2} \sum_{j=1}^{d} \left(\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2\right)$$

- $\mu_j, \sigma_j$：エンコーダが出力する第 $j$ 潜在次元の平均と標準偏差
- 平均と分散を用いた閉形式で表せるため、数値積分を行わずに計算できる。

# 2.1.3 Standard Gaussian VAE：KL ダイバージェンスの導出

今回は、エンコーダの分布と事前分布の KL ダイバージェンスを計算する。

## 計算したい式

$$D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \,\|\, p_{\mathrm{prior}}(\mathbf{z})\right)$$

## KL ダイバージェンスの定義

$$D_{\mathrm{KL}}(q\|p) = \mathbb{E}_{q(\mathbf{z})}\left[\log q(\mathbf{z}) - \log p(\mathbf{z})\right]$$

## D 次元ガウス分布の確率密度関数

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{D/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})\right)$$

ここで、$\boldsymbol{\mu}$ は平均ベクトル、$\Sigma$ は共分散行列である。

# 2.1.3 Standard Gaussian VAE：確率密度関数の具体化

エンコーダの分布は

$$q_\theta(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}\left(\mathbf{z}; \boldsymbol{\mu}, \mathrm{diag}(\boldsymbol{\sigma}^2)\right)$$

とする。ただし、$\boldsymbol{\mu} = \boldsymbol{\mu}_\theta(\mathbf{x})$、$\boldsymbol{\sigma} = \boldsymbol{\sigma}_\theta(\mathbf{x})$ とおく。
また、事前分布は標準正規分布 $p_{\mathrm{prior}}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I)$ である。

## 確率密度関数

$$q_\theta(\mathbf{z} \mid \mathbf{x}) = \frac{1}{(2\pi)^{d/2} \prod_{j=1}^{d} \sigma_j} \exp\left(-\frac{1}{2} \sum_{j=1}^{d} \frac{(z_j - \mu_j)^2}{\sigma_j^2}\right)$$

$$p_{\mathrm{prior}}(\mathbf{z}) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{1}{2} \sum_{j=1}^{d} z_j^2\right)$$

# 2.1.3 Standard Gaussian VAE：KL ダイバージェンスの導出

KL ダイバージェンスの定義より、

$$D_{\mathrm{KL}}(q_\theta \| p_{\mathrm{prior}}) = \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})}\left[\log q_\theta(\mathbf{z} \mid \mathbf{x}) - \log p_{\mathrm{prior}}(\mathbf{z})\right]$$

それぞれの対数を計算すると、

$$\log q_\theta(\mathbf{z} \mid \mathbf{x}) = -\frac{d}{2}\log(2\pi) - \sum_{j=1}^{d}\log\sigma_j - \frac{1}{2}\sum_{j=1}^{d}\frac{(z_j-\mu_j)^2}{\sigma_j^2}$$

$$\log p_{\mathrm{prior}}(\mathbf{z}) = -\frac{d}{2}\log(2\pi) - \frac{1}{2}\sum_{j=1}^{d} z_j^2$$

2 つの対数の差をとると、

$$\log q_\theta(\mathbf{z} \mid \mathbf{x}) - \log p_{\mathrm{prior}}(\mathbf{z}) = -\sum_{j=1}^{d}\log\sigma_j - \frac{1}{2}\sum_{j=1}^{d}\frac{(z_j-\mu_j)^2}{\sigma_j^2} + \frac{1}{2}\sum_{j=1}^{d} z_j^2$$

# 2.1.3 Standard Gaussian VAE：期待値の計算

前スライドの式に対して、期待値の線形性から、期待値と総和の順序を交換すると、

$$D_{\mathrm{KL}}(q_\theta \| p_{\mathrm{prior}}) = -\sum_{j=1}^{d} \log \sigma_j - \frac{1}{2}\sum_{j=1}^{d} \frac{\mathbb{E}_{q_\theta}[(z_j - \mu_j)^2]}{\sigma_j^2} + \frac{1}{2}\sum_{j=1}^{d} \mathbb{E}_{q_\theta}[z_j^2]$$

ここで、$\boldsymbol{\mu}$ と $\boldsymbol{\sigma}$ は、入力 $\mathbf{x}$ とパラメータ $\theta$ を固定したときの定数である。
よって、各次元について次の期待値を計算すればよい。

$$\mathbb{E}_{q_\theta}[(z_j - \mu_j)^2], \qquad \mathbb{E}_{q_\theta}[z_j^2]$$

# 2.1.3 Standard Gaussian VAE：期待値の計算

## 1. 平均と分散の定義

各次元について、$z_j \sim \mathcal{N}(\mu_j, \sigma_j^2)$ なので、

$$\mathbb{E}_{q_\theta}[z_j] = \mu_j, \qquad \mathrm{Var}_{q_\theta}(z_j) = \sigma_j^2$$

分散の定義より、

$$\mathbb{E}_{q_\theta}[(z_j - \mu_j)^2] = \mathrm{Var}_{q_\theta}(z_j) \quad = \sigma_j^2$$

## 2. 2 乗の期待値

分散の性質

$$\mathrm{Var}(Z) = \mathbb{E}[Z^2] - (\mathbb{E}[Z])^2$$

より、

$$\mathbb{E}_{q_\theta}[z_j^2] = \mathrm{Var}_{q_\theta}(z_j) + \left(\mathbb{E}_{q_\theta}[z_j]\right)^2 = \sigma_j^2 + \mu_j^2$$

# 2.1.3 Standard Gaussian VAE：KL ダイバージェンスの導出

前スライドまでの結果を代入すると、

$$
\begin{aligned}
&D_{\mathrm{KL}}(q_\theta \| p_{\mathrm{prior}}) \\
&= -\sum_{j=1}^{d} \log \sigma_j - \frac{1}{2}\sum_{j=1}^{d} \frac{\sigma_j^2}{\sigma_j^2} + \frac{1}{2}\sum_{j=1}^{d} (\sigma_j^2 + \mu_j^2) \\
&= \frac{1}{2}\sum_{j=1}^{d} \left(\mu_j^2 + \sigma_j^2 - 1 - 2\log \sigma_j\right)
\end{aligned}
$$

ここで、$2\log \sigma_j = \log \sigma_j^2$ より、

$$
\boxed{D_{\mathrm{KL}}(q_\theta \| p_{\mathrm{prior}}) = \frac{1}{2}\sum_{j=1}^{d} \left(\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2\right)}
$$

# 標準的な VAE の問題点

標準的な VAE には、生成画像がぼやけることがあるという問題がある。

## ぼやけが生じる仕組みを考える

原因を理解するため、エンコーダを $q_{\mathrm{enc}}$ 固定し、次の形式のデコーダを考える。

$$\boxed{p_{\mathrm{dec}}(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}\left(\mathbf{x}; \boldsymbol{\mu}(\mathbf{z}), \sigma^2 I\right)}$$

ここで、$\boldsymbol{\mu}(\mathbf{z})$ はデコーダのニューラルネットワーク、$\sigma > 0$ は固定された定数である。

## この節で扱う設定

ガウス分布のデコーダと二乗再構成誤差を用いる設定における問題を考える。これは、すべての VAE に共通する性質ではない。

# 標準 VAE の最適化と最小二乗問題

標準ガウス VAE の目的関数は、次のように表される。

$$\mathcal{L}(\theta, \phi) = \frac{1}{2\sigma^2} \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} \left[ \|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2 \right] + D_{\mathrm{KL}} \left( q_\theta(\mathbf{z} \mid \mathbf{x}) \,\|\, p_{\mathrm{prior}}(\mathbf{z}) \right).$$

**エンコーダを固定すると**

KL ダイバージェンス項はデコーダのパラメータ $\phi$ に依存しない定数となる。したがって、デコーダの最適化では再構成項のみを考えればよい。

さらに、データ分布 $p_{\mathrm{data}}(\mathbf{x})$ 全体に対する期待再構成誤差を考えると、最適化問題は

$$\boxed{\arg\min_{\boldsymbol{\mu}} \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x}) q_{\mathrm{enc}}(\mathbf{z}|\mathbf{x})} \left[ \|\mathbf{x} - \boldsymbol{\mu}(\mathbf{z})\|^2 \right]}$$

となる。これは $\boldsymbol{\mu}(\mathbf{z})$ に関する標準的な最小二乗問題である。

# 最小二乗問題の最適解

前の章で扱ったように、二乗誤差を最小化する関数は条件付き期待値で与えられる。

今回の最小二乗問題では、最適なデコーダの平均関数は

$$\boxed{\boldsymbol{\mu}^*(\mathbf{z}) = \mathbb{E}_{q_{\mathrm{enc}}(\mathbf{x}|\mathbf{z})}[\mathbf{x}]}$$

と表される。ここで、$q_{\mathrm{enc}}(\mathbf{x} \mid \mathbf{z})$ は、潜在変数 $\mathbf{z}$ が与えられたときの入力データ $\mathbf{x}$ の条件付き分布である。

# 条件付き分布の変形

最適なデコーダの平均関数は、条件付き期待値で表される。

$$\boldsymbol{\mu}^*(\mathbf{z}) = \mathbb{E}_{q_{\mathrm{enc}}(\mathbf{x}|\mathbf{z})}[\mathbf{x}]$$

ここで、ベイズの定理より

$$\boxed{q_{\mathrm{enc}}(\mathbf{x} \mid \mathbf{z}) = \frac{q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x}) p_{\mathrm{data}}(\mathbf{x})}{q_{\mathrm{enc}}(\mathbf{z})}}$$

## 潜在変数の周辺分布

$$q_{\mathrm{enc}}(\mathbf{z}) := \int q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x}) p_{\mathrm{data}}(\mathbf{x})\, d\mathbf{x}$$

データ分布全体をエンコーダに通して得られる潜在変数の周辺分布である。

# 最適なデコーダの別表現

最適なデコーダの平均関数は

$$\boldsymbol{\mu}^*(\mathbf{z}) = \mathbb{E}_{q_{\mathrm{enc}}(\mathbf{x}|\mathbf{z})}[\mathbf{x}]$$

と表される。これを積分の形に直し、前スライドで示したベイズの定理を適用すると、

$$\begin{aligned}\boldsymbol{\mu}^*(\mathbf{z}) &= \int \mathbf{x}\, q_{\mathrm{enc}}(\mathbf{x} \mid \mathbf{z})\, d\mathbf{x} \\ &= \int \mathbf{x}\, \frac{q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x}) p_{\mathrm{data}}(\mathbf{x})}{q_{\mathrm{enc}}(\mathbf{z})}\, d\mathbf{x}.\end{aligned}$$

# 最適なデコーダの式変形

$q_{\mathrm{enc}}(\mathbf{z})$ は $\mathbf{x}$ に依存しないため、積分の外に出せる。

$$\begin{aligned}\boldsymbol{\mu}^*(\mathbf{z}) &= \frac{1}{q_{\mathrm{enc}}(\mathbf{z})} \int q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x}) \mathbf{x}\, p_{\mathrm{data}}(\mathbf{x})\, d\mathbf{x} \\ &= \frac{\mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x}) \mathbf{x}\right]}{q_{\mathrm{enc}}(\mathbf{z})}.\end{aligned}$$

さらに、周辺分布の定義より

$$\begin{aligned}q_{\mathrm{enc}}(\mathbf{z}) &= \int q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x}) p_{\mathrm{data}}(\mathbf{x})\, d\mathbf{x} \\ &= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[q_{\mathrm{enc}}(\mathbf{z} \mid \mathbf{x})\right].\end{aligned}$$

# 最適なデコーダの式の意味

以上より、最適なデコーダの平均関数は

$$\boldsymbol{\mu}^*(\mathbf{z}) = \frac{\mathbb{E}_{p_{\text{data}}(\mathbf{x})}\left[q_{\text{enc}}(\mathbf{z} \mid \mathbf{x})\mathbf{x}\right]}{\mathbb{E}_{p_{\text{data}}(\mathbf{x})}\left[q_{\text{enc}}(\mathbf{z} \mid \mathbf{x})\right]}$$

と表される。

**式の意味**

$q_{\text{enc}}(\mathbf{z} \mid \mathbf{x})$ によって各入力データ $\mathbf{x}$ の寄与が重み付けされ、その重みで正規化された平均が出力される。

# 潜在空間での分布の重なりとぼやけ

異なる入力 $\mathbf{x} \neq \mathbf{x}'$ に対して、エンコーダが出力する分布 $q_{\text{enc}}(\mathbf{z} \mid \mathbf{x})$ と $q_{\text{enc}}(\mathbf{z} \mid \mathbf{x}')$ の台が潜在空間で重なる場合を考える。

**このとき何が起こるか**

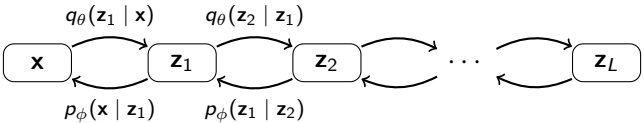
同じ潜在変数 $\mathbf{z}$ に対して、異なる入力 $\mathbf{x}, \mathbf{x}'$ が $q_{\text{enc}}(\mathbf{x} \mid \mathbf{z})$ の下で寄与を持ちうる。

その結果、最適なデコーダは複数の入力を平均したような出力を返し、ぼやけた、特徴のはっきりしない生成画像につながりうる。

# Hierarchical VAE (HVAE)

## 基本的な考え方

標準 VAE の単一の潜在変数 $\mathbf{z}$ に対して、HVAE では複数の潜在変数を階層的に導入する。




上段：エンコーダ（推論）　　下段：デコーダ（生成）

## 階層化による利点

- データの特徴を複数の抽象度で捉える
- モデルの表現力を高める
- 実世界のデータが持つ、要素の組み合わせによる構造を反映する

# HVAE's Modeling：生成モデル

## 同時分布の定義

HVAE では、各変数が直前の階層の変数に条件づけられる構造を仮定し、同時分布を次のように分解する。

$$p_\phi(\mathbf{x}, \mathbf{z}_{1:L}) = p_\phi(\mathbf{x} \mid \mathbf{z}_1) \prod_{i=2}^{L} p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i)\, p(\mathbf{z}_L)$$

## 階層構造のポイント

- 各潜在変数は、その 1 つ上の潜在変数に条件づけられる
- この構造により、データの特徴を複数の抽象度で捉える

- $p_\phi(\mathbf{x} \mid \mathbf{z}_1)$：観測データを生成する分布
- $p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i)$：1 つ下の潜在変数を生成する分布
- $p(\mathbf{z}_L)$：最上層の潜在変数に対する事前分布

# HVAE's Modeling：周辺分布と潜在変数

## 観測データの周辺分布

同時分布から潜在変数を積分消去することで、観測データ $x$ の周辺分布が得られる。

$$p_\phi(\mathbf{x}) = \int p_\phi(\mathbf{x}, \mathbf{z}_{1:L})\, d\mathbf{z}_{1:L}$$

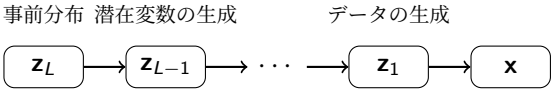
## 各分布の意味

- $p_\phi(\mathbf{x}, \mathbf{z}_{1:L})$：観測データとすべての潜在変数の同時分布
- $p_\phi(\mathbf{x})$：潜在変数を周辺化した、観測データの確率分布

# HVAE's Modeling：データの生成手順

## 生成の流れ

HVAE では、最上層の潜在変数から順番に生成し、最後に観測データを得る。




## 各段階で用いる分布

1. 最上層の潜在変数を事前分布 $p(\mathbf{z}_L)$ からサンプリングする
2. $p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i)$ に従い、上位から下位へ潜在変数を順番にサンプリングする
3. 最下層の潜在変数から $p_\phi(\mathbf{x} \mid \mathbf{z}_1)$ に従って観測データを生成する

# HVAE's Modeling：推論モデル

## 変分分布の因数分解

HVAE では、推論モデルに階層構造を導入し、変分分布を次のように因数分解する。

$$q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x}) = q_\theta(\mathbf{z}_1 \mid \mathbf{x}) \prod_{i=2}^{L} q_\theta(\mathbf{z}_i \mid \mathbf{z}_{i-1})$$

## 因数分解のポイント

- 最初に観測データ $\mathbf{x}$ から $\mathbf{z}_1$ を推論する
- その後、直前の潜在変数を条件として、上位の潜在変数を順番に推論する
- これにより、推論モデルにも階層構造が導入される

# HVAE's ELBO：Jensen の不等式による導出

周辺分布の定義より、

$$
\begin{aligned}
\log p_{\mathrm{HVAE}}(\mathbf{x}) &= \log \int p_\phi(\mathbf{x}, \mathbf{z}_{1:L})\, d\mathbf{z}_{1:L} \\
&= \log \int q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x}) \frac{p_\phi(\mathbf{x}, \mathbf{z}_{1:L})}{q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})}\, d\mathbf{z}_{1:L} \\
&= \log \mathbb{E}_{q_\theta(\mathbf{z}_{1:L}|\mathbf{x})} \left[ \frac{p_\phi(\mathbf{x}, \mathbf{z}_{1:L})}{q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})} \right] \\
&\geq \mathbb{E}_{q_\theta(\mathbf{z}_{1:L}|\mathbf{x})} \left[ \log \frac{p_\phi(\mathbf{x}, \mathbf{z}_{1:L})}{q_\theta(\mathbf{z}_{1:L} \mid \mathbf{x})} \right] \\
&:= \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}).
\end{aligned}
$$

**ポイント**

log は凹関数であるため、Jensen の不等式により対数周辺尤度の下界が得られる。

# HVAE's ELBO：因数分解の代入

生成モデルと推論モデルの因数分解をそれぞれ代入すると、

$$\begin{aligned}&\mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}) \\ &= \mathbb{E}_{q_\theta(\mathbf{z}_{1:L}|\mathbf{x})}\left[\log \frac{p(\mathbf{z}_L)\prod_{i=2}^{L} p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i) p_\phi(\mathbf{x} \mid \mathbf{z}_1)}{q_\theta(\mathbf{z}_1 \mid \mathbf{x})\prod_{i=2}^{L} q_\theta(\mathbf{z}_i \mid \mathbf{z}_{i-1})}\right].\end{aligned}$$

この式を展開・整理すると、ELBO は再構成項、隣接する層同士のマッチング項、そして最上位層の事前分布に対する KL 正則化項に分解される。

# HVAE：階層化の意義

- 深い層を積み重ねる考え方は、生成モデルにも応用されている。
- HVAE では、階層的な潜在変数を用いて、データを段階的に生成する。
- この階層構造は、スコアベースモデルや正規化フローなど、他の生成モデルにもつながる重要な考え方である。

**Observation 2.1.1**

層を積み重ねることで、大まかな特徴から細かい特徴へと段階的にデータを生成できる。これにより、高次元データの複雑な構造を捉えやすくなる。

**Note:**「大まかな特徴から細かい特徴へ」という説明は直感的な解釈であり、各潜在層がそのような役割を獲得することが理論的に保証されているわけではない。

# Why Deeper Networks in a Flat VAE are Not Enough

通常の VAE では、エンコーダ・デコーダを深くするだけでは解決できない、2 つの根本的な制約がある。

## 制約 1：変分分布の表現力

エンコーダのネットワークを深くしても、潜在変数の事後分布の形状そのものは十分に豊かにならない。

## 制約 2：Posterior Collapse

デコーダの表現力が高すぎると、潜在変数を利用せずにデータを生成する解が生じうる。

**ネットワークの深さと、潜在変数モデルの表現力は同じではない。**

# 制約1：変分分布の表現力

通常の VAE では、推論モデルを次のガウス分布で近似する。

$$q_\theta(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}\left(\boldsymbol{\mu}_\theta(\mathbf{x}), \mathrm{diag}(\boldsymbol{\sigma}^2_\theta(\mathbf{x}))\right)$$

- ネットワークを深くすることで、$\boldsymbol{\mu}_\theta(\mathbf{x})$ や $\boldsymbol{\sigma}_\theta(\mathbf{x})$ の予測精度は改善しうる。
- しかし、近似に用いる分布族そのものの制約は解消されない。
- 真の事後分布 $p_\phi(\mathbf{z} \mid \mathbf{x})$ が複数のピークを持つ場合、単峰性のガウス分布ではその構造を十分に表現できない。

**ネットワークを深くするだけでは、変分分布の表現力は十分に拡張されない。**

# ELBO の分解

データ分布 $p_{\mathrm{data}}(\mathbf{x})$ に関する ELBO の期待値を考える。

$$
\begin{aligned}
&\mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}[\mathcal{L}_{\mathrm{ELBO}}(\mathbf{x})] \\
&= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})q_\theta(\mathbf{z}|\mathbf{x})}[\log p_\phi(\mathbf{x} \mid \mathbf{z})] \\
&\quad - \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})}\left[D_{\mathrm{KL}}\left(q_\theta(\mathbf{z} \mid \mathbf{x}) \| p(\mathbf{z})\right)\right] \\
&= \mathbb{E}_{p_{\mathrm{data}}(\mathbf{x})q_\theta(\mathbf{z}|\mathbf{x})}[\log p_\phi(\mathbf{x} \mid \mathbf{z})] \\
&\quad - I_q(\mathbf{x}; \mathbf{z}) - D_{\mathrm{KL}}\left(q_\theta(\mathbf{z}) \| p(\mathbf{z})\right).
\end{aligned}
$$

- 第 1 項：データの再構成に関する項
- 第 2・第 3 項：相互情報量と分布間の KL ダイバージェンス

# 相互情報量と潜在変数

まず、データ全体にわたる潜在変数の分布を次のように定義する。

$$q_\theta(\mathbf{z}) = \int p_{\text{data}}(\mathbf{x}) q_\theta(\mathbf{z} \mid \mathbf{x})\, d\mathbf{x}$$

このとき、相互情報量は次のように表される。

$$I_q(\mathbf{x}; \mathbf{z}) = \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[ D_{\text{KL}} \left( q_\theta(\mathbf{z} \mid \mathbf{x}) \| q_\theta(\mathbf{z}) \right) \right]$$

- $q_\theta(\mathbf{z})$：データ全体にわたって得られる潜在変数の分布
- $I_q(\mathbf{x}; \mathbf{z})$：データ $\mathbf{x}$ と潜在変数 $\mathbf{z}$ の依存関係を表す量

**相互情報量が 0 なら、$\mathbf{x}$ と $\mathbf{z}$ は独立である。**

# Posterior Collapseが生じる仕組み（1）

デコーダが潜在変数 $\mathbf{z}$ を使わずにデータ分布をモデル化できる場合を考える。

$$p_\phi(\mathbf{x} \mid \mathbf{z}) = r(\mathbf{x}) \approx p_{\text{data}}(\mathbf{x})$$

このとき、ELBO の再構成項は

$$\begin{aligned} &\mathbb{E}_{p_{\text{data}}(\mathbf{x})q_\theta(\mathbf{z}|\mathbf{x})}[\log p_\phi(\mathbf{x} \mid \mathbf{z})] \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})}[\log r(\mathbf{x})] \end{aligned}$$

- $p_\phi(\mathbf{x} \mid \mathbf{z}) = r(\mathbf{x})$ は $\mathbf{z}$ に依存しない。
- そのため、再構成項は $q_\theta(\mathbf{z} \mid \mathbf{x})$、すなわちエンコーダを変えても変化しない。

**この条件下では、再構成項はエンコーダの最適化に影響しない。**

# Posterior Collapseが生じる仕組み（2）

ELBO の分解式における後半 2 項に注目する。

$$I_q(\mathbf{x}; \mathbf{z}) + D_{\mathrm{KL}}\left(q_\theta(\mathbf{z}) \| p(\mathbf{z})\right)$$

それぞれの項は KL ダイバージェンスで表され、対象となる 2 つの分布が一致するとき 0 になる。

$$I_q(\mathbf{x}; \mathbf{z}) = 0 \iff q_\theta(\mathbf{z} \mid \mathbf{x}) = q_\theta(\mathbf{z})$$

$$D_{\mathrm{KL}}\left(q_\theta(\mathbf{z}) \| p(\mathbf{z})\right) = 0 \iff q_\theta(\mathbf{z}) = p(\mathbf{z})$$

したがって、後半 2 項がともに 0 になるとき、

$$\boxed{q_\theta(\mathbf{z} \mid \mathbf{x}) = p(\mathbf{z})}$$

となり、$\mathbf{z}$ は $\mathbf{x}$ に依存しなくなる。

# Posterior Collapseによって生じる問題

$$q_\theta(\mathbf{z} \mid \mathbf{x}) = p(\mathbf{z})$$

このとき、潜在変数 $\mathbf{z}$ はデータ $\mathbf{x}$ に依存しなくなる。

**問題1：潜在表現が情報を持たない**

潜在変数にデータ依存の構造が含まれず、下流タスクに役立つ情報を得られない。

**問題2：生成結果を制御できない**

潜在変数 $\mathbf{z}$ を操作しても生成結果に影響せず、生成を制御できない。

**潜在変数を導入しても、その役割が失われてしまう。**

# What Hierarchy Changes?

前節では、通常の VAE において、エンコーダやデコーダを深くするだけでは解決できない問題を確認した。

- 変分分布の表現力には制約がある。
- デコーダが潜在変数を利用しなくなる Posterior Collapse が生じうる。

そこで、ネットワークの深さだけでなく、**潜在変数そのものを階層的に配置する**ことを考える。

**階層構造を導入すると、何が変わるのか？**

# HVAE の ELBO

HVAE の ELBO は、同時分布と推論モデルの階層的な構造に基づいて、次のように表される。

$$
\begin{aligned}
\mathcal{L}_{\mathrm{ELBO}}(\mathbf{x}) = & \mathbb{E}_{q_\theta(\mathbf{z}_1|\mathbf{x})}[\log p_\phi(\mathbf{x} \mid \mathbf{z}_1)] \\
& - \mathbb{E}_{q_\theta(\mathbf{z}_{1:2}|\mathbf{x})}\left[\log q_\theta(\mathbf{z}_1 \mid \mathbf{x}) - \log p_\phi(\mathbf{z}_1 \mid \mathbf{z}_2)\right] \\
& - \sum_{i=2}^{L-1} \mathbb{E}_{q_\theta(\mathbf{z}_{1:i+1}|\mathbf{x})}\left[\log q_\theta(\mathbf{z}_i \mid \mathbf{z}_{i-1}) - \log p_\phi(\mathbf{z}_i \mid \mathbf{z}_{i+1})\right] \\
& - \mathbb{E}_{q_\theta(\mathbf{z}_{L-1}|\mathbf{x})}\left[D_{\mathrm{KL}}\left(q_\theta(\mathbf{z}_L \mid \mathbf{z}_{L-1}) \| p(\mathbf{z}_L)\right)\right].
\end{aligned}
$$

# What Hierarchy Changes?

## 潜在層間の相互作用

各潜在層は、隣接する潜在層とのみ相互作用する。

- エンコーダ：$q_\theta(\mathbf{z}_i \mid \mathbf{z}_{i-1})$ によって下位から上位へ情報を伝える。
- デコーダ：$p_\phi(\mathbf{z}_{i-1} \mid \mathbf{z}_i)$ によって上位から下位へ情報を伝える。

## ELBO の構造

階層型 VAE の ELBO は、次の 3 種類の項に分解される。

- 再構成項
- 隣接する潜在層間の項
- 最上位の潜在変数に対する事前分布との KL 項

**階層構造は、潜在層間の相互作用と ELBO の分解に反映される。**

# What Will be Ahead?

## 階層型 VAE の学習上の課題

- エンコーダとデコーダを同時に最適化するため、学習が不安定になりうる。
- 下位の潜在層とデコーダだけで十分に再構成できると、上位の潜在変数が十分に活用されないことがある。
- 深い階層にある潜在変数には、勾配情報が間接的かつ弱く伝わりやすい。
- 条件付き分布の表現力が大きすぎると、上位の潜在変数の有用性が損なわれることがある。

# From HVAEs to Diffusion Models

## 階層構造の可能性

階層型 VAE は、複数の潜在層を導入することでモデルの表現力を高める。

## 拡散モデルのアプローチ

- 順方向のノイズ付加過程を固定する。
- 逆方向のノイズ除去過程の学習に集中する。
- これにより、学習の安定性とモデルの柔軟性を高める。

**次節では、階層構造の考え方が拡散モデルでどのように発展するかを見ていく。**