The Principles of Diffusion Models

Chapter 2: Variational Perspective — DDPM (2.2–2.3)

並松宙輝

公立千歳科学技術大学

November 5, 2026

目次

1. 2.2 DDPM：変分的な視点
   - 2.2.1 順方向過程（固定したエンコーダ）
   - 2.2.2 逆方向のノイズ除去過程（学習するデコーダ）
   - 2.2.3 逆向きの遷移核のモデル化
   - 2.2.4 予測と損失の実際的な選び方
   - 2.2.5 DDPM の ELBO
   - 2.2.6 サンプリング
2. 2.3 まとめ
3. 第 2 章を図で振り返る（補足）

2.2 DDPM：変分的な視点

- 2.2.1 順方向過程（固定したエンコーダ）
- 2.2.2 逆方向のノイズ除去過程（学習するデコーダ）
- 2.2.3 逆向きの遷移核のモデル化
- 2.2.4 予測と損失の実際的な選び方
- 2.2.5 DDPM の ELBO
- 2.2.6 サンプリング

2.2 DDPM：エンコーダを固定した階層 VAE

DDPM（Denoising Diffusion Probabilistic Models）は拡散モデルの礎．

Sohl-Dickstein et al. 2015，Ho et al. 2020

- VAE・HVAE と同じ**変分的な枠組み**（ELBO の最大化）で考えられる
- そのうえで，先行モデル（VAE・HVAE）が抱えていた**難しさを解決する工夫**がある（次のスライド）
- 工夫の中心：**エンコーダを固定**し，生成の向きだけを学習する

先行モデル（VAE・HVAE）が抱えていた難しさ

VAE（2.1 節）

1. **出力がぼやける**：最適なデコーダは条件付き平均（2.1.4）
2. **変分族が狭い**：エンコーダはガウス分布 1 つ（2.1.5）
3. **事後崩壊**：$\mathbf{z}$ を無視する解が最適になる（2.1.5）
4. **一度に全部作る**：$\mathbf{z}$ から画像全体を 1 回で生成

HVAE（2.1.5 節の最後）

1. **学習が不安定**：エンコーダとデコーダを同時に最適化
2. **勾配が弱い**：深い層に勾配が届きにくい
3. **容量の釣り合い**：下の層だけで再構成し，上の層が使われない

注意（共通の根っこ）

エンコーダも学習するので，「潜在変数に何を持たせるか」まで最適化に任せることになり，それが不安定さや崩壊を生む．

※ このスライドは補足（2.1 節の内容のまとめ）

VAE・HVAE・DDPM の比較

	VAE	HVAE	DDPM
潜在変数	$\mathbf{z}$（1 層）	$\mathbf{z}_1, \ldots, \mathbf{z}_L$	$\mathbf{x}_1, \ldots, \mathbf{x}_L$（データと同じ次元）
エンコーダ	学習する	学習する	**固定**：ガウスノイズを足す
デコーダ	学習する	学習する	学習する：1 段ずつノイズ除去
目的関数	ELBO	ELBO	ELBO（各段の回帰に分かれる）
主な難点	ぼやけ，事後崩壊	学習が不安定	生成が遅い（2.2.6 節）

エンコーダを固定すると，学習するのは生成の向きだけになり，HVAE の不安定さが消える．

※ この表は補足（本文の記述をまとめたもの）

DDPM はそれらをどう解決するか（補足）

難しさ	**DDPM での扱い**
エンコーダとの同時学習による不安定さ	エンコーダを**固定**し，学習するのはデコーダだけ
上の層が使われない・事後崩壊	各層 $\mathbf{x}_i$ の中身は「ノイズの量」で最初から決まっていて，無視しようがない
一度に全部作る難しさ	1 ステップは「少しノイズを除く」だけの易しい問題
目標が複雑で学習しにくい	各ステップの目標が閉じた形のガウス分布になり，単純な回帰問題になる（2.2.3）

残る・新しく生まれる難しさ

- **ぼやけ**：最適なノイズ除去器も条件付き平均 $\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$ を出すので，1 回の予測はぼやける． DDPM はノイズを戻して予測し直すことを何度も繰り返し，平均から具体的なサンプルへ近づける（2.2.6）
- **生成が遅い**：ステップを何百〜千回も逐次的に繰り返す必要がある（2.2.6 $\rightarrow$ 第 4 章以降の話題）

DDPM の 2 つの過程（図 2.3）

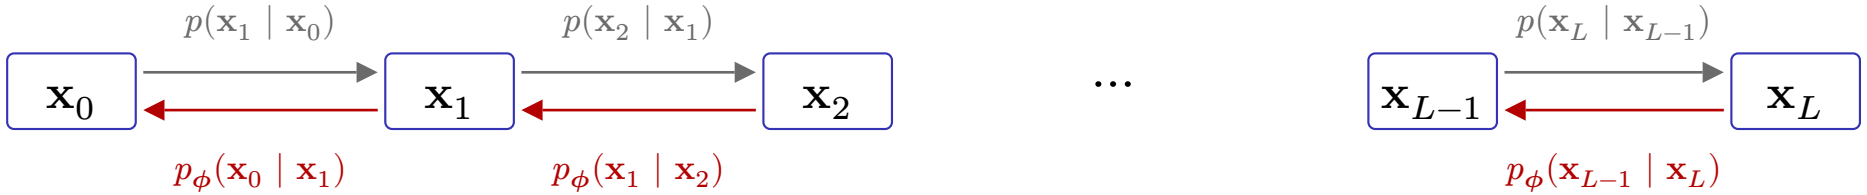


図 2.3：DDPM の図解．灰：データに少しずつガウスノイズを加える固定した順方向過程，
赤：1 ステップずつノイズを除いて新しいサンプルを作る学習する逆方向過程

- **順方向（固定したエンコーダ）**：遷移核 $p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$ でガウスノイズを少しずつ加え，データを等方的なガウス分布（純粋なノイズ）に変える．**学習しない**
- **逆方向のノイズ除去（学習するデコーダ）**：$p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ をネットワークで学習し，ノイズから少しずつノイズを除いてサンプルを作る． 1 ステップのノイズ除去は，VAE のようにサンプル全体を一から作るよりずっと易しい

この節では DDPM に焦点を当てる．より広い議論は **4.5 節**に回し，そこでより一般的で柔軟な枠組みを示す．

図は Lai et al. の図 2.3 をもとに作成

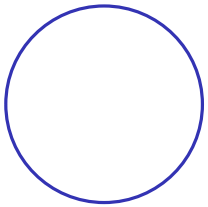
等方的なガウス分布とは（補足）

定義（等方的なガウス分布）

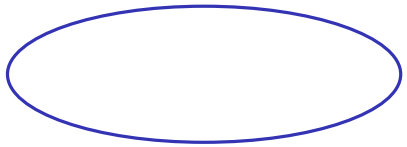
共分散行列が単位行列の定数倍 $\sigma^2\mathbf{I}$ のガウス分布 $\mathcal{N}(\boldsymbol{\mu}, \sigma^2\mathbf{I})$．すなわち

1. どの成分も分散が同じ（$\mathrm{Var}[x_1] = \cdots = \mathrm{Var}[x_D] = \sigma^2$）
2. 成分どうしに相関がない（共分散行列の対角以外が 0）

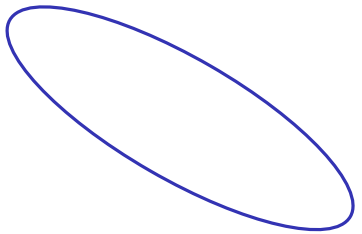
どの方向にも同じだけ広がっている：等高線は円（多次元なら球面）で，回転しても分布が変わらない．



$\sigma^2\mathbf{I}$：円
等方的 ○



$\mathrm{diag}(\sigma_1^2, \sigma_2^2)$：軸方向の楕円
等方的でない ×



一般の Σ：傾いた楕円
等方的でない ×

※ 等方的かどうかは広がり方（共分散）の話で，中心の位置（平均）とは関係ない．$\mathcal{N}((5,5), \mathbf{I})$ も等方的

DDPM で等方的であることの意味（補足）

事前分布 $p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ は，中心が原点で，しかも等方的．

- **データの情報が何も残っていない**：どの画素も同じ強さのノイズで，画素どうしの関係もない．猫の形のような「方向の偏り」が完全に消えた状態
- **サンプルが簡単に作れる**：各成分を独立に $\mathcal{N}(0, 1)$ から引くだけ
- **順方向で足すノイズも等方的**：遷移核の共分散 $\beta_i^2 \mathbf{I}$ も等方的．すべての画素に同じ強さのノイズを均一に足す

$\rightarrow$ データの分布がどんな形でも，最後は形のない球 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ に近づく．

エンコーダを固定し，生成の道筋の学習に集中する

固定するもの：エンコーダ（順方向）

$p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$ は「縮めてノイズを足す」決まった操作．パラメータをもたず，**学習しない**

学習するもの：デコーダ（逆方向）

$p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$．純粋なノイズ $\mathbf{x}_L$ から $\mathbf{x}_0$ へ，**少しずつノイズを除く道筋**だけを学習する

本文：エンコーダを固定し，段階的な生成の道筋に学習を集中させることで，DDPM は高い**安定性**と**表現力**を得る．

- **安定性**：最適化するのはデコーダだけ．各層 $\mathbf{x}_i$ の意味（どれだけノイズが乗っているか）は最初から決まっていて，学習中に動かない． VAE・HVAE のような「エンコーダとデコーダの綱引き」や事後崩壊が起きない
- **表現力**：1 ステップの逆向きは単純（ガウス）でも，それを何百回もつなげると複雑なデータの分布を表せる

2.2 DDPM：変分的な視点

- **2.2.1 順方向過程（固定したエンコーダ）**
- 2.2.2 逆方向のノイズ除去過程（学習するデコーダ）
- 2.2.3 逆向きの遷移核のモデル化
- 2.2.4 予測と損失の実際的な選び方
- 2.2.5 DDPM の ELBO
- 2.2.6 サンプリング

2.2.1 の流れ：どの順で何を決めるか（補足）

DDPM ではエンコーダ（データ $\to$ ノイズ）を学習せず**固定**する．2.2.1 ではその壊し方を決め，性質を確かめる．

問 1 1 ステップでどう壊す？	少し縮めてガウスノイズを足す $p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) = \mathcal{N}(\alpha_i \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I})$	**遷移核**
問 2 係数 α_i はどう選ぶ？	$\alpha_i = \sqrt{1-\beta_i^2}$． 何ステップ進めても分散が爆発も消滅もしない	**分散保存**
問 3 i ステップ先は？	途中を飛ばして一度に書ける $p_i(\mathbf{x}_i \mid \mathbf{x}_0) = \mathcal{N}(\bar{\alpha}_i \mathbf{x}_0, (1-\bar{\alpha}_i^2)\mathbf{I})$	**(2.2.1)**
問 4 最後はどうなる？	$\bar{\alpha}_L \to 0$ で，データによらない 標準ガウス $p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ になる	**事前分布**
問 5 ここで学ぶものは？	何もない（エンコーダは固定）． 学習するのは逆向きのデコーダだけ	**$\to$ 2.2.2**

$\to$ ゴール：データ $\to$ ノイズの道筋を固定し，どの時刻の $\mathbf{x}_i$ も閉じた形で作れるようにする

2.2.1 順方向過程（固定したエンコーダ）：概要

DDPM の順方向過程は，**学習しない固定の操作**で，**エンコーダ**の役割を果たす．

- 元のデータに何ステップもかけてノイズを加え，少しずつ壊していく
- 最終的に，単純な事前分布 $p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$ に変える

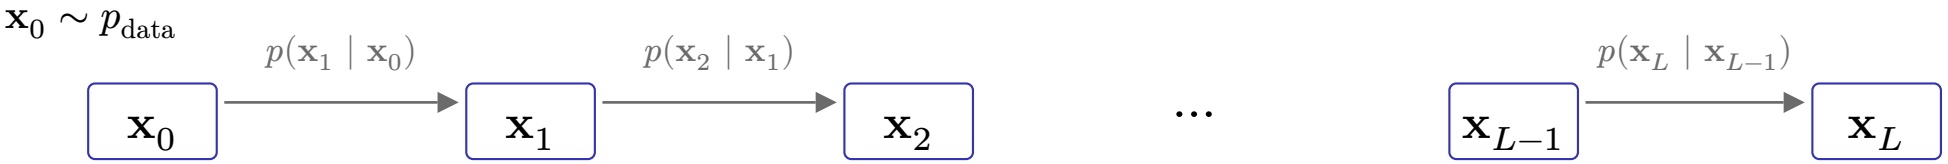


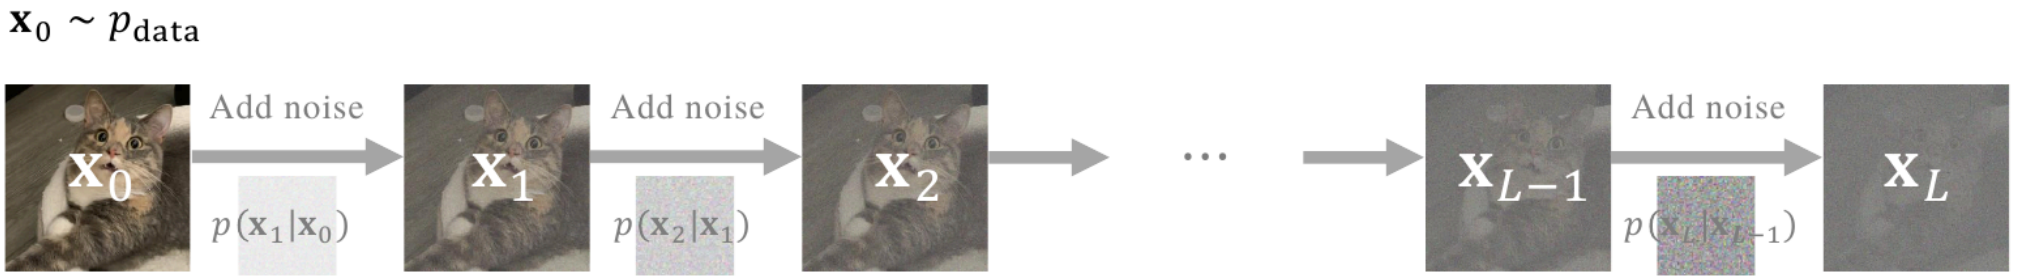
図 2.4：ガウスノイズを少しずつ加えて，データのサンプルを純粋なノイズに壊していく（各矢印が「ノイズを足す」）

意図：VAE と比べると

- **エンコーダ**と呼ぶのは，データ $\mathbf{x}_0$ を潜在変数 $\mathbf{x}_1, \ldots, \mathbf{x}_L$ に写すから（$\mathbf{x}_L$ が VAE の $\mathbf{z}$ に当たる）
- ただし $q_{\boldsymbol{\theta}}$ のような学習するネットワークはなく，壊し方は最初から決めておく．だから学習するのは逆向き（デコーダ）だけ
- 行き先が $\mathcal{N}(\mathbf{0}, \mathbf{I})$ なので，生成は「$\mathcal{N}(\mathbf{0}, \mathbf{I})$ から引いて逆向きにたどる」だけでよい

この 1 ステップずつの劣化を定式化する（次のスライド）．

図 2.4：順方向過程で画像が壊れていく様子



出典：C. Lai et al., *The Principles of Diffusion Models* (arXiv:2510.21890) の図 2.4 を引用

- **左端 $\mathbf{x}_0 \sim p_{\text{data}}$**： 本物のデータ（猫の写真）．順方向過程の出発点
- **矢印「Add noise」**： 1 ステップぶんの遷移核 $p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$．前の画像を α_i 倍に縮め，ノイズ $\beta_i\varepsilon_i$ を足す
- **矢印の下の小さな四角**： そのステップで足すノイズ $\beta_i\varepsilon_i$．右に行くほど色が濃い＝ノイズスケジュール β_i が**増加列**で，後のステップほど強いノイズを足す
- **画像が灰色に沈んでいく**： 信号が $\bar{\alpha}_i$ 倍に縮んで 0（画素値を正規化した空間では灰色）に近づき，ノイズの割合 $\sqrt{1-\bar{\alpha}_i^2}$ が増える
- **右端 $\mathbf{x}_L$**： 猫の面影がほぼ消えた純粋なノイズで，分布は $p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ に近い

逆向き（右→左）にこの鎖をたどれれば，ノイズから猫の写真を作れる．それを学習するのが 2.2.2 以降．

順方向過程の定式化：固定したガウスの遷移



定義（順方向の遷移核）

$\mathbf{x}_0 \sim p_{\text{data}}$ から出発し，各ステップを固定したガウス分布で進める．

$$p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) := \mathcal{N}\left(\mathbf{x}_i; \sqrt{1-\beta_i^2}\,\mathbf{x}_{i-1}, \beta_i^2 \mathbf{I}\right), \quad \alpha_i := \sqrt{1-\beta_i^2}$$

$\{\beta_i\}_{i=1}^L$ は単調増加のノイズスケジュールで $\beta_i \in (0,1)$．これは次の更新と同じ．

$$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i, \quad \boldsymbol{\varepsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})\ \text{（ステップごとに独立）}$$

各ステップで前の状態を α_i 倍に縮め，大きさ β_i のガウスノイズを足す．

※ 本書の β_i はノイズの標準偏差．元の DDPM 論文の β_i（分散）は本書の β_i^2 に当たる

独立同分布（i.i.d.）とは（補足）

定義（独立同分布，independent and identically distributed）

確率変数の列 $\varepsilon_1, \varepsilon_2, ..., \varepsilon_L$ が次の 2 つを満たすこと．

1. **独立**：どの ε_i の値も，ほかの ε_j の値に影響しない．同時分布が積に分かれる：$p(\varepsilon_1, ..., \varepsilon_L) = \prod_i p(\varepsilon_i)$
2. **同分布**：どれも同じ分布に従う．ここではすべて $\mathcal{N}(\mathbf{0}, \mathbf{I})$

たとえ：同じサイコロを何回も振る．毎回の目は前の目に関係なく（独立），どの回も同じ確率で目が出る（同分布）．

i.i.d. でない例

- 前のノイズを少し引きずる $\varepsilon_i = 0.9\varepsilon_{i-1} + \cdots$（独立でない）
- ステップごとに分散が違う $\varepsilon_i \sim \mathcal{N}(\mathbf{0}, i\mathbf{I})$（同分布でない）

DDPM での注意

- ノイズの**大きさ**は β_i でステップごとに変える
- ε_i 自体はすべて $\mathcal{N}(\mathbf{0}, \mathbf{I})$ で同じ分布．「強さの違い」は係数 β_i に押し込めてある

DDPM でなぜ i.i.d. が必要か（補足）

更新式 $\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i$ で，$\boldsymbol{\varepsilon}_i$ が i.i.d. であることが次を保証する．

- **マルコフ性**：$\boldsymbol{\varepsilon}_i$ は過去の $\boldsymbol{\varepsilon}_1, \ldots, \boldsymbol{\varepsilon}_{i-1}$（したがって $\mathbf{x}_0, \ldots, \mathbf{x}_{i-1}$）と独立． だから次の状態は今の状態 $\mathbf{x}_{i-1}$ だけで決まり，遷移核 $p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$ が書ける
- **遷移核が毎回同じ形**：同分布なので，どのステップも「$\mathcal{N}(\mathbf{0}, \mathbf{I})$ を β_i 倍して足す」という同じ形の操作になる
- **分散が足し算になる**：独立なノイズの和の分散は分散の和． これが摂動核の分散 $1 - \bar{\alpha}_i^2$ を求める計算（次の数枚）と，分散保存の証明の「交差項は 0」の根拠

もしノイズどうしに相関があると，分散の計算に交差項が残り，摂動核が閉じた形で書けなくなる．

遷移核と更新式は同じもの

命題（※ 補足）

$\varepsilon_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ が $\mathbf{x}_{i-1}$ と独立のとき

$$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \varepsilon_i \quad \Longleftrightarrow \quad p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) = \mathcal{N}\left(\mathbf{x}_i; \alpha_i \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I}\right)$$

- **左**：サンプルの作り方（縮めてノイズを足す）
- **右**：その結果の分布（遷移核）

2 通りで確かめる：(1) 密度を直接計算する，(2) 平均と共分散を計算する．

証明（1）：密度を直接計算する

証明

$\mathbf{x}_{i-1} = \mathbf{x}$ を固定すると $\mathbf{y} = \alpha_i \mathbf{x} + \beta_i \boldsymbol{\varepsilon}_i$．逆に解くと $\boldsymbol{\varepsilon}_i = (\mathbf{y} - \alpha_i \mathbf{x})/\beta_i$．

$$p(\mathbf{y} \mid \mathbf{x}) = p_{\boldsymbol{\varepsilon}}\left(\frac{\mathbf{y} - \alpha_i \mathbf{x}}{\beta_i}\right) \cdot \beta_i^{-D}$$

変数変換公式．ヤコビ行列 $(1/\beta_i)\mathbf{I}$ の行列式は β_i^{-D}

$$= (2\pi)^{-D/2} \exp\left(-\frac{1}{2}\left\|\frac{\mathbf{y} - \alpha_i \mathbf{x}}{\beta_i}\right\|^2\right) \cdot \beta_i^{-D}$$

標準ガウスの密度を代入

$$= \left(2\pi\beta_i^2\right)^{-D/2} \exp\left(-\frac{\|\mathbf{y} - \alpha_i \mathbf{x}\|^2}{2\beta_i^2}\right)$$

β_i をまとめる

$$= \mathcal{N}(\mathbf{y}; \alpha_i \mathbf{x}, \beta_i^2 \mathbf{I})$$

ガウスの密度の定義

逆向き（遷移核 ⇒ 更新式）は，同じ変数変換を逆にたどればよい． ■

証明（2）：条件付きの平均を計算する

ガウス分布は平均と共分散で決まる．まず平均．

証明

$$\begin{aligned}\mathbb{E}[\mathbf{x}_i \mid \mathbf{x}_{i-1}] &= \mathbb{E}[\alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i \mid \mathbf{x}_{i-1}] \\ &= \alpha_i \mathbf{x}_{i-1} + \beta_i \mathbb{E}[\boldsymbol{\varepsilon}_i \mid \mathbf{x}_{i-1}] \\ &= \alpha_i \mathbf{x}_{i-1} + \beta_i \mathbb{E}[\boldsymbol{\varepsilon}_i] \\ &= \alpha_i \mathbf{x}_{i-1}\end{aligned}$$

更新式を代入

条件の $\mathbf{x}_{i-1}$ は定数として外へ（線形性）

$\boldsymbol{\varepsilon}_i$ は $\mathbf{x}_{i-1}$ と独立

$\mathbb{E}[\boldsymbol{\varepsilon}_i] = \mathbf{0}$

平均は「前の状態を α_i 倍に縮めたもの」．

証明（2）：条件付きの共分散を計算する

証明（続き）

$$\begin{aligned}\mathrm{Cov}[\mathbf{x}_i \mid \mathbf{x}_{i-1}] &= \mathrm{Cov}[\alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i \mid \mathbf{x}_{i-1}] \\ &= \mathrm{Cov}[\beta_i \boldsymbol{\varepsilon}_i] \\ &= \beta_i^2 \ \mathrm{Cov}[\boldsymbol{\varepsilon}_i] \\ &= \beta_i^2 \mathbf{I}\end{aligned}$$

更新式を代入

定数 $\alpha_i \mathbf{x}_{i-1}$ を足しても共分散は変わらない．独立性

$\mathrm{Cov}[c\,\mathbf{v}] = c^2\ \mathrm{Cov}[\mathbf{v}]$

$\boldsymbol{\varepsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

ガウスのアフィン変換はガウスなので $p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) = \mathcal{N}\left(\alpha_i \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I}\right)$.

1 次元の例：$\beta_i = 0.6$ なら $\alpha_i = 0.8$．$x_{i-1} = 2$ のとき $x_i \sim \mathcal{N}\left(1.6, 0.6^2\right)$. ■

アフィン変換とは（補足）

定義（アフィン変換）

線形変換に平行移動を足したもの：$f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$（$A$ は行列，$\mathbf{b}$ は定数ベクトル）

	式	原点	例（1 次元）
線形変換	$A\mathbf{x}$	原点は原点へ（$f(\mathbf{0}) = \mathbf{0}$）	$f(x) = 3x$
アフィン変換	$A\mathbf{x} + \mathbf{b}$	原点が $\mathbf{b}$ にずれる	$f(x) = 3x + 2$

- $\mathbf{b} \neq \mathbf{0}$ なら線形ではない：$f(x) = 3x + 2$ では $f(0) = 2 \neq 0$
- 線形変換は $\mathbf{b} = \mathbf{0}$ の特別な場合（アフィン変換のほうが広い）
- 図形的には，直線を直線に，平行線を平行線に移す（原点は保たない）

機械学習の「線形層」$W\mathbf{x} + \mathbf{b}$ も厳密にはアフィン変換

ガウス分布はアフィン変換で閉じている（補足）

命題（ガウスのアフィン変換）

$$\varepsilon \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma) \quad \Longrightarrow \quad A\varepsilon + \mathbf{b} \sim \mathcal{N}\big(A\boldsymbol{\mu} + \mathbf{b},\, A\Sigma A^{\top}\big)$$

平均は同じ変換で動き，共分散は A で両側から挟まれる．

証明（2）での使い方：$\mathbf{x}_{i-1}$ を固定すると，更新式は ε_i のアフィン変換

$$\mathbf{x}_i = \underbrace{\beta_i \mathbf{I}}_{A} \varepsilon_i + \underbrace{\alpha_i \mathbf{x}_{i-1}}_{\mathbf{b}}$$

$\varepsilon_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ を代入すると

$$\mathbf{x}_i \sim \mathcal{N}(\beta_i \cdot \mathbf{0} + \alpha_i \mathbf{x}_{i-1},\, \beta_i \mathbf{I} \cdot \mathbf{I} \cdot \beta_i \mathbf{I}) = \mathcal{N}\big(\alpha_i \mathbf{x}_{i-1},\, \beta_i^2 \mathbf{I}\big)$$

となり，遷移核が出てくる（証明（1）の密度の計算は，この性質を $A = \beta_i \mathbf{I}$ の場合に直接確かめたもの）．

なぜ $\alpha_i = \sqrt{1-\beta_i^2}$ と選ぶのか：分散を保つ

本文は「便宜上 $\alpha_i := \sqrt{1-\beta_i^2}$ とおく」とだけ書くが，この選び方には理由がある．

命題（分散の保存（※ 補足））

$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i$，$\boldsymbol{\varepsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ は $\mathbf{x}_{i-1}$ と独立，$\alpha_i^2 + \beta_i^2 = 1$ のとき

$$\mathbb{E}[\mathbf{x}_i] = \alpha_i \mathbb{E}[\mathbf{x}_{i-1}], \quad \mathrm{Cov}[\mathbf{x}_i] - \mathbf{I} = \alpha_i^2 (\mathrm{Cov}[\mathbf{x}_{i-1}] - \mathbf{I})$$

特に $\mathrm{Cov}[\mathbf{x}_{i-1}] = \mathbf{I}$ なら $\mathrm{Cov}[\mathbf{x}_i] = \mathbf{I}$.

証明は平均 $\rightarrow$ 共分散の順に計算する（次の 3 枚）．

分散の保存の証明（1）：平均

証明

$$\mathbb{E}[\mathbf{x}_i] = \mathbb{E}[\alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i]$$

更新式を代入

$$= \alpha_i \mathbb{E}[\mathbf{x}_{i-1}] + \beta_i \mathbb{E}[\boldsymbol{\varepsilon}_i]$$

期待値の線形性（定数 α_i，β_i は外へ）

$$= \alpha_i \mathbb{E}[\mathbf{x}_{i-1}]$$

$\mathbb{E}[\boldsymbol{\varepsilon}_i] = \mathbf{0}$

以下，$\mathbf{m} := \mathbb{E}[\mathbf{x}_{i-1}]$ とおき，中心からのずれを $\mathbf{u} := \mathbf{x}_{i-1} - \mathbf{m}$ と書く（$\mathbb{E}[\mathbf{u}] = \mathbf{0}$）.

$$\mathbf{x}_i - \mathbb{E}[\mathbf{x}_i] = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i - \alpha_i \mathbf{m}$$

上の結果を引く

$$= \alpha_i \mathbf{u} + \beta_i \boldsymbol{\varepsilon}_i$$

α_i でくくる

分散の保存の証明（2）：共分散を展開する

証明（続き）

$$\begin{aligned}
\mathrm{Cov}[\mathbf{x}_i] &= \mathbb{E}\Big[(\mathbf{x}_i - \mathbb{E}[\mathbf{x}_i])(\mathbf{x}_i - \mathbb{E}[\mathbf{x}_i])^\top\Big] && \text{共分散の定義} \\
&= \mathbb{E}\Big[(\alpha_i \mathbf{u} + \beta_i \boldsymbol{\varepsilon}_i)(\alpha_i \mathbf{u} + \beta_i \boldsymbol{\varepsilon}_i)^\top\Big] && \text{前のスライドの結果} \\
&= \alpha_i^2 \mathbb{E}[\mathbf{u}\mathbf{u}^\top] + \alpha_i\beta_i \mathbb{E}[\mathbf{u}\boldsymbol{\varepsilon}_i^\top] && \text{積を展開し，期待値の線形性で 4 つに分ける} \\
&\quad + \alpha_i\beta_i \mathbb{E}[\boldsymbol{\varepsilon}_i \mathbf{u}^\top] + \beta_i^2 \mathbb{E}[\boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}_i^\top]
\end{aligned}$$

真ん中の 2 つ（交差項）と，両端の 2 つを順に計算する．

分散の保存の証明（3）：交差項が消えて整理する

証明（続き）

$$\mathbb{E}[\mathbf{u}\boldsymbol{\varepsilon}_i^\top] = \mathbb{E}[\mathbf{u}]\,\mathbb{E}[\boldsymbol{\varepsilon}_i]^\top = \mathbf{0}$$

独立なら積の期待値は期待値の積．

$$\mathbb{E}[\mathbf{u}\mathbf{u}^\top] = \mathrm{Cov}[\mathbf{x}_{i-1}], \quad \mathbb{E}[\boldsymbol{\varepsilon}_i\boldsymbol{\varepsilon}_i^\top] = \mathbf{I}$$

$\mathbb{E}[\boldsymbol{\varepsilon}_i] = \mathbf{0}$（転置も同様）

共分散の定義（どちらも平均 0）

$$\mathrm{Cov}[\mathbf{x}_i] = \alpha_i^2\ \mathrm{Cov}[\mathbf{x}_{i-1}] + \beta_i^2\mathbf{I}$$

$$= \alpha_i^2\ \mathrm{Cov}[\mathbf{x}_{i-1}] + (1-\alpha_i^2)\mathbf{I}$$

前のスライドの展開に代入

$\beta_i^2 = 1 - \alpha_i^2$

$$\mathrm{Cov}[\mathbf{x}_i] - \mathbf{I} = \alpha_i^2\ \mathrm{Cov}[\mathbf{x}_{i-1}] - \alpha_i^2\mathbf{I}$$

$$= \alpha_i^2(\mathrm{Cov}[\mathbf{x}_{i-1}] - \mathbf{I})$$

両辺から $\mathbf{I}$ を引く

α_i^2 でくくる

■

分散保存の意図

縮める量 α_i と足すノイズ β_i を

$$\alpha_i^2 + \beta_i^2 = 1$$

で釣り合わせると：

- 分散が爆発も消滅もしない（**分散保存**，variance preserving）
- 平均は毎ステップ $\alpha_i < 1$ 倍に縮んで $\mathbf{0}$ へ
- 共分散と $\mathbf{I}$ のずれも α_i^2 倍ずつ縮む

$\rightarrow$ 最後は $\mathcal{N}(\mathbf{0}, \mathbf{I})$ に近づく．

※ 元の DDPM 論文の $\mathcal{N}\left(\sqrt{1-\beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}\right)$ も，$\beta_t \leftrightarrow \beta_i^2$ と読み替えれば同じ（本文の脚注 2）

遷移核とは（補足）

定義（遷移核）

マルコフ連鎖で「今の状態から次の状態へどう移るか」を表す条件付き分布 $p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$． 1 つ前が $\mathbf{x}_{i-1}$ だったとき，次の $\mathbf{x}_i$ がどこに来やすいかを表す．

離散なら遷移行列：天気 {晴，雨} の例

今日＼明日	晴	雨
晴	0.8	0.2
雨	0.4	0.6

各行が「今日がこの天気なら明日はどうなるか」の分布． 状態が $\mathbb{R}^D$ のような連続の空間なら，行列の代わりに条件付き密度を使う．

DDPM の遷移核：1 ステップぶんの壊し方のルール

$$p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) = \mathcal{N}(\mathbf{x}_i; \alpha_i \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I})$$

「前の状態を α_i 倍に縮め，大きさ β_i のノイズを足す」．$i = 1, ..., L$ と繰り返すと順方向過程の全体．

「核」と呼ぶ理由：分布に掛けて積分すると次の分布が得られる（行列×ベクトルの連続版，積分作用素の核）

$$p_i(\mathbf{x}_i) = \int p(\mathbf{x}_i \mid \mathbf{x}_{i-1})\, p_{i-1}(\mathbf{x}_{i-1})\, \mathrm{d}\mathbf{x}_{i-1}$$

積分作用素：行列×ベクトルの連続版（補足）

定義（積分作用素）

2 変数関数 $K(y,x)$（**核**）を使って，関数 f を新しい関数 Kf に移す写像

$$(Kf)(y) := \int K(y,x)\, f(x)\, \mathrm{d}x$$

行列との対応：添字を連続変数に，和を積分に置き換えたもの

離散	**連続**
ベクトル f_i	関数 $f(x)$
行列 K_{ji}	核 $K(y,x)$
$\sum_i K_{ji} f_i$	$\int K(y,x) f(x)\, \mathrm{d}x$

行列と同じく**線形**：$K(af+bg) = aKf + bKg$.

身近な例

- **畳み込み**：$K(y,x) = g(y-x)$．画像のぼかし（ガウスフィルタ）
- **フーリエ変換**：$K(\omega, x) = e^{-i\omega x}$
- **条件付き期待値**：$K(y,x) = p(x \mid y)$ なら $(Kf)(y) = \mathbb{E}[f(X) \mid Y = y]$
- **遷移核**：$K(\mathbf{x}_i, \mathbf{x}_{i-1}) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$（次のスライド）

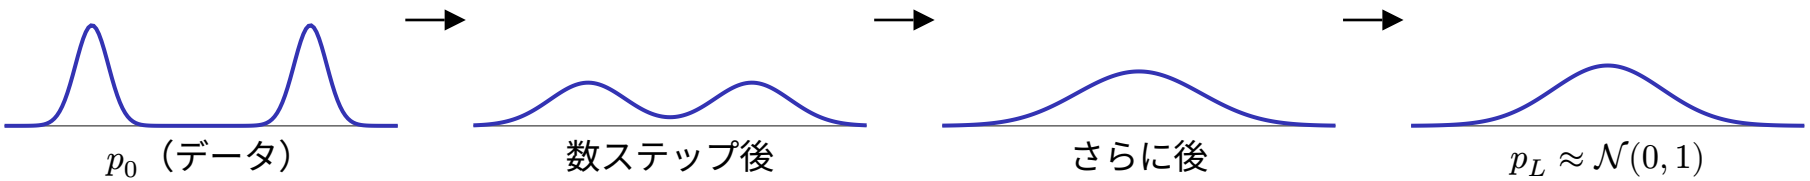
遷移核の作用：分布を 1 ステップ先へ進める（補足）

遷移核を核とする積分作用素は，今の分布を次の分布に移す（遷移行列×確率ベクトルと同じ）．

$$p_i(\mathbf{x}_i) = \int p(\mathbf{x}_i \mid \mathbf{x}_{i-1})\, p_{i-1}(\mathbf{x}_{i-1})\, \mathrm{d}\mathbf{x}_{i-1}$$

$\int p(\mathbf{x}_i \mid \mathbf{x}_{i-1})\, \mathrm{d}\mathbf{x}_i = 1$ なので，出てくるのもまた確率分布（総和 1 が保たれる）．

DDPM では「縮めてからガウスでぼかす」：遷移核がガウス分布なので，この作用は 「α_i 倍に縮める」＋「ガウスとの畳み込み（ぼかし）」．L 回かけるとデータの分布の形が消え，$\mathcal{N}(\mathbf{0}, \mathbf{I})$ になる．



図：山が 2 つのデータの分布（1 次元）に遷移核を繰り返しかけた様子．山が中央に寄りながらぼやけて 1 つになる

Perturbation Kernel and Prior Distribution

遷移核を繰り返し適用すると，元のデータ $\mathbf{x}_0$ が与えられたときのステップ i のノイズ付きサンプルの分布が，閉じた形で得られる．

$$p_i(\mathbf{x}_i \mid \mathbf{x}_0) = \mathcal{N}\big(\mathbf{x}_i; \bar{\alpha}_i \mathbf{x}_0, (1 - \bar{\alpha}_i^2)\mathbf{I}\big)$$

ここで

$$\bar{\alpha}_i := \prod_{k=1}^{i} \sqrt{1 - \beta_k^2} = \prod_{k=1}^{i} \alpha_k$$

である．これは，$\mathbf{x}_i$ を $\mathbf{x}_0$ から直接サンプルできることを意味する．

- **摂動核**（perturbation kernel）$p_i(\mathbf{x}_i \mid \mathbf{x}_0)$：きれいなデータから i ステップぶんまとめた壊し方
- **事前分布**（prior distribution）：$L \to \infty$ で摂動核は $\mathcal{N}(\mathbf{0}, \mathbf{I})$ に近づき，データによらない出発点になる

遷移核・摂動核・逆向きの遷移核の区別（補足）

名前	式	何を表すか
遷移核	$p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$	**1 ステップ**の移り方（順方向の定義）
摂動核	$p_i(\mathbf{x}_i \mid \mathbf{x}_0)$	きれいなデータから i **ステップぶん**まとめた移り方（式 (2.2.1)）
逆向きの遷移核	$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$	逆向きの 1 ステップ．未知なので p_ϕ で学習する（2.2.2）

- 摂動核は遷移核を i 回つなげたもの．ガウス分布どうしなので閉じた形になり，途中を飛ばして $\mathbf{x}_i$ を直接作れる（前のスライド）
- 順方向の遷移核は自分で決めたもの（既知）だが，逆向きの遷移核は周辺分布を含み計算できない（2.2.2）

摂動核はエンコーダの一部（補足）

名前	式	エンコーダとの関係
エンコーダ（順方向全体）	$p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = \prod_{i=1}^{L} p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$	エンコーダそのもの（鎖全体を作る）
遷移核	$p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$	エンコーダの **1 ステップぶん**の部品
摂動核	$p_i(\mathbf{x}_i \mid \mathbf{x}_0)$	エンコーダの i **ステップ目の周辺分布**

摂動核は，エンコーダの同時分布から途中の層を積分して消したもの：

$$p_i(\mathbf{x}_i \mid \mathbf{x}_0) = \int p(\mathbf{x}_{1:i} \mid \mathbf{x}_0)\, \mathrm{d}\mathbf{x}_{1:i-1}$$

エンコーダを「$\mathbf{x}_0$ から $\mathbf{x}_i$ へ一気に」見たもので，エンコーダと別物ではない．

HVAE との対応：遷移核 ↔ $q_{\boldsymbol{\theta}}(\mathbf{z}_i \mid \mathbf{z}_{i-1})$，摂動核 ↔ $q(\mathbf{z}_i \mid \mathbf{x})$． HVAE ではこれは一般に閉じた形にならない（ガウスの混合）が，DDPM は線形・ガウスなので閉じた形になり，直接サンプルできる．

摂動核と事前分布の役割の違い（補足）

なぜ鎖全体と摂動核を使い分けるのか

- **ELBO**（2.2.5）：エンコーダの鎖全体 $p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)$ を使う
- **実際の学習**（2.2.3）：各時刻 i の項に要るのは $\mathbf{x}_i$ だけ．摂動核で $\mathbf{x}_i$ を直接作れば，鎖を最初からたどらなくてよい

事前分布はエンコーダではない

- $p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ は**生成側（デコーダ）の出発点**．VAE の $p(\mathbf{z})$ に当たる
- エンコーダの行き先 $p_L(\mathbf{x}_L \mid \mathbf{x}_0)$ がほぼ $\mathcal{N}(\mathbf{0}, \mathbf{I})$ になるので，生成の出発点をそれに合わせて選んでいる

途中を飛ばして $\mathbf{x}_i$ を一度に作れる

命題（摂動核，式 (2.2.1)）

$\bar{\alpha}_i := \prod_{k=1}^{i} \alpha_k$ とおくと

$$p_i(\mathbf{x}_i \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_i; \bar{\alpha}_i \mathbf{x}_0, (1-\bar{\alpha}_i^2)\mathbf{I}), \quad \textbf{すなわち} \quad \mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\varepsilon}$$

意図：i 段ぶんの小さなノイズを足し合わせても，結局「信号を $\bar{\alpha}_i$ 倍に縮め，標準偏差 $\sqrt{1-\bar{\alpha}_i^2}$ のノイズを 1 回足す」のと同じ． 学習では途中の $\mathbf{x}_1, \ldots, \mathbf{x}_{i-1}$ を作らずに，好きな時刻の $\mathbf{x}_i$ を直接作れる．

理由：更新を展開すると $\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \big($**独立なガウスノイズの和**$\big)$．独立なガウスの和はガウスで，分散は足し算． $\alpha_k^2 + \beta_k^2 = 1$ なので，信号の 2 乗 $\bar{\alpha}_i^2$ とノイズの分散の和が常に 1 に保たれ，ノイズの分散は $1-\bar{\alpha}_i^2$ になる（i についての帰納法）．

※ 「意図」と「理由」は補足

摂動核の証明（1）：帰納法の主張と $i=1$（補足）

次の主張を i についての帰納法で示す．

命題（主張 $P(i)$）

$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\bar{\boldsymbol{\varepsilon}}_i$ と書ける．ここで $\bar{\boldsymbol{\varepsilon}}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ は $\boldsymbol{\varepsilon}_1, \ldots, \boldsymbol{\varepsilon}_i$ だけで決まり，$\mathbf{x}_0$ とも $\boldsymbol{\varepsilon}_{i+1}, \boldsymbol{\varepsilon}_{i+2}, \ldots$ とも独立．

証明（$i=1$）

$$\begin{aligned}\mathbf{x}_1 &= \alpha_1 \mathbf{x}_0 + \beta_1 \boldsymbol{\varepsilon}_1 \\ &= \bar{\alpha}_1 \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_1^2}\,\boldsymbol{\varepsilon}_1\end{aligned}$$

$\bar{\boldsymbol{\varepsilon}}_1 := \boldsymbol{\varepsilon}_1$ とすれば $P(1)$ が成り立つ（$\boldsymbol{\varepsilon}_k$ は i.i.d.）．

更新式

$\bar{\alpha}_1 = \alpha_1$，$\beta_1 = \sqrt{1-\alpha_1^2} = \sqrt{1-\bar{\alpha}_1^2}$

摂動核の証明（2）：$i-1$ から i へ（補足）

証明（続き）

$P(i-1)$ を仮定し，$s := \sqrt{1-\bar{\alpha}_{i-1}^2}$ と書く．

$$
\begin{aligned}
\mathbf{x}_i &= \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i \\
&= \alpha_i(\bar{\alpha}_{i-1}\mathbf{x}_0 + s\,\bar{\boldsymbol{\varepsilon}}_{i-1}) + \beta_i \boldsymbol{\varepsilon}_i \\
&= \alpha_i \bar{\alpha}_{i-1}\mathbf{x}_0 + (\alpha_i s\,\bar{\boldsymbol{\varepsilon}}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i) \\
&= \bar{\alpha}_i \mathbf{x}_0 + \underbrace{(\alpha_i s\,\bar{\boldsymbol{\varepsilon}}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i)}_{=:\,\mathbf{w}}
\end{aligned}
$$

更新式

帰納法の仮定 $P(i-1)$ を代入

展開して信号とノイズに分ける

$\alpha_i \bar{\alpha}_{i-1} = \bar{\alpha}_i$（$\bar{\alpha}$ の定義）

あとはノイズ部分 $\mathbf{w}$ が $\sqrt{1-\bar{\alpha}_i^2}\,\bar{\boldsymbol{\varepsilon}}_i$，$\bar{\boldsymbol{\varepsilon}}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ と書けることを示せばよい．

摂動核の証明（3）：ノイズ部分をまとめる（補足）

証明（続き）

$\bar{\varepsilon}_{i-1}$ は $\varepsilon_1, ..., \varepsilon_{i-1}$ だけで決まるので ε_i と独立．独立なガウスを並べたものはガウスなので，そのアフィン変換 $\mathbf{w}$ もガウス．

$$\mathbb{E}[\mathbf{w}] = \alpha_i s\, \mathbb{E}[\bar{\varepsilon}_{i-1}] + \beta_i \mathbb{E}[\varepsilon_i] = \mathbf{0}$$

$$\mathrm{Cov}[\mathbf{w}] = \alpha_i^2 s^2 \mathbf{I} + \beta_i^2 \mathbf{I}$$

$$= (\alpha_i^2 - \alpha_i^2 \bar{\alpha}_{i-1}^2 + \beta_i^2)\mathbf{I} = (1 - \bar{\alpha}_i^2)\mathbf{I}$$

線形性，どちらも平均 $\mathbf{0}$
独立なので交差項は 0，分散は足し算
$s^2 = 1 - \bar{\alpha}_{i-1}^2$，$\alpha_i^2 \bar{\alpha}_{i-1}^2 = \bar{\alpha}_i^2$，
$\alpha_i^2 + \beta_i^2 = 1$

よって $\bar{\varepsilon}_i := \mathbf{w}/\sqrt{1 - \bar{\alpha}_i^2} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ で，$\varepsilon_1, ..., \varepsilon_i$ だけで決まる．$P(i)$ が成り立つ． 最後に，$\mathbf{x}_0$ を固定すると $\mathbf{x}_i$ は $\bar{\varepsilon}_i$ のアフィン変換なので $p_i(\mathbf{x}_i \mid \mathbf{x}_0) = \mathcal{N}(\bar{\alpha}_i \mathbf{x}_0, (1 - \bar{\alpha}_i^2)\mathbf{I})$．

■

最後はデータによらない標準ガウス分布になる

ノイズスケジュール $\{\beta_i\}$ が増加列なら，$L \to \infty$ で

$$p_L(\mathbf{x}_L \mid \mathbf{x}_0) \longrightarrow \mathcal{N}(\mathbf{0}, \mathbf{I}) =: p_{\text{prior}}$$

となり，データ $\mathbf{x}_0$ によらない．これが生成の出発点（事前分布）を $\mathcal{N}(\mathbf{0}, \mathbf{I})$ に選べる理由．

理由：各 $\alpha_k \le \sqrt{1-\beta_1^2} < 1$ なので $\bar{\alpha}_L \to 0$．信号 $\bar{\alpha}_L \mathbf{x}_0$ が消え，ノイズの分散 $1 - \bar{\alpha}_L^2$ が 1 に近づく．

※ 「理由」は補足

事前分布への収束の証明（補足）

証明

$\{\beta_k\}$ は増加列で $\beta_k \in (0,1)$ なので，すべての k で $\beta_k \geq \beta_1 > 0$.

$$\alpha_k = \sqrt{1-\beta_k^2} \leq \sqrt{1-\beta_1^2} =: r < 1$$

$\beta_k \geq \beta_1$，$\sqrt{1-t^2}$ は減少関数

$$0 < \bar{\alpha}_L = \prod_{k=1}^{L} \alpha_k \leq r^L$$

各因子が r 以下

$$\bar{\alpha}_L \longrightarrow 0 \quad (L \to \infty)$$

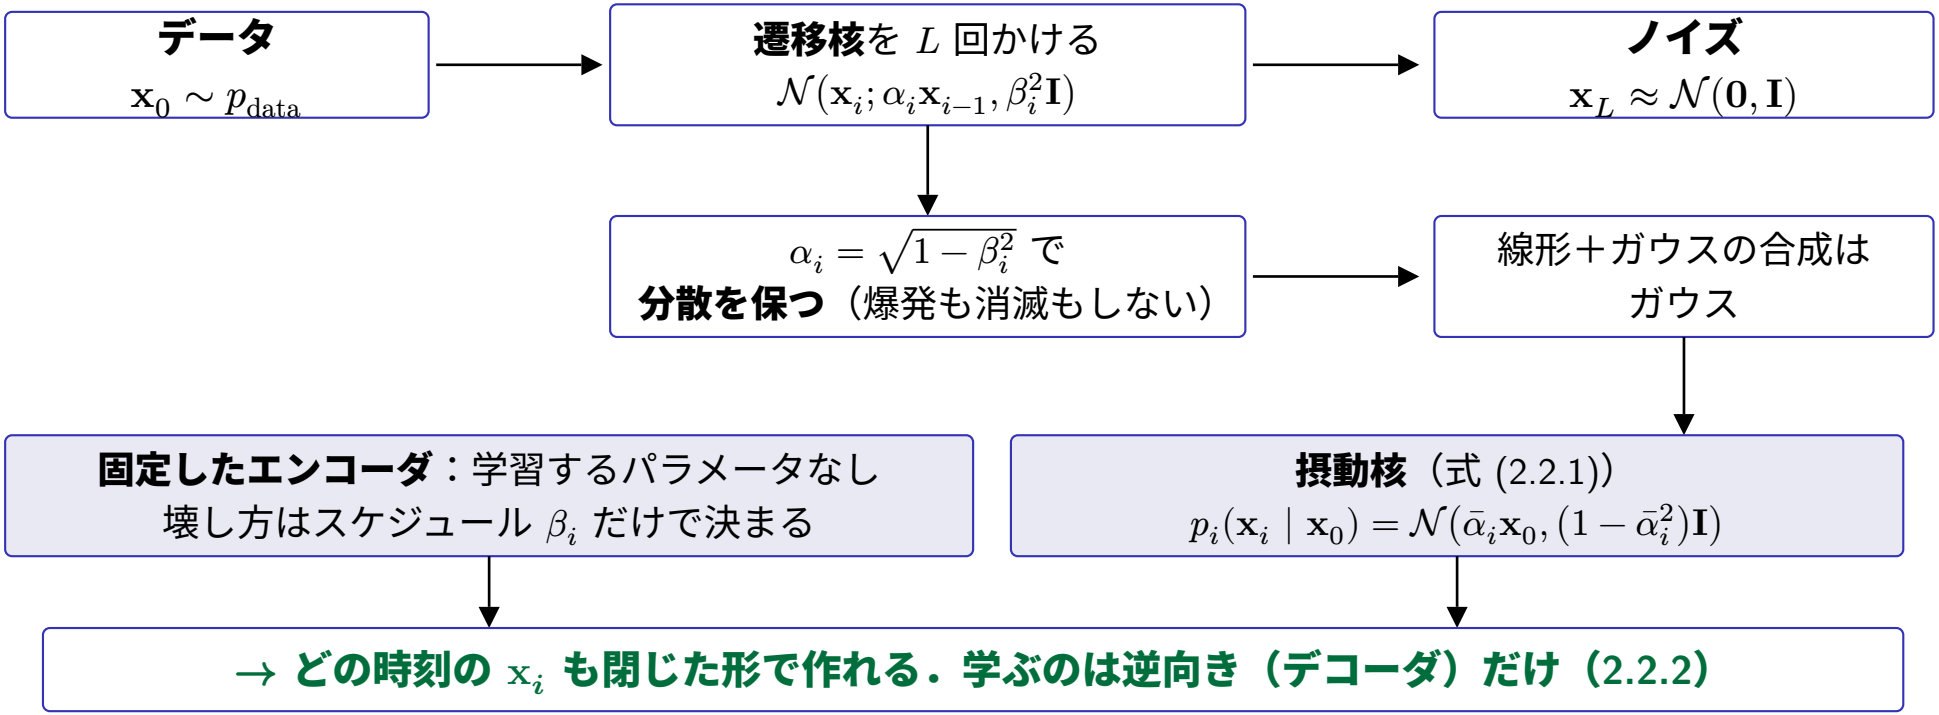
$0 \leq r < 1$ なら $r^L \to 0$（はさみうち）

平均 $\bar{\alpha}_L \mathbf{x}_0 \longrightarrow \mathbf{0}$, **共分散** $(1-\bar{\alpha}_L^2)\mathbf{I} \longrightarrow \mathbf{I}$

上の結果を摂動核に入れる

ガウス分布は平均と共分散で決まり，それらが収束するので $p_L(\mathbf{x}_L \mid \mathbf{x}_0) \to \mathcal{N}(\mathbf{0}, \mathbf{I})$（分布収束）．極限は $\mathbf{x}_0$ によらない． ■

2.2.1 のまとめ（1）：データからノイズへの道筋（補足）



2.2.1 のまとめ（2）：押さえておくこと（補足）

一言で

データに少しずつガウスノイズを足す「固定の壊し方」を決めた．壊し方が単純なので，どの時刻の状態も一度に書ける．

- **1 ステップ**：$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i$．ノイズ $\boldsymbol{\varepsilon}_i$ は i.i.d. の標準ガウス
- **分散保存**：$\alpha_i^2 + \beta_i^2 = 1$ なので，分散 $\mathbf{I}$ のデータは何ステップ後も分散 $\mathbf{I}$
- **i ステップまとめて**：$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\, \boldsymbol{\varepsilon}$，$\bar{\alpha}_i = \prod_{k=1}^{i} \alpha_k$
- **最後**：$\bar{\alpha}_L \to 0$ で $\mathbf{x}_0$ の情報が消え，データによらない事前分布 $p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ になる
- **VAE との違い**：VAE はエンコーダとデコーダを両方学ぶが，DDPM はエンコーダを固定してデコーダだけを学ぶ

次の問題：この壊し方を**逆にたどる**遷移 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ をどう学ぶか $\to$ 2.2.2

2.2 DDPM：変分的な視点

- 2.2.1 順方向過程（固定したエンコーダ）
- **2.2.2 逆方向のノイズ除去過程（学習するデコーダ）**
- 2.2.3 逆向きの遷移核のモデル化
- 2.2.4 予測と損失の実際的な選び方
- 2.2.5 DDPM の ELBO
- 2.2.6 サンプリング

2.2.2 の流れ：どの順で何を決めるか（補足）

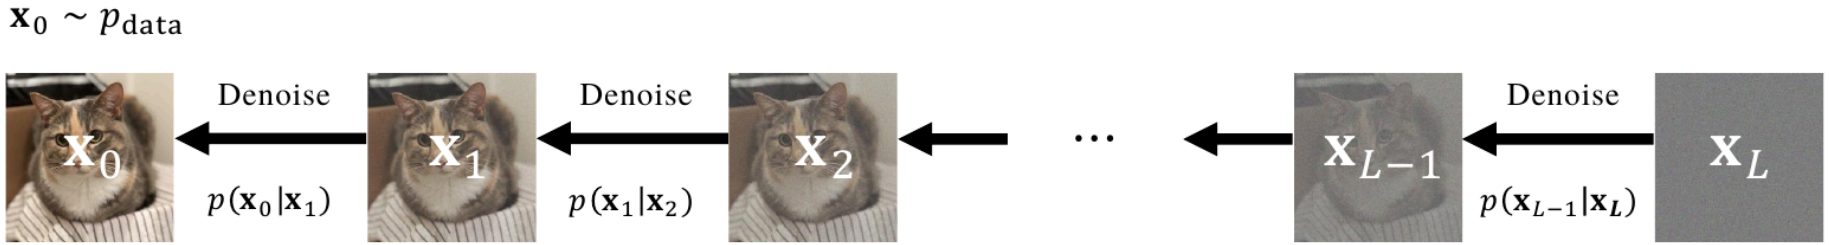
2.2.1 でデータ $\to$ ノイズの道筋を固定した．2.2.2 では，その逆向き（ノイズ $\to$ データ）を何に合わせて学ぶかを決める．

問 1 何を作りたい？	ノイズ $\mathbf{x}_L \sim p_{\text{prior}}$ から 1 歩ずつ戻る 逆向きの遷移 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$	**図 2.5**
問 2 真の逆遷移に合わせられる？	KL で合わせたいが（式 (2.2.2)），ベイズで書くと p_{data} を含む周辺 p_i が残り計算できない	**問い 2.2.1**
問 3 どう回避する？	答え $\mathbf{x}_0$ で条件付ける． $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$ は既知のガウスだけで書ける	**図 2.6**
問 4 条件付きで学んでよい？	よい．周辺の KL と定数しか違わず， 最適解（と勾配）が同じ	**定理 2.2.1**
問 5 条件付きの目標の形は？	平均 $\boldsymbol{\mu} = w_0\mathbf{x}_0 + w_i\mathbf{x}_i$，分散 $\sigma^2(i)$ の 閉じた形のガウス	**補題 2.2.2**

$\to$ ゴール：計算できない目標を「答え付きの計算できるガウス」に置き換える（2.2.3 で回帰へ）

図 2.5：逆方向過程でノイズからデータを作る

DDPM の本質は，順方向過程が加えた「制御された劣化」を**逆にたどれる**ことにある． 構造のない純粋なノイズ $\mathbf{x}_L \sim p_{\text{prior}}$ から出発し，意味のあるデータのサンプルが現れるまで，1 ステップずつノイズを除いていく． この逆向きの生成もマルコフ連鎖として進む．



出典：C. Lai et al., *The Principles of Diffusion Models* (arXiv:2510.21890) の図 2.5 を引用

図 2.5：右端のノイズ $\mathbf{x}_L$ から，$i = L, \ldots, 1$ の順に $\mathbf{x}_{i-1} \sim p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ を引いて新しいデータ $\mathbf{x}_0$ を得る．真の遷移 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ は未知なので，これを近似したい．

問い 2.2.1：逆向きの遷移核は求められるか

前のスライドの生成を実行するには，各ステップの逆向きの遷移核 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ が要る．

問い 2.2.1

逆向きの遷移核 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ を，特に $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$ の分布が複雑なときに， 正確に計算するか，少なくともうまく近似することはできるか？

本書は元論文のように ELBO から入らず（2.2.5 節で扱う），**条件付き確率を使う直観的な道**から学習目的を導く．

元論文：J. Ho, A. Jain, P. Abbeel, “Denoising Diffusion Probabilistic Models,” NeurIPS 2020（arXiv:2006.11239）． ELBO による拡散モデルの定式化自体は Sohl-Dickstein et al. (ICML 2015) にさかのぼる

Overview: Modeling and Training Objective

未知の真の逆遷移核 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ を，学習可能なパラメトリックモデル $p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ で近似する． 学習では，KL ダイバージェンスの期待値を最小化する．

$$\mathbb{E}_{p_i(\mathbf{x}_i)}\left[\mathcal{D}_{\mathrm{KL}}\left(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \,\|\, p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\right)\right] \tag{2.2.2}$$

しかし，目標の分布を直接計算するのは難しい（次のスライド）．

パラメトリックモデルとは（補足）

定義（パラメトリックモデル）

有限個のパラメータ ϕ で形が決まる分布の族 $\{p_\phi\}$．学習とは，データに合うように ϕ を選ぶこと．

たとえ：つまみ（パラメータ）のついた装置．つまみを回すと出てくる分布の形が変わり，学習はつまみの調整にあたる．

DDPM の場合（2.2.3 で具体化）

$$p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = \mathcal{N}\big(\mathbf{x}_{i-1}; \boldsymbol{\mu}_\phi(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I}\big)$$

- 分布の**形**はガウスに決めておく
- **平均** $\boldsymbol{\mu}_\phi(\mathbf{x}_i, i)$ をニューラルネットが出力し，その重みが ϕ
- $\mathbf{x}_i$ を入れるたびに，ネットが「次の一歩の分布」の平均を計算する

対比：パラメータの数を決めずデータそのものから分布を作る方法（ヒストグラム，カーネル密度推定など）はノンパラメトリック

なぜ KL ダイバージェンスの期待値を最小化するのか（補足）

KL ダイバージェンスは 2 つの分布の「ずれ」を測る量．$\mathcal{D}_{\mathrm{KL}}(p \parallel q) \geq 0$ で，$= 0$ になるのは $p = q$ のときだけ．

- **KL を最小化する $\Longrightarrow$ モデルを真の分布に近づける**：ずれが 0 なら，モデルは真の逆遷移そのもの
- **向き $\mathcal{D}_{\mathrm{KL}}(p \parallel p_\phi)$ の意味**：$\mathcal{D}_{\mathrm{KL}}(p \parallel p_\phi) = \mathbb{E}_p[\log p] - \mathbb{E}_p\left[\log p_\phi\right]$ で，第 1 項は ϕ によらない． よって最小化は $\mathbb{E}_p\left[\log p_\phi\right]$ の最大化，つまり「真の分布から出るサンプルに高い確率を与える」**最尤推定**と同じ
- **期待値 $\mathbb{E}_{p_i(\mathbf{x}_i)}$ をとる理由**：KL は $\mathbf{x}_i$ ごとに決まる．実際に現れる $\mathbf{x}_i$ すべてで良くしたいので， 現れやすさ $p_i(\mathbf{x}_i)$ で重み付けして平均する（よく出る入力ほど重視）

たとえ：天気予報士の評価．毎日の予報（p_ϕ）と実際の天気の傾向（p）のずれを，いろいろな日（$\mathbf{x}_i$）で平均して測る． 平均のずれが小さい予報士ほど良い．

目標の分布は周辺分布を含むので計算できない

式 (2.2.2) の目標の分布 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ を，ベイズの定理で順方向の量に書き直してみる．

証明（ベイズの定理の使い方）

$$
\begin{aligned}
p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) &= \frac{p(\mathbf{x}_{i-1}, \mathbf{x}_i)}{p_i(\mathbf{x}_i)} \\
&= \frac{p(\mathbf{x}_i \mid \mathbf{x}_{i-1})\, p_{i-1}(\mathbf{x}_{i-1})}{p_i(\mathbf{x}_i)} \\
&= p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) \cdot \underbrace{\frac{p_{i-1}(\mathbf{x}_{i-1})}{p_i(\mathbf{x}_i)}}_{\text{計算できない}}
\end{aligned}
$$

条件付き確率の定義（同時分布 ÷ 条件の周辺分布）

同時分布を逆向きに分ける：$p(a, b) = p(b \mid a)\, p(a)$

並べ替え．$p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$ は既知の遷移核

1・2 行目を合わせたものがベイズの定理：「$\mathbf{x}_{i-1}$ から $\mathbf{x}_i$ への向き（既知）」を使って「逆の向き（未知）」を表す．

周辺分布 p_i はなぜ計算できないのか

残った周辺分布 $p_i(\mathbf{x}_i)$（p_{i-1} も同様）を書き下す．

証明（周辺化）

$$p_i(\mathbf{x}_i) = \int p(\mathbf{x}_0, \mathbf{x}_i)\, \mathrm{d}\mathbf{x}_0$$

$$= \int p_i(\mathbf{x}_i \mid \mathbf{x}_0)\, p_{\mathrm{data}}(\mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0$$

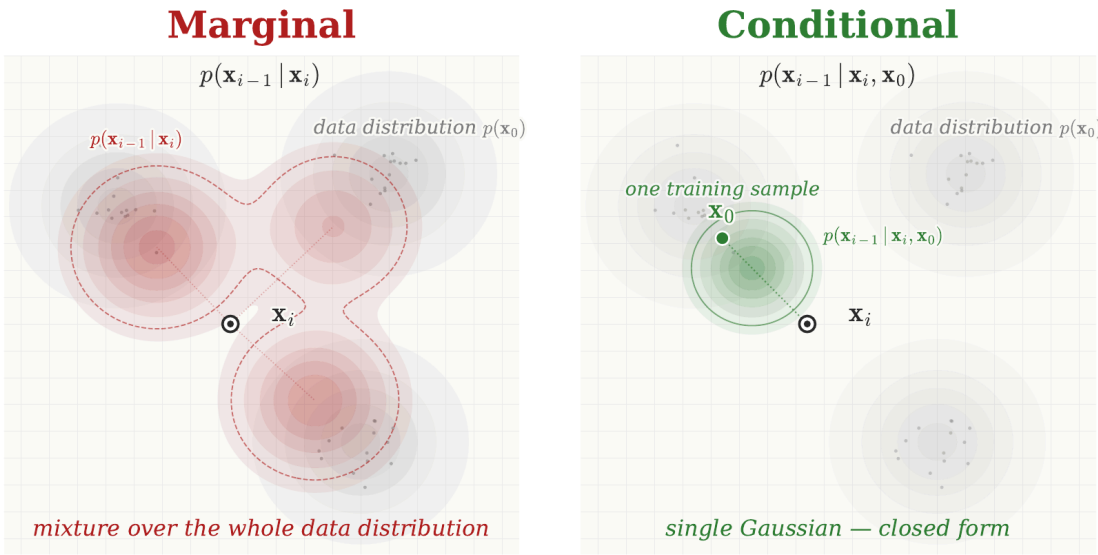
周辺化：$\mathbf{x}_0$ について積分して消す

同時分布を分ける：$p(\mathbf{x}_0, \mathbf{x}_i) = p_i(\mathbf{x}_i \mid \mathbf{x}_0)\, p_{\mathrm{data}}(\mathbf{x}_0)$

- 摂動核 $p_i(\mathbf{x}_i \mid \mathbf{x}_0)$ は閉じた形（既知）
- しかし p_{data} が**未知**なので，積分は閉じた形で求まらない．サンプルで近似するのがせいぜいで，正確な密度は実際には使えない

$\rightarrow$ 目標 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ も計算できない．これを**条件付けの工夫**で解決する（次のスライド）．

図 2.6：DDPM の条件付けの工夫



出典：C. Lai et al., *The Principles of Diffusion Models* (arXiv:2510.21890) の図 2.6 を引用

左：周辺 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$

その $\mathbf{x}_i$ を作りえた**すべての** $\mathbf{x}_0$ について平均したもの．山がいくつもある**複雑な混合分布**になりうる

右：条件付き $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$

学習中は $\mathbf{x}_i$ を作った $\mathbf{x}_0$ が**わかっている**．条件付けると平均と分散が閉じた形の**ガウス分布 1 つ**になり，単純な回帰の目標として使える

Overcoming Intractability with Conditioning

DDPM の中心的な洞察は，逆遷移を**きれいなデータのサンプル $\mathbf{x}_0$ で条件付ける**ことである．この一歩で，計算できない核が計算できるものに変わる．

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) \frac{p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)}{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}$$

計算できるようになるのは，順方向過程の 2 つの性質のおかげである：**マルコフ性**と，すべての分布が**ガウス**であること（次のスライドと補題 2.2.2）．

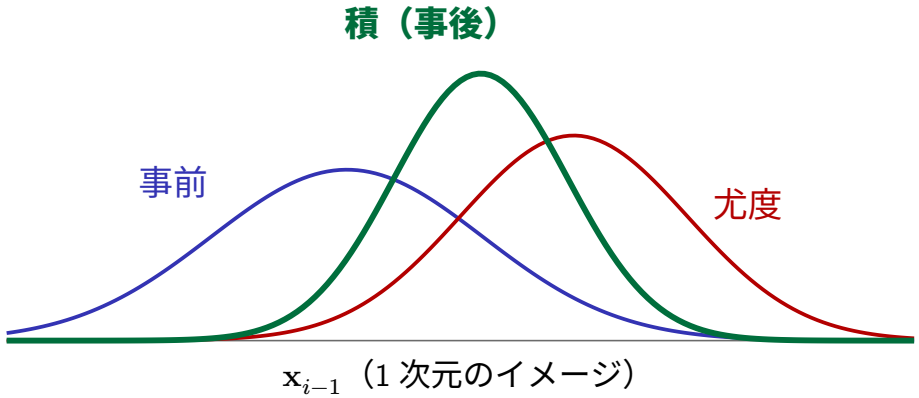
- 各学習例は，1 つのきれいなサンプル $\mathbf{x}_0$ だけで条件付けている
- しかし全サンプルで平均すると，周辺の逆分布を直接学ぶのと**同じ最適モデル**が得られる（定理 2.2.1）
- したがって，周辺の混合分布という複雑で計算できない目標に直接回帰しなくても，同じ最適な逆向きの予測を学べる

条件付けの式は何をしているのか（補足）

$\mathbf{x}_0$ を固定し，$\mathbf{x}_{i-1}$ の関数として読む（分母は $\mathbf{x}_{i-1}$ を含まない定数）：

$$\underbrace{p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)}_{\text{求めたい（事後）}} \propto \underbrace{p(\mathbf{x}_i \mid \mathbf{x}_{i-1})}_{\text{今の } \mathbf{x}_i \text{ と合うか（尤度）}} \times \underbrace{p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)}_{\text{きれいな } \mathbf{x}_0 \text{ からの見込み（事前）}}$$

- **事前**：$\mathbf{x}_0$ をノイズ $i-1$ 段ぶん壊すと，$\mathbf{x}_{i-1}$ はこのあたりのはず（摂動核）
- **尤度**：その $\mathbf{x}_{i-1}$ から 1 歩壊して，手元の $\mathbf{x}_i$ になりそうか（遷移核）
- **掛け算**：両方の手がかりに合う場所に絞り込む．どちらもガウスなので，結果もガウス（閉じた形）



たとえ：「出発地（$\mathbf{x}_0$）からの道のり」と「今いる場所（$\mathbf{x}_i$）」の 2 つの情報から，1 つ前にいた場所を推理する

条件付きの逆向き遷移はベイズの定理で書ける

命題

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) \frac{p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)}{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}$$

理由：$\mathbf{x}_0$ を条件に入れたままベイズの定理を使い，マルコフ性 $p(\mathbf{x}_i \mid \mathbf{x}_{i-1}, \mathbf{x}_0) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$ で分子を簡単にする．

意図：右辺の 3 つは遷移核と摂動核で，どれも**閉じた形のガウス分布**． 周辺のときに邪魔だった未知の p_i，p_{i-1} が，$\mathbf{x}_0$ を条件に入れたことで計算できる摂動核に置き換わった． だから左辺もガウス分布で，平均と分散が書ける（補題 2.2.2）．

※ 「理由」「意図」は補足

条件付きのベイズの定理を 1 行ずつ（補足）

方針：$\mathbf{x}_0$ を**最後までずっと条件に入れたまま**，前と同じベイズの定理の手順をたどる．

証明

$$
\begin{aligned}
p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) &= \frac{p(\mathbf{x}_{i-1}, \mathbf{x}_i \mid \mathbf{x}_0)}{p(\mathbf{x}_i \mid \mathbf{x}_0)} \\
&= \frac{p(\mathbf{x}_i \mid \mathbf{x}_{i-1}, \mathbf{x}_0)\, p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)}{p(\mathbf{x}_i \mid \mathbf{x}_0)} \\
&= \frac{p(\mathbf{x}_i \mid \mathbf{x}_{i-1})\, p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)}{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}
\end{aligned}
$$

条件付き確率の定義（全体を $\mathbf{x}_0$ で条件付けた世界で）

同時分布を分ける：$p(a, b \mid c) = p(b \mid a, c)\, p(a \mid c)$

マルコフ性：$\mathbf{x}_{i-1}$ がわかれば $\mathbf{x}_0$ は余分（下の注）

マルコフ性が成り立つ理由：$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i$ で，$\boldsymbol{\varepsilon}_i$ は $\mathbf{x}_0$ とも $\mathbf{x}_{i-1}$ とも独立． だから $\mathbf{x}_{i-1}$ を固定すると $\mathbf{x}_i$ の分布は $\mathcal{N}(\alpha_i \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I})$ で決まり，$\mathbf{x}_0$ をさらに知っても変わらない．

右辺の 3 つはすべて既知のガウス分布（補足）

右辺の因子	名前	分布
$p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$	遷移核	$\mathcal{N}(\mathbf{x}_i; \alpha_i \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I})$
$p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)$	摂動核（$i-1$）	$\mathcal{N}(\mathbf{x}_{i-1}; \bar{\alpha}_{i-1} \mathbf{x}_0, (1-\bar{\alpha}_{i-1}^2)\mathbf{I})$
$p_i(\mathbf{x}_i \mid \mathbf{x}_0)$	摂動核（i）	$\mathcal{N}(\mathbf{x}_i; \bar{\alpha}_i \mathbf{x}_0, (1-\bar{\alpha}_i^2)\mathbf{I})$

- 周辺のとき（p_{i-1}，p_i）は未知の p_{data} を含んでいたが，$\mathbf{x}_0$ を条件に入れたことで，すべて**式で書ける**分布になった
- 分母 $p_i(\mathbf{x}_i \mid \mathbf{x}_0)$ は $\mathbf{x}_{i-1}$ を含まないので，$\mathbf{x}_{i-1}$ の分布としては**正規化定数**にすぎない
- よって左辺は「$\mathbf{x}_{i-1}$ についての 2 つのガウスの積」に比例し，ガウス分布になる（補題 2.2.2）

定理 2.2.1：周辺の KL と条件付きの KL は同じ最適解をもつ

定理 2.2.1（周辺と条件付きの KL 最小化の同値性）

$$\begin{aligned}&\mathbb{E}_{p_i(\mathbf{x}_i)}\left[\mathcal{D}_{\mathrm{KL}}\left(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\parallel p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\right)\right]\\&=\mathbb{E}_{p_{\mathrm{data}}(\mathbf{x}_0)}\mathbb{E}_{p_i(\mathbf{x}_i\mid\mathbf{x}_0)}\left[\mathcal{D}_{\mathrm{KL}}\left(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\parallel p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\right)\right]-C\end{aligned}\tag{2.2.3}$$

$C\geq 0$ は $\boldsymbol{\phi}$ によらない定数．最小解は $p^*(\mathbf{x}_{i-1}\mid\mathbf{x}_i)=\mathbb{E}_{p(\mathbf{x}_0\mid\mathbf{x}_i)}[p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)]=p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)$.

意図：左辺（本当に最小化したいが計算できない）の代わりに，右辺（目標が閉じた形）を最小化すればよい． 2 つは $\boldsymbol{\phi}$ によらない定数 C しか違わないので，最適解は同じ．

※ 本文は右辺に $+C$ と書くが，定数の名前の付け方の違いで最適化には影響しない

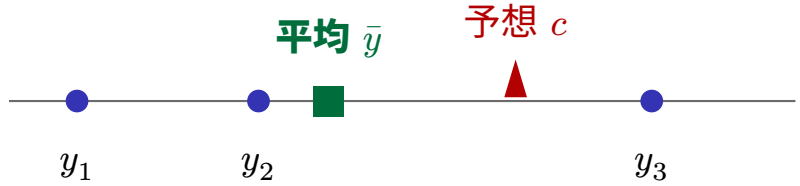
定理 2.2.1 の直感（1）：二乗誤差で考える

まず簡単な場合：ばらついた目標 y に，1 つの予想 c でなるべく近づきたい．

$$\mathbb{E}[(y-c)^2] = \underbrace{(\bar{y}-c)^2}_{\text{平均とのずれ}} + \underbrace{\mathrm{Var}[y]}_{\text{目標のばらつき}}$$

（$\bar{y} := \mathbb{E}[y]$．$y - c = (y-\bar{y}) + (\bar{y}-c)$ と分けて展開すると交差項が 0）

- 右の第 2 項は c によらない定数
- だから「目標たちに平均的に近づく」ことは「目標の**平均** $\bar{y}$ に近づく」ことと同じ
- 最適な予想は $c^* = \bar{y}$



目標 y_1, y_2, y_3 はばらつくが，予想 c は平均 $\bar{y}$ に寄せればよい

定理 2.2.1 の直感（2）：同じことを分布と KL で

$\mathbf{x}_i$ を 1 つ固定する．それを作りえたきれいなデータ $\mathbf{x}_0$ はいろいろあり，$\mathbf{x}_0$ ごとに**目標** $p_{\mathrm{c}} := p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$ が決まる．

	二乗誤差（前のスライド）	**定理 2.2.1（KL）**
ばらつく目標	y	$\mathbf{x}_0$ ごとの p_{c}
目標の平均	$\bar{y} = \mathbb{E}[y]$	$p_{\mathrm{m}} := p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = \mathbb{E}_{\mathbf{x}_0 \mid \mathbf{x}_i}[p_{\mathrm{c}}]$
予想（モデル）	c	$p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$
平均的な近さ	$\mathbb{E}[(y-c)^2]$	$\mathbb{E}_{\mathbf{x}_0 \mid \mathbf{x}_i}\left[\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{c}} \parallel p_{\boldsymbol{\phi}})\right]$（右辺）
平均とのずれ	$(\bar{y}-c)^2$	$\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{m}} \parallel p_{\boldsymbol{\phi}})$（左辺）
ばらつき（定数）	$\mathrm{Var}[y]$	$\mathbb{E}_{\mathbf{x}_0 \mid \mathbf{x}_i}[\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{c}} \parallel p_{\mathrm{m}})] = C$

$$\underbrace{\mathbb{E}\left[\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{c}} \parallel p_{\boldsymbol{\phi}})\right]}_{\text{右辺：個々の目標に合わせる}} = \underbrace{\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{m}} \parallel p_{\boldsymbol{\phi}})}_{\text{左辺：平均の目標に合わせる}} + \underbrace{C}_{\boldsymbol{\phi}\text{ によらない}}$$

$\rightarrow$ 計算できる右辺を最小化すれば，左辺も最小化され，最適なモデルは**目標の平均** p_{m} になる（あとで $\mathbf{x}_i \sim p_i$ で平均）．

定理 2.2.1 の理解のしかた（補足）

① 周辺では計算できない

目標 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ には未知の p_{data} が入っていて，KL の期待値が計算できない

② 条件付ければ計算できる

$\mathbf{x}_0$ で条件付けた目標 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$ は閉じた形のガウス分布

③ 平均すると一致する

$\mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)}[p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)] = p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$

一致するのは「最適解」であって，KL の値そのものではない

$$\underbrace{\mathbb{E}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{c}} \parallel p_{\boldsymbol{\phi}}\right)\right]}_{\text{条件付き（計算できる）}} = \underbrace{\mathbb{E}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_{\boldsymbol{\phi}}\right)\right]}_{\text{周辺（計算できない）}} + \underbrace{C}_{C \geq 0,\ \boldsymbol{\phi}\ \text{によらない}}$$

値は C だけずれるが，ϕ によらないので最適な p_ϕ も勾配も同じ（$\mathbb{E}[(y-c)^2]$ と $(\bar{y}-c)^2$ の関係と同じ）.

平均のとり方：$\mathbf{x}_i$ を作りえた答え $\mathbf{x}_0$ についての平均（$p(\mathbf{x}_0 \mid \mathbf{x}_i)$）. 実際の学習では $\mathbf{x}_0 \sim p_{\text{data}}$ を引いてノイズを足し $\mathbf{x}_i$ を作るので，**自動的にこの平均をとったことになる**（$p(\mathbf{x}_0 \mid \mathbf{x}_i)$ を計算する必要はない）.

定理 2.2.1 は最小二乗法なのか（補足）

1. 定理 2.2.1 そのものは「最小二乗法と同じ構造」（一般の分布と KL の主張で，二乗誤差は出てこない）

最小二乗	定理 2.2.1
$\mathbb{E}[(y-c)^2] = (\bar{y}-c)^2 + \mathrm{Var}[y]$	$\mathbb{E}\big[\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{c}} \parallel p_{\boldsymbol{\phi}})\big] = \mathcal{D}_{\mathrm{KL}}(p_{\mathrm{m}} \parallel p_{\boldsymbol{\phi}}) + C$
最適解は目標の平均 $\bar{y}$	最適解は目標の平均 $p_{\mathrm{m}} = \mathbb{E}_{\mathbf{x}_0 \mid \mathbf{x}_i}[p_{\mathrm{c}}]$

2. DDPM では本当に最小二乗法になる（2.2.3）：モデルを分散固定のガウスにすると，KL が平均の二乗誤差になる

$$\mathcal{D}_{\mathrm{KL}}(\mathcal{N}(\boldsymbol{\mu}_1, \sigma^2\mathbf{I}) \parallel \mathcal{N}(\boldsymbol{\mu}_2, \sigma^2\mathbf{I})) = \frac{1}{2\sigma^2}\|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2$$

$\rightarrow$ 学習は「目標の平均 $\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)$ を $\boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$ で当てる重み付き最小二乗」．最適解は条件付き期待値 （ε-予測なら $\mathbb{E}[\varepsilon \mid \mathbf{x}_i]$，$x$-予測なら $\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$）．

注意：ガウス 1 つのモデルでは混合分布 p_{m} そのものは表せず，合わせられるのは**平均**だけ． だから 1 ステップを小さくして逆向きの分布をガウスに近づける必要がある（2.2.6「サンプリングは遅い」）．

定理 2.2.1 の証明（1）：入れ子の期待値にする（補足）

記号：$p_{\mathrm{c}} := p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$（条件付き），$p_{\mathrm{m}} := p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$（周辺），$p_{\boldsymbol{\phi}} := p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$．付録 D.1.1 の流れに沿う．

証明

$$\text{右辺} = \iint p(\mathbf{x}_0, \mathbf{x}_i)\, \mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{c}} \parallel p_{\boldsymbol{\phi}}\right) \mathrm{d}\mathbf{x}_0\, \mathrm{d}\mathbf{x}_i$$

外側の 2 つの期待値を同時分布 $p(\mathbf{x}_0, \mathbf{x}_i) = p_{\mathrm{data}}(\mathbf{x}_0) p_i(\mathbf{x}_i \mid \mathbf{x}_0)$ の 1 つにまとめる

$$= \iiint p(\mathbf{x}_0, \mathbf{x}_i)\, p_{\mathrm{c}} \log \frac{p_{\mathrm{c}}}{p_{\boldsymbol{\phi}}} \mathrm{d}\mathbf{x}_{i-1}\, \mathrm{d}\mathbf{x}_0\, \mathrm{d}\mathbf{x}_i$$

KL の定義 $\mathcal{D}_{\mathrm{KL}}(p \parallel q) = \int p \log(p/q)$ を代入

$$= \int p(\mathbf{x}_i) \int p(\mathbf{x}_0 \mid \mathbf{x}_i) \int p_{\mathrm{c}} \log \frac{p_{\mathrm{c}}}{p_{\boldsymbol{\phi}}} \mathrm{d}\mathbf{x}_{i-1}\, \mathrm{d}\mathbf{x}_0\, \mathrm{d}\mathbf{x}_i$$

確率の連鎖律 $p(\mathbf{x}_0, \mathbf{x}_i) = p(\mathbf{x}_i)\, p(\mathbf{x}_0 \mid \mathbf{x}_i)$

$$= \mathbb{E}_{p(\mathbf{x}_i)} \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)} \mathbb{E}_{p_{\mathrm{c}}} \left[\log \frac{p_{\mathrm{c}}}{p_{\boldsymbol{\phi}}} \right]$$

積分を入れ子の期待値として書く

定理 2.2.1 の証明（2）：log を 2 つに分ける（補足）

証明（続き）

log の中に周辺 p_{m} を掛けて割る：

$$\log \frac{p_{\mathrm{c}}}{p_{\phi}} = \log \left(\frac{p_{\mathrm{c}}}{p_{\mathrm{m}}} \cdot \frac{p_{\mathrm{m}}}{p_{\phi}} \right) = \log \frac{p_{\mathrm{c}}}{p_{\mathrm{m}}} + \log \frac{p_{\mathrm{m}}}{p_{\phi}}$$

$p_{\mathrm{m}}/p_{\mathrm{m}} = 1$ を掛ける．積の log は和

これを前のスライドの最後の式に代入し，期待値の線形性で 2 項に分ける：

$$\text{右辺} = \underbrace{\mathbb{E}_{p(\mathbf{x}_i)} \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)} \mathbb{E}_{p_{\mathrm{c}}} \left[\log \frac{p_{\mathrm{c}}}{p_{\mathrm{m}}} \right]}_{\text{第 1 項}}$$

期待値の線形性

$$+ \underbrace{\mathbb{E}_{p(\mathbf{x}_i)} \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)} \mathbb{E}_{p_{\mathrm{c}}} \left[\log \frac{p_{\mathrm{m}}}{p_{\phi}} \right]}_{\text{第 2 項}}$$

次のスライドで，第 1 項が定数 C，第 2 項が左辺になることを示す．

定理 2.2.1 の証明（3）：各項を計算する（補足）

証明（続き）

第 2 項：中身 $\log p_{\mathrm{m}}/p_{\boldsymbol{\phi}}$ は $\mathbf{x}_0$ を含まない．$g(\mathbf{x}_{i-1}) := \log p_{\mathrm{m}}/p_{\boldsymbol{\phi}}$ とおく．

$$\mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)}\mathbb{E}_{p_{\mathrm{c}}}[g] = \int \left(\int p(\mathbf{x}_0 \mid \mathbf{x}_i)\, p_{\mathrm{c}}\, \mathrm{d}\mathbf{x}_0 \right) g\, \mathrm{d}\mathbf{x}_{i-1}$$

期待値の定義．g は $\mathbf{x}_0$ を含まないので積分の順序を入れ替え

$$= \int p_{\mathrm{m}}\, g\, \mathrm{d}\mathbf{x}_{i-1} = \mathbb{E}_{p_{\mathrm{m}}}\left[\log \frac{p_{\mathrm{m}}}{p_{\boldsymbol{\phi}}} \right] = \mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_{\boldsymbol{\phi}}\right)$$

全確率の法則 $\int p(\mathbf{x}_0 \mid \mathbf{x}_i) p_{\mathrm{c}}\, \mathrm{d}\mathbf{x}_0 = p_{\mathrm{m}}$．KL の定義

よって 第 2 項 $= \mathbb{E}_{p_i(\mathbf{x}_i)}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_{\boldsymbol{\phi}}\right)\right] =$ 左辺．

第 1 項：内側の期待値が KL の定義そのもので，$\boldsymbol{\phi}$ を含まない．

$$\text{第 1 項} = \mathbb{E}_{p_i(\mathbf{x}_i)}\mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)}[\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{c}} \parallel p_{\mathrm{m}})] =: C \geq 0$$

以上で 右辺 $=$ 左辺 $+C$（式 (2.2.3)）．■

定理 2.2.1 の証明（4）：最適解は周辺 p_{m}（補足）

証明（最適解 その 1）

右辺を $R(\phi)$，左辺を $L(\phi) := \mathbb{E}_{p_i(\mathbf{x}_i)}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_\phi\right)\right]$ と書く．(3) より $R(\phi) = L(\phi) + C$.

$$\arg\min_\phi R(\phi) = \arg\min_\phi (L(\phi) + C) = \arg\min_\phi L(\phi)$$

C は ϕ によらないので，足しても最小点は動かない

$$L(\phi) = \mathbb{E}_{p_i(\mathbf{x}_i)}\left[\underbrace{\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_\phi\right)}_{\geq 0}\right] \geq 0$$

KL は非負．非負のものの期待値も非負

$$L(\phi) = 0 \Longleftrightarrow \mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_\phi\right) = 0 \text{（ほぼすべての } \mathbf{x}_i \text{）}$$

$$\Longleftrightarrow p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$$

非負の量の期待値が 0 になるのは，ほぼ至る所 0 のとき
KL が 0 になるのは 2 つの分布が一致するときだけ

よって，モデルの族が p_{m} を表せるほど豊かなら，最小値 0 は $p_\phi = p_{\mathrm{m}}$ で達成され，$p^* = p_{\mathrm{m}}$.

定理 2.2.1 の証明（5）：p_{m} は条件付きの目標の平均（補足）

証明（最適解 その 2）

$\mathbf{x}_i$ を条件に入れたまま，$\mathbf{x}_0$ を周辺化する．

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = \int p(\mathbf{x}_{i-1}, \mathbf{x}_0 \mid \mathbf{x}_i)\, \mathrm{d}\mathbf{x}_0$$

$$= \int p(\mathbf{x}_0 \mid \mathbf{x}_i)\, p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)\, \mathrm{d}\mathbf{x}_0$$

$$= \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)}[p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)]$$

周辺化：$\mathbf{x}_0$ について積分して消す（$\mathbf{x}_i$ は条件のまま）

条件付きの連鎖律：$p(a, b \mid c) = p(b \mid c)\, p(a \mid b, c)$

期待値の定義（$p(\mathbf{x}_0 \mid \mathbf{x}_i)$ についての平均）

よって $p^* = p_{\mathrm{m}} = \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)}[p_{\mathrm{c}}]$：最適なモデルは，条件付きの目標を答え $\mathbf{x}_0$ について平均したもの． ■

※ $p(\mathbf{x}_0 \mid \mathbf{x}_i)$ は「この $\mathbf{x}_i$ を作りえた答えの分布」．p_{c} はガウスでも，その平均 p_{m} は一般に混合分布（図 2.6 の左）．C. Lai et al. の付録 D.1.1 に沿って途中の式と理由を補った

条件付けの見方は DDPM の土台

この見方（**条件付けで計算できる目的関数を得る**）は DDPM の土台であり，第 3 章・第 5 章で見る他の重要な拡散モデルとの深い共通点も示している．

注意（定理 2.2.1 が言っていること）

周辺分布どうしの KL を最小化することは，特定の条件付き分布どうしの KL を最小化することと数学的に同じ．

後者が非常に便利なのは，鍵となる条件付き分布 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ が扱いやすい**閉じた形**をもつから（次の補題 2.2.2）．

補題 2.2.2：逆向きの条件付き遷移は閉じた形のガウス分布

補題 2.2.2（逆向きの条件付き遷移核）

$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ はガウス分布 $\mathcal{N}(\mathbf{x}_{i-1}; \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i), \sigma^2(i)\mathbf{I})$ で，

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}\mathbf{x} + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}\mathbf{x}_i, \quad \sigma^2(i) := \frac{1-\bar{\alpha}_{i-1}^2}{1-\bar{\alpha}_i^2}\beta_i^2 \tag{2.2.4}$$

意図：$\mathbf{x}_{i-1}$ について 2 つの手がかりがあり，それを組み合わせている．

- 今の状態 $\mathbf{x}_i$ から：「$\mathbf{x}_i$ は $\mathbf{x}_{i-1}$ を α_i 倍してノイズを足したもの」（遷移核）
- きれいなデータ $\mathbf{x}$ から：「$\mathbf{x}_{i-1}$ は $\mathbf{x}$ を $\bar{\alpha}_{i-1}$ 倍してノイズを足したもの」（摂動核）

平均は 2 つの手がかりの**重み付き平均**，分散はスケジュールだけで決まり，データによらない．

ここでの $\mathbf{x}$ は $\mathbf{x}_0$ のこと（本文の表記）．より一般の式は補題 4.5.2

補題 2.2.2 の式の読み方（補足）

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) = \underbrace{\frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}}_{w_0}\mathbf{x}_0 + \underbrace{\frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}}_{w_i}\mathbf{x}_i, \quad \sigma^2(i) = \frac{1-\bar{\alpha}_{i-1}^2}{1-\bar{\alpha}_i^2}\beta_i^2$$

平均：2 つの手がかりの混ぜ合わせ

- w_0：きれいな $\mathbf{x}_0$ への引き寄せ（摂動核からの手がかり）
- w_i：今いる $\mathbf{x}_i$ にとどまる力（遷移核からの手がかり）
- 係数はスケジュールだけで決まる．データは $\mathbf{x}_0$，$\mathbf{x}_i$ にしか入らない

分散：データによらない定数

- $\sigma^2(i) \le \beta_i^2$：$\mathbf{x}_0$ を知っている分，1 歩ぶんのノイズより少しだけ不確かさが減る

両端で確かめる

- $i=1$：$\bar{\alpha}_0 = 1$ より $w_0 = 1$，$w_i = 0$，$\sigma^2 = 0$． 1 歩戻るとちょうど $\mathbf{x}_0$（答えそのもの）
- ノイズが強い段：w_i が大きく w_0 は小さい． 今の位置から $\mathbf{x}_0$ の方へ**少しだけ**動く

数値例（$\bar{\alpha}_{i-1} = 0.8$，$\alpha_i = 0.95$）

- $w_0 \approx 0.18$，$w_i \approx 0.81$
- $\sigma \approx 0.29$（$\beta_i \approx 0.31$ より小さい）

$w_0 + w_i$ は一般に 1 ではない（$\mathbf{x}_i$ と $\mathbf{x}_0$ で信号の縮み方 $\bar{\alpha}$ が違うため）ので，厳密には線形結合

補題 2.2.2 の証明の考え方：2 つのガウスの積はガウス

$\mathbf{x}_{i-1} =: \mathbf{y}$ と書く．前の命題の分母は $\mathbf{y}$ を含まないので，$\mathbf{y}$ の関数として

$$p(\mathbf{y} \mid \mathbf{x}_i, \mathbf{x}_0) \propto \underbrace{\mathcal{N}(\mathbf{x}_i; \alpha_i \mathbf{y}, \beta_i^2 \mathbf{I})}_{\text{遷移核}} \cdot \underbrace{\mathcal{N}(\mathbf{y}; \bar{\alpha}_{i-1} \mathbf{x}_0, (1-\bar{\alpha}_{i-1}^2)\mathbf{I})}_{\text{摂動核}}$$

どちらも指数の肩が $\mathbf{y}$ の 2 次式なので，積も 2 次式になり，**ガウス分布**になる．$\|\mathbf{y}\|^2$ と $\mathbf{y}$ の係数を読み取ると

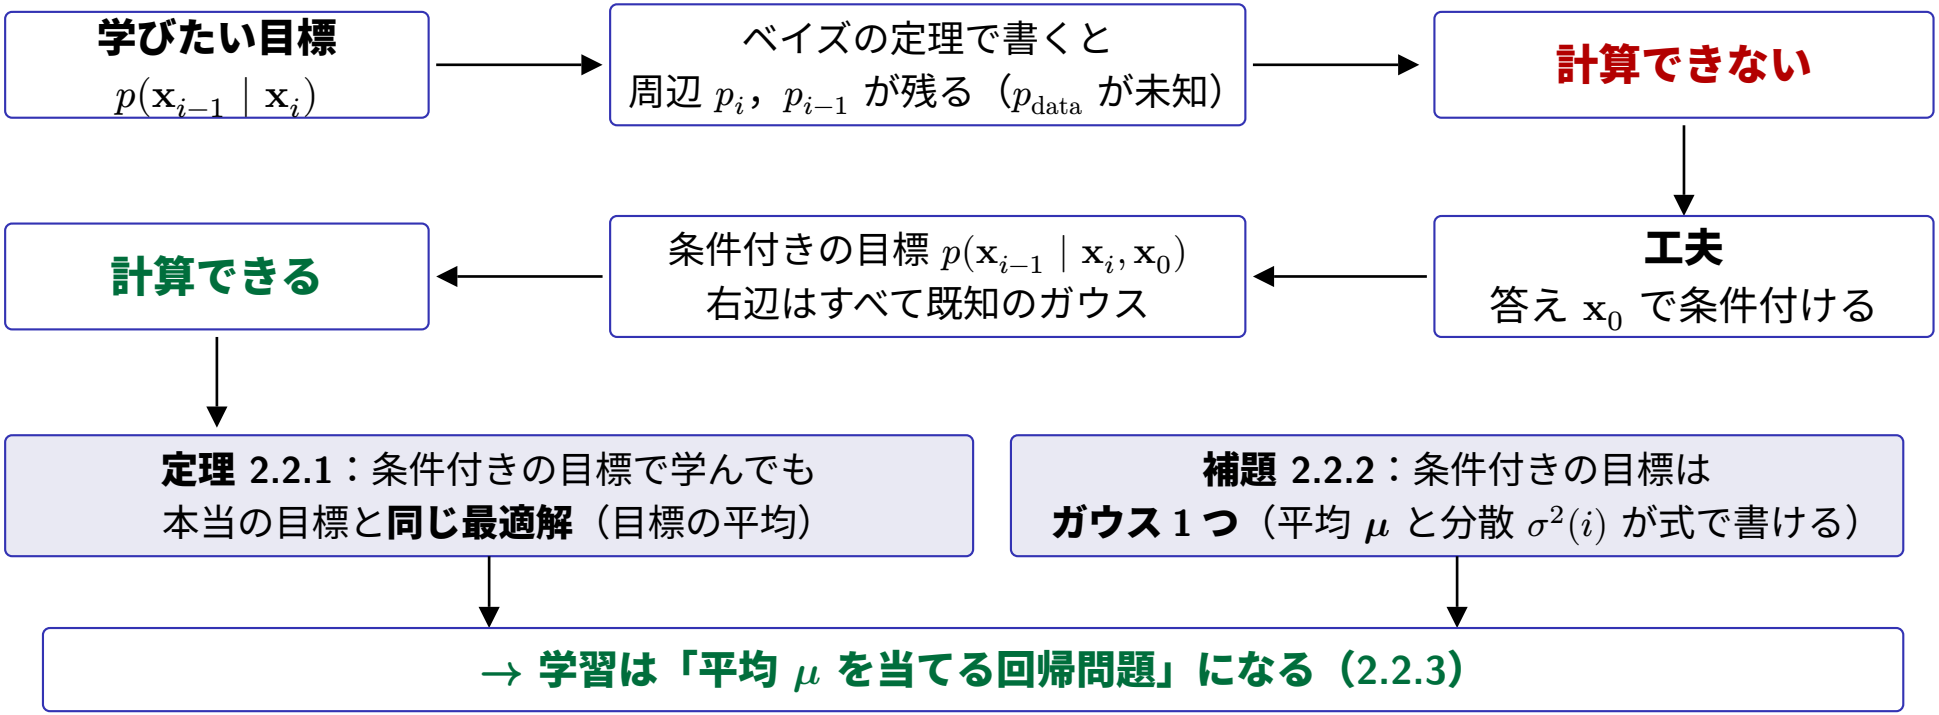
$$\frac{1}{\sigma^2}(i) = \frac{\alpha_i^2}{\beta_i^2} + \frac{1}{1-\bar{\alpha}_{i-1}^2}, \quad \frac{\boldsymbol{\mu}}{\sigma^2}(i) = \frac{\alpha_i \mathbf{x}_i}{\beta_i^2} + \frac{\bar{\alpha}_{i-1}\mathbf{x}_0}{1-\bar{\alpha}_{i-1}^2}$$

- **精度（分散の逆数）は足し算**：2 つの手がかりの確かさを足したものが，合わせた確かさ
- **平均は精度で重み付けした平均**：確かな手がかりほど強く効く

あとは $\alpha_i^2 + \beta_i^2 = 1$，$\alpha_i \bar{\alpha}_{i-1} = \bar{\alpha}_i$ で整理すると式 (2.2.4) になる．

※ 証明は補足

2.2.2 のまとめ（1）：問題から解決までの流れ（補足）



2.2.2 のまとめ（2）：定理 2.2.1 が言っていること（補足）

一言で

計算できない「本当の目標」の代わりに，計算できる「答え付きの目標」に合わせて学習してよい．

- $\mathbf{x}_i$ を作りえた答え $\mathbf{x}_0$ はいろいろあり，目標 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$ は答えごとにばらつく
- それらの**平均が本当の目標** $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$
- 最小二乗と同じ構造：「ばらつく目標に平均的に合わせる ＝ 目標の平均に合わせる ＋ 定数」
- 差の定数 C は「$\mathbf{x}_0$ を知らないことによる，避けられないずれ」で，ϕ によらない

たとえ：答え付きの練習問題をたくさん解くと，1 問ごとの答えはばらついても「平均的に正しい予想」が身につく．

2.2.2 のまとめ（3）：補題 2.2.2 が言っていること（補足）

一言で

答え付きの目標は「2 つの手がかりを合わせたガウス分布 1 つ」で，平均と分散が式で書ける．

平均 $\boldsymbol{\mu} = w_0\mathbf{x}_0 + w_i\mathbf{x}_i$

- $\mathbf{x}_0$ への引き寄せと，今の $\mathbf{x}_i$ にとどまる力の混ぜ合わせ
- 係数はスケジュールだけで決まる

分散 $\sigma^2(i)$

- データによらない定数
- $\mathbf{x}_0$ を知っている分，1 歩ぶんのノイズ β_i^2 より少し小さい

なぜガウスか：事前（摂動核）$\times$ 尤度（遷移核）がどちらもガウスで，ガウスの積はガウス．

$\rightarrow$ モデルもガウス $\mathcal{N}\big(\boldsymbol{\mu}_{\boldsymbol{\phi}}, \sigma^2(i)\mathbf{I}\big)$ にすれば，KL は平均の二乗誤差になり，**学習は回帰**（2.2.3）．

第 3 章（スコアマッチング）・第 5 章（フローマッチング）でも同じ「条件付けて計算できる目標にする」工夫が現れる

2.2 DDPM：変分的な視点

- 2.2.1 順方向過程（固定したエンコーダ）
- 2.2.2 逆方向のノイズ除去過程（学習するデコーダ）
- **2.2.3 逆向きの遷移核のモデル化**
- 2.2.4 予測と損失の実際的な選び方
- 2.2.5 DDPM の ELBO
- 2.2.6 サンプリング

2.2.3 の流れ：どの順で何を決めるか（補足）

2.2.2 で「答え $\mathbf{x}_0$ 付きの目標 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$ はガウスで，それに合わせて学んでよい」ことがわかった．2.2.3 ではそれを使って学習法を決める．

問 1 モデルをどんな形にする？	逆遷移もガウス．分散は $\sigma^2(i)$ に固定し，平均 $\boldsymbol{\mu}_\phi(\mathbf{x}_i, i)$ だけ学ぶ	(2.2.5)
問 2 何を最小化する？	各時刻の「正解の 1 歩」と「モデルの 1 歩」の KL の和（勾配は本当の目標と同じ）	(2.2.6)
問 3 その KL は計算できる？	分散が同じガウスどうしなので，平均の二乗誤差になる	(2.2.7)
問 4 最終的な学習目的は？	データで平均し定数を落とす → 平均を当てる重み付き最小二乗（回帰）	(2.2.8)
問 5 効率よく計算できる？	摂動核で $\mathbf{x}_0$ から $\mathbf{x}_i$ を直接作れるので，1 サンプル・1 時刻で推定できる	**摂動核**

→ ゴール：分布を合わせる問題を「ノイズ付きの $\mathbf{x}_i$ から平均を当てる回帰」にする（2.2.4 で ε-予測へ）

2.2.3 逆向きの遷移もガウス分布でモデル化する

定理 2.2.1（勾配レベルの同値性）と補題 2.2.2（目標はガウス分布）から，モデルもガウス分布にする．

定義（DDPM の逆向きの遷移のモデル）

$$p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i) := \mathcal{N}\big(\mathbf{x}_{i-1}; \boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I}\big) \tag{2.2.5}$$

$\boldsymbol{\mu}_{\boldsymbol{\phi}}(\cdot, i) : \mathbb{R}^D \to \mathbb{R}^D$ は学習する平均の関数，分散 $\sigma^2(i) > 0$ は式 (2.2.4) の値に固定する．

- これは**逆遷移（1 ステップぶんのノイズ除去）のモデル**で，DDPM の「デコーダ」にあたる．$\mathbf{x}_i$ を入れると 1 段きれいな $\mathbf{x}_{i-1}$ の分布を返す
- 学習するのは平均 $\boldsymbol{\mu}_{\boldsymbol{\phi}}$ だけ．時刻 i も入力にした **1 つのネットワーク**をすべてのステップで共有する
- 入力は $\mathbf{x}_i$ と i だけで $\mathbf{x}_0$ **は使わない**（生成のときは答えがわからないから）

	式	役割
真の逆遷移	$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$	本当に学びたいもの（計算できない）
条件付きの逆遷移	$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$	学習の目標（閉じた形，補題 2.2.2）
逆遷移のモデル	$p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$	学習するもの．目標に合わせて訓練し，生成で使う

勾配レベルの同値性：条件付きの KL で学習できる

定理 2.2.1 より，2 つの目的関数は ϕ によらない定数 C だけ違う：

$$\underbrace{\mathbb{E}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{c}} \parallel p_{\phi}\right)\right]}_{\text{条件付き（計算できる）}} = \underbrace{\mathbb{E}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_{\phi}\right)\right]}_{\text{周辺（計算できない）}} + C$$

両辺を ϕ で微分すると C が消え，**勾配がまったく同じ**になる：

$$\nabla_{\phi}\mathbb{E}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{c}} \parallel p_{\phi}\right)\right] = \nabla_{\phi}\mathbb{E}\left[\mathcal{D}_{\mathrm{KL}}\left(p_{\mathrm{m}} \parallel p_{\phi}\right)\right]$$

$\rightarrow$ 計算できる条件付きの KL で勾配法を回せば，本当の目標と同じ方向に更新され，最適解も同じ．
そこで時刻をまたいで

$$\mathcal{L}_{\text{diffusion}}(\mathbf{x}_0;\boldsymbol{\phi}) := \sum_{i=2}^{L} \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}\left[\mathcal{D}_{\mathrm{KL}}\left(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \parallel p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\right)\right] \tag{2.2.6}$$

とおく．

注意：一致するのは期待値としての勾配．ミニバッチでは 1 つの x_i に 1 つの x_0 しか使わないので推定値のばらつきは大きめだが，平均すれば正しい勾配（不偏）

式 (2.2.6) の読み方（補足）

$$\mathcal{L}_{\text{diffusion}}(\mathbf{x}_0;\phi)=\sum_{i=2}^{L}\underbrace{\mathbb{E}_{p_i(\mathbf{x}_i\mid\mathbf{x}_0)}}_{\text{③ 壊し方について平均}}\Bigg[\underbrace{\mathcal{D}_{\text{KL}}\Bigg(\underbrace{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)}_{\text{① 正解の 1 歩}}\,\Big\|\,\underbrace{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}_{\text{② モデルの 1 歩}}\Bigg)}_{\text{④ 1 歩のずれ}}\Bigg]$$

きれいなデータ $\mathbf{x}_0$ を 1 つ固定して，内側から読む：

1. **正解の 1 歩**：答え $\mathbf{x}_0$ を知っているときの「$\mathbf{x}_i$ から 1 歩戻る」分布（補題 2.2.2 のガウス）
2. **モデルの 1 歩**：答えを知らないモデルが予想する「1 歩戻る」分布
3. **1 歩のずれ**：その 2 つの KL．モデルの 1 歩がどれだけ正解からずれているか
4. **壊し方について平均**：$\mathbf{x}_0$ を i 段壊してできる $\mathbf{x}_i$ はノイズ次第でいろいろ．それらについて平均する
5. **全ステップで足す**：$i=2,\ldots,L$ のすべての段のずれを足し合わせる

一言で：各時刻（ステップ）での 1 歩のずれ（KL）の平均を，全時刻について足し合わせたもの． さらに $\mathbf{x}_0\sim p_{\text{data}}$ で平均すると DDPM の学習目的になる（式 (2.2.8)）．

$i=1$（$\mathbf{x}_1\to\mathbf{x}_0$）の項は和に入らず，2.2.5 の ELBO で「再構成項」として別に扱う．$\mathcal{L}_{\text{diffusion}}$ が ELBO の一部であることも 2.2.5 で示される

DDPM の学習目的：平均の回帰

式 (2.2.6) の各項は，分散が同じ $\sigma^2(i)\mathbf{I}$ のガウス分布どうしの KL．このとき KL は平均の二乗誤差になる：

$$\mathcal{D}_{\mathrm{KL}}(\mathcal{N}(\boldsymbol{\mu}_1, \sigma^2\mathbf{I}) \parallel \mathcal{N}(\boldsymbol{\mu}_2, \sigma^2\mathbf{I})) = \frac{1}{2\sigma^2}\|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2$$

（一般のガウスの KL の公式で共分散を同じにすると，平均の項だけが残る）．よって DDPM の学習目的は

$$\mathcal{L}_{\mathrm{DDPM}}(\boldsymbol{\phi}) := \sum_{i=2}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)} \left[\left\| \boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 \right] \tag{2.2.8}$$

意図：分布を合わせる問題が，「ノイズ付きの $\mathbf{x}_i$ を見て，目標の平均 $\boldsymbol{\mu}$ を当てる」**回帰問題**になった．

摂動核が学習を速くする：時刻 i を選んだら $\mathbf{x}_i$ を $\mathbf{x}_0$ から直接作れるので，各項は「きれいなサンプル 1 つ，時刻 1 つ，壊したサンプル 1 つ」で推定できる． ※ 本文の式 (2.2.7) では一般の定数 C を書いているが，ここでは $C = 0$

KL が平均の二乗誤差になる式変形（1）（補足）

命題

分散が同じ等方ガウス $p_1 = \mathcal{N}(\boldsymbol{\mu}_1, \sigma^2 \mathbf{I})$，$p_2 = \mathcal{N}(\boldsymbol{\mu}_2, \sigma^2 \mathbf{I})$（$D$ 次元）に対し

$$\mathcal{D}_{\mathrm{KL}}(p_1 \parallel p_2) = \frac{1}{2\sigma^2} \|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2$$

証明（対数密度から直接計算）

$$\log p_k(\mathbf{x}) = -\frac{D}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2$$

等方ガウスの密度の対数（$k = 1, 2$）

$$\log \frac{p_1}{p_2} = \frac{1}{2\sigma^2} \left(\|\mathbf{x} - \boldsymbol{\mu}_2\|^2 - \|\mathbf{x} - \boldsymbol{\mu}_1\|^2 \right)$$

分散が同じなので正規化定数 $-\frac{D}{2} \log(2\pi\sigma^2)$ が打ち消し合う

KL が平均の二乗誤差になる式変形（2）（補足）

証明（続き）

$\mathbf{x} - \boldsymbol{\mu}_2 = (\mathbf{x} - \boldsymbol{\mu}_1) + (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ と分けて展開する：

$$\|\mathbf{x} - \boldsymbol{\mu}_2\|^2 = \|\mathbf{x} - \boldsymbol{\mu}_1\|^2 + 2(\mathbf{x} - \boldsymbol{\mu}_1)^\top(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) + \|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2$$

$\|a + b\|^2 = \|a\|^2 + 2a^\top b + \|b\|^2$

$$\log \frac{p_1}{p_2} = \frac{1}{2\sigma^2}\left(2(\mathbf{x} - \boldsymbol{\mu}_1)^\top(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) + \|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2\right)$$

(1) の式に代入．$\|\mathbf{x} - \boldsymbol{\mu}_1\|^2$ が打ち消し合う

$$\mathcal{D}_{\mathrm{KL}}(p_1 \parallel p_2) = \mathbb{E}_{p_1}\left[\log \frac{p_1}{p_2}\right]$$

KL の定義（$\mathbf{x} \sim p_1$ で平均）

$$= \frac{1}{2\sigma^2}\left(2\underbrace{\left(\mathbb{E}_{p_1}[\mathbf{x}] - \boldsymbol{\mu}_1\right)}_{=\mathbf{0}}^\top(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) + \|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2\right)$$

期待値の線形性．$\boldsymbol{\mu}_1, \boldsymbol{\mu}_2$ は定数

$$= \frac{1}{2\sigma^2}\|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2$$

$\mathbb{E}_{p_1}[\mathbf{x}] = \boldsymbol{\mu}_1$ なので交差項は 0

■

KL が平均の二乗誤差になる式変形（3）（補足）

証明（別解：一般のガウスの KL の公式から）

多次元ガウスの KL の公式（No.3 の補足）：

$$\mathcal{D}_{\mathrm{KL}}(\mathcal{N}(\boldsymbol{\mu}_1,\Sigma_1)\,\|\,\mathcal{N}(\boldsymbol{\mu}_2,\Sigma_2)) = \frac{1}{2}\left[\mathrm{tr}(\Sigma_2^{-1}\Sigma_1) + (\boldsymbol{\mu}_2-\boldsymbol{\mu}_1)^\top\Sigma_2^{-1}(\boldsymbol{\mu}_2-\boldsymbol{\mu}_1) - D + \log\frac{\det\Sigma_2}{\det\Sigma_1}\right]$$

$\Sigma_1 = \Sigma_2 = \sigma^2\mathbf{I}$ を代入すると：

$$\mathrm{tr}\big(\Sigma_2^{-1}\Sigma_1\big) = \mathrm{tr}(\mathbf{I}) = D$$

$\Sigma_2^{-1}\Sigma_1 = (\mathbf{I}/\sigma^2)(\sigma^2\mathbf{I}) = \mathbf{I}$

$$(\boldsymbol{\mu}_2-\boldsymbol{\mu}_1)^\top\Sigma_2^{-1}(\boldsymbol{\mu}_2-\boldsymbol{\mu}_1) = \frac{1}{\sigma^2}\|\boldsymbol{\mu}_1-\boldsymbol{\mu}_2\|^2$$

マハラノビス距離が通常の距離の $1/\sigma^2$ 倍になる

$$\log\frac{\det\Sigma_2}{\det\Sigma_1} = \log 1 = 0$$

共分散が同じ

$$\mathcal{D}_{\mathrm{KL}} = \frac{1}{2}\left[D + \frac{1}{\sigma^2}\|\boldsymbol{\mu}_1-\boldsymbol{\mu}_2\|^2 - D + 0\right]$$

3 つを公式に代入

$$= \frac{1}{2\sigma^2}\|\boldsymbol{\mu}_1-\boldsymbol{\mu}_2\|^2$$

D が打ち消し合い，平均の項だけが残る

■

KL が平均の二乗誤差になる式変形（4）：式 (2.2.8) へ（補足）

証明（式 (2.2.6) に当てはめる）

$$p_{\mathrm{c}} := p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) = \mathcal{N}\big(\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i), \sigma^2(i)\mathbf{I}\big)$$

$$p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = \mathcal{N}\big(\boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I}\big)$$

補題 2.2.2：$\boldsymbol{\mu}_1 = \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)$
式 (2.2.5)：$\boldsymbol{\mu}_2 = \boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$．分散は同じ $\sigma^2(i)$

$$\mathcal{D}_{\mathrm{KL}}\big(p_{\mathrm{c}} \parallel p_{\boldsymbol{\phi}}\big) = \frac{1}{2\sigma^2(i)} \big\| \boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \big\|^2$$

命題を適用．$\|\boldsymbol{a} - \boldsymbol{b}\| = \|\boldsymbol{b} - \boldsymbol{a}\|$

$$\mathbb{E}_{\mathbf{x}_0}[\mathcal{L}_{\mathrm{diffusion}}] = \sum_{i=2}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)} \Big[\big\| \boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu} \big\|^2 \Big]$$

式 (2.2.6) の各項に代入し $\mathbf{x}_0 \sim p_{\mathrm{data}}$ で平均．これが式 (2.2.8) の $\mathcal{L}_{\mathrm{DDPM}}$

■

ポイント：モデルの分散を目標と同じ $\sigma^2(i)$ に固定した（式 (2.2.5)）から，KL のずれは「平均のずれ」だけになる

閉じた形の目的関数：式 (2.2.7)・(2.2.8)

式 (2.2.6) の 2 つの分布はどちらもガウスで，パラメータ化は式 (2.2.5)．そのため目的関数は**閉じた形**で書け，次のように簡単になる：

$$\mathcal{L}_{\text{diffusion}}(\mathbf{x}_0;\boldsymbol{\phi}) = \sum_{i=2}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)} \left[\left\| \boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 \right] + C \tag{2.2.7}$$

ここで C は ϕ によらない定数．データ分布で平均し，最適化に影響しない定数 C を落とすと，**DDPM の最終的な学習目的**は

$$\mathcal{L}_{\text{DDPM}}(\boldsymbol{\phi}) := \sum_{i=2}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)} \left[\left\| \boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 \right], \quad \mathbf{x}_0 \sim p_{\text{data}} \tag{2.2.8}$$

順方向の摂動核 $p_i(\mathbf{x}_i \mid \mathbf{x}_0)$ の計算上の役割：

- $p_i(\mathbf{x}_i \mid \mathbf{x}_0)$ は，きれいな $\mathbf{x}_0$ から順方向に i ステップ進めたノイズ付きの状態 $\mathbf{x}_i$ の分布
- 各遷移は線形かつガウスなので，それらの合成も閉じた形のガウス分布になる（式 (2.2.1) 周辺の議論）
- よって時刻 i を選んだら，途中の $\mathbf{x}_1, \ldots, \mathbf{x}_{i-1}$ を作らずに $\mathbf{x}_0$ から直接 $\mathbf{x}_i \sim p_i(\mathbf{x}_i \mid \mathbf{x}_0)$ をサンプルできる
- 各損失項は「きれいなサンプル 1 つ，選んだ時刻 1 つ，直接壊したサンプル 1 つ」だけで推定でき，確率的な学習が計算上効率的になる

式 (2.2.8) の読み方（補足）

$$\mathcal{L}_{\mathrm{DDPM}}(\boldsymbol{\phi}) = \sum_{i=2}^{L} \underbrace{\frac{1}{2\sigma^2(i)}}_{\text{④ 時刻ごとの重み}} \underbrace{\mathbb{E}_{\mathbf{x}_0 \sim p_{\mathrm{data}}}}_{\text{③ データで平均}} \underbrace{\mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}}_{\text{② 壊し方で平均}} \left[\left\| \underbrace{\boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)}_{\text{① モデルの予測}} - \underbrace{\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)}_{\text{① 正解（目標の平均）}} \right\|_2^2 \right]$$

1. **予測と正解**：モデルは $\mathbf{x}_i$ と i だけを見て平均を予測．正解は $\mathbf{x}_0$ も使える補題 2.2.2 の平均．その二乗誤差
2. **壊し方で平均**：同じ $\mathbf{x}_0$ でもノイズ次第で $\mathbf{x}_i$ はいろいろ．それらについて平均
3. **データで平均**：式 (2.2.6) は $\mathbf{x}_0$ を 1 つ固定した損失．それを $\mathbf{x}_0 \sim p_{\mathrm{data}}$ で平均して，$\mathbf{x}_0$ によらない目的関数にする
4. **重み $1/(2\sigma^2(i))$**：KL から自然に出る係数．分散 $\sigma^2(i)$ が小さい時刻ほど，同じずれでも重く数える
5. **全ステップで足す**：$i = 2, \ldots, L$ のすべての時刻を 1 つのネットワーク $\boldsymbol{\mu}_{\boldsymbol{\phi}}(\cdot, i)$ で同時に学習する

一言で：「ノイズ付きの $\mathbf{x}_i$ を見て，1 歩戻った先の平均を当てる」**重み付き最小二乗（回帰）**を，全データ・全ノイズ・全時刻で平均したもの．

本文の式 (2.2.7) では $\mathcal{L}_{\mathrm{diffusion}} = \sum(\cdots) + C$ と定数 C を書き，式 (2.2.8) ではそれを落としている．C は ϕ によらないので最適化に影響しない

式 (2.2.8) の最小化：何を学び，どう計算するか（補足）

最適解は「正解の平均の平均」：時刻 i ごとに見ると「$\mathbf{x}_i$ から目標を当てる最小二乗」なので，最適解は条件付き期待値になる：

$$\boldsymbol{\mu}^*_\phi(\mathbf{x}_i, i) = \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)}[\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)]$$

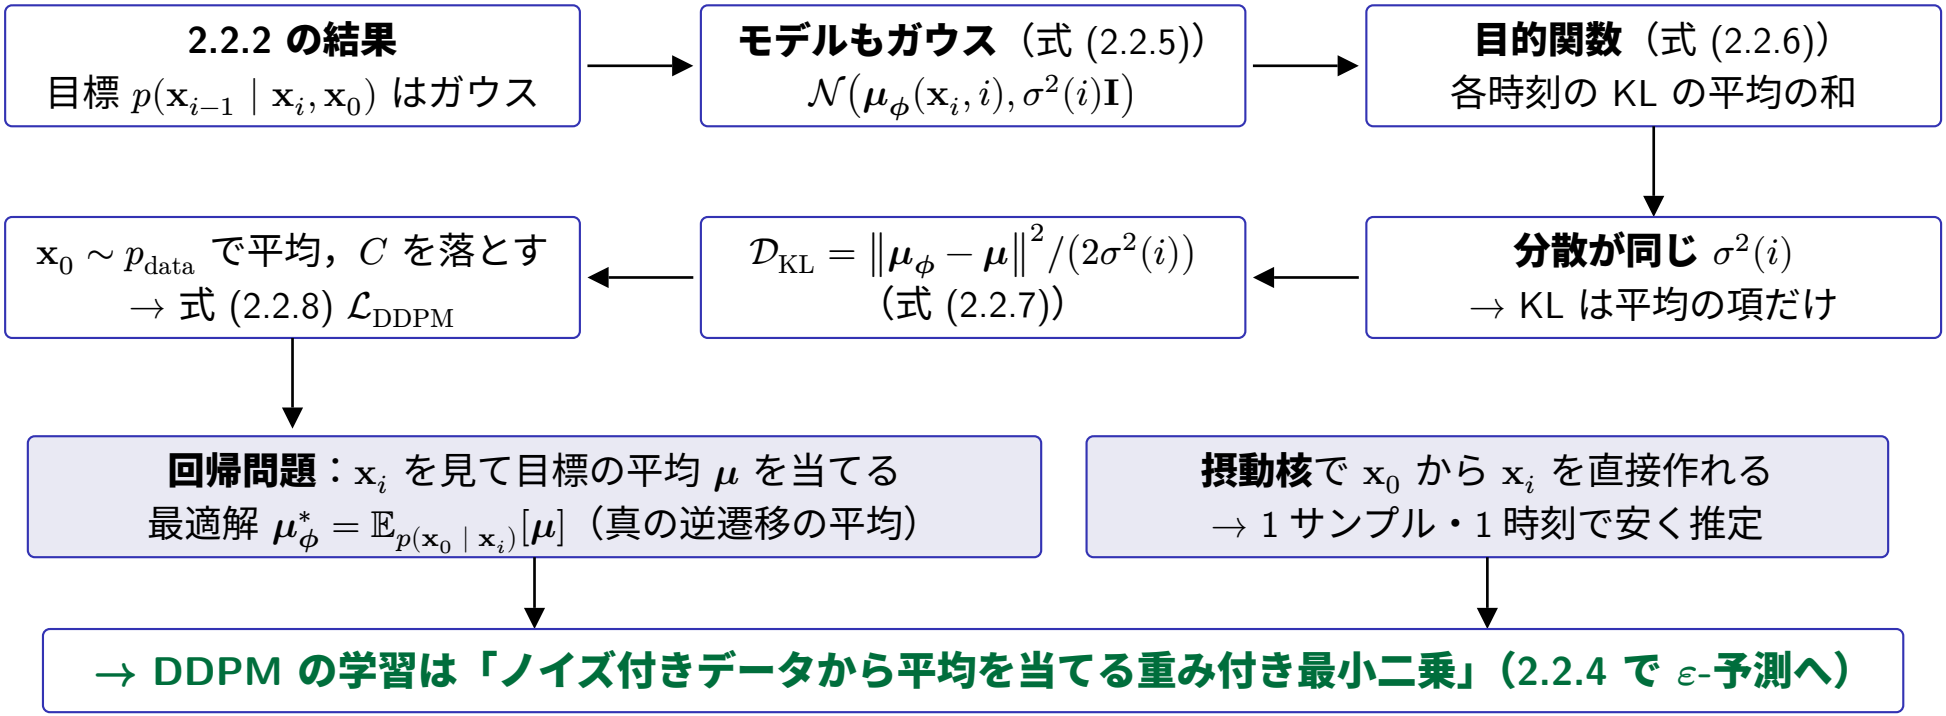
- $\mathbf{x}_i$ だけでは $\mathbf{x}_0$ は 1 つに決まらないので，ありうる $\mathbf{x}_0$ について正解の平均を平均したものが最良の予測
- これは真の逆遷移 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ の平均に一致する（$p_{\mathrm{m}} = \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_i)}[p_{\mathrm{c}}]$，定理 2.2.1）

1 回の更新での計算（確率的勾配法）：期待値をサンプル 1 つで置き換える

手順	内容
1	データ $\mathbf{x}_0 \sim p_{\mathrm{data}}$ と時刻 $i \sim \mathrm{Uniform}\{2, \dots, L\}$ を選ぶ
2	摂動核で $\mathbf{x}_i \sim p_i(\mathbf{x}_i \mid \mathbf{x}_0)$ を**直接**作る（$\mathbf{x}_1, \dots, \mathbf{x}_{i-1}$ を経由しなくてよい）
3	正解 $\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)$ を補題 2.2.2 の式で計算し，予測 $\boldsymbol{\mu}_\phi(\mathbf{x}_i, i)$ との重み付き二乗誤差を求める
4	その勾配で ϕ を更新する（期待値としては正しい勾配：不偏推定）

和 $\sum_{i=2}^{L}$ は「i を一様に選んで $L-1$ 倍」と同じなので，ランダムな i 1 つで推定できる

2.2.3 のまとめ（1）：KL から回帰へ（補足）



2.2.3 のまとめ（2）：押さえておくこと（補足）

一言で

逆遷移のモデルを「分散を固定したガウス」にしたことで，分布を合わせる問題が平均の回帰になった．

- **モデルの形**：$p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = \mathcal{N}\big(\boldsymbol{\mu}_\phi(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I}\big)$．学ぶのは平均だけ，入力は $\mathbf{x}_i$ と i（$\mathbf{x}_0$ は使わない）
- **なぜ条件付きの KL でよいか**：定理 2.2.1 より勾配が本当の目標と同じ（勾配レベルの同値性）
- **なぜ二乗誤差になるか**：分散が同じガウスどうしの KL は $1/(2\sigma^2)\|\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2\|^2$
- **何を学ぶか**：最適な $\boldsymbol{\mu}_\phi$ は，ありうる $\mathbf{x}_0$ についての目標の平均の平均 ＝ 真の逆遷移の平均
- **なぜ速く学べるか**：途中の $\mathbf{x}_1, \ldots, \mathbf{x}_{i-1}$ を作らずに $\mathbf{x}_i$ を直接サンプルできる

まだ残っていること：和が $i = 2$ から始まる理由（$i = 1$ は再構成項）と，$\mathcal{L}_{\mathrm{DDPM}}$ が ELBO・最尤推定とつながること $\rightarrow$ 2.2.5

2.2 DDPM：変分的な視点

- 2.2.1 順方向過程（固定したエンコーダ）
- 2.2.2 逆方向のノイズ除去過程（学習するデコーダ）
- 2.2.3 逆向きの遷移核のモデル化
- **2.2.4 予測と損失の実際的な選び方**
- 2.2.5 DDPM の ELBO
- 2.2.6 サンプリング

2.2.4 の流れ：どの順で何を決めるか（補足）

2.2.3 で学習は「平均 $\boldsymbol{\mu}$ を当てる回帰」（式 (2.2.8)）になった．2.2.4 では，実装で**何を予測させるか**を決める．

問 1 平均はノイズで書ける？	$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\boldsymbol{\varepsilon}$ を使い $\mathbf{x}_0$ を消す $\rightarrow \boldsymbol{\mu} = (\mathbf{x}_i - c_i\boldsymbol{\varepsilon})/\alpha_i$	**(2.2.9)**
問 2 損失はどうなる？	$\mathbf{x}_i$ が消えてノイズの二乗誤差になる （$\boldsymbol{\varepsilon}$-予測，重みは時刻だけで決まる）	**$\boldsymbol{\varepsilon}$-予測**
問 3 重みは必要？	目標 $\boldsymbol{\varepsilon}$ の大きさはどの時刻でも同じ $\rightarrow$ 重みを外した $\mathcal{L}_{\text{simple}}$	**(2.2.10)**
問 4 最適解は変わる？	変わらない．どちらも $\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$ （時刻ごとの最小二乗の最小解）	**命題**
問 5 他の予測は？	x-予測：最適解 $\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$ $\boldsymbol{\varepsilon}$-予測とは式 (2.2.12) で結ばれる	**(2.2.11)**

$\rightarrow$ ゴール：何を予測するかは書き方の違いで，中身はどれも同じ（実装では $\boldsymbol{\varepsilon}$-予測と $\mathcal{L}_{\text{simple}}$）

2.2.4 ε-予測：平均をノイズで書き直す

実装では，平均を直接予測する代わりに，同値な**ノイズ予測**（ε-予測）を使うことが多い．

命題

$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\varepsilon}$（式 (2.2.9)）のとき，式 (2.2.4) の平均は

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) = \frac{1}{\alpha_i}\left(\mathbf{x}_i - \frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\boldsymbol{\varepsilon}\right)$$

理由：式 (2.2.9) を $\mathbf{x}_0 = \left(\mathbf{x}_i - \sqrt{1-\bar{\alpha}_i^2}\boldsymbol{\varepsilon}\right)/\bar{\alpha}_i$ と解いて式 (2.2.4) に代入し，$\alpha_i^2 + \beta_i^2 = 1$ で整理する．

意図：目標の平均は「今の $\mathbf{x}_i$ から，加えられたノイズ $\boldsymbol{\varepsilon}$ を適量引いて少し拡大したもの」． $\mathbf{x}_i$ は手元にあるので，未知なのはノイズ $\boldsymbol{\varepsilon}$ だけ．だからネットワークには $\boldsymbol{\varepsilon}$ を当てさせればよい．

※ 「理由」「意図」は補足

式 (2.2.4) の平均をノイズで書き直す（1）：$\mathbf{x}_0$ を消す（補足）

証明（準備と代入）

使う関係：$\bar{\alpha}_i = \alpha_i \bar{\alpha}_{i-1}$ $(\bar{\alpha}_i = \prod_{k=1}^{i} \alpha_k)$，$\alpha_i^2 + \beta_i^2 = 1$

$$\boldsymbol{\mu} = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}\mathbf{x}_0 + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}\mathbf{x}_i$$

式 (2.2.4) の平均

$$\mathbf{x}_0 = \frac{\mathbf{x}_i - \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\varepsilon}}{\bar{\alpha}_i}$$

式 (2.2.9) を $\mathbf{x}_0$ について解く

$$\frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}\mathbf{x}_0 = \frac{\beta_i^2}{\alpha_i(1-\bar{\alpha}_i^2)}\left(\mathbf{x}_i - \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\varepsilon}\right)$$

代入．$\bar{\alpha}_{i-1}/\bar{\alpha}_i = 1/\alpha_i$

$$\boldsymbol{\mu} = \underbrace{\left[\frac{\beta_i^2}{\alpha_i(1-\bar{\alpha}_i^2)} + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}\right]}_{\text{(A)}}\mathbf{x}_i - \underbrace{\frac{\beta_i^2\sqrt{1-\bar{\alpha}_i^2}}{\alpha_i(1-\bar{\alpha}_i^2)}}_{\text{(B)}}\boldsymbol{\varepsilon}$$

$\mathbf{x}_i$ の項と $\boldsymbol{\varepsilon}$ の項に分けて集める

式 (2.2.4) の平均をノイズで書き直す（2）：係数を整理する（補足）

証明（続き）

(A)：$\mathbf{x}_i$ の係数

$$(\mathrm{A}) = \frac{\beta_i^2 + \alpha_i^2(1-\bar{\alpha}_{i-1}^2)}{\alpha_i(1-\bar{\alpha}_i^2)}$$

分母を $\alpha_i(1-\bar{\alpha}_i^2)$ にそろえて通分

$$= \frac{\beta_i^2 + \alpha_i^2 - \alpha_i^2\bar{\alpha}_{i-1}^2}{\alpha_i(1-\bar{\alpha}_i^2)} = \frac{1-\bar{\alpha}_i^2}{\alpha_i(1-\bar{\alpha}_i^2)} = \frac{1}{\alpha_i}$$

$\beta_i^2 + \alpha_i^2 = 1$，$\alpha_i^2\bar{\alpha}_{i-1}^2 = \bar{\alpha}_i^2$

(B)：$\boldsymbol{\varepsilon}$ の係数

$$(\mathrm{B}) = \frac{\beta_i^2}{\alpha_i\sqrt{1-\bar{\alpha}_i^2}} = \frac{1-\alpha_i^2}{\alpha_i\sqrt{1-\bar{\alpha}_i^2}}$$

$\sqrt{1-\bar{\alpha}_i^2}/(1-\bar{\alpha}_i^2) = 1/\sqrt{1-\bar{\alpha}_i^2}$，
$\beta_i^2 = 1-\alpha_i^2$

(A)，(B) を戻して $1/\alpha_i$ でくくると

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) = \frac{1}{\alpha_i}\left(\mathbf{x}_i - \frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\boldsymbol{\varepsilon}\right)$$

■

ε-予測では損失がノイズの二乗誤差になる

モデルの平均も同じ形にし，ノイズを予測するネットワーク $\boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$ で表す．

$$\boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) = \frac{1}{\alpha_i}\left(\mathbf{x}_i - \frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)\right)$$

目標の平均と引くと $\mathbf{x}_i$ の項は打ち消し合い，ノイズの差だけが残る：

$$\left\|\boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu}\right\|_2^2 = (\textbf{時刻 } i \textbf{ だけで決まる係数}) \times \left\|\boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \boldsymbol{\varepsilon}\right\|_2^2$$

よって平均の回帰は，時刻ごとの重みを除いて**ノイズの二乗誤差の回帰**と同じ．

直観：モデルは加えられたノイズを推定する「ノイズ探偵」．推定したノイズを引けば元に近づく．

※ 係数は $(1-\alpha_i^2)^2/(\alpha_i^2(1-\bar{\alpha}_i^2))$（補足）

平均の回帰がノイズの回帰になるしくみ（補足）

2 つの平均を同じ形にそろえる（$c_i := (1-\alpha_i^2)/\sqrt{1-\bar{\alpha}_i^2}$）：

$$\boldsymbol{\mu}_{\boldsymbol{\phi}} = \frac{1}{\alpha_i}\big(\mathbf{x}_i - c_i \boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)\big), \quad \boldsymbol{\mu} = \frac{1}{\alpha_i}(\mathbf{x}_i - c_i \boldsymbol{\varepsilon})$$

$$\boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu} = -\frac{c_i}{\alpha_i}\big(\boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \boldsymbol{\varepsilon}\big)$$

両方にある $\mathbf{x}_i/\alpha_i$ が打ち消し合う

$$\big\|\boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu}\big\|^2 = \underbrace{\frac{c_i^2}{\alpha_i^2}}_{\text{重み}} \big\|\boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \boldsymbol{\varepsilon}\big\|^2$$

二乗ノルムをとる．重み $c_i^2/\alpha_i^2 = (1-\alpha_i^2)^2/(\alpha_i^2(1-\bar{\alpha}_i^2))$

- 平均の差は**ノイズの予測誤差** $\boldsymbol{\varepsilon}_{\boldsymbol{\phi}} - \boldsymbol{\varepsilon}$ だけで書ける（$\mathbf{x}_i$ は両方に同じ形で入るので差に残らない）
- 前の係数は時刻 i だけで決まり，データにもパラメータ $\boldsymbol{\phi}$ にもよらない
- $\rightarrow$ 式 (2.2.8) の最小化 $=$ **時刻ごとの重み付きでノイズを当てる回帰**の最小化

直感：正解の平均は「手元の $\mathbf{x}_i$ からノイズ $\boldsymbol{\varepsilon}$ を適量引いたもの」．$\mathbf{x}_i$ はもうわかっているので，未知なのは $\boldsymbol{\varepsilon}$ だけ．だからネットワークには $\boldsymbol{\varepsilon}$ を当てさせればよい．

次：この重み c_i^2/α_i^2 も外したのが $\mathcal{L}_{\text{simple}}$（式 (2.2.10)）．外しても最適解は $\boldsymbol{\varepsilon}^* = \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$ のまま．変わるのはどの時刻を重く数えるかだけ

重みを外した損失 $\mathcal{L}_{\text{simple}}$ も同じ最適解をもつ

実際にはさらに重みを省き，広く使われる DDPM の損失

$$\mathcal{L}_{\text{simple}}(\phi) := \mathbb{E}_i \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}} \mathbb{E}_{\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\| \boldsymbol{\varepsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\varepsilon} \right\|_2^2 \right], \quad \mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\, \boldsymbol{\varepsilon} \tag{2.2.10}$$

を使う．目標のノイズはどの時刻でも分散 1 なので，損失の大きさが時刻をまたいで揃い，重み付けが要らない．

命題

$\mathcal{L}_{\text{DDPM}}$ と $\mathcal{L}_{\text{simple}}$ の最適解はどちらも $\boldsymbol{\varepsilon}^*(\mathbf{x}_i, i) = \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$.

理由：どちらも時刻ごとの「$\mathbf{x}_i$ から $\boldsymbol{\varepsilon}$ を当てる最小二乗問題」の和で，重みが違うだけ． 二乗誤差の最適な予測は条件付き期待値で，正の重みは時刻ごとの最適解を変えない（証明は次の 2 枚）.

直感：$\boldsymbol{\varepsilon}_\phi$ は $\mathbf{x}_i$ を作るために加えられたノイズを推定する．$\mathbf{x}_i$ だけでは元のきれいなサンプルは 1 つに決まらないが，最適な状態では推定値は本当のノイズの条件付き期待値 $\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$ に一致する.

脚注 3：重みを外すとどのノイズの強さを重視するかが変わり，最適化や性能には影響しうる（理想的な予測は同じ）

命題の証明（1）：時刻ごと・$\mathbf{x}_i$ ごとの問題に分ける（補足）

証明（$\mathcal{L}_{\mathrm{DDPM}}$ と $\mathcal{L}_{\mathrm{simple}}$ の最適解）

どちらも正の重み w_i をもつ形 $\sum_i w_i J_i(\phi)$ に書ける：

$$J_i(\phi) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\varepsilon}}\left[\left\|\boldsymbol{\varepsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\varepsilon}\right\|^2\right], \quad \mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\varepsilon}$$

J_i：**時刻 i だけの損失**（記号はこの証明のために導入）

重み：$\mathcal{L}_{\mathrm{simple}}$ は w_i が一定，$\mathcal{L}_{\mathrm{DDPM}}$ は $w_i = c_i^2/(2\sigma^2(i)\alpha_i^2)$

$$J_i(\phi) = \mathbb{E}_{\mathbf{x}_i \sim p_i}\left[\mathbb{E}_{\boldsymbol{\varepsilon} \mid \mathbf{x}_i}\left[\left\|\boldsymbol{\varepsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\varepsilon}\right\|^2 \mid \mathbf{x}_i\right]\right]$$

各 $(\mathbf{x}_i, i)$ で内側を最小にすれば J_i も最小

$\arg\min_\phi \sum_i w_i J_i =$ **各 J_i の最小解**

入れ子の期待値：外で $\mathbf{x}_i$，内で $\mathbf{x}_i$ を固定した ε について平均
入力 $(\mathbf{x}_i, i)$ ごとに別の値を出せる（表現力が十分）

$w_i > 0$ は最小点を動かさない

命題の証明（2）：二乗誤差の最小解は条件付き期待値（補足）

証明（続き：$\mathbf{x}_i$ を固定した内側の問題）

$\mathbf{x}_i$ を固定し，$\boldsymbol{a} := \varepsilon_\phi(\mathbf{x}_i, i)$（定数ベクトル），$\boldsymbol{m} := \mathbb{E}[\varepsilon \mid \mathbf{x}_i]$ とおく．

$$\mathbb{E}\big[\|\boldsymbol{a} - \varepsilon\|^2 \mid \mathbf{x}_i\big] = \mathbb{E}\big[\|(\boldsymbol{a} - \boldsymbol{m}) - (\varepsilon - \boldsymbol{m})\|^2 \mid \mathbf{x}_i\big]$$

m を足して引く

$$= \|\boldsymbol{a} - \boldsymbol{m}\|^2 - 2(\boldsymbol{a} - \boldsymbol{m})^\top \underbrace{\mathbb{E}[\varepsilon - \boldsymbol{m} \mid \mathbf{x}_i]}_{=\mathbf{0}} + \mathbb{E}\big[\|\varepsilon - \boldsymbol{m}\|^2 \mid \mathbf{x}_i\big]$$

展開．$a - m$ は $\mathbf{x}_i$ を固定すれば定数なので期待値の外へ

$$= \underbrace{\|\boldsymbol{a} - \boldsymbol{m}\|^2}_{\phi \text{ による部分（非負）}} + \underbrace{\mathbb{E}\big[\|\varepsilon - \boldsymbol{m}\|^2 \mid \mathbf{x}_i\big]}_{\text{避けられない誤差}}$$

$\mathbb{E}[\varepsilon \mid \mathbf{x}_i] = m$ なので交差項は 0

よって $\boldsymbol{a} = \boldsymbol{m}$ で最小．すなわち $\mathcal{L}_{\text{DDPM}}$ と $\mathcal{L}_{\text{simple}}$ の最適解はともに

$$\varepsilon^*(\mathbf{x}_i, i) = \mathbb{E}[\varepsilon \mid \mathbf{x}_i]$$

■

No.3 の 2.1.4「条件付き平均が最適であることの証明」と同じ論法．本の命題 4.3.1（付録 D.2.6）・命題 6.3.1（付録 D.4.1）もこの論法を使う

式 (2.2.10) の読み方（補足）

$$\mathcal{L}_{\text{simple}}(\phi) = \underbrace{\mathbb{E}_{i}}_{\text{① 時刻を選ぶ}} \underbrace{\mathbb{E}_{\mathbf{x}_0 \sim p_{\text{data}}}}_{\text{② データを選ぶ}} \underbrace{\mathbb{E}_{\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})}}_{\text{③ ノイズを引く}} \left[\left\| \underbrace{\boldsymbol{\varepsilon}_{\phi}(\mathbf{x}_i, i)}_{\text{④ 混ぜたノイズの予想}} - \underbrace{\boldsymbol{\varepsilon}}_{\text{正解}} \right\|_2^2 \right]$$

1 回の計算は次の「ノイズ当てゲーム」：

1. **時刻 i をランダムに選ぶ**：壊し具合をランダムに決める
2. **データ $\mathbf{x}_0$ を 1 つ選ぶ**
3. **ノイズ $\boldsymbol{\varepsilon}$ を引く**：どの時刻でも同じ $\mathcal{N}(\mathbf{0}, \mathbf{I})$ から
4. **壊す**：$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\, \boldsymbol{\varepsilon}$（摂動核で一度に作れる）
5. **当てさせる**：$\mathbf{x}_i$ と i だけを見せて「どんなノイズを混ぜた？」と聞き，二乗誤差を罰する

時刻 i の役割：答えの形（標準ガウスのノイズ）はどの時刻でも同じ．i は「どれくらい壊れているか」を伝えるヒント．

繰り返すと「この壊れ方なら混ざったノイズはだいたいこれ」という見当 $\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$ が身につく．生成ではそれを引いて少し戻る操作を繰り返す

「どの時刻でも同じスケール」とは（補足）

目標の大きさが時刻によらない：目標 $\varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ は毎回同じ分布なので $\mathbb{E}\|\varepsilon\|_2^2 = D$（次元数）．何もわからず $\mathbf{0}$ と答えるだけでも損失は**どの時刻でもちょうど** D．損失の物差しが時刻をまたいで共通．

平均で測ると時刻ごとにばらばら：$\|\mu_\phi - \mu\|^2 = (c_i^2/\alpha_i^2)\|\varepsilon_\phi - \varepsilon\|^2$ の係数は β_i^2 程度と小さく，時刻で大きく変わる．

時刻 i	**2**	**100**	**500**
c_i^2/α_i^2	6.5×10^{-5}	4.2×10^{-5}	1.1×10^{-4}
ELBO の重み全体	0.60	0.010	0.006

$L = 1000$，β_i^2 を 10^{-4} から 0.02 へ線形に増やした場合（Ho et al., 2020 と同じ設定）．ELBO の重み全体 $= c_i^2/(2\sigma^2(i)\alpha_i^2)$

$\rightarrow$ 平均で学ぶと学ぶべき信号が小さすぎ（**消える**），時刻ごとに大きさも違う．ノイズで学べばどの時刻も「単位分散のノイズを出す」同じ仕事になり，重みで大きさを揃える必要がない．

注意：揃うのは目標の大きさ．到達できる最小の損失は時刻で違う（i が大きいと $\mathbf{x}_i \approx \varepsilon$ で当てやすく，i が小さいと難しい）

Another Equivalent Parametrization: x-Prediction

式 (2.2.4) から，もう 1 つの同値なパラメータ化が考えられる．x-**予測**（clean prediction）では，ノイズレベル i のノイズ付き入力 $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$ から，きれいな（ノイズを除いた）サンプルを予測するようにネットワーク $\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$ を学習する．逆向きの平均の式の本当のきれいなサンプル $\mathbf{x}_0$ を $\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$ に置き換えると，次のモデルになる：

$$\boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}\mathbf{x}_i$$

目標の平均と引くと $\mathbf{x}_i$ の項が消え，$\left\|\boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu}\right\|^2 \propto \left\|\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \mathbf{x}_0\right\|^2$．よって平均の回帰 (2.2.8) は

$$\mathbb{E}_i \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{\boldsymbol{\varepsilon}} \left[\omega_i \left\| \mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \mathbf{x}_0 \right\|_2^2 \right]$$

という「ノイズ付きの $\mathbf{x}_i$ からきれいな $\mathbf{x}_0$ を当てる」回帰（ノイズ除去）になる．$\omega_i > 0$ は時刻ごとに決まる**重み**．最適解は

$$\mathbf{x}^*(\mathbf{x}_i, i) = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i], \quad \mathbf{x}_i \sim p_i \tag{2.2.11}$$

※ 重み ω_i の導出は次のスライド，式 (2.2.11) の証明はその次のスライド（補足）

x-予測の損失を導く：平均の差を計算する（補足）

証明（平均の回帰から x-予測の回帰へ）

係数を $a_i := (\bar{\alpha}_{i-1}\beta_i^2)/(1-\bar{\alpha}_i^2)$，$b_i := ((1-\bar{\alpha}_{i-1}^2)\alpha_i)/(1-\bar{\alpha}_i^2)$ とおく．

$$\boldsymbol{\mu}_{\boldsymbol{\phi}} = a_i \mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) + b_i \mathbf{x}_i, \quad \boldsymbol{\mu} = a_i \mathbf{x}_0 + b_i \mathbf{x}_i$$

モデルと目標（式 (2.2.4)）

$$\boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu} = a_i \big(\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \mathbf{x}_0\big)$$

共通の $b_i \mathbf{x}_i$ が消える

$$\big\|\boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu}\big\|^2 = a_i^2 \big\|\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \mathbf{x}_0\big\|^2$$

a_i^2 は時刻だけで決まる

$$\frac{1}{2\sigma^2(i)}\big\|\boldsymbol{\mu}_{\boldsymbol{\phi}} - \boldsymbol{\mu}\big\|^2 = \underbrace{\frac{\bar{\alpha}_{i-1}^2 \beta_i^2}{2(1-\bar{\alpha}_{i-1}^2)(1-\bar{\alpha}_i^2)}}_{=:\omega_i} \big\|\mathbf{x}_{\boldsymbol{\phi}} - \mathbf{x}_0\big\|^2$$

$1/(2\sigma^2(i))$ を掛け，式 (2.2.4) の $\sigma^2(i)$ を代入

よって式 (2.2.8) は $\sum_{i=2}^{L} \omega_i \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{\boldsymbol{\varepsilon}} \Big[\big\|\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) - \mathbf{x}_0\big\|^2 \Big]$ となり，本文の $\mathbb{E}_i \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{\boldsymbol{\varepsilon}} \big[\omega_i \|\cdot\|^2\big]$ の形になる．■

$\sum_{i=2}^{L}$ と $\mathbb{E}_i$（i を一様に選ぶ）は定数倍 $L-1$ しか違わないので，その差は ω_i に含めてよい．ε-予測（「平均の回帰がノイズの回帰になるしくみ」）と同じく，$\mathbf{x}_i$ が消えて「予測したいものの差」だけが残る

式 (2.2.11) の証明：最適解は $\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$（補足）

証明（x-予測の最適解）

損失は $\sum_i \omega_i K_i(\phi)$，$K_i(\phi) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\varepsilon}}\left[\left\|\mathbf{x}_\phi(\mathbf{x}_i,i)-\mathbf{x}_0\right\|^2\right]$（$K_i$：時刻 i だけの損失）．

$\boldsymbol{a} := \mathbf{x}_\phi(\mathbf{x}_i,i)$，$\boldsymbol{m} := \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$ とおく．

$$K_i(\phi) = \mathbb{E}_{\mathbf{x}_i\sim p_i}\left[\mathbb{E}\left[\left\|\mathbf{x}_\phi(\mathbf{x}_i,i)-\mathbf{x}_0\right\|^2 \mid \mathbf{x}_i\right]\right]$$

入れ子の期待値

各 $(\mathbf{x}_i,i)$ で内側を最小にすればよい

入力ごとに別の値を出せる，$\omega_i>0$

$$\mathbb{E}\left[\left\|\boldsymbol{a}-\mathbf{x}_0\right\|^2 \mid \mathbf{x}_i\right] = \left\|\boldsymbol{a}-\boldsymbol{m}\right\|^2 + \mathbb{E}\left[\left\|\mathbf{x}_0-\boldsymbol{m}\right\|^2 \mid \mathbf{x}_i\right]$$

$\boldsymbol{m}$ を足して引く．交差項は 0

$$\mathbf{x}^*(\mathbf{x}_i,i) = \boldsymbol{m} = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$$

第 1 項が 0 になる所で最小

■

「命題の証明（1）（2）」（ε-予測）で $\boldsymbol{\varepsilon}$ を $\mathbf{x}_0$ に置き換えたもの．**意味**：$\mathbf{x}_i$ だけでは $\mathbf{x}_0$ は 1 つに決まらないので，最良の予測は「ありうる $\mathbf{x}_0$ の平均」．

本の参照先：命題 6.3.1（付録 D.4.1）は結果のみ，命題 4.3.1（付録 D.2.6）はスコアで同じ論法．No.3 の 2.1.4 とも同じ形

3 通りの予測は同じ情報を表す

x-予測と ε-予測は数学的に同値で，順方向の式で結ばれている．

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) + \sqrt{1-\bar{\alpha}_i^2}\, \boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i) \tag{2.2.12}$$

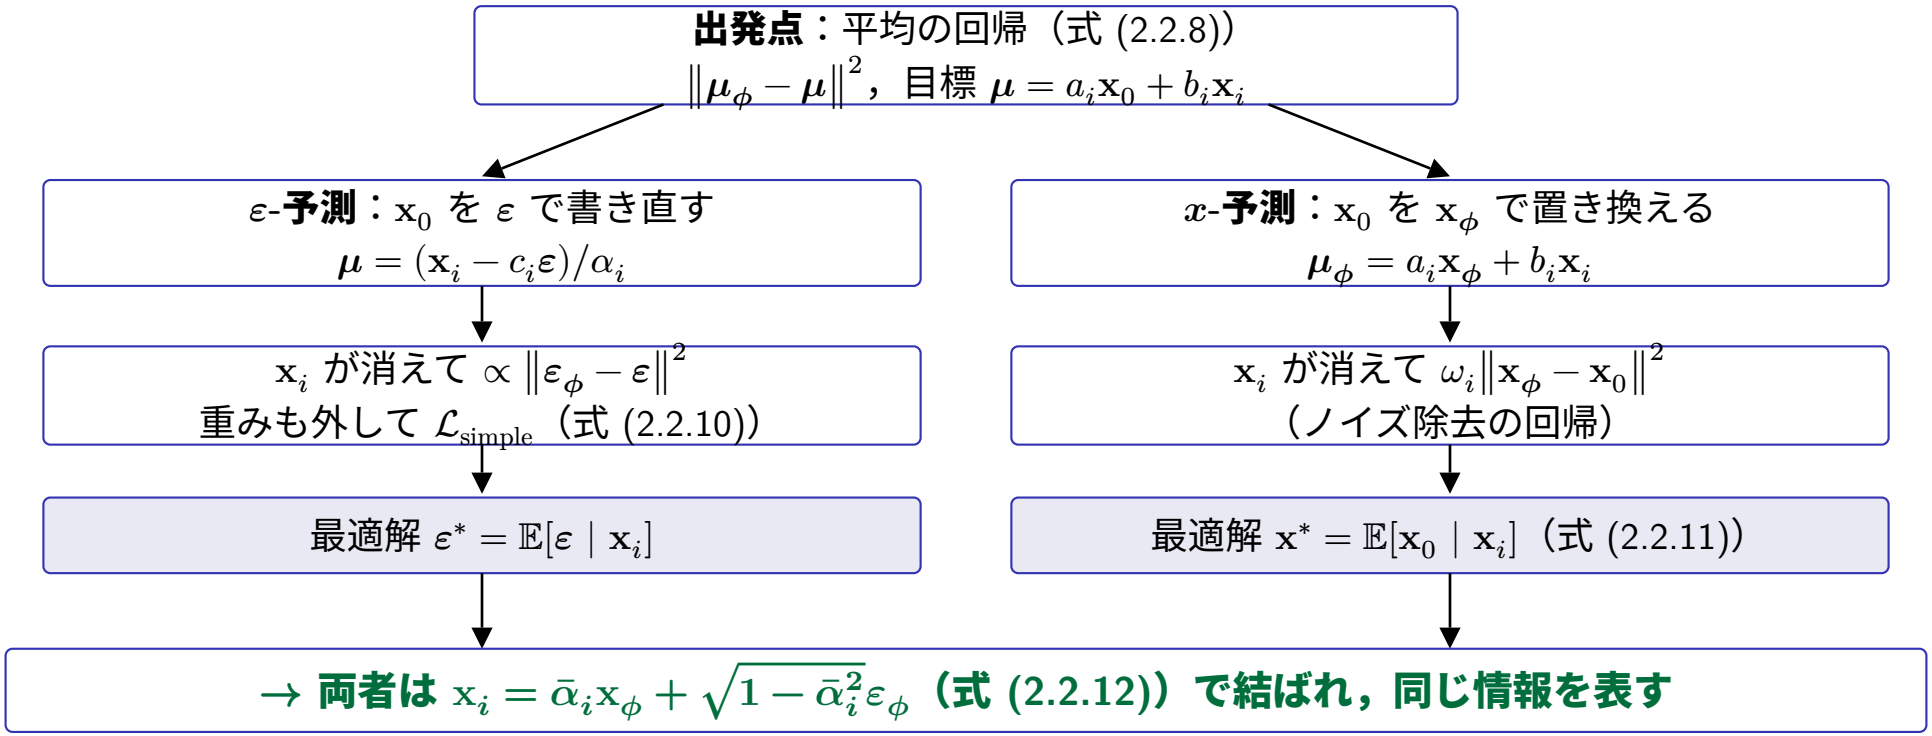
きれいなデータとノイズのどちらを予測しても，組み合わせると $\mathbf{x}_i$ が再現される．

予測するもの	**ネットワーク**	**最適解**
平均	$\boldsymbol{\mu}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$	$\mathbb{E}[\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \mid \mathbf{x}_i]$
ノイズ	$\boldsymbol{\varepsilon}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$	$\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$
きれいなデータ	$\mathbf{x}_{\boldsymbol{\phi}}(\mathbf{x}_i, i)$	$\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$

最適解どうしも整合している：$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\boldsymbol{\varepsilon}$ の両辺の $\mathbf{x}_i$ についての条件付き期待値をとると， 左辺は $\mathbf{x}_i$ のままなので $\mathbf{x}_i = \bar{\alpha}_i \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i] + \sqrt{1-\bar{\alpha}_i^2}\, \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$.

※ 表と最後の段落は補足（第 2 章の目標「3 通りの予測は同じノイズ除去の情報を表す」）

2.2.4 のまとめ（1）：平均の回帰から 3 通りの予測へ（補足）



a_i, b_i：式 (2.2.4) の平均の係数（「x-予測の損失を導く」），$c_i = (1-\alpha_i^2)/\sqrt{1-\bar{\alpha}_i^2}$（「平均の回帰がノイズの回帰になるしくみ」）

2.2.4 のまとめ（2）：押さえておくこと（補足）

一言で

何を予測するか（平均・ノイズ・きれいなデータ）は書き方の違いで，どれも「$\mathbf{x}_i$ から条件付き期待値を当てる重み付き最小二乗」．違うのは時刻ごとの重みだけ．

- **なぜ書き換えられるか**：$\mathbf{x}_i$ は手元にあるので，未知なのは $\boldsymbol{\varepsilon}$（または $\mathbf{x}_0$）だけ．差をとると $\mathbf{x}_i$ が消える
- **なぜ $\boldsymbol{\varepsilon}$-予測が使われるか**：目標 $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ の大きさがどの時刻でも同じで，重みを外した単純な二乗誤差 $\mathcal{L}_{\text{simple}}$ で学べる
- **重みを外してよいか**：最適解は変わらない（$\mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{x}_i]$）．変わるのはどの時刻を重視するかで，最適化や性能には影響しうる
- **最適解の意味**：$\mathbf{x}_i$ だけでは元は 1 つに決まらないので，ありうるノイズ（データ）の平均が最良の予測

次：$\mathcal{L}_{\text{DDPM}}$ が ELBO・最尤推定とどうつながるか $\rightarrow$ 2.2.5

2.2 DDPM：変分的な視点

- 2.2.1 順方向過程（固定したエンコーダ）
- 2.2.2 逆方向のノイズ除去過程（学習するデコーダ）
- 2.2.3 逆向きの遷移核のモデル化
- 2.2.4 予測と損失の実際的な選び方
- **2.2.5 DDPM の ELBO**
- 2.2.6 サンプリング

2.2.5 の流れ：どの順で何を示すか（補足）

2.2.3・2.2.4 で学習法（平均・ノイズの回帰）は決まった．2.2.5 では，それが**最尤推定に根拠づけられる**ことを示す．

問 1 生成モデルは何？	逆向きの遷移をつないだ同時分布 $p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})$ を周辺化した $p_\phi(\mathbf{x}_0)$	**定義**
問 2 尤度の下界は？	順方向をエンコーダとみてイェンセンの不等式 $\rightarrow -\log p_\phi(\mathbf{x}_0) \leq -\mathcal{L}_{\text{ELBO}}$	**(2.2.13)**
問 3 ELBO は何に分かれる？	$\mathcal{L}_{\text{prior}} + \mathcal{L}_{\text{recon.}} + \mathcal{L}_{\text{diffusion}}$ （順方向を逆向きに書き直すと現れる）	**定理 2.2.3**
問 4 各項はどう扱う？	prior は無視できる，recon. はモンテカルロ，diffusion は 2.2.3 の目的（式 (2.2.6)）そのもの	**3 つの項**
問 5 何が DDPM を楽にした？	順方向が固定で線形ガウスなので，各 KL が閉じた形の目標をもつ回帰になる	**Remark**

→ ゴール：2.2.3 の学習目的は ELBO の一部で，DDPM の学習は最尤推定の近似になっている

2.2.5 DDPM の ELBO：最尤推定との結びつき

定義（DDPM の生成モデル）

逆向きの遷移 (2.2.5) をつなげた同時分布と，データの周辺分布

$$p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L}) := p_\phi(\mathbf{x}_0 \mid \mathbf{x}_1)\, p_\phi(\mathbf{x}_1 \mid \mathbf{x}_2) \cdots p_\phi(\mathbf{x}_{L-1} \mid \mathbf{x}_L)\, p_{\text{prior}}(\mathbf{x}_L)$$

$$p_\phi(\mathbf{x}_0) := \int p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})\, \mathrm{d}\mathbf{x}_{1:L}$$

定理 2.2.3（DDPM の ELBO）

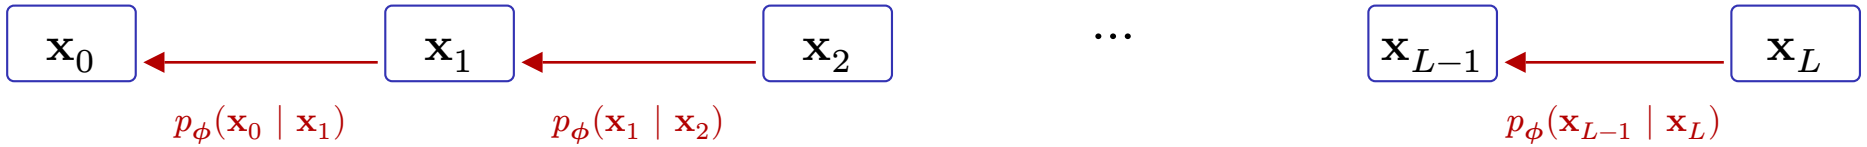
$$-\log p_\phi(\mathbf{x}_0) \le -\mathcal{L}_{\text{ELBO}}(\mathbf{x}_0; \phi) := \mathcal{L}_{\text{prior}}(\mathbf{x}_0) + \mathcal{L}_{\text{recon.}}(\mathbf{x}_0; \phi) + \mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \phi) \quad (2.2.13)$$

$$\mathcal{L}_{\text{prior}} := \mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_L \mid \mathbf{x}_0) \,\|\, p_{\text{prior}}(\mathbf{x}_L)\big), \quad \mathcal{L}_{\text{recon.}} := \mathbb{E}_{p(\mathbf{x}_1 \mid \mathbf{x}_0)}\big[-\log p_\phi(\mathbf{x}_0 \mid \mathbf{x}_1)\big]$$

$$\mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \phi) = \sum_{i=2}^{L} \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}\big[\mathcal{D}_{\text{KL}}\big(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \,\|\, p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\big)\big] \quad \textbf{(式 (2.2.6))}$$

式 (2.2.6) による学習は，VAE・HVAE と同じく対数尤度の下界の最大化として，最尤推定 (1.1.2) に厳密に根拠づけられる．

DDPM の生成モデルの定義を直感的に読む（補足）



同時分布 ＝ 1 本の生成の道筋の確率：

$$p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L}) = \underbrace{p_{\text{prior}}(\mathbf{x}_L)}_{\text{① ノイズから出発}} \times \underbrace{p_\phi(\mathbf{x}_{L-1} \mid \mathbf{x}_L) \cdots p_\phi(\mathbf{x}_1 \mid \mathbf{x}_2)}_{\text{② 1 歩ずつノイズ除去}} \times \underbrace{p_\phi(\mathbf{x}_0 \mid \mathbf{x}_1)}_{\text{③ 最後の 1 歩でデータ}}$$

- ノイズ $\mathbf{x}_L$ を引き，学習した逆遷移で 1 歩ずつ戻る（生成の手順そのもの，2.2.6）．各 1 歩は直前の状態だけで決まる（マルコフ）ので掛け算になる．HVAE のデコーダの分解と同じ形

周辺分布 ＝ どの道筋を通ってもよいので全部足す：$p_\phi(\mathbf{x}_0) = \int p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})\, \mathrm{d}\mathbf{x}_{1:L}$

- 「最終的にデータ $\mathbf{x}_0$ が出てくる確率」．途中の $\mathbf{x}_{1:L}$ がどうであったかは問わない．VAE の $p_\phi(\mathbf{x}) = \int p_\phi(\mathbf{x} \mid \mathbf{z}) p(\mathbf{z})\, \mathrm{d}\mathbf{z}$ で，潜在変数を $\mathbf{z} = \mathbf{x}_{1:L}$ にしたもの

サンプルを作るのは簡単（①→②→③と順に引く）だが，$p_\phi(\mathbf{x}_0)$ の値は高次元の積分で計算できない．だから VAE と同じく ELBO（下界）を使う → 定理 2.2.3

定理 2.2.3 の証明（1）：イェンセンで下界を作る（補足）

証明（付録 D.1.2 に沿って）

記号：$\mathbf{x}_{1:L} := (\mathbf{x}_1, \ldots, \mathbf{x}_L)$．順方向 $p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = \prod_{i=1}^{L} p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$ をエンコーダとして使う．

$$\log p_{\boldsymbol{\phi}}(\mathbf{x}_0) = \log \int p_{\boldsymbol{\phi}}(\mathbf{x}_0, \mathbf{x}_{1:L})\, \mathrm{d}\mathbf{x}_{1:L}$$

周辺化（生成モデルの定義）

$$= \log \int p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) \frac{p_{\boldsymbol{\phi}}(\mathbf{x}_0, \mathbf{x}_{1:L})}{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)}\, \mathrm{d}\mathbf{x}_{1:L}$$

$p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)/p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = 1$ を掛ける

$$= \log \mathbb{E}_{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)} \left[\frac{p_{\boldsymbol{\phi}}(\mathbf{x}_0, \mathbf{x}_{1:L})}{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)} \right]$$

積分を期待値として読む

$$\geq \mathbb{E}_{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)} \left[\log \frac{p_{\boldsymbol{\phi}}(\mathbf{x}_0, \mathbf{x}_{1:L})}{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)} \right] =: \mathcal{L}_{\mathrm{ELBO}}(\mathbf{x}_0; \boldsymbol{\phi})$$

イェンセンの不等式（log は凹関数）．VAE・HVAE（2.1 節）と同じ

両辺に -1 を掛けて $-\log p_{\boldsymbol{\phi}}(\mathbf{x}_0) \leq -\mathcal{L}_{\mathrm{ELBO}}(\mathbf{x}_0; \boldsymbol{\phi})$．

定理 2.2.3 の証明（2）：ELBO を展開すると向きがずれる（補足）

証明（続き）

生成側と順方向をそれぞれ積に分解する：

$$p_{\phi}(\mathbf{x}_0, \mathbf{x}_{1:L}) = p_{\text{prior}}(\mathbf{x}_L) \prod_{i=1}^{L} p_{\phi}(\mathbf{x}_{i-1} \mid \mathbf{x}_i), \quad p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = \prod_{i=1}^{L} p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$$

log をとると積は和になる（期待値は $\mathbb{E}_{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)}$）：

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}\left[\log p_{\text{prior}}(\mathbf{x}_L) + \sum_{i=1}^{L} \log p_{\phi}(\mathbf{x}_{i-1} \mid \mathbf{x}_i) - \sum_{i=1}^{L} \log p(\mathbf{x}_i \mid \mathbf{x}_{i-1})\right]$$

問題：生成側は「$\mathbf{x}_i \to \mathbf{x}_{i-1}$（逆向き）」，順方向は「$\mathbf{x}_{i-1} \to \mathbf{x}_i$（順向き）」．向きがそろわないので，このままでは項どうしを KL にまとめられない．

$\to$ 順方向の積を**逆向きの条件付き遷移の積**に書き直す（次のスライド）．

定理 2.2.3 の証明（3）：順方向を逆向きに書き直す（補足）

証明（補題：$p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = p(\mathbf{x}_L \mid \mathbf{x}_0) \prod_{i=2}^{L} p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$）

$$p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1}, \mathbf{x}_0) \quad (i \geq 2)$$

マルコフ性：$\mathbf{x}_{i-1}$ がわかれば $\mathbf{x}_0$ は余分

$$= \frac{p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)\, p(\mathbf{x}_i \mid \mathbf{x}_0)}{p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)}$$

$\mathbf{x}_0$ で条件付けたままベイズの定理

$$\prod_{i=2}^{L} p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) = \prod_{i=2}^{L} p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \cdot \frac{p(\mathbf{x}_L \mid \mathbf{x}_0)}{p(\mathbf{x}_1 \mid \mathbf{x}_0)}$$

分数 $p(\mathbf{x}_i \mid \mathbf{x}_0)/p(\mathbf{x}_{i-1} \mid \mathbf{x}_0)$ が隣どうしで約分（望遠鏡和）

$$p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = p(\mathbf{x}_1 \mid \mathbf{x}_0) \prod_{i=2}^{L} p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$$

$i = 1$ の因子だけ分ける

$$= p(\mathbf{x}_L \mid \mathbf{x}_0) \prod_{i=2}^{L} p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$$

上の積を代入．$p(\mathbf{x}_1 \mid \mathbf{x}_0)$ が分母と消える

これで順方向も「$\mathbf{x}_L$ から出発して逆向きにたどる」形になり，生成側と向きがそろう．

定理 2.2.3 の証明（4）：同じ向きどうしを組にする（補足）

証明（続き）

$$-\mathcal{L}_{\mathrm{ELBO}} = \mathbb{E}\big[\log p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) - \log p_{\boldsymbol{\phi}}(\mathbf{x}_0, \mathbf{x}_{1:L})\big]$$

(1) の定義の符号を反転

$$= \mathbb{E}\Bigg[\log p(\mathbf{x}_L \mid \mathbf{x}_0) + \sum_{i=2}^{L} \log p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$$

$$- \log p_{\mathrm{prior}}(\mathbf{x}_L) - \sum_{i=2}^{L} \log p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i) - \log p_{\boldsymbol{\phi}}(\mathbf{x}_0 \mid \mathbf{x}_1)\Bigg]$$

(3) の補題を代入．生成側は $i = 1$ の因子だけ別にする

$$= \mathbb{E}\Bigg[(\mathrm{a}) + \sum_{i=2}^{L} (\mathrm{b})_i + (\mathrm{c})\Bigg]$$

同じ変数・同じ向きの log どうしを組にする

$$(\mathrm{a}) = \log \frac{p(\mathbf{x}_L \mid \mathbf{x}_0)}{p_{\mathrm{prior}}(\mathbf{x}_L)}, \quad (\mathrm{b})_i = \log \frac{p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)}{p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)}, \quad (\mathrm{c}) = -\log p_{\boldsymbol{\phi}}(\mathbf{x}_0 \mid \mathbf{x}_1)$$

期待値はすべて $\mathbb{E}_{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)}$．各項を計算する（次のスライド）．

定理 2.2.3 の証明（5）：各項が 3 つの損失になる（補足）

証明（続き）

各項は一部の変数しか含まないので，ほかの変数は周辺化で消える．

$$\mathbb{E}[(\mathrm{a})] = \mathbb{E}_{p(\mathbf{x}_L \mid \mathbf{x}_0)}\left[\log \frac{p(\mathbf{x}_L \mid \mathbf{x}_0)}{p_{\text{prior}}(\mathbf{x}_L)}\right] = \mathcal{L}_{\text{prior}}(\mathbf{x}_0)$$

$\mathbf{x}_L$ だけを含む．KL の定義

$$\mathbb{E}[(\mathrm{c})] = \mathbb{E}_{p(\mathbf{x}_1 \mid \mathbf{x}_0)}\left[-\log p_{\boldsymbol{\phi}}(\mathbf{x}_0 \mid \mathbf{x}_1)\right] = \mathcal{L}_{\text{recon.}}(\mathbf{x}_0; \boldsymbol{\phi})$$

$\mathbf{x}_1$ だけを含む

$$\mathbb{E}[(\mathrm{b})_i] = \mathbb{E}_{p(\mathbf{x}_i \mid \mathbf{x}_0)}\mathbb{E}_{p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)}\left[\log \frac{p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)}{p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)}\right]$$

$(\mathbf{x}_{i-1}, \mathbf{x}_i)$ だけを含む．同時分布を $p(\mathbf{x}_i \mid \mathbf{x}_0)p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$ と分解

$$= \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}\left[\mathcal{D}_{\mathrm{KL}}\left(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \parallel p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)\right)\right]$$

内側は KL の定義

$$\sum_{i=2}^{L} \mathbb{E}[(\mathrm{b})_i] = \sum_{i=2}^{L} \mathbb{E}_{p_i(\mathbf{x}_i \mid \mathbf{x}_0)}[\mathcal{D}_{\mathrm{KL}}(\cdots)] = \mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \boldsymbol{\phi})$$

$i = 2, \ldots, L$ で足す（式 (2.2.6)）

よって $-\mathcal{L}_{\text{ELBO}} = \mathcal{L}_{\text{prior}} + \mathcal{L}_{\text{recon.}} + \mathcal{L}_{\text{diffusion}}$（式 (2.2.13)）．

■

ELBO の 3 つの項の役割

項	役割と扱い
$\mathcal{L}_{\text{prior}}$	ノイズスケジュール $\{\beta_i\}$ を $p(\cdot \mid \mathbf{x}_0) \approx p_{\text{prior}}$ となるように選べば無視できる（ϕ を含まない）
$\mathcal{L}_{\text{recon.}}$	モンテカルロ推定で近似・最適化できる（実装は Ho et al. 2020，Kingma et al. 2021）
$\mathcal{L}_{\text{diffusion}}$	すべてのステップ i で，逆向きの遷移 $p_{\boldsymbol{\phi}}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ を $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ に合わせる（式 (2.2.6)）

データ処理不等式による見方：潜在変数を $\mathbf{z} = \mathbf{x}_{1:L}$ とみると，式 (2.1.2) と同じく

$$\mathcal{D}_{\mathrm{KL}}\big(p_{\text{data}}(\mathbf{x}_0) \,\|\, p_{\boldsymbol{\phi}}(\mathbf{x}_0)\big) \leq \mathcal{D}_{\mathrm{KL}}\big(p(\mathbf{x}_0, \mathbf{x}_{1:L}) \,\|\, p_{\boldsymbol{\phi}}(\mathbf{x}_0, \mathbf{x}_{1:L})\big)$$

ここで $p(\mathbf{x}_0, \mathbf{x}_{1:L}) := p_{\text{data}}(\mathbf{x}_0) p(\mathbf{x}_1 \mid \mathbf{x}_0) \cdots p(\mathbf{x}_L \mid \mathbf{x}_{L-1})$ は順方向の過程に沿った同時分布．

$\mathcal{L}_{\text{prior}}$ はなぜ無視できるか（補足）

$p(\mathbf{x}_L \mid \mathbf{x}_0) = \mathcal{N}(\bar{\alpha}_L \mathbf{x}_0, (1-\bar{\alpha}_L^2)\mathbf{I})$ と $p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ の KL を，多次元ガウスの KL の公式（No.3）で計算する：

$$\begin{aligned}\mathcal{L}_{\text{prior}} &= \frac{1}{2}\left[D(1-\bar{\alpha}_L^2) + \bar{\alpha}_L^2 \|\mathbf{x}_0\|^2 - D - D\log(1-\bar{\alpha}_L^2)\right] \\ &= \frac{1}{2}\bar{\alpha}_L^2 \|\mathbf{x}_0\|^2 + O(\bar{\alpha}_L^4)\end{aligned}$$

トレース・マハラノビス・$-D$・$\log\det$ の比
$-\log(1-a) = a + a^2/2 + \cdots$ で
$D\bar{\alpha}_L^2$ が打ち消し合う

- $\bar{\alpha}_L \to 0$ となるようにスケジュールを選べば $\mathcal{L}_{\text{prior}} \to 0$
- 例：$L = 1000$，β_i^2 を 10^{-4} から 0.02 へ線形（Ho et al., 2020）では $\bar{\alpha}_L^2 \approx 4 \times 10^{-5}$．$32 \times 32$ のカラー画像（$D = 3072$，$\|\mathbf{x}_0\|^2 \approx D$）で $\mathcal{L}_{\text{prior}} \approx 0.06$ nat（1 次元あたり 2×10^{-5}）
- そもそも $\mathcal{L}_{\text{prior}}$ は ϕ を含まないので，学習では定数として扱える

意味：L ステップ壊すと元のデータの情報がほぼ消え，生成の出発点 p_{prior} とほぼ区別できなくなる（2.2.1 の事前分布への収束）

データ処理不等式による見方を直感的に読む（補足）

$$\underbrace{\mathcal{D}_{\mathrm{KL}}\big(p_{\mathrm{data}}(\mathbf{x}_0)\,\|\,p_{\boldsymbol{\phi}}(\mathbf{x}_0)\big)}_{\text{最後の 1 コマ（データ）だけ比べる}} \le \underbrace{\mathcal{D}_{\mathrm{KL}}\big(p(\mathbf{x}_0,\mathbf{x}_{1:L})\,\|\,p_{\boldsymbol{\phi}}(\mathbf{x}_0,\mathbf{x}_{1:L})\big)}_{\text{道筋全体（動画まるごと）を比べる}}$$

- **データ処理不等式**：変数を捨てる（周辺化する）と，2 つの分布の違いは**増えない**．見る情報を減らすほど違いは見えにくくなる
- **左辺**：本当に小さくしたいもの（最尤推定の目標）．ただし $p_{\boldsymbol{\phi}}(\mathbf{x}_0)$ は計算できない
- **右辺**：順方向の動画「データ $\to$ ノイズ」と，生成の動画「ノイズ $\to$ データ」を 1 コマずつ比べる．両方とも積に分解できるので扱える
- 道筋全体を一致させれば，最後のコマ（データの分布）も自然に一致する．逆は成り立たない（最後だけ合っても途中は違ってよい）

ELBO との関係：右辺を展開すると，ELBO をデータで平均したものになる：

$$\textbf{右辺} = \mathbb{E}_{p_{\mathrm{data}}}[-\mathcal{L}_{\mathrm{ELBO}}(\mathbf{x}_0;\boldsymbol{\phi})] - \mathcal{H}(p_{\mathrm{data}}),\quad \textbf{左辺} = \mathbb{E}_{p_{\mathrm{data}}}\big[-\log p_{\boldsymbol{\phi}}(\mathbf{x}_0)\big] - \mathcal{H}(p_{\mathrm{data}})$$

$\mathcal{H}(p_{\mathrm{data}})$（データのエントロピー）は $\boldsymbol{\phi}$ によらないので，この不等式は定理 2.2.3 をデータで平均したものと同じ．

等号は，モデルの事後分布 $p_{\boldsymbol{\phi}}(\mathbf{x}_{1:L}\mid\mathbf{x}_0)$ が順方向 $p(\mathbf{x}_{1:L}\mid\mathbf{x}_0)$ と一致するとき（VAE の ELBO のギャップと同じ，2.1.2）

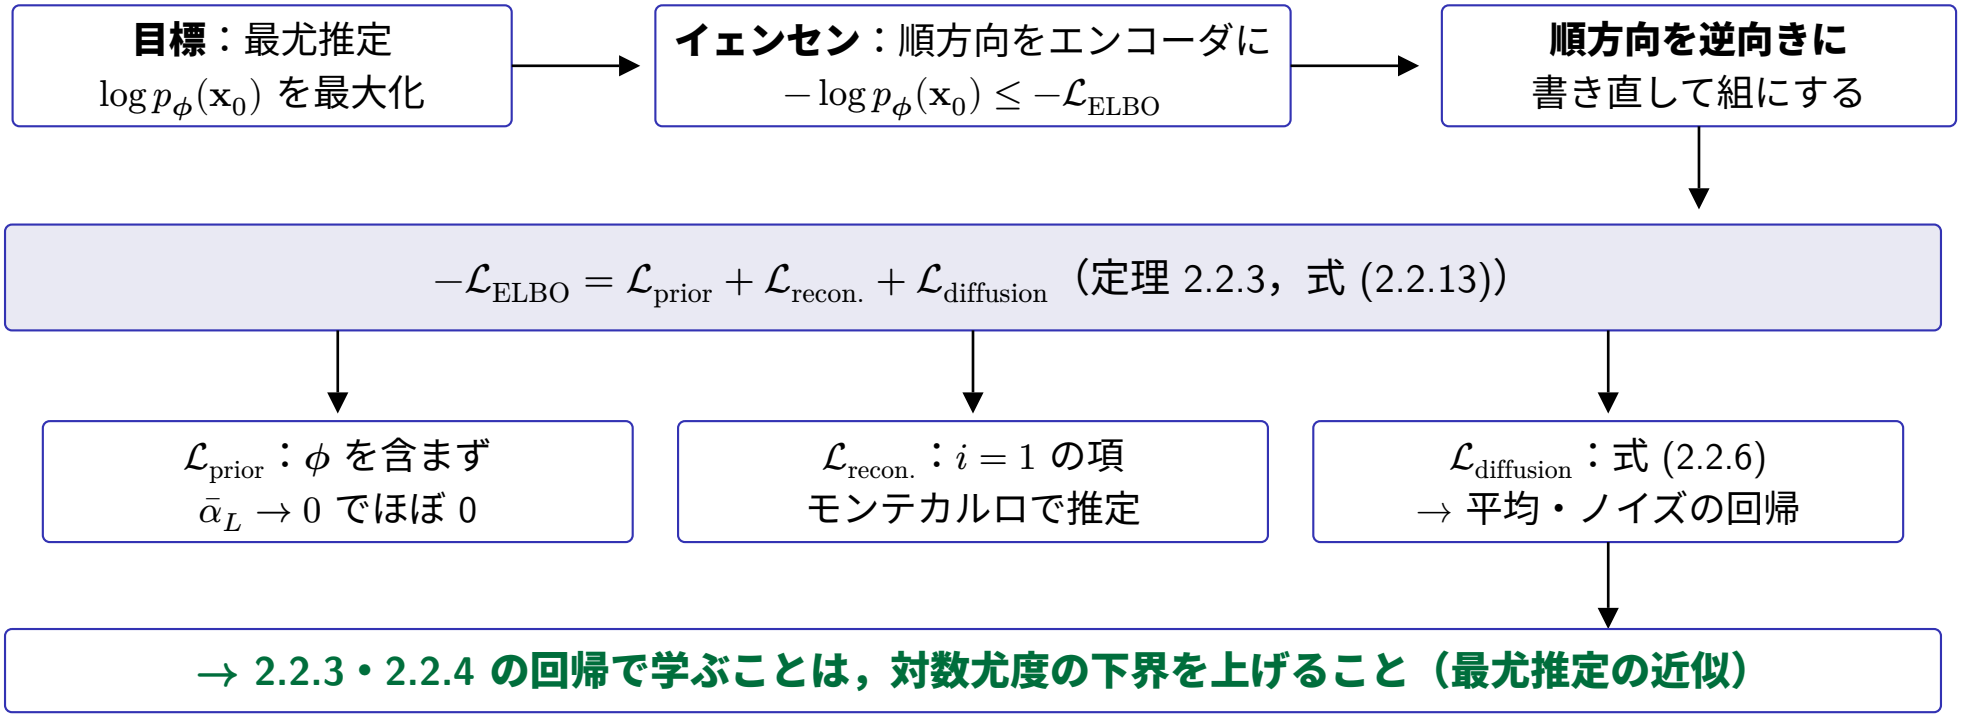
DDPM は階層的な潜在変数モデルの特に扱いやすい場合

注意（本文の Remark）

拡散モデルの変分的な見方は，階層的な潜在変数モデルの描像にとてもうまく収まる． 「エンコーダ」は固定した順方向のノイズの連鎖なので，学習する推論ネットワークはない． それでも ELBO は，各ステップの KL 項と，最後の事前分布の項・再構成の項に分かれる（式 (2.2.13)）.

DDPM の学習を特に扱いやすくしているのは，線形でガウスの順方向過程のもとで， 各ステップの KL 項が**閉じた形の条件付きの目標をもつ単純なノイズ除去の回帰問題**に書き直せること． 要点は，層ごとの KL 項がないことではなく，順方向が固定されているために， それらが効率よくサンプルできる教師ありのノイズ除去の目的になることにある.

2.2.5 のまとめ（1）：学習目的から最尤推定まで（補足）



2.2.5 のまとめ（2）：押さえておくこと（補足）

一言で

DDPM は「エンコーダを固定した階層 VAE」．その ELBO を分解すると，2.2.3 で作った学習目的 $\mathcal{L}_{\text{diffusion}}$ がそのまま現れる．

- **下界の作り方**：VAE・HVAE と同じイェンセンの不等式．エンコーダは学習しない順方向の過程
- **分解のカギ**：順方向をベイズで逆向きに書き直す（望遠鏡和）と，各ステップで「答え付きの逆遷移」と「モデルの逆遷移」の KL が並ぶ
- **3 つの項**：prior は定数でほぼ 0，recon. は最後の 1 歩，diffusion は残りすべての 1 歩
- **VAE との違い**：層ごとの KL 項はある．違いは，順方向が固定・線形ガウスなので，それが閉じた形の目標をもつ回帰になること

次：学習した逆遷移でどうサンプルを作るか → 2.2.6

2.2 DDPM：変分的な視点

- 2.2.1 順方向過程（固定したエンコーダ）
- 2.2.2 逆方向のノイズ除去過程（学習するデコーダ）
- 2.2.3 逆向きの遷移核のモデル化
- 2.2.4 予測と損失の実際的な選び方
- 2.2.5 DDPM の ELBO
- **2.2.6 サンプリング**

2.2.6 の流れ：どの順で何を見るか（補足）

2.2.3〜2.2.5 で逆遷移の学び方とその根拠がそろった．2.2.6 では，学習したモデルで**どうやってデータを作るか**を見る．

問 1 どう生成する？	$\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ から出発し，学習した逆遷移で $i = L, \ldots, 1$ と 1 歩ずつ戻る	(2.2.14)
問 2 1 歩で何をしている？	予測したきれいなデータに，1 段弱いノイズを加え直す（ノイズ除去 ＋ 再ノイズ化）	(2.2.15)
問 3 ノイズの強さは合う？	ノイズの分散がちょうど $1 - \bar{\alpha}_{i-1}^2$ で，順方向の $i-1$ 段目と一致する	図 2.7
問 4 最適な予測の限界は？	平均しか出せずノイズが強いとぼやける → 何度も予測し直して少しずつ洗練	(2.2.11)
問 5 なぜ遅い？	ガウスで近似できるよう小さなステップを多数踏むので $O(L)$ 回の逐次計算	→ 第 4 章

→ ゴール：学習したノイズ除去を繰り返してノイズからデータを作る．その遅さが後の章の動機

2.2.6 サンプリング：学習した逆向きの遷移を順にたどる

学習を終えて固定した ε-予測モデル $\varepsilon_{\phi^\times}(\mathbf{x}_i, i)$ を使い，$p_{\phi^\times}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ から順にサンプルする．

DDPM のサンプリング

1. $\mathbf{x}_L \sim p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ を引く
2. $i = L, L-1, ..., 1$ の順に，次の更新を繰り返す

$$\mathbf{x}_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i}\left(\mathbf{x}_i - \frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\varepsilon_{\phi^\times}(\mathbf{x}_i, i)\right)}_{\boldsymbol{\mu}_{\phi^\times}(\mathbf{x}_i, i)} + \sigma(i)\boldsymbol{\varepsilon}_i, \quad \boldsymbol{\varepsilon}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \tag{2.2.14}$$

3. 最後に得た $\mathbf{x}_0$ が生成されたきれいなサンプル

第 1 項はモデルの平均（式 (2.2.5)），第 2 項は分散 $\sigma^2(i)$ のガウス分布からのサンプルに当たる．

記号 $\times$ は，学習を終えて固定したモデルであることを表す（本文の脚注 4）

式 (2.2.14) の読み方（補足）

$$\mathbf{x}_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i}}_{\text{③ 少し拡大}} \left(\mathbf{x}_i - \underbrace{\frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}}_{\text{② 適量}} \underbrace{\boldsymbol{\varepsilon}_{\boldsymbol{\phi}^\times}(\mathbf{x}_i, i)}_{\text{① 混ざったノイズの予想}} \right) + \underbrace{\sigma(i)\boldsymbol{\varepsilon}_i}_{\text{④ 新しいノイズ}}$$

1. **ノイズを予想**：ネットワークが「$\mathbf{x}_i$ に混ざっているノイズ」を当てる（2.2.4 のノイズ当てゲームの答え）
2. **適量だけ引く**：全部ではなく 1 歩ぶんだけ引く．一度に全部引くと平均（ぼやけた予測）に飛んでしまう
3. **少し拡大**：順方向で毎回 α_i 倍に縮めた分を戻す．①〜③がモデルの平均 $\boldsymbol{\mu}_{\boldsymbol{\phi}^\times}(\mathbf{x}_i, i)$
4. **新しいノイズを足す**：$p_{\boldsymbol{\phi}^\times}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ は平均のまわりに広がった**分布**なので，そこから 1 つ引く．$\boldsymbol{\varepsilon}_i$ は毎ステップ新しく引く（順方向で混ぜたノイズとは別物）

一言で：「混ざったノイズを少し取り除き，その分のゆらぎを新しく足す」を L 回繰り返す．毎回ノイズの強さが 1 段ずつ下がる．

Ho et al. (2020) の実装では最後の 1 歩（$i = 1$）だけ新しいノイズを足さず，平均をそのまま出力する．ノイズを足さない決定論的なサンプラーは係数の調整が必要（9.2 節）

サンプリングの別の見方：ノイズ除去してから再びノイズを加える

命題（式 (2.2.15)）

$\sigma(i) = \tilde{\beta}_i$，$\tilde{\beta}_i^2 := ((1-\bar{\alpha}_{i-1}^2)(1-\alpha_i^2))/(1-\bar{\alpha}_i^2)$ とし，$\hat{\mathbf{x}} := \mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$，$\hat{\boldsymbol{\varepsilon}} := \boldsymbol{\varepsilon}_{\phi^\times}(\mathbf{x}_i, i)$ を式 (2.2.12) で結ばれた予測とすると，更新 (2.2.14) は

$$\mathbf{x}_{i-1} \leftarrow \bar{\alpha}_{i-1}\hat{\mathbf{x}} + \sqrt{1-\bar{\alpha}_{i-1}^2-\tilde{\beta}_i^2}\,\hat{\boldsymbol{\varepsilon}} + \tilde{\beta}_i\boldsymbol{\varepsilon}_i$$

理由：平均の式に $\mathbf{x}_i = \bar{\alpha}_i\hat{\mathbf{x}} + \sqrt{1-\bar{\alpha}_i^2}\hat{\boldsymbol{\varepsilon}}$ を代入して $\hat{\mathbf{x}}$ と $\hat{\boldsymbol{\varepsilon}}$ ごとにまとめると，$\hat{\mathbf{x}}$ の係数は $\bar{\alpha}_{i-1}$，$\hat{\boldsymbol{\varepsilon}}$ の係数は 2 乗すると $1-\bar{\alpha}_{i-1}^2-\tilde{\beta}_i^2$ になる．

意図：右辺は「予測したきれいなデータ」「予測したノイズ」「新しいノイズ」の組み合わせ． ノイズの 2 つの係数の 2 乗和は $1-\bar{\alpha}_{i-1}^2$ で，順方向の $i-1$ 段目のノイズの分散にちょうど一致する．

※ $\tilde{\beta}_i^2$ は補題 2.2.2 の $\sigma^2(i)$ と同じもの．「理由」「意図」は補足で，導出は次の 2 枚

式 (2.2.15) の導出（1）：平均を $\hat{\mathbf{x}}$ と $\hat{\boldsymbol{\varepsilon}}$ で書く（補足）

証明（平均の書き換え）

$$\boldsymbol{\mu}_{\phi^\times} = \frac{1}{\alpha_i}\left(\mathbf{x}_i - \frac{\beta_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\hat{\boldsymbol{\varepsilon}}\right)$$

式 (2.2.14) の平均．$1-\alpha_i^2 = \beta_i^2$

$$\mathbf{x}_i = \bar{\alpha}_i\hat{\mathbf{x}} + \sqrt{1-\bar{\alpha}_i^2}\,\hat{\boldsymbol{\varepsilon}}$$

式 (2.2.12)：2 つの予測の関係

$$\boldsymbol{\mu}_{\phi^\times} = \frac{1}{\alpha_i}\left(\bar{\alpha}_i\hat{\mathbf{x}} + \left(\sqrt{1-\bar{\alpha}_i^2} - \frac{\beta_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\right)\hat{\boldsymbol{\varepsilon}}\right)$$

$\mathbf{x}_i$ を代入し $\hat{\boldsymbol{\varepsilon}}$ でくくる

$$= \bar{\alpha}_{i-1}\hat{\mathbf{x}} + \frac{1-\bar{\alpha}_i^2-\beta_i^2}{\alpha_i\sqrt{1-\bar{\alpha}_i^2}}\hat{\boldsymbol{\varepsilon}}$$

$\bar{\alpha}_i/\alpha_i = \bar{\alpha}_{i-1}$，通分

$$= \bar{\alpha}_{i-1}\hat{\mathbf{x}} + \underbrace{\frac{\alpha_i(1-\bar{\alpha}_{i-1}^2)}{\sqrt{1-\bar{\alpha}_i^2}}}_{=:c_i'}\hat{\boldsymbol{\varepsilon}}$$

$1-\beta_i^2 = \alpha_i^2$，$\alpha_i^2 - \bar{\alpha}_i^2 = \alpha_i^2(1-\bar{\alpha}_{i-1}^2)$

$c_i' \geq 0$ なので，本文の脚注 5 の $\sqrt{1-\bar{\alpha}_{i-1}^2-\tilde{\beta}_i^2}$ と書いてよい（次のスライドで確認）．

式 (2.2.15) の導出（2）：係数の 2 乗和がノイズの強さに一致（補足）

証明（続き）

$\tilde{\beta}_i^2 := (1-\bar{\alpha}_{i-1}^2)(1-\alpha_i^2)/(1-\bar{\alpha}_i^2)$（補題 2.2.2 の $\sigma^2(i)$ と同じ）とおく．

$$1-\bar{\alpha}_{i-1}^2-\tilde{\beta}_i^2 = (1-\bar{\alpha}_{i-1}^2)\left(1-\frac{1-\alpha_i^2}{1-\bar{\alpha}_i^2}\right)$$

$1-\bar{\alpha}_{i-1}^2$ でくくる

$$= (1-\bar{\alpha}_{i-1}^2)\frac{\alpha_i^2-\bar{\alpha}_i^2}{1-\bar{\alpha}_i^2} = \frac{\alpha_i^2(1-\bar{\alpha}_{i-1}^2)^2}{1-\bar{\alpha}_i^2} = (c_i')^2$$

通分．$\alpha_i^2-\bar{\alpha}_i^2 = \alpha_i^2(1-\bar{\alpha}_{i-1}^2)$

$$\mathbf{x}_{i-1} = \boldsymbol{\mu}_{\phi^\times} + \tilde{\beta}_i\boldsymbol{\varepsilon}_i = \bar{\alpha}_{i-1}\hat{\mathbf{x}} + \sqrt{1-\bar{\alpha}_{i-1}^2-\tilde{\beta}_i^2}\,\hat{\boldsymbol{\varepsilon}} + \tilde{\beta}_i\boldsymbol{\varepsilon}_i$$

$\sigma(i) = \tilde{\beta}_i$．これが式 (2.2.15)

ノイズの 2 つの係数の 2 乗和：$\left(1-\bar{\alpha}_{i-1}^2-\tilde{\beta}_i^2\right)+\tilde{\beta}_i^2 = 1-\bar{\alpha}_{i-1}^2$ = 順方向の $i-1$ 段目のノイズの分散．

■

$\hat{\varepsilon}$ と ε_i をどちらも単位分散で独立とみなせば，合わせたノイズの標準偏差は $\sqrt{1-\bar{\alpha}_{i-1}^2}$（本文の “combined std.”）

式 (2.2.15) は順方向の周辺と同じ形

式 (2.2.15) と順方向の周辺（式 (2.2.1)）を並べると，構造は同じ：

サンプリング（式 (2.2.15)）： $\mathbf{x}_{i-1} = \bar{\alpha}_{i-1}\,\hat{\mathbf{x}} + \underbrace{\sqrt{1-\bar{\alpha}_{i-1}^2-\tilde{\beta}_i^2}\,\hat{\boldsymbol{\varepsilon}} + \tilde{\beta}_i\boldsymbol{\varepsilon}_i}_{\text{標準偏差 } \sqrt{1-\bar{\alpha}_{i-1}^2}}$

順方向の周辺（式 (2.2.1)）： $\mathbf{x}_{i-1} = \bar{\alpha}_{i-1}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_{i-1}^2}\,\bar{\boldsymbol{\varepsilon}}$

信号の係数 $\bar{\alpha}_{i-1}$ もノイズの標準偏差 $\sqrt{1-\bar{\alpha}_{i-1}^2}$ も同じ．違いは未知の $\mathbf{x}_0$ がネットワークの予測 $\hat{\mathbf{x}} = \mathbf{x}_{\boldsymbol{\phi}^\times}(\mathbf{x}_i, i)$ に置き換わっただけ．

言い換えると，DDPM の各ステップは**きれいなデータを予測し，それをちょうどノイズの強さ $i-1$ まで再びノイズ化**している．

DDPM の 1 ステップ ＝ ノイズ除去 ＋ 再ノイズ化

DDPM のサンプリングは次の 2 つの操作の繰り返しとみなせる：

1. **ノイズ除去**：今のノイズ付き入力 $\mathbf{x}_i$ からきれいなデータ $\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$ を推定する
2. **再ノイズ化**：1 段低いノイズの強さ $i-1$ のノイズを加え直し，順方向の $i-1$ 段目と同じノイズの強さの $\mathbf{x}_{i-1}$ を作る

これは Part B の導入の最初のサンプリングのひな形 (1.4.1) と同じ：きれいな部分を予測し，低いノイズの強さで書き直す.

- DDPM はこの書き直しを**確率的**に行う：$\mathbf{x}_i$ から推定したノイズの向き $\hat{\varepsilon}$ と，新しく引いたノイズ ε_i を組み合わせる
- 決定論的なサンプラーは，新しいランダムさを除き，残りのノイズ係数を調整する（9.2 節）

この「ノイズ除去してから再ノイズ化」を図示したのが図 2.7（2 枚後）

最適なノイズ除去器でも平均しか出せない

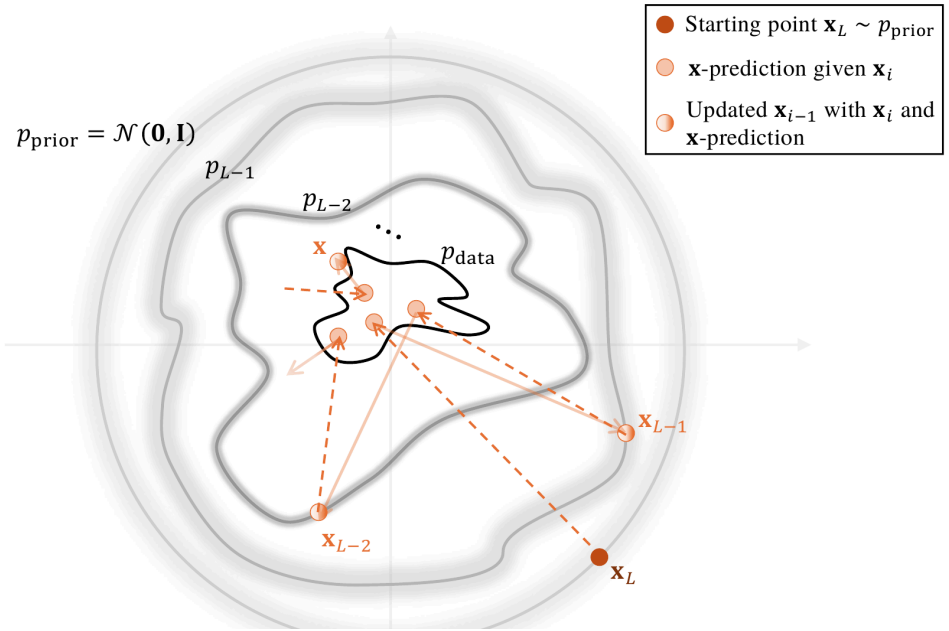
$\mathbf{x}_{\phi^\times}$ を最適なノイズ除去器（条件付き期待値，式 (2.2.11)）まで学習できても，$\mathbf{x}_i$ が与えられたときの**平均の**きれいなサンプルしか予測できない． そのため特にノイズが強いところでは，ひどく壊れた入力から細部を復元するのが難しく，予測はぼやける．

この見方では，拡散モデルのサンプリングは強いノイズから弱いノイズへ進みながら，きれいな信号の推定を少しずつ洗練していく過程：

- 最初のステップで全体の構造が決まり
- 後のステップで細部が加わり
- ノイズが除かれるにつれてサンプルが本物らしくなる

※ 2.1.4 の VAE のぼやけ（最適なデコーダが条件付き平均）と同じ理由．拡散モデルはそれを 1 回で終わらせず，何度も予測し直すことで回避する

図 2.7：ノイズ除去してから再ノイズ化する



出典：C. Lai et al., *The Principles of Diffusion Models* (arXiv:2510.21890) の図 2.7 を引用

図の見方

- 外側の円から内側へ：$p_{\text{prior}} \to p_{L-1} \to p_{L-2} \to \cdots \to p_{\text{data}}$（ノイズが弱くなるほど内側）
- **濃い点**：出発点 $\mathbf{x}_L \sim p_{\text{prior}}$
- **薄い点**：$\mathbf{x}_i$ から予測したきれいなデータ $\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$（$p_{\text{data}}$ の近く）
- **半分塗りの点**：予測を 1 段弱いノイズ $i-1$ に戻した $\mathbf{x}_{i-1}$（p_{i-1} の上）
- 破線：ノイズ除去（予測へ），実線：再ノイズ化（1 段内側へ）

本文のキャプション：今のノイズ付きサンプル $\mathbf{x}_i$ から，モデルはまずきれいな信号 $\mathbf{x}_{\phi^\times}(\mathbf{x}_i, i)$ を推定し，その推定を $(i-1)$ 段目のノイズの強さまで再びノイズ化して，よりノイズの少ない点 $\mathbf{x}_{i-1}$ を引く．

「予測して書き直す」を直感的に読む（補足）

1 ステップは **2 段階**．次のサンプル $\mathbf{x}_{i-1}$ を直接予測するのではない：

段階	式	やっていること
① ノイズ除去	$\hat{\mathbf{x}} = \mathbf{x}_{\phi^\times}(\mathbf{x}_i, i) \approx \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$	ゴールのきれいなデータを予測
② 再ノイズ化	$\mathbf{x}_{i-1} = \bar{\alpha}_{i-1}\hat{\mathbf{x}} + \sqrt{1-\bar{\alpha}_{i-1}^2} \times (\textbf{ノイズ})$	予測を 1 段弱いノイズ $i-1$ で書き直す

なぜ予測 $\hat{\mathbf{x}}$ をそのまま答えにしないのか

- $\hat{\mathbf{x}}$ は条件付き期待値で，ノイズが強いうちは**ぼやけた平均**．そのまま出すとぼやけて終わる
- まだ自信のない部分はノイズとして残し，$\mathbf{x}_{i-1}$ を順方向の p_{i-1} 上の点に置き直す
- するとモデルは，学習で見たのと同じ種類の入力（ノイズの強さ $i-1$）から**もう一度予測し直せる**
- 繰り返すとノイズが 1 段ずつ弱まり，予測も粗い構造から細部へ正確になる

たとえ：ぼやけた写真から完成図を予想し，それを少しだけぼかし直して次の下書きにする．次はその下書きからまた完成図を予想する．ぼかしが毎回少しずつ弱くなるので，最後はくっきりした絵になる．

図 2.7 の破線（予測へ向かう）が①，実線（1 段内側へ戻る）が②

確率的な書き直しと決定論的な書き直し（補足）

DDPM（確率的）：書き直しで加えるノイズは 2 種類の混合

$$\mathbf{x}_{i-1} = \bar{\alpha}_{i-1}\hat{\mathbf{x}} + \underbrace{c_i'\hat{\boldsymbol{\varepsilon}}}_{\text{使い回し}} + \underbrace{\tilde{\beta}_i\boldsymbol{\varepsilon}_i}_{\text{新しいノイズ}}, \quad (c_i')^2 + \tilde{\beta}_i^2 = 1 - \bar{\alpha}_{i-1}^2$$

- 新しいノイズの割合は $\tilde{\beta}_i^2/(1-\bar{\alpha}_{i-1}^2) = \beta_i^2/(1-\bar{\alpha}_i^2)$．歩幅 β_i が小さいので**ほんの少し**．大部分は使い回し
- 同じ $\mathbf{x}_L$ から出発しても毎回違うサンプルができる

決定論的なサンプラー：新しいノイズを 0 にし，使い回す係数を全体の大きさまで引き上げる

$$\mathbf{x}_{i-1} = \bar{\alpha}_{i-1}\hat{\mathbf{x}} + \sqrt{1-\bar{\alpha}_{i-1}^2}\,\hat{\boldsymbol{\varepsilon}}$$

- ランダムな部分がないので，$\mathbf{x}_L$ が決まれば $\mathbf{x}_0$ も 1 つに決まる
- 「予測して 1 段弱いノイズで書き直す」考え方は同じ．違いはノイズを使い回しだけで作るか，新しいものも混ぜるか

どちらもノイズの強さは順方向の $i-1$ 段目と同じ $\sqrt{1-\bar{\alpha}_{i-1}^2}$．決定論的な形は DDIM（Song et al., 2021）と呼ばれるサンプラーの形．本では 9.2 節で体系的に扱う．c_i' は式 (2.2.15) の導出（1）を参照

DDPM のサンプリングは遅い

元の DDPM では，1 つのサンプルを作るのに約 1000 回のノイズ除去が要る． 各ステップは今のサンプルを少しだけきれいにし，次の更新は前の結果から始めるしかないので，強く逐次的になる．

なぜ小さなステップをたくさん踏む必要があるのか：

- 定理 2.2.1 より，表現力が十分な $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ なら真の逆向きの分布に一致できる
- しかし実際は p_ϕ を**ガウス分布**でモデル化しており，表現力が限られる
- 順方向のノイズ β_i が小さければ，真の逆向きの分布はほぼガウス分布で，よく近似できる
- β_i が大きいと，真の逆向きの分布は山が複数あったり強くガウスから外れたりし，1 つのガウスでは捉えられない

そこで小さな β_i のステップを多数並べるが，各ステップでネットワーク $\varepsilon_{\phi^\times}$ の評価が要るので， $O(L)$ 回の逐次的な計算になり並列化できない．第 4 章でこれを微分方程式の問題として捉え直し，連続時間の数値解法で高速化する．

なぜ小さなステップなら逆向きをガウスで近似できるか（補足）

ベイズの定理で，真の逆遷移は「1 歩の壊し方」と「1 段前の分布」の積：

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \propto \underbrace{p(\mathbf{x}_i \mid \mathbf{x}_{i-1})}_{\text{中心 } \mathbf{x}_i/\alpha_i \text{，幅 } \beta_i/\alpha_i \text{ のガウス}} \times \underbrace{p_{i-1}(\mathbf{x}_{i-1})}_{\text{複雑な分布（ } p_{\text{data}} \text{ 由来）}}$$

- β_i **が小さい**：第 1 因子の幅が狭い．その狭い範囲では $\log p_{i-1}$ はほぼ 1 次関数（テイラー展開）で，「ガウス $\times$ 指数の 1 次式」はガウス．中心が少しずれるだけ：

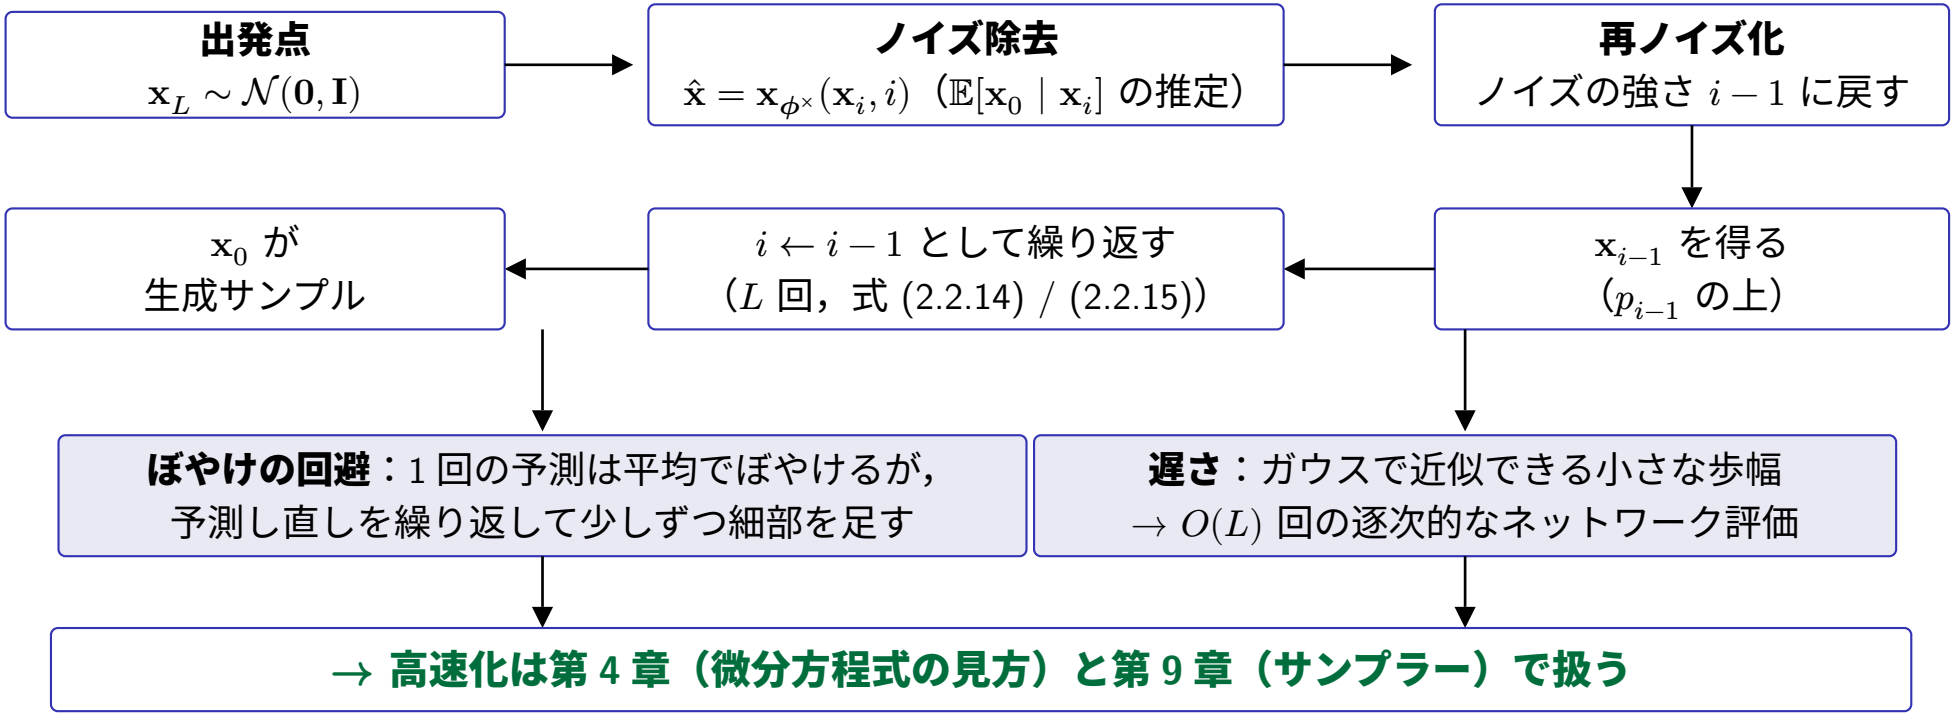
$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \approx \mathcal{N}\left(\frac{\mathbf{x}_i}{\alpha_i} + \frac{\beta_i^2}{\alpha_i^2}\nabla \log p_{i-1}\left(\frac{\mathbf{x}_i}{\alpha_i}\right), \frac{\beta_i^2}{\alpha_i^2}\mathbf{I}\right)$$

- β_i **が大きい**：第 1 因子の幅が広く，p_{i-1} の複数の山を同時に含む $\rightarrow$ 逆遷移も多峰になり，ガウス 1 つでは表せない

$\rightarrow$ ガウスのモデル p_ϕ が正確であるためには小さな β_i が必要．そのぶんステップ数 L が増え，サンプリングが遅くなる．

ずれの向き $\nabla \log p_{i-1}$ は**スコア関数**．第 3 章のスコアベースの視点につながる（ここでは近似の雰囲気を示すための式で，本文にはない）

2.2.6 のまとめ（1）：サンプリングの流れ（補足）



2.2.6 のまとめ（2）：押さえておくこと（補足）

一言で

DDPM のサンプリングは「きれいなデータを予測し，1 段弱いノイズで書き直す」の繰り返し．学習したノイズ除去を L 回使ってノイズからデータを作る．

- **更新式**：予測したノイズを適量引いて少し拡大し，新しいノイズを足す（式 (2.2.14)）
- **別の見方**：予測 $\hat{\mathbf{x}}$ を順方向の $i-1$ 段目と同じ形・同じノイズの強さに戻す（式 (2.2.15)，図 2.7）
- **なぜ繰り返すか**：最適な予測でも平均しか出せずぼやける．粗い構造から細部へと少しずつ洗練する
- **なぜ遅いか**：真の逆遷移がガウスに近いのは歩幅 β_i が小さいときだけなので，多数のステップが要る

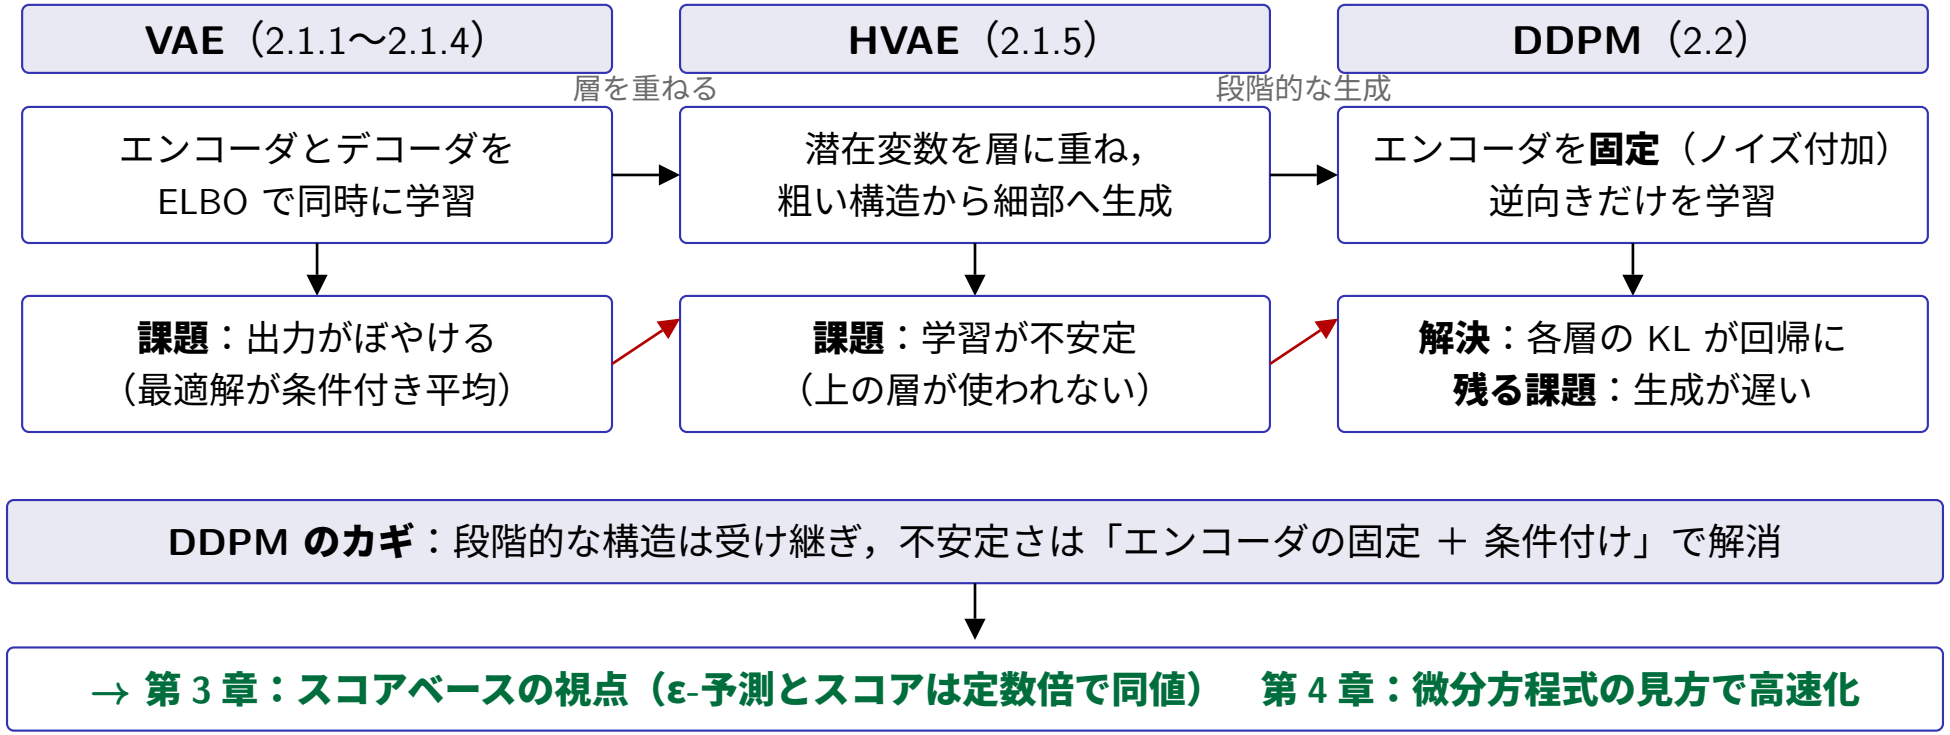
次：2.3 で第 2 章全体をまとめ，第 3 章のスコアベースの視点へ

2.3 まとめ

2.3 まとめ：変分的な視点から見た拡散モデル

- **VAE**：データと構造化された潜在空間の間の確率的な対応を，ELBO を通して学習する基礎的な生成モデル
- **階層的 VAE**：潜在変数の層を重ね，粗い構造から細部へ段階的に生成するという強力な考えを導入した． ただし学習の安定性とサンプルの質に課題がある
- **DDPM**：変分的な枠組みの中での決定的な進化．エンコーダを少しずつノイズを足す過程に**固定**し，逆向きのノイズ除去だけを学習することで，HVAE の不安定さを避ける
- DDPM も対数尤度の変分下界の最大化で学習され，その目的は単純なノイズ除去の問題の列に分解される
- これを可能にするのが**条件付けの工夫**：計算できない周辺の目的を，計算できる条件付きの目的に変える（拡散モデルで繰り返し現れるテーマ）

VAE → HVAE → DDPM：発展の流れ（補足）



次章へ：スコアベースの視点

変分的な枠組みは DDPM の完全で強力な土台だが，理解の仕方はこれだけではない． エネルギーベースモデルの原理から，同じくらい基本的な別の視点が現れる．

第 3 章 スコアベースの視点

1. ノイズ除去の遷移確率 $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ を学習する代わりに，データの対数密度の勾配，すなわち**スコア関数**を直接学習する
2. EBM から始まるこのアプローチが **NCSN**（Noise Conditional Score Network）を生み，DDPM で学習するノイズ予測（ε-予測）とスコア関数が数学的に深く同値であることを明らかにする

この視点は新しい洞察を与えるだけでなく，後で展開する連続時間の統一的な枠組みのもう1つの柱になる．

第 2 章を直感的にまとめる（補足）

一言で

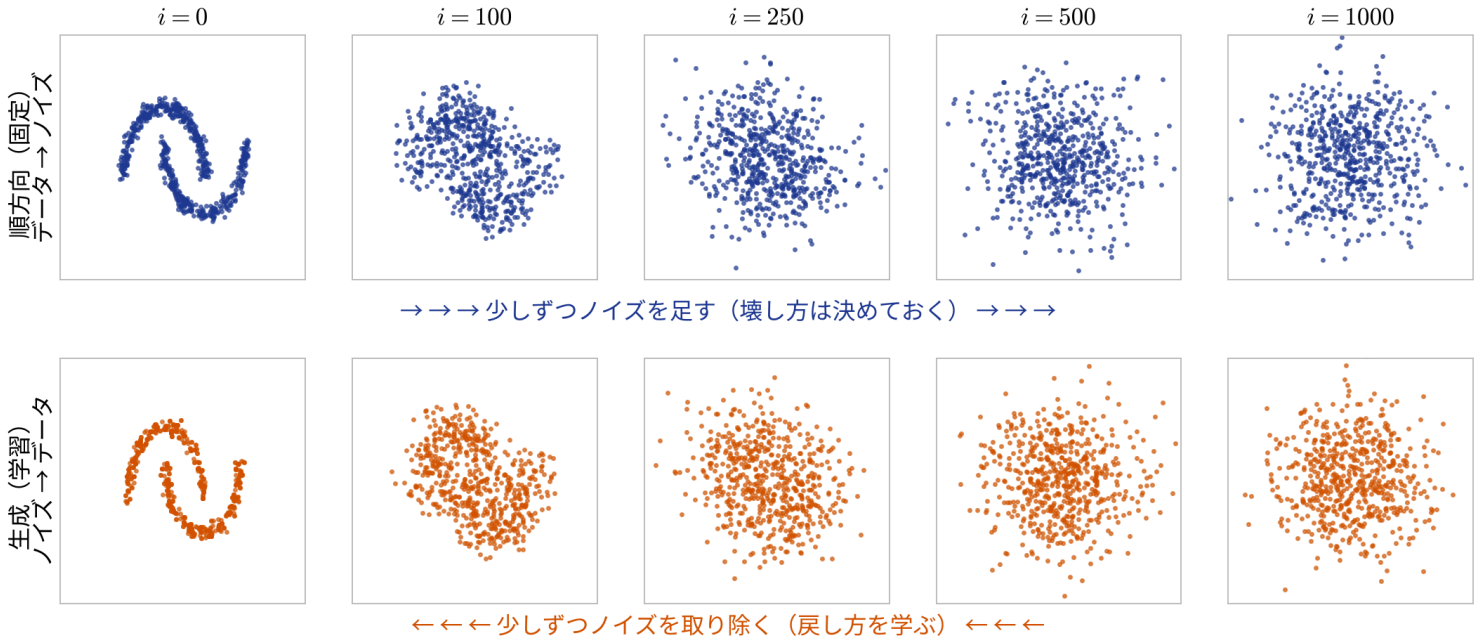
DDPM は「壊し方を固定し，**戻し方だけ**を学ぶ」VAE．学習は「混ざったノイズを当てる」練習，生成は「予想して少しずつ書き直す」繰り返し．

キーワード	**直感的には**	**対応する節**
VAE・ELBO	圧縮して復元する．尤度は計算できないので，計算できる下界を上げる	2.1.1〜2.1.3
ぼやけ	二乗誤差の最適解は「ありうる答えの平均」なのでぼやける	2.1.4
HVAE	潜在変数を層にして粗い構造から細部へ．ただし学習が不安定	2.1.5
順方向（固定）	データに少しずつノイズを足す．どの時刻も一度に作れる	2.2.1
条件付けの工夫	答え $\mathbf{x}_0$ 付きの練習問題で学んでも，本当の目標と同じ最適解	2.2.2
学習（回帰）	壊れた $\mathbf{x}_i$ から混ざったノイズを当てる二乗誤差	2.2.3〜2.2.4
ELBO との関係	そのノイズ当ては，尤度の下界を上げること（最尤推定の近似）	2.2.5
生成	きれいなデータを予想し，1 段弱いノイズで書き直すを繰り返す．遅い	2.2.6

1 回の予測はぼやけた平均でも，何度も予想し直すことで細部まで作れる．これが VAE との大きな違い

第 2 章を図で振り返る（補足）

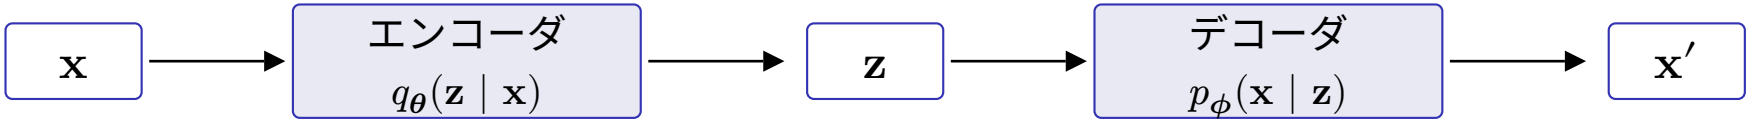
全体像：壊し方は決めておき，戻し方を学ぶ（補足）



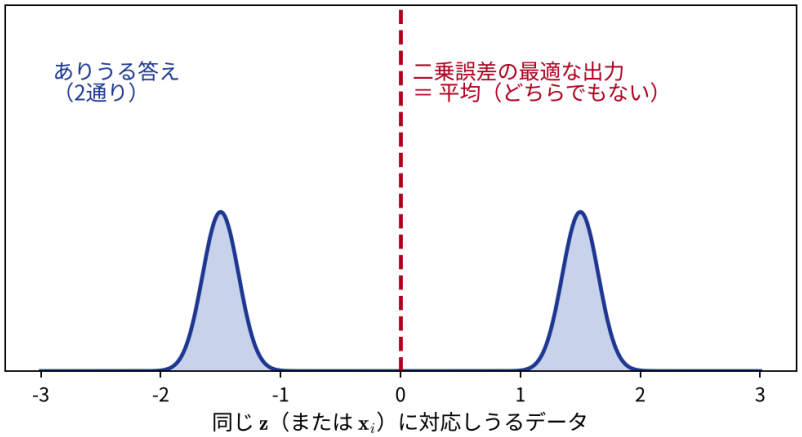
上：順方向（2.2.1）．データ（2 つの三日月）に少しずつノイズを足すと，最後は $\mathcal{N}(\mathbf{0}, \mathbf{I})$ になる． 下：生成（2.2.6）．学習したモデルでノイズから 1 歩ずつ戻ると，データと同じ形が現れる．

図はすべて 2 次元・1 次元の簡単な例で実際に計算したもの（$L = 1000$，β_i^2 を 10^{-4} から 0.02 へ線形．生成には学習の代わりに最適なノイズ除去器を使用）

VAE：圧縮して復元する．ただし出力はぼやける（補足）



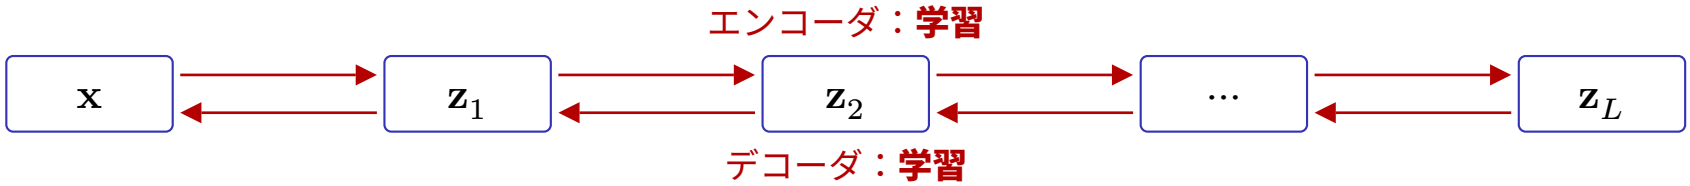
小さな潜在表現（圧縮）



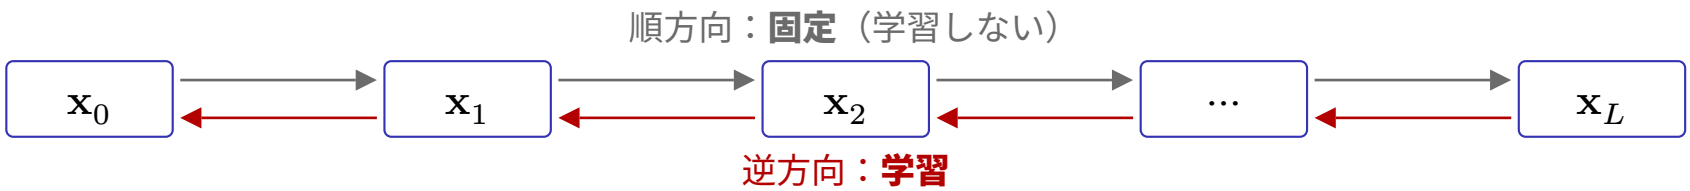
- 尤度 $p_{\phi}(\mathbf{x})$ は積分で計算できない → 計算できる**下界 ELBO** を上げる（2.1.2）
- 同じ $\mathbf{z}$ からありうるデータが複数あると，二乗誤差の最適な出力は**それらの平均**（2.1.4）
- 平均は「どちらでもない」中間 → **ぼやけた出力**
- 層を重ねた HVAE（2.1.5）は段階的に作れるが，学習が不安定

HVAE と DDPM：同じ「層の連鎖」，違いは何を学ぶか（補足）

HVAE（2.1.5）

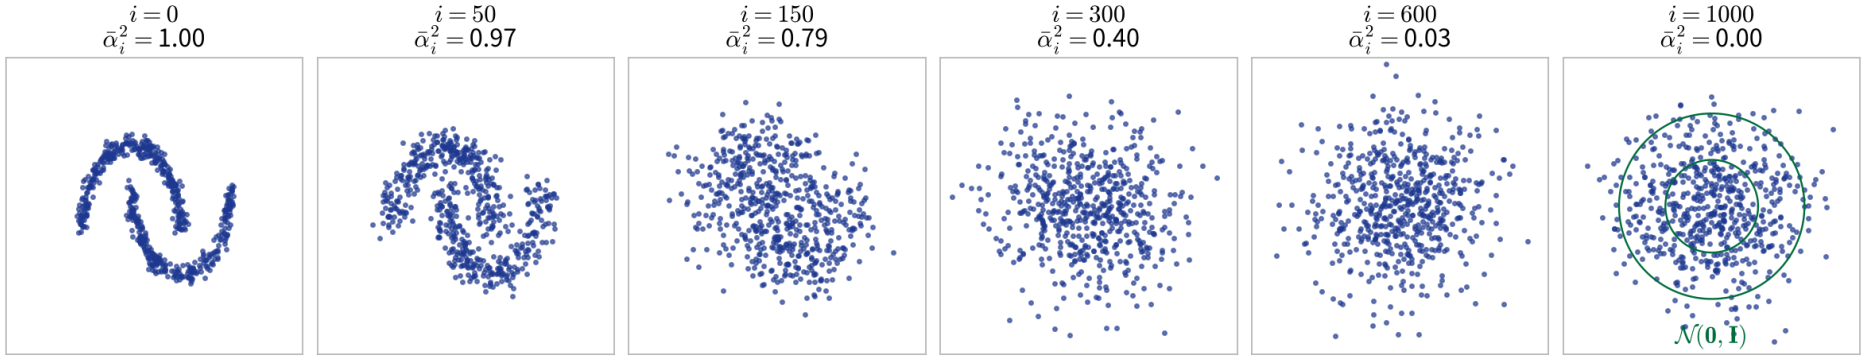


DDPM（2.2）



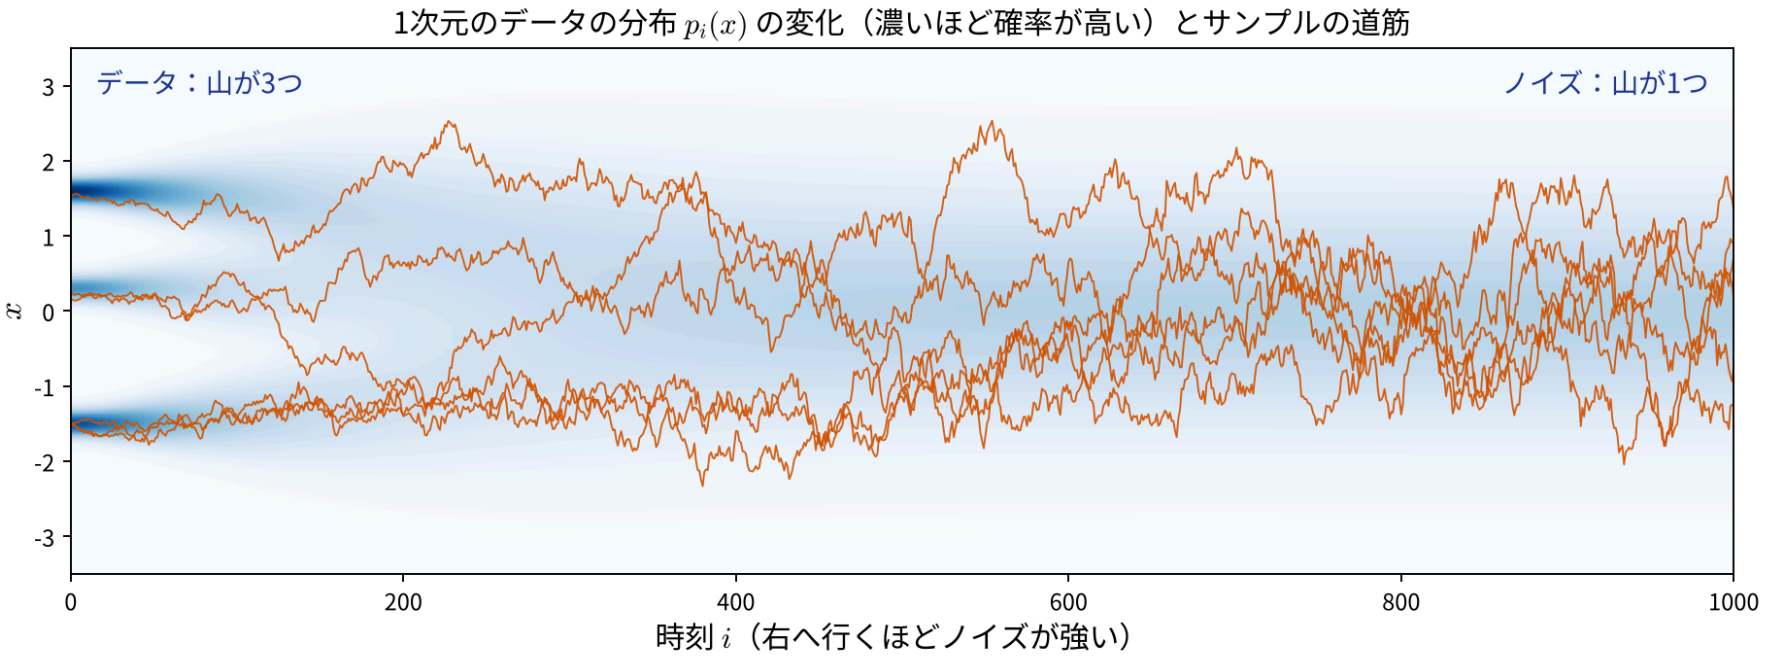
- 構造は同じ「潜在変数の連鎖」で，ELBO もステップごとの KL に分かれる（2.2.5）
- DDPM はエンコーダを固定したので，学ぶのは逆向きだけ．両側を同時に合わせる不安定さがない
- 固定した順方向は線形ガウスなので，どの層の目標も**閉じた形**で書ける（2.2.2）

順方向：データが少しずつノイズになる（補足）



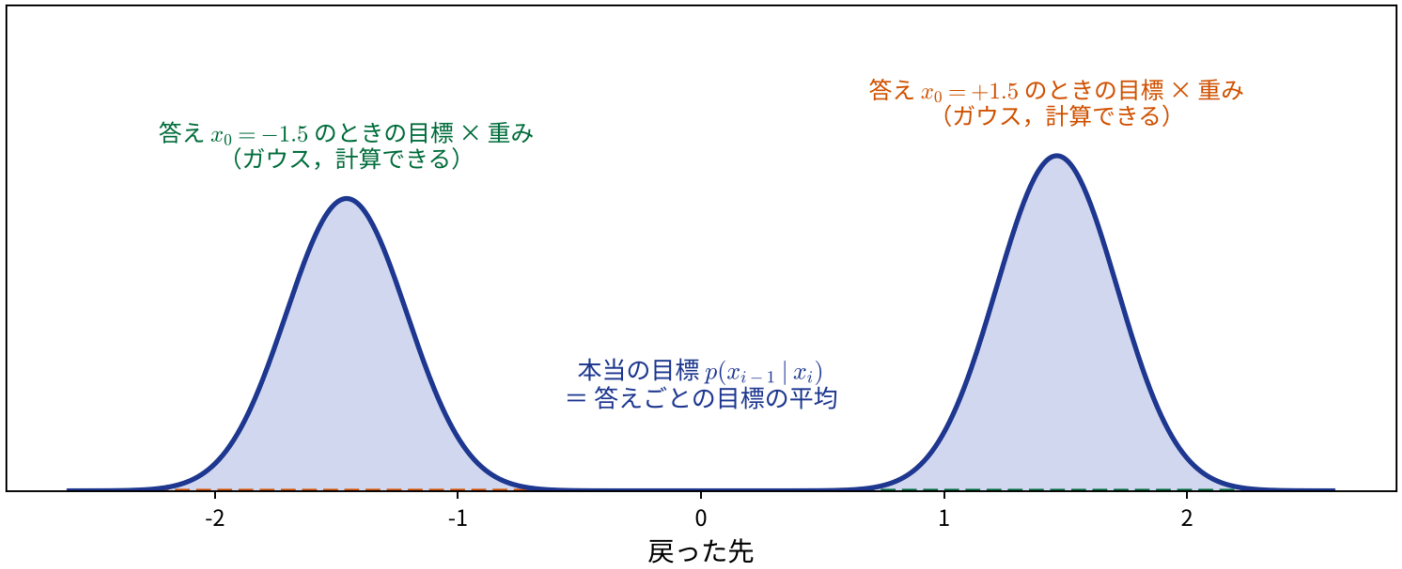
- 各ステップで少し縮めてノイズを足す：$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \boldsymbol{\varepsilon}_i$（$\alpha_i^2 + \beta_i^2 = 1$ で分散を保つ）
- $\bar{\alpha}_i^2$ は「データが残っている割合」．1 から 0 へ単調に減る
- 途中を飛ばして一度に作れる：$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\, \boldsymbol{\varepsilon}$（摂動核）
- 最後は形が完全に消え，データによらない $\mathcal{N}(\mathbf{0}, \mathbf{I})$ になる $\rightarrow$ 生成の出発点

分布で見ると：データの山が溶けて 1 つの山になる（補足）



- 横軸が時刻，縦軸が値．色の濃さが各時刻の分布 $p_i(x)$．橙の線は 1 つ 1 つのサンプルの道筋（ランダムに揺れながら進む）
- 3 つの山（データ）が少しずつ広がって混ざり，最後は 1 つの山 $\mathcal{N}(0,1)$ になる
- 生成はこの図を**右から左へ**たどること：1 つの山から出発して，正しい山へ分かれていく

条件付けの工夫：答え付きの目標の平均が本当の目標（補足）

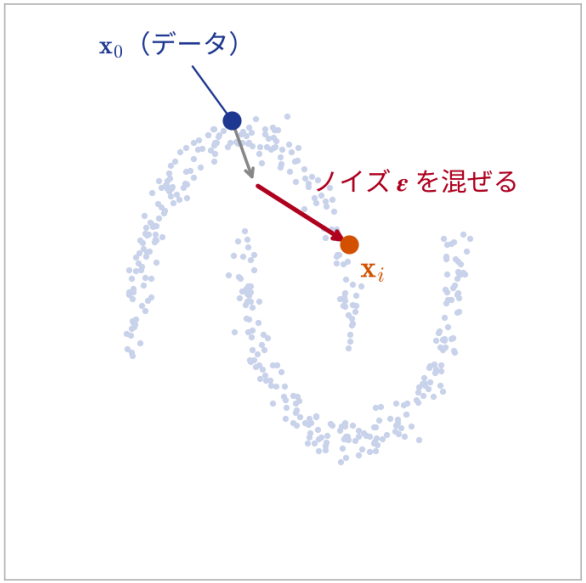


- 本当の逆遷移 $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$（青）は，$\mathbf{x}_i$ を作りえた答え $\mathbf{x}_0$ ごとの目標（破線）の**重み付き平均**
- 答え $\mathbf{x}_0$ を知っていれば目標はガウス 1 つで，式で書ける（補題 2.2.2）
- 答え付きの目標に合わせて学べば，平均として本当の目標に合う（定理 2.2.1）＝ 答え付きの練習問題をたくさん解く

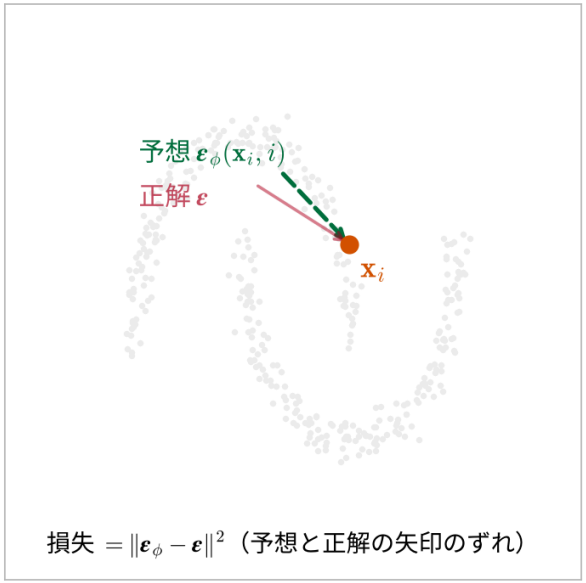
図は大きく戻る場合（$i = 500 \to 60$）で，違いが見やすいようにしたもの．実際の 1 歩は小さい

学習：混ぜたノイズを当てるゲーム（補足）

① 壊す：$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1-\bar{\alpha}_i^2}\,\boldsymbol{\varepsilon}$



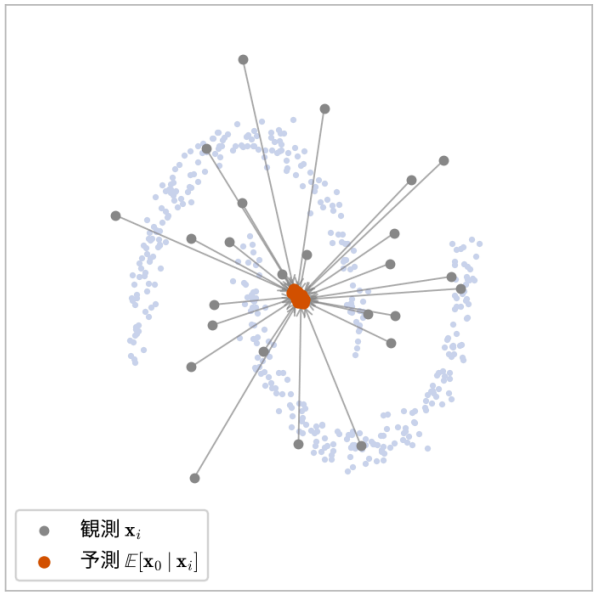
② 当てる：$\mathbf{x}_i$ と i だけ見て「混ぜたノイズは？」



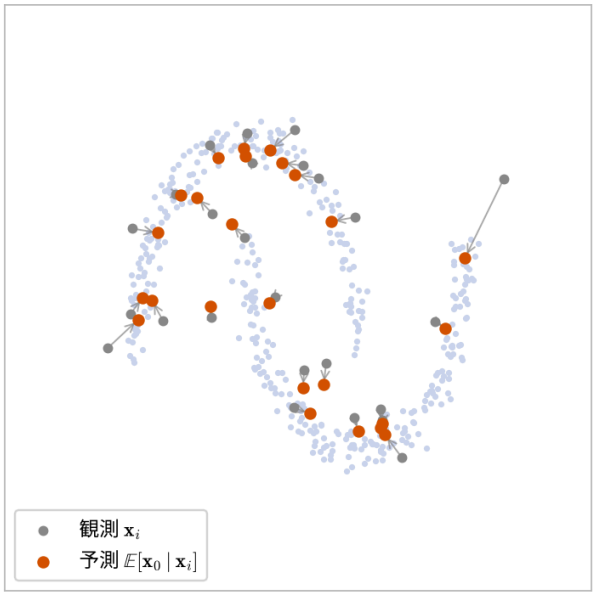
- ① データ $\mathbf{x}_0$ と時刻 i を選び，ノイズ ε を混ぜて $\mathbf{x}_i$ を作る（摂動核で一度に）
- ② ネットワークは $\mathbf{x}_i$ と i だけを見て混ぜたノイズを予想し，正解との二乗誤差を小さくする（$\mathcal{L}_{\text{simple}}$，2.2.4）
- このノイズ当ては，ELBO を上げること（最尤推定の近似）と同じ（2.2.3・2.2.5）

最適な予測は「ありうる答えの平均」（補足）

ノイズが強い（$i = 800$）：予測はぼやけた平均

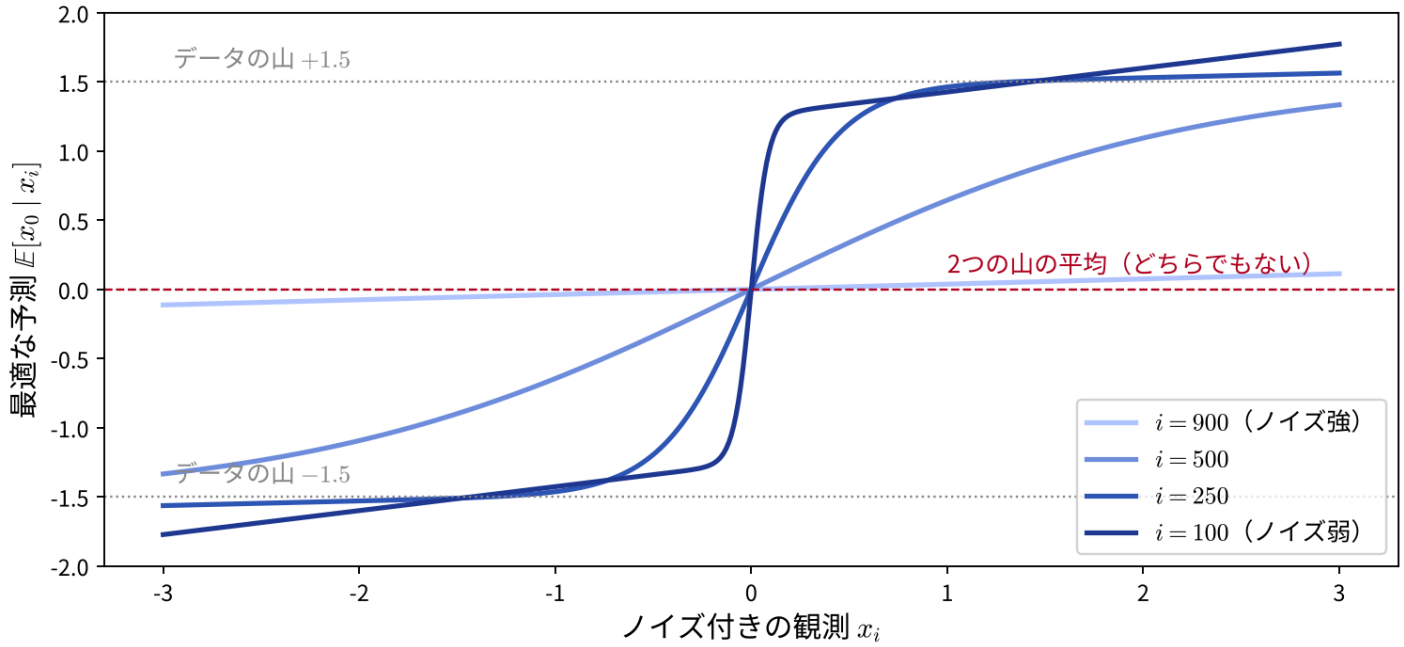


ノイズが弱い（$i = 120$）：予測はデータの上



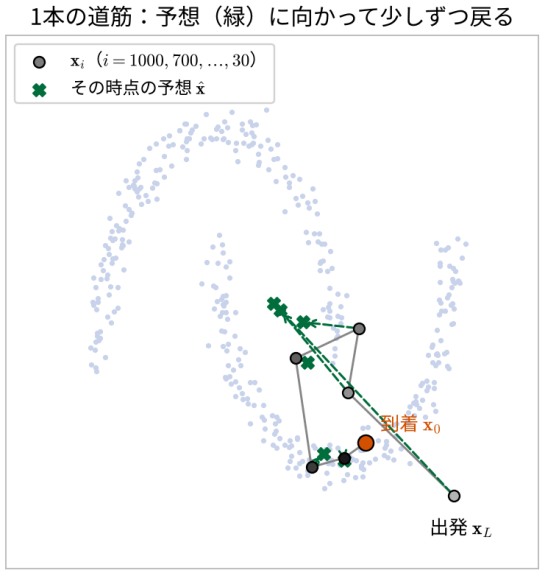
- 灰色の観測 $\mathbf{x}_i$ から，橙の最適な予測 $\mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i]$ へ矢印
- **ノイズが強い**（左）：どのデータから来たか見当がつかず，予測はほぼ全体の平均（中心）に集まる → ぼやける
- **ノイズが弱い**（右）：元のデータがほぼ決まるので，予測はデータの上に乗る

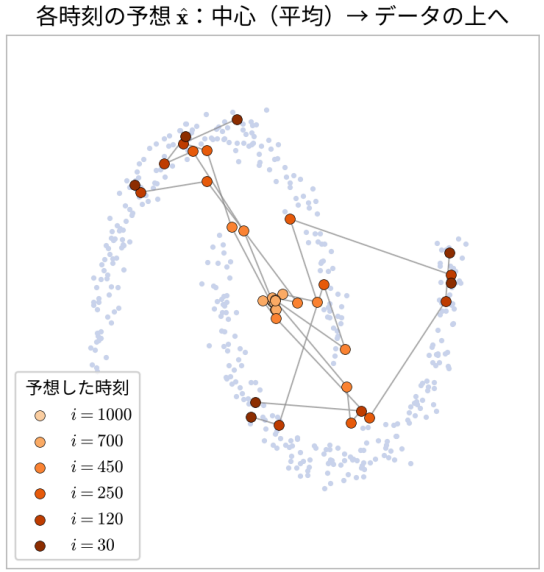
ノイズの強さと最適な予測（1 次元の例）（補足）



- データは -1.5 と $+1.5$ の 2 つの山．横軸の観測 x_i から最適な予測 $\mathbb{E}[x_0 \mid x_i]$ を描いた
- ノイズが強い（$i = 900$）と，予測はどの x_i でもほぼ 0（2 つの山の平均）
- ノイズが弱くなるほど，予測は「近い方の山」にはっきり分かれる（階段状）
- だから 1 回で答えを出さず，ノイズを少しずつ弱めながら**何度も予測し直す**

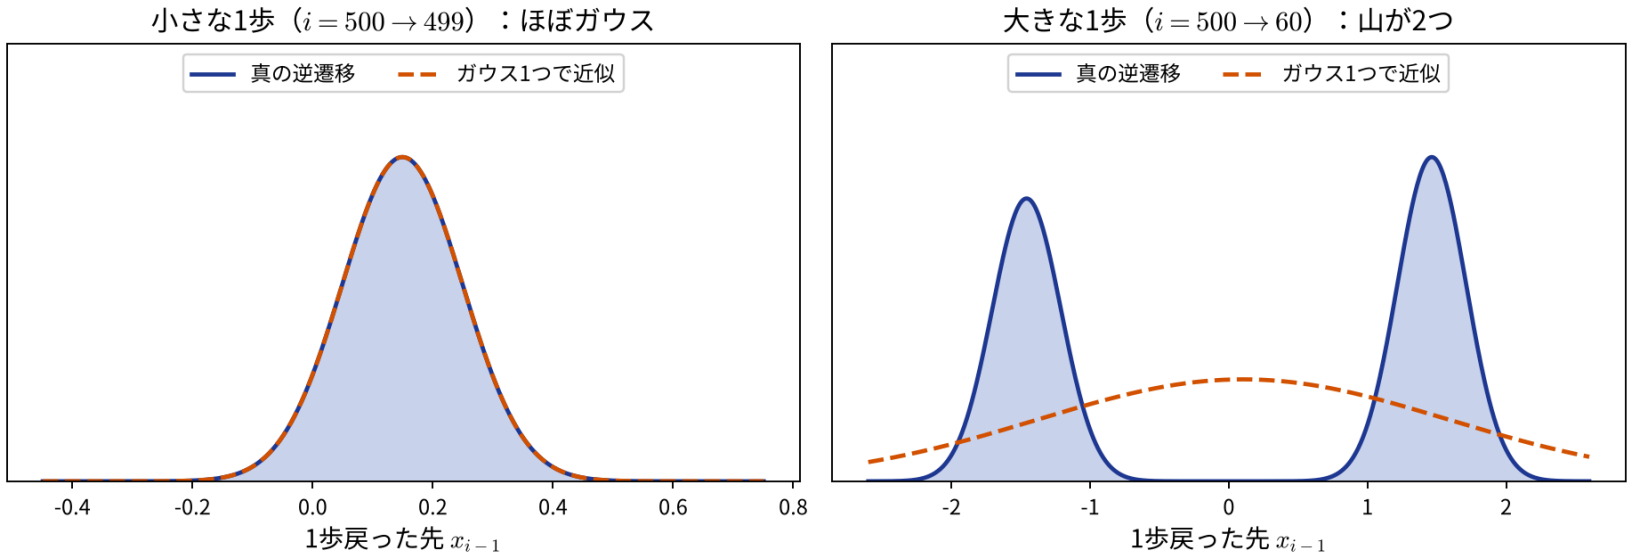
生成：予想して，1 段弱いノイズで書き直す（補足）





- 左：1 本の道筋．各時点で予想 $\hat{\mathbf{x}}$（緑）を立て，それに向かって少しだけ戻る（ノイズを 1 段弱めて書き直す，式 (2.2.15)）
- 右：予想の変化．最初は中心（平均）でぼやけているが，ノイズが弱まるにつれてデータの上に落ち着く
- 全体の構造が先に決まり，細部は後から決まる（2.2.6）

なぜ 1000 ステップも必要か（補足）



- 左：小さな 1 歩なら，本当の逆遷移（青）はガウス 1 つ（橙の破線）でほぼ完全に表せる
- 右：大きく 1 歩で戻ろうとすると，本当の逆遷移は山が 2 つになり，ガウス 1 つでは表せない
- DDPM はモデルをガウスにしたので，小さな歩幅を多数並べるしかない $\to$ 生成が遅い（第 4 章で解決）

第 2 章のストーリー（補足）

